

Gheorghe Oprişan Gabriela Ilieana Sebe

$$\left(\frac{n}{3} - \right) = \left\{ \frac{1}{3} - (\xi -) \right\} = \frac{1}{3} - \left(\frac{\xi - }{\sqrt{3}} \right)$$

$$\left\{ \frac{1}{3} - (\xi -) \right\}^2 = \left(\frac{1}{3} - (\xi -) \right)^2 = \left(\frac{\xi - }{\sqrt{3}} \right)^2$$

$$\frac{1}{9} - \frac{2}{3} \cdot \frac{1}{3} (\xi -) + \frac{1}{3} (\xi -)^2 = \frac{1}{9} - \frac{2}{3} \cdot \frac{1}{3} (\xi -) + \frac{1}{3} (\xi -)^2$$

$$\frac{1}{9} - \frac{2}{9} (\xi -) + \frac{1}{3} (\xi -)^2 = \frac{1}{9} - \frac{2}{9} (\xi -) + \frac{1}{3} (\xi -)^2$$

$$\frac{1}{9} - \frac{2}{9} (\xi -) + \frac{1}{3} (\xi -)^2 = \frac{1}{9} - \frac{2}{9} (\xi -) + \frac{1}{3} (\xi -)^2$$

*Compendiu de teoria
probabilităților și
statistică matematică*

Gheorghe OPRIŞAN

Gabriela Ileana SEBE

**COMPENDIU
DE TEORIA PROBABILITĂȚILOR
ȘI STATISTICĂ MATEMATICĂ**



**EDITURA TEHNICĂ
Bucuresti, 1999**



Copyright © 1999, S.C. Editura TEHNICĂ S.A.
Toate drepturile sunt rezervate editurii

Adresa:S.C. Editura TEHNICĂ S.A.
Piața Presei Libere, 1
33 București, România
cod 79738

Biblioteca de Matematică



1100 019 4297

Coperta seriei: Andrei Mănescu

Redactor: Gheorghe Oprișan
Tehnoredactor: Diana Jilavu

Bun de tipar: 19.03.1999 ; colo de tipar: 14,5
C.Z.U. 517

ISBN 973-31-1325-5

Tipărit la Tipografia SEMNE

PREFATĂ

"Norocul ajută numai mintile pregătite". Louis Pasteur

Prezenta lucrare își propune să prezinte într-o manieră cât mai naturală și accesibilă, însă fără a renunța la rigoarea matematică, noțiuni și rezultate fundamentale din teoria probabilităților și statistica matematică, ramuri ale matematicii solicitate în cele mai variate domenii.

Deși teoria probabilităților își are originile în observațiile făcute pe seama rezultatelor jocurilor de noroc, în prezent, după aproape trei secole, această disciplină se bazează pe un aparat matematic foarte dezvoltat, bogat în concepte și rezultate care permit descrierea și investigarea fenomenelor aleatoare.

Statistica matematică reprezintă multimea procedeelor prin care se studiază proprietăți, caracteristici ale populațiilor numeroase, folosind instrumentul matematic în analiză și interpretare. Ea prezintă legitatea caracteristicilor în modele abstrakte desprinse din lumea datelor concrete, empirice, de care dispune statisticianul.

Teoria probabilităților constituie aparatul matematic de bază al statisticii matematice, permătând construirea logică a științei respective, și în același timp, punе în evidență intervalul de aplicare a ei.

Revenind asupra importanței deosebite ce o au teoria probabilităților și statistica matematică, subliniem că ele sunt folosite atât direct în rezolvarea a variate probleme puse de practica social-economică, în industrie, agricultură, comerț, planificare, investiții etc., cât și ca bază teoretică necesară altor ramuri speciale ale matematicii ca: programarea matematică, teoria așteptării, teoria informaticii și cibernetică etc.

Întrucăt teoria probabilităților construiește variate modele abstractive care pot servi la interpretarea diverselor fenomene reale, asistăm la întrepătrunderea cu alte științe cum sunt științele tehnice, economia, biologia, lingvistica etc., generând noi domenii de cercetare ca: mecanica statistică, statistica economică, biologia matematică, lingvistica matematică.

Chiar cercetarea matematică fundamentală folosește teoria probabilităților ca instrument de lucru, de exemplu, în teoria numerelor, în analiza numerică, în probleme legate de utilizarea mașinilor electronice de calcul etc.

Cartea de față este concepută în paisprezece capitole. În primele patru capitole este expusă teoria clasică a probabilităților. Următoarele șase capi-

CUPRINS

INTRODUCERE	ix
Capitolul 1. Spațiu de probabilitate	
§1.1. Evenimente	1
§1.2. Probabilitate	6
§1.3. Independență și condiționare	16
Capitolul 2. Variabile aleatoare	
§2.1. Noțiunea de variabilă aleatoare	25
§2.2. Funcția de repartiție	26
§2.3. Funcții de variabile aleatoare	36
§2.4. Valori medii și valori medii condiționate	41
§2.5. Funcția generatoare și funcția caracteristică	54
§2.6. Cumulanți	64
Capitolul 3. Repartiții clasice	
§3.1. Repartiția binomială	67
§3.2. Repartiția binomial negativă	70
§3.3. Repartiția geometrică	71
§3.4. Repartiția hipergeometrică	73
§3.5. Repartiția Poisson	75
§3.6. Repartiția normală	78
§3.7. Repartiția lognormală	81
§3.8. Repartiția uniformă	81
§3.9. Repartiția exponențială	83
§3.10. Repartiția Weibull	85
§3.11. Repartiția Rayleigh	86
§3.12. Repartiția Gamma	85
§3.13. Repartiția Beta	87
§3.14. Repartiția χ^2 (hi pătrat)	87
§3.15. Repartiția t a lui Student	89
§3.16. Repartiția F a lui Snedecor-Fisher	90
§3.17. Repartiția Z a lui Fisher	90
§3.18. Repartiția Cauchy	90
§3.19. Repartiția Pareto	91
§3.20. Repartiția normală n -dimensională	91
§3.21. Repartiția multinomială	92
§3.22. Repartiția Poisson multidimensională	93

Capitolul 12. Teoria estimării	
§12.1. Funcții de estimare (estimator)	181
§12.2. Metoda verosimilității maxime	182
Capitolul 13. Verificarea ipotezelor statistice	
§13.1. Ipoteze statistice	185
§13.2. Teste statistice	186
§13.3. Testul χ^2	187
§13.4. Testul F (Fisher-Snedecor)	187
§13.5. Testul t (Student)	188
§13.6. Testul Kolmogorov-Smirnov	189
Capitolul 14. Regresia	
§14.1. Curbe de regresie	191
§14.2. Dreapta de regresie	191
§14.3. Regresia curbilinie	194
Note istorice	195
Bibliografie	199
Anexa 1	202
Anexa 2	203
Anexa 3	207
Anexa 4	210
Anexa 5	211
Index	212

INTRODUCERE

Teoria probabilităților este o teorie matematică care se ocupă cu studiul fenomenelor întâmplătoare sau aleatoare, utilizând în acest scop metodele deductive ale matematicii. Fenomenelor aleatoare de masă le este caracteristică proprietatea de stabilitate a frecvențelor. Conceptul fundamental de probabilitate corespunde intuitiv constantei în jurul căreia oscilează frecvențele și către care sirul acestor frecvențe tinde, când numărul probelor crește nelimitat.

Teoria proceselor stocastice¹ este partea teoriei contemporane a probabilităților, care a contribuit cel mai mult la progresul ei. În prezent, procesele stocastice fac obiectul unor investigații teoretice din partea matematicienilor, dar în același timp prezintă largi utilizări practice în inginerie, economie, biologie, psihologie, sociologie, lingvistică etc.

Teoria proceselor stocastice se ocupă cu studiul structurii familiilor de variabile aleatoare.

Statistica matematică are ca obiect elaborarea noțiunilor și metodelor specifice studiului statistic al fenomenelor de masă, înțelegând prin acestea fenomenele care se constituie sub acțiunea colectivă și repetată a unui număr mare de factori întâmplători.

Statistica matematică se ocupă cu gruparea, analiza și interpretarea datelor referitoare la anumite fenomene, precum și cu unele previziuni privind producerea lor în viitor.

Metodele statistice moderne, bazate pe teoria probabilităților, sunt utilizate în industrie, administrația de stat, agricultură, medicină, fizică, sociologie, psihologie, educație etc.

¹Cuvântul "stochastic" își are originea în cuvântul grecesc "stokhastikos", a cărui semnificație este "a ținti".

Capitolul 1

Spațiu de probabilitate

1.1 Evenimente

Pe baza observațiilor și experimentelor știința deduce legi care guvernează cursul fenomenelor studiate. Un experiment poate fi definit ca realizarea unui set (complex) de condiții (C). Prin urmare, două experimente diferă între ele prin seturile de condiții (C) specifice fiecărui dintre ele. În urma efectuării unui experiment se realizează un eveniment. De exemplu, dacă apa la presiunea atmosferică (760 mm) este încălzită la 100° C (setul de condiții (C)), ea se transformă în vaporii (evenimentul realizat). În urma efectuării experimentului unele evenimente se realizează cu certitudine, iar altele pot sau nu să se realizeze (adică uneori se realizează, alteori nu).

Din acest punct de vedere un experiment poate fi considerat determinist sau aleator. Experimentul descris în exemplul de mai sus este determinist, dacă avem în vedere doar evenimentul ce constă în transformarea apei în vaporii. Pe de altă parte, dacă delimităm în spațiu un volum de 1 dm³ fixat și ne referim la evenimentul ce constă în faptul că în acest volum numărul de molecule de apă este $\geq 10^6$, atunci experimentul nostru poate fi considerat aleator. În concluzie, un experiment aleator este un experiment al căruia rezultat este influențat de factori întâmplători. În continuare vor fi considerate doar experimente aleatoare.

Totalitatea rezultatelor posibile ale unui experiment se numește spațiu de evenimentelor elementare (spațiu eșantioanelor sau spațiu de selecție) asociat experimentului. (Evident, de aici rezultă că "eveniment elementar" înseamnă "rezultat posibil"). Spațiu evenimentelor elementare este notat cu Ω , iar elementele lui Ω sunt evenimente elementare.

Un eveniment asociat unui experiment aleator, deci unui spațiu de evenimente elementare, corespunde unui enunț privind experimentul, enunț care poate fi corect sau fals. Multimea evenimentelor pentru care enunțul este

corect constituie evenimentul considerat. Astfel, orice eveniment este o submultime a spațiului evenimentelor elementare Ω . Dacă multimea Ω este finită sau infinit numărabilă, atunci este valabilă și reciprocă: orice submultime a lui Ω este un eveniment. În cazul în care Ω este o mulțime infinit nenumărabilă nu este întotdeauna posibil să luăm ca evenimente asociate lui Ω toate submultimile sale (vezi exemplul 1, §1.2). Evenimentele vor fi notate cu litere mari A, B, C, \dots

Orice eveniment elementar care intră în componența unui eveniment A se numește *favorabil* lui A . Întregul spațiu al evenimentelor Ω va fi numit *evenimentul sigur*, iar evenimentul care nu conține nici un eveniment elementar, deci mulțimea vidă \emptyset , va fi numit *evenimentul imposibil*. Justificarea acestor denumiri este imediată: evenimentul sigur se realizează cu certitudine la fiecare efectuare a experimentului, iar cel imposibil nu se realizează la nici o efectuare a experimentului. Evenimentul imposibil constă în nerealizarea evenimentului sigur și reciproc.

Fie A și B două evenimente din Ω . Se spune că evenimentul A implica evenimentul B , dacă $A \subset B$, adică dacă A este o submultime a lui B . Deci evenimentul B se realizează ori de câte ori se realizează evenimentul A . Orice eveniment implica evenimentul sigur, iar evenimentul imposibil implica orice eveniment. Evenimentele elementare nu sunt implicate de nici un alt eveniment cu excepția celui imposibil.

Dacă $A = B$, atunci fiecare eveniment îl implica pe celălalt și se spune că evenimentele A și B sunt *echivalente*.

Operațiile cu evenimente se identifică cu operațiile cu mulțimi.

Reuniunea evenimentelor A și B , notată $A \cup B$, este evenimentul ce constă din acele evenimente elementare care aparțin fie lui A , fie lui B , fie amânduroră. Deci realizarea lui $A \cup B$ este echivalentă cu realizarea a cel puțin unuia dintre evenimentele A sau B .

Intersecția evenimentelor A și B , notată $A \cap B$, este evenimentul ce constă din acele evenimente elementare care aparțin atât lui A , cât și lui B . Realizarea lui $A \cap B$ este echivalentă cu realizarea atât a lui A , cât și a lui B .

Complementarul sau *opusul* evenimentului A , notat \bar{A} sau A^c , este evenimentul ce constă din acele evenimente elementare care nu aparțin lui A . Evenimentul \bar{A} se realizează dacă și numai dacă A nu se realizează.

Diferența a două evenimente A și B , notată $A \setminus B$, este evenimentul ce constă din acele evenimente elementare care aparțin lui A și nu aparțin lui B . Deci realizarea lui $A \setminus B$ este echivalentă cu realizarea lui A , dar cu nerealizarea lui B . Evident, $A \setminus B = A \cap \bar{B}$.

Diferența simetrică a două evenimente A și B , notată $A \Delta B$, este evenimentul ce constă din acele evenimente elementare care aparțin fie lui $A \setminus B$, fie lui $B \setminus A$.

Două evenimente A și B se numesc *incompatibile* sau *disjuncte* dacă ele nu

au nici un eveniment elementar comun, adică dacă $A \cap B = \emptyset$. Prin urmare, nu este posibilă atât realizarea lui A , cât și a lui B .

Definițiile anterioare se extind evident și la cazul unui număr finit de evenimente A_1, \dots, A_n sau la cazul unei infinități numărabile de evenimente A_1, A_2, \dots

Se spune că n evenimente A_1, \dots, A_n sunt disjuncte în ansamblul lor dacă $A_i \cap A_j = \emptyset$, $i \neq j$, $1 \leq i, j \leq n$. (Evident, definiția se extinde și la cazul unei infinități numărabile de evenimente).

Un sistem (finit sau infinit numărabil) de evenimente disjuncte în ansamblul lor se numește sistem complet de evenimente dacă reuniunea lor este evenimentul sigur. Cu alte cuvinte, un sistem complet de evenimente este o partiție a evenimentului sigur.

Din cele constatațe anterior, se observă că oricărui experiment îi sunt proprii următoarele două obiecte matematice și anume spațiul evenimentelor elementare Ω și o familie \mathcal{K} de părți ale lui Ω , numită mulțimea evenimentelor corespunzătoare experimentului considerat, care verifică următoarele axiome:

1. $\Omega \in \mathcal{K}$;
2. $A \in \mathcal{K} \Rightarrow \bar{A} \in \mathcal{K}$;
3. $A, B \in \mathcal{K} \Rightarrow A \cup B \in \mathcal{K}$.

Familia de evenimente \mathcal{K} este numită algebră sau câmp de evenimente.

Din axiomele de mai sus rezultă că orice succesiune finită de operații de tip reuniune, intersecție, diferență, s-ar face cu evenimentele din \mathcal{K} , rezultatul va fi tot un eveniment din \mathcal{K} .

Din considerente de ordin matematic, în locul axiomei 3 se consideră următoarea axiomă

$$3'. \{A_n \mid n \geq 1\} \subset \mathcal{K} \Rightarrow \bigcup_{n \geq 1} A_n \in \mathcal{K}.$$

Familia \mathcal{K} de submulțimi ale lui Ω care îndeplinește axiomele 1, 2 și 3' este numită σ -algebră sau σ -câmp de evenimente.

Dacă Ω este o mulțime finită, $\Omega = \{\omega_1, \dots, \omega_n\}$, atunci \mathcal{K} coincide cu $\mathcal{P}(\Omega)$ (mulțimea părților lui Ω) și conține 2^n elemente. Un astfel de câmp de evenimente se numește finit generat. În acest caz nu există nici o deosebire între câmp și σ -câmp de evenimente.

Dacă $\mathcal{F} \subset \mathcal{P}(\Omega)$ este o familie de submulțimi ale lui Ω , atunci cea mai mică σ -algebră care conține pe \mathcal{F} se numește σ -algebră generată de \mathcal{F} și se notează $\sigma(\mathcal{F})$. Există cel puțin o σ -algebră care conține pe \mathcal{F} , de exemplu $\mathcal{P}(\Omega)$. Este evident că $\sigma(\mathcal{F})$ este egală cu intersecția tuturor σ -algebrelor ce conțin pe \mathcal{F} . Prin urmare, $\sigma(\mathcal{F})$ este o σ -algebră definită pe Ω care se caracterizează prin următoarea proprietate: dacă \mathcal{H} este o σ -algebră oarecare definită pe Ω și $\mathcal{H} \supset \mathcal{F}$, atunci $\mathcal{H} \supset \sigma(\mathcal{F})$.

algebra $\mathcal{B} = \sigma(\mathcal{O})$ este numită σ -algebră Borel¹ pe \mathbb{R} , iar o mulțime din \mathcal{B} este numită boreliană.

În legătură cu \mathcal{B} se pot demonstra următoarele:

- orice interval din \mathbb{R} de orice formă $((a, b], [a, b], (-\infty, a]$ etc.) este mulțime boreliană;

- σ -algebra generată de oricare din tipurile precedente de intervale coincide cu \mathcal{B} .

Similar, dacă $\Omega = \mathbb{R}^n$, σ -algebra generată de mulțimile deschise din \mathbb{R}^n , notată \mathcal{B}^n , este numită σ -algebră Borel pe \mathbb{R}^n . În ceea ce privește proprietățile precedente, în locul intervalelor se vor considera paralelipipede de diverse forme.

Pentru $(A_n)_{n \geq 1}$ un sir de evenimente din σ -algebra \mathcal{K} , se definesc evenimentele

$$\liminf_{n \rightarrow \infty} A_n = \bigcup_n \bigcap_{m \geq n} A_m,$$

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_n \bigcup_{m \geq n} A_m,$$

numite *limită inferioară*, respectiv *limită superioară* ale sirului. Dacă

$$\liminf_{n \rightarrow \infty} A_n = \limsup_{n \rightarrow \infty} A_n = A,$$

atunci sirul de evenimente considerat se numește convergent la limita A . Se constată că limita inferioară constă din acele evenimente elementare care aparțin tuturor evenimentelor A_n , $n \geq 1$, cu excepția unui număr finit dintre acestea, iar limita superioară constă din acele evenimente elementare care aparțin la o infinitate de evenimente A_n , $n \geq 1$.

Noțiunile de limită superioară și limită inferioară ale unui sir de evenimente pot fi reduse la noțiunile mai familiare de limită superioară și limită inferioară ale unui sir de funcții. Dacă pentru un eveniment A se introduce *indicatorul* χ_A al acestuia ca funcție definită prin relația

$$\chi_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A, \end{cases}$$

atunci indicatorul evenimentului $\liminf_{n \rightarrow \infty} A_n$ este funcția $\liminf_{n \rightarrow \infty} \chi_{A_n}$, iar cel al evenimentului $\limsup_{n \rightarrow \infty} A_n$ este funcția $\limsup_{n \rightarrow \infty} \chi_{A_n}$. Sirul $(A_n)_{n \geq 1}$ este convergent dacă și numai dacă sirul de funcții $(\chi_{A_n})_{n \geq 1}$ este convergent.

Exemplul 1. Fie $\Omega \neq \emptyset$ și $A \subset \Omega$, $A \neq \emptyset$. Atunci $\mathcal{K} = \{\emptyset, A, \bar{A}, \Omega\}$ este o σ -algebră.

Exemplul 2. Se consideră experimentul aruncării unei monede a) o dată; b) de două ori.

¹După numele lui Emile Borel (1871-1956), mare matematician francez.

- a) Dacă se notează cu v și s evenimentele elementare care constau în apariția "valorii" și respectiv a "stemei", atunci în cazul a) spațiul evenimentelor elementare este $\Omega = \{v, s\}$, iar $\mathcal{K} = \mathcal{P}(\Omega) = \{\emptyset, \{v\}, \{s\}, \Omega\}$;
 b) spațiul evenimentelor elementare este $\Omega = \{(vs), (sv), (vv), (ss)\}$, iar $\mathcal{K} = \mathcal{P}(\Omega)$.

Exemplul 3. Se consideră experimentul aruncării unui zar. Cum evenimentele elementare constau în apariția uneia dintre cele şase fețe ale zarului, atunci $\Omega = \{1, 2, 3, 4, 5, 6\}$ și

$$\mathcal{K} = \{\emptyset, \{i\}, \{i, j\}, \{i, j, k\}, \{i, j, k, l\}, \{i, j, k, l, m\}, \Omega\},$$

unde $i, j, k, l, m \in \Omega$, $i \neq j \neq k \neq l \neq m$. Numărul de evenimente din cîmp este $n = 2^6 = 64$.

Exemplul 4. Dintre studenții prezenți la cursul de "Teoria probabilităților și statistică matematică" se alege la întâmplare unul. Se notează cu A evenimentul ce constă în aceea că studentul ales este băiat, cu B evenimentul că el nu fumează și cu C evenimentul că el locuiește la cămin. Se cere:

- a) să se interpreze evenimentul $A \cap B \cap \bar{C}$;
- b) când este adevărată relația $\bar{C} \subset B$?
- c) în ce condiții are loc identitatea $A \cap B \cap C = A$?
- d) când va putea avea loc egalitatea $\bar{A} = B$? (Va avea loc dacă toți băieții fumează?).

Soluție. a) A fost ales un băiat care nu locuiește în cămin și care nu fumează.

b) Incluziunea $\bar{C} \subset B$ este adevărată când toți studenții fumători locuiesc în cămin.

c) Identitatea $A \cap B \cap C = A$ are loc când toți băieții locuiesc în cămin și nici unul nu fumează.

d) $\bar{A} = B$ are loc când nici o fată nu fumează, iar toți băieții fumează. Egalitatea are loc dacă fumează toți băieții, deoarece pot fuma și fetele.

Exemplul 5. În tabelul 1.1 sunt enumerate toate rezultatele posibile (spațiul evenimentelor elementare) ale distribuirii la întâmplare a 3 bile (a,b și c) în 3 urne.

Distribuirea a 3 bile în 3 urne

1	(abc - -)	10	(a bc -)	19	(- a bc)
2	(- abc -)	11	(b ac -)	20	(- b ac)
3	(- abc)	12	(c ab -)	21	(- c ab)
4	(ab c -)	13	(a - bc)	22	(a b c)
5	(ac b -)	14	(b - ac)	23	(a c b)
6	(bc a -)	15	(c - ab)	24	(b a c)
7	(ab - c)	16	(- ab c)	25	(b c a)
8	(ac - b)	17	(- ac b)	26	(c a b)
9	(bc - a)	18	(- bc a)	27	(c b a)

Tabelul 1.1

Fiecare din aranjamentele enumerate reprezintă un eveniment elementar și orice alt eveniment este o reuniune de evenimente elementare, deci este vorba de un câmp finit generat. Evenimentul A , descris astfel: "într-o din urme se află mai multe bile" se realizează ori de câte ori se realizează unul din primele 21 evenimente elementare din tabelul 1.1. De asemenea, evenimentul B , ce constă în faptul că "a două urnă nu este goală", poate fi descompus în evenimentele elementare 2, 4 - 6, 10 - 12, 16 - 27. Evenimentul $C = A \cap B$ se obține din descompunerea evenimentelor elementare 2, 4 - 6, 10 - 12, 16 - 21. Evident $A \cup B = \Omega$, iar \emptyset este evenimentul ce constă în faptul că "în nici una dintre urme nu se află mai mult de o bilă și a două urnă este goală".

O problemă mai generală, care poate fi studiată în același mod, este aceea a distribuirii la întâmplare a r bile în n urne. Cazul considerat mai sus se obține pentru $r = n = 3$.

Trebue remarcat faptul că natura fizică a spațiului evenimentelor elementare nu este relevantă; astfel, în exemplul dat, s-a vorbit despre bile și urne, dar există multe spații reale, complet deosebite, care din punct de vedere abstract sunt echivalente cu problema considerată. Dăm mai jos o enumerare a unora dintre aceste situații:

- repartizarea a r accidente rutiere pe zilele săptămânii coreponde cu plasarea a r bile în $n = 7$ urne;
- distribuirea a r persoane în n profesii;
- distribuirea a r particule elementare în n regiuni ale spațiului.

1.2 Probabilitate

Probabilitatea unui eveniment este o măsură a gradului de posibilitate a acestui eveniment, grad de posibilitate care merge de la valoarea 0 (pentru evenimentul imposibil) până la valoarea 1 (pentru evenimentul sigur). Pentru un eveniment

intermediar $A, \emptyset \subset A \subset \Omega$, probabilitatea lui A va trebui să reflecte stabilitatea asimptotică a frecvenței lui A într-un număr arbitrar de mare de repetări independente ale experimentului căruia A îi este asociat.

Dacă A și B sunt evenimente incompatibile, atunci numărul de apariții ale evenimentului $A \cup B$ într-un număr arbitrar de repetări ale experimentului fiind egal cu suma numărului de apariții ale lui A și a numărului de apariții ale lui B , probabilitatea lui $A \cup B$ trebuie să fie egală cu suma probabilităților lui A și a lui B . Prin urmare, probabilitatea va trebui să posede o proprietate de aditivitate pentru evenimente incompatibile.

Plecând de la aceste considerente nematematice, matematicianul rus Kolmogorov² a dat următoarea definiție conceptului matematic de probabilitate.

Fie (Ω, \mathcal{K}) un σ -câmp de evenimente. Se numește probabilitate pe \mathcal{K} o aplicație $P : \mathcal{K} \rightarrow \mathbf{R}$ cu proprietățile:

- 1) $0 \leq P(A) \leq 1, \quad \forall A \in \mathcal{K}$ și $P(\Omega) = 1$;
- 2) (σ -aditivitatea) pentru orice familie cel mult numărabilă $\{A_i | i \in I\}$ de evenimente din \mathcal{K} , disjuncte în ansamblul lor

$$P\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} P(A_i).$$

Tripletul (Ω, \mathcal{K}, P) se numește spațiu (câmp) de probabilitate.

Următoarele proprietăți rezultă din definiția probabilității

- a) $P(\emptyset) = 0; P(\bar{A}) = 1 - P(A) \quad \forall A \in \mathcal{K}$;
- b) (monotonie) $P(A_1) \leq P(A_2)$ și $P(A_2 \setminus A_1) = P(A_2) - P(A_1)$ dacă $A_1 \subset A_2$ în \mathcal{K} ;
- c) (aditivitatea tare)

$$P(A_1 \cup A_2) = P(A_1) + P(A_2) - P(A_1 \cap A_2) \quad \forall A_1, A_2 \in \mathcal{K};$$

- d) (finit-subaditivitatea) pentru orice familie finită $\{A_i | i \in I\}$ de evenimente

$$P\left(\bigcup_{i \in I} A_i\right) \leq \sum_{i \in I} P(A_i);$$

- e) (formula lui Poincaré³) pentru orice familie finită

$$P\left(\bigcup_{i \in I} A_i\right) = \sum_{L \subset I} (-1)^{\text{card } L - 1} P\left(\bigcap_{i \in L} A_i\right).$$

²A.N.Kolmogorov (1903-1987), unul dintre fondatorii teoriei moderne a probabilităților, este autorul monografiei "Fundamentele teoriei probabilităților" apărută în anul 1933.

³Henri Poincaré (1854-1912) a fost numit ultimul universalist dintre matematicieni. Contribuția sa în teoria probabilităților are o mare valoare filozofică și pedagogică

Dacă $\Omega = \{\omega_1, \dots, \omega_n\}$, $\mathcal{K} = \mathcal{P}(\Omega)$ și p_1, \dots, p_n sunt numere reale nenegative astfel încât $\sum_{i=1}^n p_i = 1$, atunci funcția definită prin $P(\omega_i) = p_i$, $i = \overline{1, n}$, este o probabilitate pe Ω . Dacă $p_1 = \dots = p_n = \frac{1}{n}$, atunci evenimentele elementare ω_i se numesc *egal probabile* și probabilitatea unui eveniment A se definește ca raportul dintre numărul "cazurilor favorabile" producerii lui A și numărul "cazurilor posibile" ale experimentului⁴. Aceasta este aşa numita *definiție clasică* a probabilității care, după cum se vede, este aplicabilă numai în condiții deosebit de restrictive.

Fie A un eveniment legat de un anumit experiment. Se repetă acest experiment de n ori (în condiții identice) și se notează cu $N_n(A)$, numărul de realizări ale lui A . Raportul $\frac{N_n(A)}{n}$ se numește *frecvența relativă* a realizării evenimentului A în cele n repetări.

Se remarcă ușor că dacă se aruncă o monedă nefedformată de un număr mare de ori, frecvența de apariție a unei fețe oscilează în jurul valorii $p = 1/2$. Un fapt destul de amuzant, dar semnificativ în sine, este că la începutul secolului XX, statisticianul Pearson a obținut în 24.000 de aruncări o frecvență relativă egală cu 0,5005. Această stabilitate a frecvenței relative este fundamentată riguros de teoremele de tip "legea numerelor mari" (vezi §4.2).

Se arată că pentru ca o aplicație $P : \mathcal{K} \rightarrow [0, 1]$ să fie o probabilitate este necesar și suficient ca

$$1) P(\Omega) = 1;$$

2') (*finit-aditivitatea*) pentru orice familie finită $\{A_i | i \in I\}$ de evenimente disjuncte în ansamblul lor

$$P\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} P(A_i);$$

3') (*continuitatea monoton secvențială în \emptyset*) pentru orice sir $\{A_n | n \geq 1\}$ de evenimente descrescătoare la \emptyset , adică

$$A_1 \supseteq A_2 \supseteq \dots \text{ și } \bigcap_{n \geq 1} A_n = \emptyset, \quad \lim_{n \rightarrow \infty} P(A_n) = 0.$$

Pentru a stabili alte proprietăți fundamentale ale probabilității, ce decurg în mod esențial din (3'), se introduce următoarea notație $A_n \downarrow A$ (respectiv $A_n \uparrow A$) când $n \rightarrow \infty$, dacă $A_n \supseteq A_{n+1} (n \geq 1)$ și $\bigcap_{n \geq 1} A_n = A$ în \mathcal{K} (respectiv $A_n \subseteq A_{n+1}, n \geq 1$ și $\bigcup_{n \geq 1} A_n = A$ în \mathcal{K}).

⁴De exemplu, dacă $A = \{\omega_{i_1}, \dots, \omega_{i_m}\}$, $m \leq n$, atunci $P(A) = m/n$.

Astfel se poate arăta următoarea proprietate numită continuitatea monoton secvențială a probabilității

$$A_n \downarrow A \ (n \rightarrow \infty) \text{ în } \mathcal{K} \Rightarrow P(A_n) \downarrow P(A);$$

$$A_n \uparrow A \ (n \rightarrow \infty) \text{ în } \mathcal{K} \Rightarrow P(A_n) \uparrow P(A).$$

De asemenea, are loc și proprietatea numită σ -subaditivitatea probabilității, ce constă în faptul că pentru orice familie numărabilă $\{A_i | i \in I\}$ de evenimente astfel încât $\bigcup_{i \in I} A_i \in \mathcal{K}$

$$P\left(\bigcup_{i \in I} A_i\right) \leq \sum_{i \in I} P(A_i).$$

Dacă o proprietate referitoare la elementele lui Ω are loc pentru orice $\omega \in \Omega \setminus A$, unde $A \in \mathcal{K}$ și $P(A) = 0$, se spune că proprietatea are loc *aproape sigur* (prescurtat a.s.) în raport cu P .

Observație. Din enunțul unei probleme clasice de probabilități trebuie să rezulte foarte clar care este spațiul evenimentelor elementare corespunzător. Dacă enunțul problemei dă loc la interpretări, atunci pot apărea rezultate contradictorii (vezi exemplul 7 din acest paragraf). De obicei, confuziile apar din cauza insuficientei explicitări a termenului "la întâmplare".

Exemplul 1. Fie Ω mulțimea primelor 120 de numere naturale $\{1, 2, \dots, 120\}$. Se consideră mulțimile

$$A = \{\omega \in \Omega | \omega \text{ este multiplu de } 3\},$$

$$B = \{\omega \in \Omega | \omega \text{ este multiplu de } 4\}.$$

Dacă se consideră funcția de probabilitate P definită pe $\mathcal{P}(\Omega)$ prin

$$P(E) = \frac{\text{card } E}{\text{card } \Omega} \quad \forall E \in \mathcal{P}(\Omega),$$

atunci

$$P(A) = \frac{1}{3} \quad \text{și} \quad P(B) = \frac{1}{4}.$$

Elementele mulțimilor A , respectiv B sunt în progresie aritmetică de razie 3, respectiv 4. În continuare se calculează $P(A \cap B)$ și $P(A \cup B)$. Cum $A \cap B$ reprezintă mulțimea multiplilor lui 12, atunci $P(A \cap B) = \frac{1}{12}$. Pe baza proprietății de aditivitate tare se obține

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) = \frac{1}{3} + \frac{1}{4} - \frac{1}{12} = \frac{1}{2}.$$

Se observă, de asemenea, că

$$P(A \cap B) = \frac{1}{12} = \frac{1}{3} \cdot \frac{1}{4} = P(A) \cdot P(B),$$

acest lucru fiind posibil deoarece numerele 3 și 4 sunt relativ prime.

Se consideră și mulțimea

$$C = \{\omega \in \Omega \mid \omega \text{ este multiplu de } 6\}.$$

Cum $P(C) = \frac{1}{6}$, cât este $P(B \cap C)$? Deoarece $B \cap C$ reprezintă mulțimea numerelor naturale cuprinse între 1 și 120, divizibile la 4 și la 6, adică divizibile la c.m.m.m.c (4, 6) = 12, rezultă că $P(B \cap C) = \frac{1}{12}$. Apoi se obține

$$P(B \cup C) = P(B) + P(C) - P(B \cap C) = \frac{1}{4} + \frac{1}{6} - \frac{1}{12} = \frac{1}{3}.$$

Se consideră Ω' astfel încât $\Omega \subseteq \Omega'$, Ω' fiind o mulțime finită de numere naturale succesive și se ia funcția de probabilitate construită în același mod

$$P' : \mathcal{P}(\Omega') \rightarrow [0, 1]$$

$$P'(E) = \frac{\text{card } E}{\text{card } \Omega'} \quad \forall E \in \mathcal{P}(\Omega').$$

Pentru mulțimile

$$A' = \{\omega \in \Omega' \mid \omega \text{ este multiplu de } 3\},$$

$$B' = \{\omega \in \Omega' \mid \omega \text{ este multiplu de } 4\},$$

$$C' = \{\omega \in \Omega' \mid \omega \text{ este multiplu de } 6\},$$

se observă că

$$P'(A') = \frac{1}{3}, \quad P'(B') = \frac{1}{4} \quad \text{și} \quad P'(C') = \frac{1}{6}.$$

În concluzie, independent de cardinalul mulțimii finite Ω , proporția în care se află numerele unei progresii aritmetice (de rație 3,4, respectiv 6) este aceeași. Problema care se pune este ce se întâmplă dacă Ω este o mulțime infinit numărabilă, de exemplu $\Omega = \mathbb{N}^*$. Cum definiția anterioară a probabilității nu mai este valabilă, se consideră probabilitatea definită pe baza frecvenței de apariție a evenimentelor respective. De exemplu, pentru multiplii de 3, se ia $P(A) = \frac{1}{3}$. De fapt, această frecvență se calculează utilizând $N_n(A)$,

numărul de apariții ale multiplilor de 3 aflăți în primele n numere naturale, unde $n \in A$. Atunci frecvența este dată de limita

$$\lim_{n \rightarrow \infty} \frac{N_n(A)}{n} = \frac{1}{3}.$$

Limite similare există și pentru mulțimile $B, C, A \cap B, B \cap C$, având valorile deja găsite anterior. În concluzie, se pot studia toate mulțimile de forma

$$A_m = \{\omega | \omega \text{ este multiplu de } m\}, \quad m \in \mathbb{N}^*,$$

cu aceeași metodă dacă $\Omega = \mathbb{N}^*$.

Totuși noua definiție a lui P creează surprize, deși P funcționează corect pe mulțimile de forma A_m .

Fie, de exemplu, mulțimea $Z = \{1999\}$ sau $Z = \{1, 2, \dots, 1999\}$. Atunci probabilitatea $P(Z)$ va fi dată de $\lim_{n \rightarrow \infty} \frac{N_n(Z)}{n} = 0$. În concluzie, orice submulțime finită a mulțimii numerelor naturale are probabilitatea 0, în acord cu această metodă de calcul. Cum P ar trebui să fie σ -aditivă, atunci s-ar obține $P(\Omega) = P(\mathbb{N}^*) = 0$ în loc de $P(\Omega) = 1$.

Această contradicție arată că P nu poate fi o probabilitate pe $\Omega = \mathbb{N}^*$. Există totuși o cale de ieșire din această situație paradoxală. Astfel abandonând cerința ca probabilitatea P să fie definită pe $\mathcal{P}(\Omega) = \mathcal{P}(\mathbb{N}^*)$, se poate rezolva situația.

Astfel se consideră doar un număr finit de mulțimi A_m și toate mulțimile derivate din acestea prin operațiile de complementarizare, reuniune și intersecție. Familia de mulțimi, obținută astfel, se va numi familia generată de mulțimile A_m fixate inițial. În acest fel, va fi posibilă definirea funcției P , în maniera descrisă anterior, pe toate mulțimile acestei familii.

O mulțime care nu se află în această familie nu are probabilitate, adică probabilitatea ei nu este definită. Astfel se spune mai degrabă că probabilitatea mulțimii Z nu este definită, decât că ea este egală cu zero. Deci, în acest context, Z nu este măsurabilă.

Exemplul 2. Se reia problema distribuirii a r bile în n urne. Pentru aceasta se consideră numerele întregi r_1, r_2, \dots, r_k astfel încât $r_1 + r_2 + \dots + r_k = n$, $r_i \geq 0$, $i = 1, k$. Se arată că numărul de moduri în care o mulțime ce conține n elemente poate fi partitionată în k mulțimi astfel încât prima submulțime să conțină r_1 elemente, a două r_2 elemente, și.a.m.d., este

$$\frac{n!}{r_1! r_2! \dots r_k!}.$$

Se observă mai întâi că ordinea submulțimilor este esențială în sensul că $(r_1 = 2, r_2 = 3)$ și $(r_1 = 3, r_2 = 2)$ reprezintă partiții diferite. Pe de altă parte, ordinea elementelor într-o submulțime nu are importanță.

Pentru a obține partitia dorită trebuie mai întâi selectate r_1 dintre cele n elemente (ceea ce se poate face în $C_n^{r_1}$ moduri), apoi selectate r_2 elemente din cele $n - r_1$ rămase (ceea ce se poate face în $C_{n-r_1}^{r_2}$ moduri), și.a.m.d.

După ce se formează a $(k-1)$ -a submulțime rămân $n - r_1 - r_2 - \dots - r_{k-1} = r_k$ elemente, care formează ultimul grup. În concluzie, numărul de partitii posibile este

$$C_n^r \cdot C_{n-r_1}^{r_2} \cdots C_{n-r_1-r_2-\dots-r_{k-1}}^{r_k} = \frac{n!}{r_1!r_2!\dots r_k!}.$$

Revenind la problema distribuirii a r bile în n urne, se observă de la început că, dacă se face distincție între bile, numărul total de distribuiră este n^r (spațiul evenimentelor elementare conține n^r elemente). Dacă se admite că ele sunt egal probabile, atunci fiecare din ele va avea probabilitatea n^{-r} .

Dacă se presupune că nu contează care anume bile sunt distribuite într-o urnă oarecare, ci numai numărul acestor bile, atunci ținând seama de cele precedente, probabilitatea ca în prima urnă să fie r_1 bile, în a doua r_2 bile, și.a.m.d., este dată de

$$p_1 = \frac{r!}{r_1!r_2!\dots r_n!} n^{-r}. \quad (1.1)$$

Acest mod de a atribui o probabilitate fiecărei secvențe (r_1, r_2, \dots, r_n) , $r_1 + r_2 + \dots + r_n = r$, este cunoscut sub denumirea de *statistica Maxwell-Boltzmann*.

Se presupune acum că nu se face distincție între bile, ceea ce atrage după sine modificarea spațiului evenimentelor elementare. Pentru a stabili numărul de elemente ale spațiului evenimentelor elementare se reprezintă urnele prin spațiile dintre $n+1$ bare, iar bilele prin stelușe. Astfel, de exemplu, simbolul $| * * | * | | * * * |$ va însemna că (pentru $n=5, r=6$) în prima urnă sunt 2 bile, în a doua una, a treia și a patra urnă sunt goale, iar a cincea urnă conține 3 bile.

Un astfel de simbol începe și se sfârșește cu câte o bară, dar celelalte $n-1$ bare și r stelușe apar într-o ordine arbitrară. Deci pentru a scrie un astfel de simbol, trebuie alese r poziții, dintre cele $n+r-1$, pe care se pun stelușe. Este deci clar că numărul total de simboluri, deci de distribuiră, este C_{n+r-1}^r .

Dacă se presupune că toate distribuirile sunt egal probabile, atunci fiecare va avea probabilitatea $1/C_{n+r-1}^r$ și se obține astăzi numita *statistică Bose-Einstein*.

Condiția ca în nici una din urne să nu fie mai mult de o bilă, se traduce prin condiția de a nu avea două stelușe una după alta. Cele $n+1$ bare lasă între ele n spații, care trebuie ocupate de r stelușe și aceasta se poate face în C_n^r moduri.

Dacă se presupune că toate distribuirile sunt egal probabile, cu excepția acelora în care apare vreo urnă cu două sau mai multe bile și care se vor considera de probabilitate nulă, atunci probabilitatea unei distribuiră, în care nici o urnă nu conține mai mult de o bilă, va fi $1/C_n^r$. Aceasta este astăzi numita *statistică Fermi-Dirac*.

În concluzie, în experimentul care constă în distribuirea a r bile (fără a face distincție între bile) în n urne, spațiul evenimentelor elementare este mulțimea secvențelor (r_1, r_2, \dots, r_n) cu proprietatea că

$$r_1 + r_2 + \dots + r_n = r, \quad (r_i \in \mathbb{N}).$$

Fiecarei astfel de secvențe i se poate atașa una din probabilitățile

$$P_1(\{r_1, r_2, \dots, r_n\}) = \frac{r!}{r_1!r_2!\dots r_n!} n^{-r}$$

în cazul statisticii Maxwell-Boltzmann,

$$P_2(\{r_1, r_2, \dots, r_n\}) = 1/C_{n+r-1}^r$$

în cazul statisticii Bose-Einstein,

$$P_3(\{r_1, r_2, \dots, r_n\}) = \begin{cases} 1/C_n^r, & \text{dacă } r_i \leq 1, i = \overline{1, n} \\ 0, & \text{dacă există cel puțin un } r_i > 1 \end{cases}$$

în cazul statisticii Fermi-Dirac.

Cele trei statistici apar în fizică prin considerarea unui sistem de r particule, fiecare din ele putându-se găsi într-o anumită regiune (sau celulă) a spațiului care a fost împărțit într-un număr n de astfel de regiuni. În acest fel, starea întregului sistem este descrisă de distribuirea la întâmplare a r particule în n celule. Alegerea uneia dintre cele trei statistici se face în funcție de natura particulelor.

Exemplul 3. Acest exemplu este denumit "problema zilei de naștere" și constă în determinarea probabilității ca dintre r persoane cel puțin două să aibă ziua de naștere în aceeași zi a anului, presupus a fi format din n zile. Se observă că această problemă se încadrează în problema generală a distribuirii a r bile în n urne, mai precis este vorba de statistică Maxwell-Boltzmann.

Pentru rezolvarea problemei se calculează probabilitatea evenimentului contrar și anume probabilitatea ca în fiecare urnă să se afle cel mult o bilă. Prin urmare vor exista r urne ce conțin o singură bilă, iar celelalte $n - r$ nu vor conține nici o bilă. Dacă se fixează cele r urne în care se găsește câte o bilă și se ține seama de formula (1.1), rezultă că probabilitatea unui astfel de eveniment este $r!n^{-r}$; cum cele r urne pot fi alese în C_n^r moduri, rezultă că probabilitatea ca în nici o urnă să nu fie mai mult de o bilă este

$$C_n^r r! n^{-r} = n(n-1)\dots(n-r+1)n^{-r}.$$

În concluzie, probabilitatea ca cel puțin două persoane să aibă ziua de naștere în aceeași zi este

$$p = 1 - n(n-1)\dots(n-r+1)n^{-r}.$$

Dacă $n = 365$, pentru $r \geq 1/2$ se constată că $p > 1/2$. Acest rezultat este interesant, pentru că la o examinare superficială a problemei era de așteptat ca $p > 1/2$ numai dacă $r > 182$.

Exemplul 4. Exemplul următor este cunoscut sub denumirea de "problema întâlnirii" și se enunță astfel: două persoane hotărăsc să se întâlnească în intervalul de timp $[0, T]$, momentele sosirilor lor în acest interval fiind aleatoare. Prima persoană care sosetează așteaptă un timp t , fără a depăși intervalul $[0, T]$; deci dacă sosetează la momentul $t_0 \in [0, T]$, ea așteaptă un timp egal cu $\min\{t, T - t_0\}$. Se cere probabilitatea ca cele două persoane să se întâlnească.

Înregistrând momentul sosirii lui A pe axa Ox , iar momentul sosirii lui B pe axa Oy , rezultă că spațiul evenimentelor elementare poate fi identificat cu $\Omega = \{(x, y) | 0 \leq x \leq T, 0 \leq y \leq T\}$. Pentru ca A și B să se întâlnească este necesar și suficient ca $|x - y| \leq t$. Atunci evenimentul, a cărui probabilitate este căutată, este dat de domeniul hașurat din fig. 1.1.

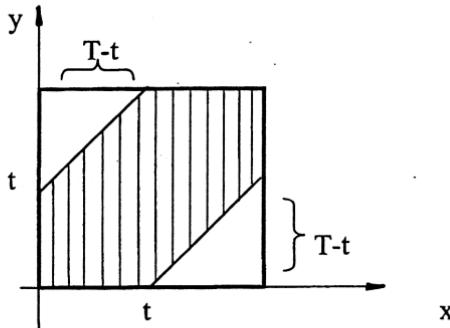


Fig. 1.1

Probabilitatea căutată va fi raportul dintre aria acestui domeniu hașurat și aria lui Ω ⁵, adică

$$p = 1 - \frac{(T-t)^2}{T^2}.$$

Problema întâlnirii poate fi utilizată, ca o primă aproximare în rezolvarea unor probleme de tipul următor: un muncitor deserveste două utilaje; fiecare din cele două utilaje necesită supraveghere la un moment de timp aleator. Se poate întâmpla ca, în timp ce muncitorul se află la unul din utilaje, prezența sa să fie necesară la celălalt. Care este timpul mediu de neutilizare al unuia din utilaje?

⁵Se presupune că cele două persoane sosesc independent una de cealaltă și pentru fiecare din ele probabilitatea de a sosi într-un anumit interval de timp este proporțională cu lungimea acestui interval.

Exemplul 5. Două semnale de lungime $\tau < \frac{1}{2}$ sunt transmise într-un interval de timp $[0,1]$, transmiterea lor începând la orice moment al intervalului $[0, 1 - \tau]$ (probabilitățile ca acest moment să se găsească în intervale de aceeași lungime sunt egale). Dacă semnalele se suprapun chiar și parțial, atunci ambele sunt distorsionate și nu pot fi recepționate. Să se determine probabilitatea ca semnalele să fie recepționate fără distorsiuni.

Această problemă este o aplicație a exemplului precedent (problema întâlnirii). Utilizând rezultatele de mai sus, se găsește probabilitatea căutată

$$p = \frac{(1 - 2\tau)^2}{(1 - \tau)^2}.$$

Exemplul 6. Imaginea punctuală a unui obiect pe ecranul circular al unui radar (fig.1.2) are o poziție aleatoare în disc, domeniile de aceeași arie fiind egal probabile. Se consideră evenimentul A ce constă în faptul că distanța ρ_M de la imaginea M la centrul ecranului este mai mică decât $\frac{r}{2}$. Se cere $P(A)$.

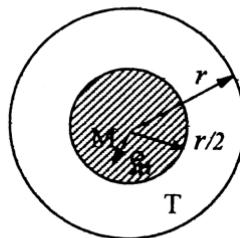


Fig. 1.2

Dacă T este mulțimea punctelor ecranului, adică spațiul evenimentelor elementare, atunci $A = \left\{ M \in T \mid \rho_M < \frac{r}{2} \right\}$. Deci

$$P(A) = \frac{\text{aria } A}{\text{aria } T} = \frac{\pi \frac{r^2}{4}}{\pi r^2} = \frac{1}{4}.$$

Exemplul 7 (Paradoxul lui Bertrand). Într-un cerc de rază R se alege o coardă la întâmplare. Care este probabilitatea ca lungimea acestei coarde să fie mai mare decât latura triunghiului echilateral inscris în cerc?

Vom da trei soluții la această problemă.

Soluția 1. Din motive de simetrie, se poate fixa o direcție cu care trebuie să fie paralelă coarda aleasă. Ducem un diametru perpendicular pe această

direcție (vezi fig. 1.3 a)). Dacă coarda intersectează acest diametru în intervalul cuprins între $1/4$ și $3/4$ din lungimea sa, atunci coarda este mai mare decât latura triunghiului echilateral inscris. Deci probabilitatea căutată este $1/2$.

Soluția 2. Din motive de simetrie putem fixa unul din capetele coardei dinainte, urmând să alegem la întâmplare pe cel de al doilea. Tangenta la cerc în punctul ales A și laturile triunghiului echilateral cu un vârf în A , inscris în cerc, formează unghiuri de $\frac{\pi}{3}$.

Cel de al doilea capăt al coardei trebuie să fie pe arcul \widehat{BC} și rezultă că probabilitatea căutată este $1/3$ (vezi fig. 1.3 b)).

Soluția 3. Pentru a defini poziția coardei este suficient să specificăm mijlocul ei. Pentru a satisface condițiile problemei trebuie ca mijlocul să fie în discul cu centrul în O și de rază $\frac{R}{2}$ (vezi fig. 1.3 c)). Prin urmare, probabilitatea căutată este $\frac{1}{4}$.

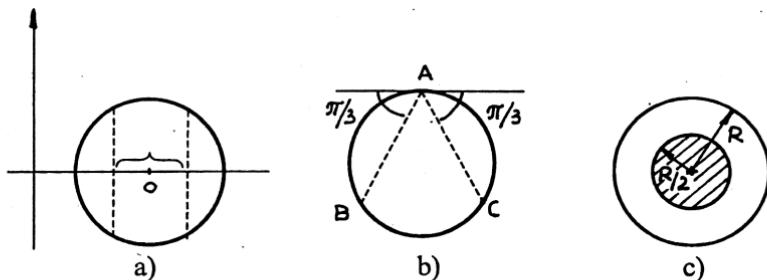


Fig. 1.3.

Acest "paradox" provine din faptul că enunțul problemei nu a permis stabilirea categorică a spațiului evenimentelor elementare. Propunem cititorului să precizeze spațiul evenimentelor elementare la fiecare din cele 3 soluții.

1.3 Independență și condiționare

Conceptul de independență este conceptul de bază din teoria clasică a probabilităților. El este specific teoriei probabilităților și este unul din concepții care au permis delimitarea ei ca disciplină matematică independentă. Însuși Kolmogorov afirma: "În conceptul de independență se percepce cel puțin primul germene al adevărătei naturi a problemelor din teoria probabilităților".

Evenimentele A_1 și A_2 ale câmpului de probabilitate (Ω, \mathcal{K}, P) se numesc P -independente (stocastic independente) dacă

$$P(A_1 \cap A_2) = P(A_1)P(A_2) \quad (1.2)$$

Trei evenimente $A_1, A_2, A_3 \in \mathcal{K}$ se numesc P -independente dacă

$$P(A_1 \cap A_2) = P(A_1)P(A_2)$$

$$P(A_2 \cap A_3) = P(A_2)P(A_3)$$

$$P(A_1 \cap A_3) = P(A_1)P(A_3)$$

$$P(A_1 \cap A_2 \cap A_3) = P(A_1)P(A_2)P(A_3).$$

În general, dacă $\{A_i \mid i \in I\}$ este o familie oarecare de evenimente din \mathcal{K} , atunci evenimentele A_i , $i \in I$, se numesc P -independente (în totalitatea lor), dacă pentru orice mulțime finită de indici $J \subset I$

$$P\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} P(A_j).$$

Dacă evenimentele familiei $\{A_i \mid i \in I\}$ sunt P -independente (două căte două), adică

$$P(A_i \cap A_j) = P(A_i)P(A_j) \quad \forall i, j \in I, \quad i \neq j,$$

aceasta nu atrage după sine faptul că evenimentele familiei sunt P -independente (vezi exemplul 4). De aceea, nu trebuie confundată independența totală a evenimentelor cu independența evenimentelor două căte două (în perechi).

Două familii $\mathcal{L}_1, \mathcal{L}_2 \subset \mathcal{K}$ se numesc P -independente dacă relația (1.2) are loc pentru orice $A_1 \in \mathcal{L}_1$ și orice $A_2 \in \mathcal{L}_2$.

Fie două familii P -independente \mathcal{L}_1 și \mathcal{L}_2 cu proprietatea: dacă $A, B \in \mathcal{L}_i$, atunci $A \cap B \in \mathcal{L}_i$, $i = 1, 2$. Atunci σ -algebrele $\sigma(\mathcal{L}_1)$ și $\sigma(\mathcal{L}_2)$ sunt de asemenea P -independente.

Se observă că noțiunea de independență este relativă la probabilitatea considerată în contrast, de exemplu, cu noțiunea de evenimente incompatibile, care nu depinde de nici o probabilitate.

O discuție mai elaborată, legată de noțiunea de independență, va fi făcută ulterior, în legătură cu variabilele aleatoare.

Fie $A, B \in \mathcal{K}$, $P(B) \neq 0$. Se numește probabilitatea lui A conditionată de B, notată $P_B(A)$ sau $P(A|B)$, valoarea $\frac{P(A \cap B)}{P(B)}$. Această raport semnifică

⁶Litera P poate lipsi, dacă rezultă din context.



probabilitatea lui A , știind că evenimentul B s-a realizat. Spre exemplu, la experimentul care constă în aruncarea a două zaruri, unde probabilitatea fiecărui eveniment elementar este $\frac{1}{36}$, se consideră următoarele evenimente: evenimentul B care constă în faptul că pe primul zar a apărut un punct și evenimentul A care constă în faptul că suma punctelor apărute pe cele două zaruri este 3. Atunci

$$P(B) = \frac{6}{36} = \frac{1}{6} \quad \text{și} \quad P(A) = \frac{2}{36} = \frac{1}{18}.$$

Presupunând că după aruncarea primului zar, evenimentul B s-a realizat, probabilitatea ca după aruncarea celui de al doilea zar, suma punctelor să fie 3 este

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{1/36}{1/6} = \frac{1}{6},$$

ceea ce poate fi verificat și printr-un calcul direct.

Dacă evenimentele A și B sunt P -independente, atunci, după cum era de așteptat $P(A|B) = P(A)$.

Propoziția 1.1. *Au loc următoarele egalități:*

- a) $P(A|B) = P(A \cap B|B)$, $\forall A \in \mathcal{K}$ dacă $P(B) \neq 0$;
- b) $P(C|A \cap B) P(B|A) = P(C \cap B|A)$ dacă $P(A \cap B) \neq 0$;
- c) (formula de înmulțire) $P(A_1 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$ dacă $P(A_1 \cap \dots \cap A_{n-1}) \neq 0$.

Teorema 1.2 (formula probabilității totale). *Fie*

$$\bigcup_{i \in I} A_i = \Omega, \quad A_i \in \mathcal{K}, \quad A_i \cap A_j \neq \emptyset, \quad i \neq j, \quad i, j \in I,$$

unde I este cel mult numărabilă, iar $A \in \mathcal{K}$ arbitrar. Atunci are loc relația

$$P(A) = \sum_{i \in I} P(A_i) \cdot P(A|A_i)$$

dacă $P(A_i) \neq 0$, $\forall i \in I$.

Teorema 1.3 (formula lui Bayes). *În ipotezele teoremei 1.2 are loc relația*

$$P(A_i|A) = \frac{P(A_i)P(A|A_i)}{\sum_{i \in I} P(A_i)P(A|A_i)}, \quad i \in I,$$

dacă $P(A) \neq 0$.

Celebra formulă a lui Bayes, publicată în anul 1763, permite calculul "probabilității inverse" sau "probabilității cauzei" A_i , pe baza "efectului" observat A . Probabilitatea $P(A_i)$ se numește *probabilitatea apriori* a cauzei A_i , în timp ce $P(A_i|A)$ reprezintă *probabilitatea aposteriori* a cauzei A_i . De exemplu, dacă

A este evenimentul producerii unui cutremur și A_i sunt diferite teorii seismologice, care explică acest fenomen, atunci formula ar putea ajuta specialiștii să aleagă între aceste teorii. De remarcat este și faptul că Laplace⁷ a utilizat această formulă pentru a calcula probabilitatea ca "soarele să răsără și mâine". Din păcate utilitatea practică a acestei formule este limitată de lipsa noastră de informații despre probabilitățile apriori.

Propoziția 1.4 (Borel-Cantelli). *Pentru orice sir $\{A_n | n \geq 1\}$ de evenimente au loc următoarele implicații*

$$\sum_{n=1}^{\infty} P(A_n) < \infty \Rightarrow \limsup_n A_n = \emptyset \quad a.s.$$

$$\sum_{n=1}^{\infty} P\left(A_n \mid \bigcap_{m=1}^{n-1} \bar{A}_m\right) = \infty \Rightarrow \sup_n A_n = \Omega \quad a.s.$$

În particular, pentru orice sir $\{A_n | n \geq 1\}$ de evenimente independente rezultă $\limsup_n A_n = \emptyset$ sau Ω a.s., după cum seria $\sum_{n=1}^{\infty} P(A_n)$ converge sau diverge.

Exemplul 1. Dacă evenimentele A_1 și A_2 sunt P -independente, atunci următoarele perechi de evenimente sunt P -independente: (A_1, \bar{A}_2) , (\bar{A}_1, A_2) , (\bar{A}_1, \bar{A}_2) . În acest caz $\mathcal{L}_1 = \{A_1\}$, $\mathcal{L}_2 = \{A_2\}$, $\sigma(\mathcal{L}_1) = \{\emptyset, A_1, \bar{A}_1, \Omega\}$ și $\sigma(\mathcal{L}_2) = \{\emptyset, A_2, \bar{A}_2, \Omega\}$.

Exemplul 2 (Experimentul Bernoulli repetat⁸).

Prin experiment Bernoulli se înțelege un experiment aleator cu două rezultate posibile s succes și \bar{s} eșec, având probabilitățile p , respectiv q , $p + q = 1$. Dacă experimentul este repetat de n ori, atunci spațiul evenimentelor elementare asociat Ω_n , va fi reprezentat de cele 2^n siruri ordonate de lungime n de componente s și \bar{s} . Presupunând că repetările succesive sunt independente și considerând A_i , evenimentele ca rezultatul repetării de rang i a experimentului să fie s , atunci

$$P(A_i) = p \quad și \quad P(\bar{A}_i) = 1 - p = q, \quad 1 \leq i \leq n.$$

Dacă $\omega \in \Omega_n$ conține de k ori, $0 \leq k \leq n$, componenta s și de $n - k$ ori componenta \bar{s} , atunci $P(\omega) = p^k q^{n-k}$, ca o consecință a independenței. Este important de remarcat că numărul $p^k q^{n-k}$ reprezintă probabilitatea obținerii unui sir specific, care conține componenta s de k ori. Astfel pentru a calcula probabilitatea obținerii a k succese în n repetări, se observă mai întâi că există C_n^k siruri specifice ω , cu această componență.

⁷Pierre Simon de Laplace (1749-1827), astronom, matematician și fizician francez, a scris un monumental tratat de probabilități în anul 1815.

⁸Această schemă clasică, cunoscută sub denumirea *experimentul Bernoulli repetat*, a constituit subiectul cercetărilor făcute de Bernoulli, De Moivre, Laplace, Borel etc.

Atunci probabilitatea căutată este $C_n^k p^k q^{n-k}$. Acest rezultat este cunoscut sub denumirea de *formula lui Bernoulli*.

Acest experiment poate fi realizat și cu ajutorul unei urne, ce conține bile albe și negre. Probabilitatea ca la o extragere să se obțină o bilă albă este p , iar ca să se obțină o bilă neagră este $q = 1 - p$. Se fac n extrageri, după fiecare extragere punându-se bila la loc. Se presupune că extragerile sunt independente între ele. În acest caz se pune problema găsirii probabilității ca în cele n extrageri, să se obțină bila albă de exact k ori, $0 \leq k \leq n$. În continuare se face același raționament ca mai sus⁹.

Exemplul 3. Se consideră toate familiile, care au doi copii. Dacă se presupune că nașterile băieților și ale fetelor sunt egal probabile, atunci spațiul evenimentelor elementare poate fi notat schematic

$$\Omega = \{(bb), (bf), (fb), (ff)\},$$

unde b = băiat, f = fată. Ordinea din fiecare pereche reprezintă ordinea cronologică a nașterilor. Se alege o familie la întâmplare și se consideră următoarele trei evenimente

- A - primul copil este băiat;
- B - cei doi copii au sexe diferite;
- C - primul copil este fată.

Atunci rezultă

$$A \cap B = \{(bf)\}, \quad B \cap C = \{(fb)\}, \quad A \cap C = \emptyset.$$

Un calcul trivial arată că

$$P(A \cap B) = P(A)P(B),$$

$$P(B \cap C) = P(B)P(C),$$

dar $P(A \cap C) = 0 \neq P(A)P(C)$. Astfel perechile de evenimente (A, B) și (B, C) sunt P -independente, dar A și C nu sunt P -independente.

Exemplul 4 (S.N. Bernstein). Fie

$$\Omega = \{\omega_1, \omega_2, \omega_3, \omega_4\}, \quad \mathcal{K} = \mathcal{P}(\Omega),$$

$$P(\{\omega_1\}) = P(\{\omega_2\}) = P(\{\omega_3\}) = P(\{\omega_4\}) = \frac{1}{4}.$$

Se consideră evenimentele

$$A = \{\omega_1, \omega_2\}, \quad B = \{\omega_1, \omega_3\}, \quad C = \{\omega_1, \omega_4\}.$$

⁹Această schemă clasică este cunoscută și sub denumirea de *urna lui Bernoulli cu bila repetată*.

Deoarece

$$P(A) = P(B) = P(C) = \frac{1}{2} \quad \text{și} \quad P(A \cap B) = P(A \cap C) = P(B \cap C) = \frac{1}{4},$$

rezultă că evenimentele A, B, C sunt două câte două P -independente. Pe de altă parte

$$P(A \cap B \cap C) = P(\{\omega_1\}) = \frac{1}{4} \neq P(A)P(B)P(C) = \frac{1}{8}.$$

Deci evenimentele A, B, C nu sunt P -independente în ansamblul lor.

Exemplul 5. Care este probabilitatea ca aruncând șase zaruri perfecte, să se obțină șase fețe diferite? Numerotând zarurile de la 1 la 6 și punând

A_1 - evenimentul ca zarul 1 să prezinte orice față;

A_2 - evenimentul ca zarul 2 să prezinte o față diferită de a primului zar;

A_3 - evenimentul ca zarul 3 să prezinte o față diferită de fețele primelor două zaruri ... etc.

rezultă

$$P(A_1) = 1, \quad P(A_2 | A_1) = \frac{5}{6}, \quad P(A_3 | A_1 \cap A_2) = \frac{4}{6}, \dots, \quad P(A_6 | A_1 \cap \dots \cap A_5) = \frac{1}{6}.$$

În final, aplicând formula de înmulțire (propoziția 1.1, c)) se obține

$$P(A_1 \cap \dots \cap A_6) = \frac{6}{6} \cdot \frac{5}{6} \cdot \frac{4}{6} \cdot \frac{3}{6} \cdot \frac{2}{6} \cdot \frac{1}{6} = \frac{6!}{6^6}.$$

Exemplul 6. Un zar perfect este aruncat de două ori succesiv. Știind că numărul total de puncte obținute în ambele aruncări este 7, care este probabilitatea ca la prima aruncare să se obțină k puncte, $1 \leq k \leq 6$?

Pentru aceasta, fie A_1 evenimentul ca la prima aruncare să se obțină k puncte și A evenimentul ca numărul total de puncte din ambele aruncări să fie 7. Atunci

$$P(A_1 | A) = \frac{P(A_1 \cap A)}{P(A)} = \frac{1}{6}.$$

Datorită alegerii fericite a numărului 7, probabilitatea necondiționată $P(A_1)$ este egală cu $P(A_1 | A)$. Dacă, în schimb, se ia A_1 evenimentul ca în prima aruncare să se obțină k puncte, $1 \leq k \leq 5$ și A evenimentul ca numărul total de puncte din ambele aruncări să fie 6, atunci

$$P(A_1 | A) = \frac{1}{5} \quad \text{și} \quad P(A_1) = \frac{1}{6}.$$

Exemplul 7 (Schema lui Pólya)¹⁰. Se consideră o urnă cu a bile albe și b bile negre. După fiecare extragere a unei bile din urnă, bilă respectivă este

¹⁰George Pólya a fost profesor la Universitatea Stanford și a avut contribuții majore în teoria probabilităților, numărându-se printre cei mai eminenți analiști ai timpurilor moderne.

reintrodusă în urnă împreună cu încă c bile de aceeași culoare cu cea extrasă ($c > 0$). Dacă c este un întreg negativ, atunci din urnă se scot c bile, având culoarea bilei extrase inițial. Dacă $c = 0$ schema se reduce la schema bilei repetate. În general, dacă c este negativ procesul se va opri după un număr finit de extrageri, dar dacă $c \geq 0$ procesul poate fi continuat la infinit. Ne vom restrângă la cazul $c \geq -1$, cunoscut sub denumirea de *urna lui Pólya*¹¹.

Notând cu a și b , culoarea albă și respectiv neagră, care este probabilitatea ca în schema urbei lui Pólya primele trei bile extrase să aibă culorile în acestă ordine $\{a, a, b\}$? Dar $\{a, b, a\}$? Dar $\{b, a, a\}$?

Se notează că A_1 evenimentul ca în prima extragere să se obțină o bilă albă, cu A_2 evenimentul ca în a doua extragere să se obțină o bilă albă și cu B_3 evenimentul ca în a treia extragere să se obțină o bilă neagră. Atunci

$$\begin{aligned} P(A_1 \cap A_2 \cap B_3) &= P(A_1) \cdot P(A_2 | A_1) \cdot P(B_3 | A_1 \cap A_2) = \\ &= \frac{a}{a+b} \cdot \frac{a+c}{a+b+c} \cdot \frac{b}{a+b+2c} \end{aligned}$$

conform formulei de înmulțire. Cu notații similare rezultă

$$\begin{aligned} P(A_1 \cap B_2 \cap A_3) &= P(A_1) \cdot P(B_2 | A_1) \cdot P(A_3 | A_1 \cap B_2) = \\ &= \frac{a}{a+b} \cdot \frac{b}{a+b+c} \cdot \frac{a+c}{a+b+2c}, \end{aligned}$$

$$\begin{aligned} P(B_1 \cap A_2 \cap A_3) &= P(B_1) \cdot P(A_2 | B_1) \cdot P(A_3 | B_1 \cap A_2) = \\ &= \frac{b}{a+b} \cdot \frac{a}{a+b+c} \cdot \frac{a+c}{a+b+2c}. \end{aligned}$$

Se observă că s-a obținut același rezultat în cele trei cazuri. În concluzie, probabilitatea extragerii a două bile albe și a unei bile negre, nu depinde de ordinea în care bilele sunt extrase.

Exemplul 8. Se consideră a) două urne cu câte 8 bile, dintre care 2 albe și 6 negre, b) trei urne cu câte 10 bile, dintre care 6 albe și 4 negre. Din cele 5 urne se alege una la întâmplare, iar apoi din acea urnă se alege o bilă la întâmplare. Care este probabilitatea ca bila să fie albă?

Se notează cu A_1 (respectiv A_2) evenimentul care constă în faptul că urna aleasă este de tipul (a) (respectiv (b)). Dacă C este evenimentul a cărui probabilitate se cere, atunci, conform teoremei 1.2

$$P(C) = P(A_1)P(C|A_1) + P(A_2)P(C|A_2) = \frac{2}{5} \cdot \frac{2}{8} + \frac{3}{5} \cdot \frac{6}{10} = 0,46.$$

¹¹ Acest model a fost inventat de Pólya cu scopul de a studia o problemă apărută în medicină.

Exemplul 9. În condițiile exemplului precedent, se presupune că, în urma efectuării experimentului, se constată că bila extrasă este albă. Care este probabilitatea ca bila să provină dintr-o urnă de tipul (a) ?

Trebuie calculat $P(A_1 | C)$; pentru aceasta se utilizează teorema 1.3.

$$P(A_1 | C) = \frac{P(A_1)P(C|A_1)}{P(C)} = \frac{(2/5)(2/8)}{0,46} = \frac{5}{23}.$$

Exemplul 10. Un radar urmărește independent între ele n aeronave. În timpul unei perioade de supraveghere, cea de a i -a aeronavă poate fi pierdută cu probabilitatea p_i , $i = \overline{1, n}$. Să se găsească probabilitățile următoarelor evenimente

$$A = \{ \text{nici o aeronavă nu este pierdută}\};$$

$$B = \{ \text{este pierdută cel puțin o aeronavă}\};$$

$$C = \{ \text{cel mult o aeronavă este pierdută}\}.$$

Dacă A_i , ($P(A_i) = p_i$), este evenimentul ce constă în pierderea celei de a i -a aeronave, $i = \overline{1, n}$, atunci, prin ipoteză, aceste evenimente sunt independente. Obținem

$$P(A) = P\left(\bigcap_{i=1}^n \bar{A}_i\right) = \prod_{i=1}^n P(\bar{A}_i) = \prod_{i=1}^n (1 - p_i)$$

$$P(B) = 1 - P(A) = 1 - \prod_{i=1}^n (1 - p_i)$$

$$\begin{aligned} P(C) &= P\left(A \cup \left(\bigcup_{i=1}^n (\bar{A}_1 \cap \dots \cap \bar{A}_{i-1} \cap A_i \cap \bar{A}_{i+1} \cap \dots \cap \bar{A}_n)\right)\right) = \\ &= P(A) + \sum_{i=1}^n P(\bar{A}_1 \cap \dots \cap \bar{A}_{i-1} \cap A_i \cap \bar{A}_{i+1} \cap \dots \cap \bar{A}_n) = \\ &= \prod_{i=1}^n (1 - p_i) + \prod_{i=1}^n (1 - p_1) \dots (1 - p_{i-1}) p_i (1 - p_{i+1}) \dots p_n \end{aligned}$$

(în ultima relație se consideră $A_0 = \emptyset$).

Exemplul 11. Un mesaj poate fi transmis printr-unul din cele n canale de comunicație, grupate în 4 grupe, după calitățile lor în ceea ce privește corectitudinea transmisiei. Aceste grupe conțin respectiv n_1, n_2, n_3, n_4 canale, ($n_1 + n_2 + n_3 + n_4 = n$). Probabilitatea ca un mesaj să fie transmis corect pentru un canal din grupa i este p_i , $i = \overline{1, 4}$. Pentru a îmbunătăți calitatea transmisiei, fiecare mesaj este transmis de două ori pe două canale diferite. Probabilitatea selectării unui canal este aceeași pentru oricare dintre ele, iar această selectare este independentă de calitatea transmisiei. Să se determine probabilitatea ca mesajul să fie transmis corect pe cel puțin un canal.

Se notează cu A evenimentul a cărui probabilitate este cerută și cu A_i și H_i evenimentele care constau în faptul că primul și respectiv cel de al doilea mesaj sunt transmise prin canale din grupa i , $i = \overline{1, 4}$.

$$\begin{aligned} P(A| A_i) &= \sum_{j=1}^4 P(A \cap H_j | A_i) = \sum_{j=1}^4 P(H_j | A_i)P(A | H_j \cap A_i) = \\ &= \frac{n_i - 1}{n - 1}[1 - (1 - p_i)^2] + \sum_{j \neq i} \frac{n_j}{n - 1}[1 - (1 - p_i)(1 - p_j)], \end{aligned}$$

iar $P(A_i) = \frac{n_i}{n}$, $i = \overline{1, 4}$. Prin urmare, din teorema 1.2 rezultă

$$P(A) = \sum_{i=1}^4 P(A_i)P(A | A_i).$$

Capitolul 2

Variabile aleatoare

2.1 Noțiunea de variabilă aleatoare

Fie (Ω, \mathcal{K}, P) un câmp de probabilitate. O funcție $X : \Omega \rightarrow \mathbf{R}$ se numește variabilă aleatoare reală, dacă pentru orice $A \in \mathcal{B}$, rezultă $X^{-1}(A) \in \mathcal{K}$.

Această condiție este echivalentă cu oricare din următoarele:

- a) $\{\omega | X(\omega) \leq c\} \in \mathcal{K}$ pentru orice $c \in \mathbf{R}$;
- b) $\{\omega | X(\omega) \geq c\} \in \mathcal{K}$ pentru orice $c \in \mathbf{R}$;
- c) $\{\omega | a \leq X(\omega) \leq b\} \in \mathcal{K}$ pentru orice $a, b \in \mathbf{R}$.

Din aceste condiții se pot obține alte condiții echivalente prin înlocuirea inegalităților nestrictive cu inegalități stricte. Însă condiția inițială stă la baza definirii conceptului de variabilă aleatoare cu valori într-o mulțime arbitrară M în care s-a introdus o σ -algebră de părți \mathcal{M} . Așadar, o funcție $X : \Omega \rightarrow M$ se numește variabilă aleatoare cu valori în M pe un câmp de probabilitate (Ω, \mathcal{K}, P) , dacă pentru orice $A \in \mathcal{M}$ rezultă $X^{-1}(A) \in \mathcal{K}$.¹ În particular, o variabilă aleatoare cu valori în spațiul euclidian n -dimensional se numește vector aleator n -dimensional.

O funcție $Z : \Omega \rightarrow \mathbf{C}$ (\mathbf{C} este corpul numerelor complexe) se numește variabilă aleatoare complexă, dacă funcțiile $\text{Re } Z$ și $\text{Im } Z$ sunt variabile aleatoare reale.

În cele ce urmează, variabilele aleatoare vor fi notate prescurtat cu v.a..

O v.a. X se numește discretă², dacă mulțimea valorilor sale (reale sau nu) este cel mult numărabilă.

Dacă X este o v.a. discretă, atunci valorile sale x_i , $i \in I$, se numesc puncte de concentrație.

¹ Este interesant de notat că definiția conceptului de variabilă aleatoare nu face să intervină probabilitatea P , ci numai Ω și \mathcal{K} .

² Cel mai simplu exemplu de v.a. discretă este cel al unei "variabile" cu o singură valoare posibilă (deci o constantă).

O v.a. reală X se numește *simplă* sau *etajată*, dacă mulțimea valorilor sale este finită.

O v.a. reală X se numește *continuă*³ dacă $P(\{\omega \mid X(\omega) = x\}) = 0$ pentru orice $x \in \mathbb{R}$.

În continuare, pentru simplificarea scrierii, se va suprima în notație evenimentul aleator ω , adică se va scrie $\{X < x\}$ și $\{X \in A\}$, în loc de $\{\omega \mid X(\omega) < x\}$, respectiv $\{\omega \mid X(\omega) \in A\}$.

2.2 Funcția de repartiție

Un mod de a caracteriza v.a. reale este acela care utilizează noțiunea de funcție de repartiție. Prin *funcție de repartiție* a v.a. X se înțelege funcția

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Funcția de repartiție are următoarele proprietăți:

- 1) F_X este crescătoare ($x_1 < x_2 \Rightarrow F_X(x_1) \leq F_X(x_2)$);
- 2) F_X este continuă la dreapta ($F_X(x+0) = F_X(x)$, $x \in \mathbb{R}$)⁴;
- 3) $\lim_{x \rightarrow -\infty} F_X(x) = F_X(-\infty) = 0$; $\lim_{x \rightarrow +\infty} F_X(x) = F_X(+\infty) = 1$.

Dacă v.a. X este discretă cu valorile x_1, x_2, \dots , iar $p_i = P(X = x_i)$, atunci $F_X(x) = \sum_{x_i \leq x} p_i$, suma făcându-se după toți indicii i pentru care $x_i \leq x$. În acest caz F_X se numește *funcție de repartiție de tip discret*.

Funcția care atâșează valorilor x_i probabilitățile p_i se numește *funcția de frecvență* sau *repartiția de probabilitate* a v.a. De obicei funcția de frecvență a v.a. X este dată sub forma

$$X : \begin{pmatrix} x_1 & x_2 & \dots & x_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix}.$$

Dacă v.a. X este simplă,

$$X : \begin{pmatrix} x_1 & \dots & x_n \\ p_1 & \dots & p_n \end{pmatrix} \quad x_1 < \dots < x_n,$$

³Există v.a. care nu sunt nici discrete și nici continue.

⁴Unii autori definesc funcția de repartiție prin relația $F_X(x) = P(X < x)$. Această definiție atrage după sine continuitatea la stânga a funcției de repartiție, fără a provoca modificări esențiale de rezultate.

atunci F_X ia valori constante pe intervalele $(x_{i-1}, x_i]$, adică este o funcție în scără

$$F_X(x) = \begin{cases} 0, & x \leq x_1 \\ p_1, & x_1 < x \leq x_2 \\ p_1 + p_2, & x_2 < x \leq x_3 \\ \dots & \dots \\ p_1 + \dots + p_{n-1}, & x_{n-1} < x \leq x_n \\ 1, & x > x_n. \end{cases}$$

Dacă există o funcție integrabilă $p_X : \mathbf{R} \rightarrow \mathbf{R}_+$ astfel încât

$$F_X(x) = \int_{-\infty}^x p_X(t)dt \quad \forall x \in \mathbf{R},$$

atunci se spune că v.a. X admite densitate de probabilitate sau densitate de repartiție, iar p_X este numită densitatea de probabilitate sau de repartiție a v.a. X . În acest caz, evident v.a. este continuă.

În general, aici este vorba despre o integrală Lebesgue⁵. Întrucât funcția p_X este pozitivă, convergența (în sens Riemann) a integralei $\int_{-\infty}^{\infty} p_X(t)dt$ atrage după sine integrabilitatea Lebesgue pe \mathbf{R} . De obicei se întâlnește cazul în care p_X este integrabilă Riemann.

Întrucât $F_X(+\infty) = 1$, rezultă că densitatea de probabilitate trebuie să îndeplinească condiția $\int_{-\infty}^{\infty} p_X(t)dt = 1$.

De asemenea, dacă p_X este continuă, atunci $F'_X(x) = p_X(x)$, $x \in \mathbf{R}$.

Dacă F_X este funcția de repartiție a v.a. X , atunci pentru orice $a, b \in \mathbf{R}$ au loc relațiile

$$\begin{aligned} P(a < X \leq b) &= F_X(b) - F_X(a), \\ P(a < X < b) &= F_X(b - 0) - F_X(a), \\ P(a \leq X \leq b) &= F_X(b) - F_X(a - 0), \\ P(a \leq X < b) &= F_X(b - 0) - F_X(a - 0), \\ P(X = a) &= F_X(a) - F_X(a - 0). \end{aligned} \tag{2.1}$$

Dacă F_X este continuă, atunci în membrul stâng al relațiilor (2.1) nu are importanță dacă inegalitățile sunt stricte sau nu. De asemenea, din ultima relație (2.1) rezultă că dacă F_X este continuă atunci v.a. X este continuă.

⁵Henri Lebesgue (1875-1941), cofondator cu E.Borel al școlii moderne de teoria măsurii și integrării.

Evident, dacă X admite o densitate de probabilitate p_X , atunci F_X este continuă și în acest caz

$$P(a \leq X \leq b) = \int_a^b p_X(t)dt.$$

Fie $X = (X_1, X_2, \dots, X_n)$ un vector aleator definit pe spațiul de probabilitate (Ω, \mathcal{K}, P) . Funcția $F_X : \mathbf{R}^n \rightarrow [0, 1]$ dată prin relația

$$F_X(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)^6$$

se numește *funcția de repartiție n-dimensională* a vectorului aleator n -dimensional $X = (X_1, X_2, \dots, X_n)$.

Funcția de repartiție n -dimensională îndeplinește condițiile:

1') F_X este crescătoare în fiecare variabilă, adică $x_i < x'_i$ implică

$$F_X(x_1, \dots, x_i, \dots, x_n) \leq F_X(x_1, \dots, x'_i, \dots, x_n);$$

2') F_X este continuă la dreapta în fiecare variabilă, adică

$$F_X(x_1, \dots, x_{i+0}, \dots, x_n) = F(x_1, \dots, x_i, \dots, x_n), \quad \forall 1 \leq i \leq n;$$

3') $F_X(-\infty, -\infty, \dots, -\infty) = 0$ și $F_X(+\infty, +\infty, \dots, +\infty) = 1$.

Dacă există o funcție $p_X : \mathbf{R}^n \rightarrow \mathbf{R}_+$ integrabilă, cu proprietatea

$$F_X(x_1, x_2, \dots, x_n) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_n} p_X(t_1, t_2, \dots, t_n) dt_1 dt_2 \dots dt_n$$

pentru orice $(x_1, x_2, \dots, x_n) \in \mathbf{R}^n$ se spune că p_X este *densitatea de probabilitate (de repartiție)* a vectorului aleator $X = (X_1, X_2, \dots, X_n)$. Evident

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} p_X(t_1, t_2, \dots, t_n) dt_1 dt_2 \dots dt_n = 1. \quad (2.2)$$

De asemenea, pentru orice $a_1 < b_1, \dots, a_n < b_n$, $a_i, b_i \in \overline{\mathbf{R}}$, avem

$$P(a_1 \leq X_1 \leq b_1, \dots, a_n \leq X_n \leq b_n) = \int_{a_1}^{b_1} \dots \int_{a_n}^{b_n} p_X(x_1, \dots, x_n) dx_1 \dots dx_n.$$

În general, dacă $A \in \mathcal{B}^n$ (A este o mulțime boreliană din \mathbf{R}^n), atunci

$$P((X_1, \dots, X_n) \in A) = \int \dots \int_A p_X(x_1, \dots, x_n) dx_1 \dots dx_n. \quad (2.3)$$

⁶Pentru simplificarea scrierii, virgula va înlocui semnul \cap . Astfel $\{X_1 \leq x_1, \dots, X_n \leq x_n\}$ va însemna $\{X_1 \leq x_1\} \cap \dots \cap \{X_n \leq x_n\}$. Acest mod de scriere se va utiliza și în continuare.

Dacă $p_X(x_1, \dots, x_n)$ este continuă atunci

$$p_X(x_1, \dots, x_n) = \frac{\partial^n F_X(x_1, \dots, x_n)}{\partial x_1 \dots \partial x_n}. \quad (2.4)$$

Dacă $(X_{i_1}, \dots, X_{i_k})$ este un vector aleator extras din $X = (X_1, \dots, X_n)$, atunci funcția de repartiție a vectorului $(X_{i_1}, \dots, X_{i_k})$ se obține din $F_X(x_1, \dots, x_n)$ făcând limita către $+\infty$ după toate variabilele x_i , $i \neq i_1, \dots, i_k$. Existența unei densități de probabilitate $p_X(x_1, \dots, x_n)$ pentru vectorul aleator (X_1, \dots, X_n) implică existența densității pentru $(X_{i_1}, \dots, X_{i_k})$ care este dată de

$$p_{i_1 \dots i_k}(x_{i_1}, \dots, x_{i_k}) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} p_X(x_1, \dots, x_n) dx_i \quad (2.5)$$

integrala efectuându-se în raport cu toate variabilele x_i , $i \neq i_1, \dots, i_k$.

V.a. X_1, \dots, X_n se numesc *P-independente* dacă

$$P(X_1 \leq x_1, \dots, X_n \leq x_n) = P(X_1 \leq x_1) \dots P(X_n \leq x_n)$$

pentru orice $x_1, \dots, x_n \in \mathbb{R}$. Prin urmare dacă F_X este funcția de repartiție (și p_X densitatea de probabilitate) a vectorului aleator $X = (X_1, \dots, X_n)$, iar F_{X_i} este funcția de repartiție (și p_{X_i} , densitatea de probabilitate) a v.a. X_i , $i = \overline{1, n}$, atunci în cazul independenței au loc relațiile

$$\begin{aligned} F_X(x_1, \dots, x_n) &= \prod_{i=1}^n F_{X_i}(x_i) \\ p_X(x_1, \dots, x_n) &= \prod_{i=1}^n p_{X_i}(x_i). \end{aligned} \quad (2.6)$$

Reciproc, fiecare din relațiile (2.6) atrage după sine independența v.a. X_1, \dots, X_n .

Independența a două v.a. X_1 și X_2 este echivalentă cu independența oricărui perechi de familii de evenimente:

$$\begin{aligned} \mathcal{L}_1 &= \{X_1^{-1}(-\infty, x_1); x_1 \in \mathbb{R}\}, & \mathcal{L}_2 &= \{X_2^{-1}(-\infty, x_2); x_2 \in \mathbb{R}\}; \\ \mathcal{L}_1 &= \{X_1^{-1}(x_1, \infty); x_1 \in \mathbb{R}\}, & \mathcal{L}_2 &= \{X_2^{-1}(x_2, \infty); x_2 \in \mathbb{R}\}; \\ \mathcal{L}_1 &= \{X_1^{-1}(-\infty, x_1]; x_1 \in \mathbb{R}\}, & \mathcal{L}_2 &= \{X_2^{-1}(-\infty, x_2]; x_2 \in \mathbb{R}\}; \\ \mathcal{L}_1 &= \{X_1^{-1}[x_1, \infty); x_1 \in \mathbb{R}\}, & \mathcal{L}_2 &= \{X_2^{-1}[x_2, \infty); x_2 \in \mathbb{R}\}. \end{aligned}$$

Theoria clasică a probabilităților culminează cu un studiu extensiv al sirurilor (infinite) de v.a. (reale) independente (vezi cap. 4). Un astfel de sir se caracterizează prin aceea că orice submulțime finită de elemente ale sale este constituită din v.a. independente.

Exemplul 1. Se consideră v.a.

$$X : \begin{pmatrix} 5 & 10 \\ \frac{1}{3} & \frac{2}{3} \end{pmatrix}$$

Funcția sa de repartiție este

$$F_X(x) = \begin{cases} 0, & x < 5 \\ \frac{1}{3}, & 5 \leq x < 10 \\ 1, & x \geq 10 \end{cases}.$$

Exemplul 2. Se aruncă un zar. Fie căruia eveniment elementar, ce constă în apariția unei fețe, i se asociază unul din numerele 1,2,...,6, numere scrise pe fețele zarului. V.a. X poate lua șase valori $x_i = i$, $i = \overline{1,6}$, cu aceeași probabilitate $P(X = x_i) = \frac{1}{6}$, $i = \overline{1,6}$. Să se reprezinte grafic funcția $P(X < x)$.

Deoarece evenimentul ca v.a. X să ia valori mai mici ca 1 este imposibil, rezultă $P(X < 1) = 0$.

Dacă x este un număr satisfăcând inegalitățile $1 \leq x < 2$ atunci

$$P(X < x) = P(X = 1) = \frac{1}{6}.$$

Dacă $2 \leq x < 3$, atunci

$$P(X < x) = P(X = 1) + P(X = 2) = \frac{1}{3}.$$

Analog, pentru $5 \leq x < 6$ rezultă

$$P(X < x) = \sum_{i=1}^5 P(X = i) = \frac{5}{6},$$

iar pentru $x \geq 6$, rezultă

$$P(X < x) = P(X \leq 6) = \sum_{i=1}^6 P(X = i) = 1.$$

Graficul este o funcție în scară (vezi fig. 2.1).

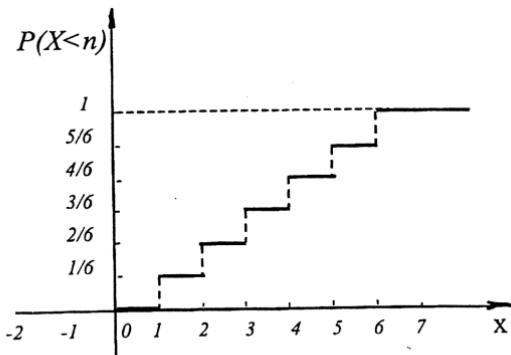


Fig. 2.1.

Exemplul 3. Se aruncă două zaruri. Să se calculeze funcția de repartiție a sumei punctelor obținute. Suma punctelor obținute prin aruncarea a două zaruri determină următoarea v.a.

$$X : \left(\begin{array}{cccccccccccc} 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 & 11 & 12 \\ \frac{1}{36} & \frac{2}{36} & \frac{3}{36} & \frac{4}{36} & \frac{5}{36} & \frac{6}{36} & \frac{5}{36} & \frac{4}{36} & \frac{3}{36} & \frac{2}{36} & \frac{1}{36} \end{array} \right).$$

Funcția de repartiție este

$$F_X(x) = \begin{cases} 0, & x < 2 \\ \frac{1}{36}, & 2 \leq x < 3 \\ \frac{3}{36}, & 3 \leq x < 4 \\ \dots \\ \frac{35}{36}, & 11 \leq x < 12 \\ 1, & x \geq 12. \end{cases}$$

Exemplul 4. Se consideră funcția $p : \mathbb{R} \rightarrow \mathbb{R}$ definită prin

$$p(x) = \begin{cases} a e^{-x/5}, & x > 0 \\ 0, & \text{în rest} \end{cases}$$

unde $a \in \mathbb{R}$. Se cer valorile parametrului a pentru care p este o densitate de probabilitate. Întrucât p este pozitivă și integrabilă pentru orice $a \in \mathbb{R}$,

singura condiție care trebuie impusă este $\int_{-\infty}^{\infty} p(x)dx = 1$, care conduce la

$$a \int_0^{\infty} e^{-x/5} dx = 1, \text{ de unde se deduce } a = \frac{1}{5}.$$

Exemplul 5. Se presupune că durata unei con vorbiri telefonice la distanță mare este o v.a. X cu funcția de repartiție

$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1 - \frac{1}{2}e^{-x/3} - \frac{1}{2}e^{-[x/3]}, & x \geq 0 \end{cases}$$

unde prin $[y]$ se înțelege cel mai mare număr întreg mai mic sau egal cu y (partea întreagă a lui y). Să se calculeze $P(X > 6)$ și $P(X = 3)$.

$$P(X > 6) = 1 - P(X \leq 6) = 1 - F_X(6) = \frac{1}{2}e^{-2} + \frac{1}{2}e^{-[2]} \simeq 0,135,$$

$$P(X = 3) = F_X(3) - F_X(3 - 0) = \frac{1}{2}(1 - e^{-1}) \simeq 0,316.$$

Exemplul 6. Momentul sosirii unui semnal este o v.a. T cu densitatea de probabilitate p . Până la un moment $t_0 < \tau$ semnalul nu a venit. Să se determine probabilitatea ca el să sosească în intervalul de timp $(t_0, \tau]$ (vezi fig. 2.2).

Se consideră evenimentul $A(t)$ ce constă în faptul că semnalul sosește în intervalul $(0, t]$. Atunci

$$P(A(t)) = P(T \leq t) = \int_0^t p(u)du.$$

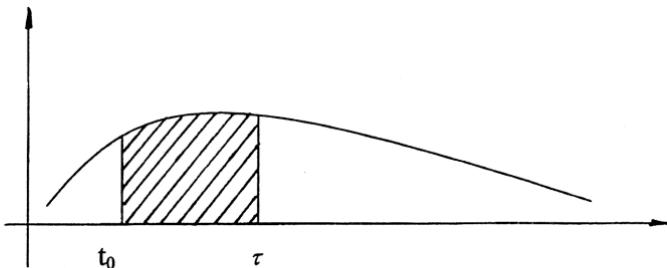


Fig.2.2.

Trebuie calculată probabilitatea $q = P(A(\tau) | \overline{A(t_0)})$. Deoarece

$$\begin{aligned} P(A(\tau)) &= P(A(\tau)) \cap A(t_0)) + P(A(\tau)) \cap \overline{A(t_0)} = \\ &= P(A(t_0)) + P(\overline{A(t_0)}) \cdot P(A(\tau) | \overline{A(t_0)}) \end{aligned}$$

rezultă că

$$\int_0^\tau p(t)dt = \int_0^{t_0} p(t)dt + \left[1 - \int_0^{t_0} p(t)dt \right] q.$$

Prin urmare

$$q = \frac{\int_0^\tau p(t)dt}{1 - \int_0^t p(t)dt}.$$

Exemplul 7. Două mesaje sunt transmise, independent unul de altul, putând fi distorsionate sau nu. Probabilitățile de distorsiune pentru cele două mesaje sunt p_1 și respectiv p_2 . Se consideră v.a. X și Y definite astfel

$$X = \begin{cases} 1, & \text{dacă primul mesaj este distorsionat} \\ 0, & \text{dacă primul mesaj nu este distorsionat} \end{cases}$$

$$Y = \begin{cases} 1, & \text{dacă al doilea mesaj este distorsionat} \\ 0, & \text{dacă al doilea mesaj nu este distorsionat.} \end{cases}$$

Să se determine funcția de repartiție a vectorului aleator (X, Y) .

Dacă se notează cu C -mesaj transmis corect și cu D -mesaj transmis distorsionat, atunci spațiul evenimentelor elementare este reprezentat în tabelul 2.1.

	C	D
C	(C,C)	(C,D)
D	(D,C)	(D,D)

Tabelul 2.1.

	C	D
C	$q_1 q_2$	$q_1 p_2$
D	$p_1 q_2$	$p_1 p_2$

Tabelul 2.2.

De exemplu, evenimentul (D, C) înseamnă că primul mesaj a fost distorsionat, iar cel de al doilea corect. Dacă se notează $q_1 = 1 - p_1$, $q_2 = 1 - p_2$, atunci probabilitățile acestor evenimente sunt date în tabelul 2.2. și de aici se deduce repartiția (funcția de frecvență) vectorului aleator (X, Y) (tabelul 2.3.). Funcția de repartiție este dată în tabelul 2.4.

X \ Y	0	1
0	$q_1 q_2$	$q_1 p_2$
1	$p_1 q_2$	$p_1 p_2$

Tabelul 2.3.

$X \setminus Y$	$Y < 0$	$0 \leq Y < 1$	$Y \geq 1$
$X < 0$	0	0	0
$0 \leq X < 1$	0	$q_1 q_2$	q_1
$X \geq 1$	0	q_2	1

Tabelul 2.4.

Exemplul 8. Se reia exemplul 6, §1.2, pentru $r = 1$. Pentru un punct A de pe ecran se notează cu R și ϕ coordonatele sale polare într-un sistem de axe (vezi fig.2.3). Evident, R și ϕ sunt v.a. Să se determine densitatea de probabilitate $p(\rho, \varphi)$ a vectorului aleator (R, ϕ) și să se precizeze dacă R și ϕ sunt v.a. independente.

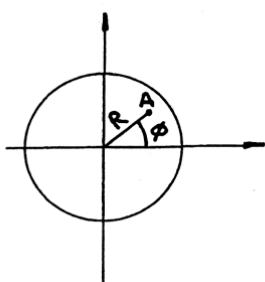


Fig. 2.3.

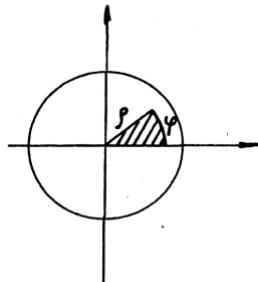


Fig. 2.4.

Se observă că $p(\rho, \varphi) = 0$ pentru $\rho > 1$ sau și $\varphi \notin [0, 2\pi)$. Pentru $0 < \rho \leq 1$ și $0 \leq \varphi < 2\pi$ rezultă

$$P(R \leq \rho, \phi \leq \varphi) = P(A \in D) = \frac{\text{aria } D}{\pi} = \frac{\rho^2 \varphi}{2\pi},$$

unde D este domeniul hașurat din fig. 2.4. Conform relației (2.4) se obține

$$p(\rho, \varphi) = \begin{cases} \frac{\rho}{\pi}, & 0 < \rho \leq 1; 0 \leq \varphi < 2\pi \\ 0, & \text{în rest.} \end{cases}$$

Densițările de probabilitate ale v.a. R și ϕ sunt respectiv (vezi (2.5))

$$p_R(\rho) = \int_0^{2\pi} p(\rho, \varphi) d\varphi = 2\rho, \quad 0 < \rho \leq 1,$$

$$p_\phi(\varphi) = \int_0^1 p(\rho, \varphi) d\rho = \frac{1}{2\pi}, \quad 0 \leq \varphi < 2\pi.$$

Întrucât $p(\rho, \varphi) = p_R(\rho) \cdot p_\phi(\varphi)$, rezultă că v.a. R și ϕ sunt independente conform relației (2.6).

Exemplul 9. (*Acul lui Buffon*). Pe o suprafață plană orizontală sunt trase drepte paralele echidistante la distanța $2a$. Un ac de lungime $2l$ ($l < a$) este aruncat pe această suprafață. Fie ϕ v.a. care desemnează unghiul (cuprins între 0 și π) făcut de ac cu direcția paralelor (vezi fig.2.5), iar X v.a. care desemnează distanța de la mijlocul acului la cea mai apropiată paralelă.

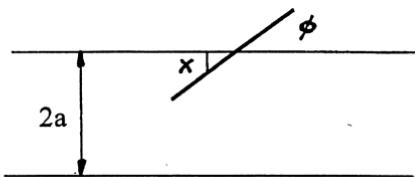


Fig. 2.5.

Se fac următoarele ipoteze:

- densitatea de probabilitate a v.a. X este

$$p_X(x) = \begin{cases} \frac{1}{a}, & 0 \leq x \leq a \\ 0, & \text{în rest} \end{cases}$$

- densitatea de probabilitate a v.a. ϕ este

$$p_\phi(\varphi) = \begin{cases} \frac{1}{\pi}, & 0 \leq \varphi \leq \pi \\ 0, & \text{în rest} \end{cases}$$

- v.a. X și ϕ sunt independente.

Se cere probabilitatea ca acul să întâlnească una dintre paralele.

Conform relației (2.6) densitatea de probabilitate a vectorului aleator (X, ϕ) este

$$p(x, \varphi) = p_X(x)p_\phi(\varphi) = \begin{cases} \frac{1}{a\pi}, & 0 \leq x \leq a, 0 \leq \varphi \leq \pi \\ 0, & \text{în rest.} \end{cases}$$

Condiția necesară și suficientă ca acul să întâlnească una dintre drepte este $X \leq l \sin \phi$. Prin urmare, dacă

$$A = \{(x, \varphi) | 0 \leq x \leq a, 0 \leq \varphi \leq \pi, x \leq l \sin \varphi\}$$

(vezi fig. 2.6), atunci conform relației (2.3) probabilitatea căutată este

$$\begin{aligned} P((X, \phi) \in A) &= \iint_A p(x, \varphi) dx d\varphi = \frac{1}{a\pi} \iint_A dx d\varphi = \\ &= \frac{\text{aria } A}{a\pi} = \frac{\int_0^\pi l \sin \varphi d\varphi}{a\pi} = \frac{2l}{a\pi}. \end{aligned}$$

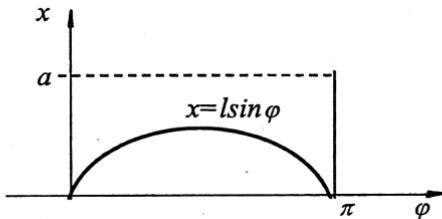


Fig. 2.6.

2.3 Funcții de variabile aleatoare

De remarcat este faptul că toate operațiile aritmetice și trecerile la limită (pentru șiruri) efectuate pe v.a., conduc la alte v.a. Mai precis, dacă X și Y sunt v.a. pe un același câmp de probabilitate, atunci $X+Y$, $X \cdot Y$, $\frac{X}{Y}$ ($Y \neq 0$) și deci, în particular, $X+c$ și cX , unde c este un număr real arbitrar, sunt v.a.

Mai general, fie $f : \mathbf{R}^n \rightarrow \mathbf{R}$ o funcție astfel încât pentru orice $a \in \mathbf{R}$ mulțimea

$$\{(x_1, x_2, \dots, x_n) \mid f(x_1, x_2, \dots, x_n) < a\}$$

este o mulțime boreliană din \mathbf{R}^n (adică o mulțime din \mathcal{B}^n) (de exemplu, aceasta se întâmplă dacă f este continuă), iar X_1, X_2, \dots, X_n v.a. reale. Atunci funcția $Y = f(X_1, X_2, \dots, X_n)$ care în punctul ω ia valoarea

$$Y(\omega) = f(X_1(\omega), X_2(\omega), \dots, X_n(\omega))$$

este de asemenea o v.a. Dacă vectorul aleator (X_1, X_2, \dots, X_n) admite densitatea de probabilitate p , iar F_Y este funcția de repartiție a v.a. Y , atunci are loc următoarea formulă

$$F_Y(x) = \int_B p(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n \quad (2.7)$$

unde

$$B = \{(x_1, x_2, \dots, x_n) \in \mathbf{R}^n \mid f(x_1, x_2, \dots, x_n) \leq x\}.$$

Fie $f : \mathbf{R} \rightarrow \mathbf{R}$ o funcție derivabilă, cu derivata nenulă cu excepția unei mulțimi cel mult numărabile de puncte, dar care sunt în număr finit în orice interval mărginit. Se presupune că ecuația $f(x) = y$, $y \in \mathbf{R}$, admite un număr finit de soluții în orice interval mărginit. Mulțimea tuturor soluțiilor ecuației va fi notată $\{x_1, x_2, \dots\}$.

Se consideră v.a. X cu densitatea de probabilitate p_X , precum și v.a. $Y = f(X)$. În condițiile de mai sus, densitatea de probabilitate ρ_Y a v.a. Y este

$$\rho_Y = \sum_{k \in \mathbf{N}^*} p_X(x_k) / |f'(x_k)|. \quad (2.8)$$

Dacă $\{X_i \mid i \in I\}$ este o familie numărabilă de v.a., atunci aplicațiile $\sup_{i \in I} X_i$ și $\inf_{i \in I} X_i$ sunt v.a. De aceea se pot defini pentru orice sir $\{X_n \mid n \geq 1\}$ de v.a., noile v.a.

$$\limsup_{n \rightarrow \infty} X_n = \inf_n \sup_{m \geq n} X_m$$

$$\liminf_{n \rightarrow \infty} X_n = \sup_n \inf_{m \geq n} X_m.$$

Mulțimea de convergență a sirului $\{X_n \mid n \geq 1\}$ este definită ca fiind mulțimea măsurabilă

$$\{\limsup_{n \rightarrow \infty} X_n = \liminf_{n \rightarrow \infty} X_n\}.$$

În particular, dacă $\limsup_{n \rightarrow \infty} X_n = \liminf_{n \rightarrow \infty} X_n$ pe Ω , se spune că sirul $\{X_n \mid n \geq 1\}$ converge peste tot și se notează cu $\lim_{n \rightarrow \infty} X_n$ expresia comună precedentă. Astfel limita oricărui sir convergent de v.a. este încă o v.a.

Dacă $\{X_n \mid n \geq 1\}$ este un sir crescător (respectiv descrescător) de v.a. convergent punctual la v.a. X , atunci se adoptă notația

$$X_n \uparrow X \quad (\text{respectiv } X_n \downarrow X), \quad n \rightarrow \infty.$$

Exemplul 1. Fie $Y = X_1 + X_2$ o v.a. Utilizând formula (2.7) se obține

$$F_Y(x) = \int \int_{\{x_1+x_2 \leq x\}} p(x_1, x_2) dx_1 dx_2,$$

integrala dublă efectuându-se pe domeniul hașurat (vezi fig. 2.7).

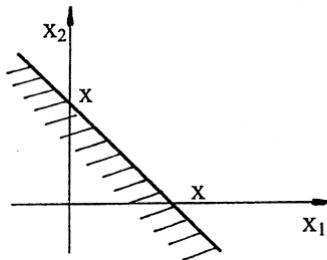


Fig. 2.7

Dacă se face schimbarea de variabile $u = x_1$, $v = x_1 + x_2$, atunci domeniul de integrare devine $\{(u, v) | u \in \mathbb{R}, v \leq x\}$; cum jacobianul acestei transformări este 1 se obține

$$F_Y(x) = \int_{-\infty}^x dv \int_{-\infty}^{\infty} p(u, v-u) du. \quad (2.9)$$

Din relația (2.9), prin derivare în raport cu x , se găsește densitatea de probabilitate ρ_Y a v.a. Y

$$\rho_Y(x) = \int_{-\infty}^{\infty} p(u, x-u) du. \quad (2.10)$$

Dacă v.a. X_1 și X_2 sunt pozitive, deci $p(x_1, x_2) = 0$ pentru $x_1 \leq 0$ sau/și $x_2 \leq 0$, formulele (2.9) și (2.10) devin

$$F_Y(x) = \int_0^x dv \int_0^x p(u, v-u) du \quad (2.11)$$

și respectiv

$$\rho_Y(x) = \int_0^x p(u, x-u) du. \quad (2.12)$$

Dacă v.a. X_1 și X_2 sunt independente și au densitățile de probabilitate p_1 și respectiv p_2 , atunci (2.10) devine

$$\rho_Y(x) = \int_{-\infty}^{\infty} p_1(u)p_2(x-u) du. \quad (2.13)$$

Exemplul 2. Fie $Y = X^2$ o v.a., iar p densitatea de probabilitate a v.a. X . Utilizând relația (2.7) rezultă

$$F_Y(x) = \int_{\{y^2 \leq x\}} p(y) dy, \quad x > 0,$$

sau

$$F_Y(x) = \int_{-\sqrt{x}}^{\sqrt{x}} p(y) dy$$

de unde, prin derivare în raport cu x se găsește densitatea de probabilitate

$$\rho_Y(x) = \frac{1}{2\sqrt{x}}(p(\sqrt{x}) + p(-\sqrt{x})), \quad x > 0.$$

Exemplul 3. Se consideră vectorul aleator $X = (X_1, X_2)$ având densitatea de probabilitate $p(x_1, x_2)$. Să se calculeze densitatea de probabilitate a v.a. $Y = \sqrt{X_1^2 + X_2^2}$. Pentru aceasta se utilizează relația (2.7) și se obține

$$F_Y(x) = \begin{cases} 0, & x \leq 0 \\ \iint_{\{x_1^2 + x_2^2 \leq x^2\}} p(x_1, x_2) dx_1 dx_2, & x > 0. \end{cases}$$

Trecând la coordonate polare $x = \rho \cos \theta$, $y = \rho \sin \theta$, $\rho > 0$, $0 < \theta < 2\pi$,

$$F_Y(x) = \int_0^{2\pi} d\theta \int_0^x p(\rho \cos \theta, \rho \sin \theta) \rho d\rho, \quad x > 0.$$

Densitatea de probabilitate ρ_Y a v.a. Y se obține prin derivare în raport cu x

$$\rho_Y(x) = \int_0^{2\pi} x p(x \cos \theta, x \sin \theta) d\theta, \quad x > 0.$$

Exemplul 4. Trei obuze sunt trase independent. Distanța de la obiectiv la punctele de impact sunt trei v.a. X_1, X_2, X_3 independente și identic repartizate, având densitatea de probabilitate p și funcția de repartiție G . Să se determine probabilitatea ca cel puțin unul din obuze să cadă la o distanță mai mică sau egală cu x_0 de obiectiv.

Fie $Y = \min(X_1, X_2, X_3)$. Se va determina funcția de repartiție și densitatea de probabilitate a v.a. Y . Conform relațiilor (2.6) și (2.7) rezultă

$$\begin{aligned} F_Y(x) &= \iiint_{\{\min(x_1, x_2, x_3) \leq x\}} p(x_1)p(x_2)p(x_3) dx_1 dx_2 dx_3 = \\ &= \iiint_{\{x_1 < x, x_1 < x_2, x_1 < x_3\}} p(x_1)p(x_2)p(x_3) dx_1 dx_2 dx_3 + \\ &+ \iiint_{\{x_2 < x, x_2 < x_1, x_2 < x_3\}} p(x_1)p(x_2)p(x_3) dx_1 dx_2 dx_3 + \\ &+ \iiint_{\{x_3 < x, x_3 < x_1, x_3 < x_2\}} p(x_1)p(x_2)p(x_3) dx_1 dx_2 dx_3. \end{aligned}$$

Cum cele trei integrale triple sunt egale datorită simetriei, rezultă

$$\begin{aligned} F_Y(x) &= 3 \int_0^x dx_1 \int_{x_1}^\infty dx_2 \int_{x_1}^\infty p(x_1)p(x_2)p(x_3)dx_3 = \\ &= 3 \int_0^x [1 - G(x_1)]^2 p(x_1)dx_1. \end{aligned}$$

Prin urmare densitatea de probabilitate a v.a. Y este

$$\rho_Y(x) = 3[1 - G(x)]^2 p(x), \quad x > 0$$

și

$$P(Y \leq x_0) = F_Y(x_0) = \int_0^{x_0} \rho_Y(x)dx.$$

Exemplul 5. Se consideră două v.a. independente X și Y cu densitățile de probabilitate $p(x)$ și respectiv $q(y)$. Să se calculeze probabilitatea evenimentului $\{X \leq Y\}$.

Dacă se notează $Z = X - Y$, atunci conform relațiilor (2.6) și (2.7), funcția de repartição a v.a. Z este

$$F(z) = \iint_{\{x-y<z\}} p(x)q(y)dxdy$$

și utilizând schimbarea de variabile $x - y = u$, $y = v$ rezultă

$$F(z) = \int_{-\infty}^z du \int_{-\infty}^{\infty} p(u+v)q(v)dv.$$

Probabilitatea căutată este

$$P(Z \leq 0) = F(0) = \int_{-\infty}^0 du \int_{-\infty}^{\infty} p(u+v)q(v)dv = \int_0^{\infty} du \int_{-\infty}^{\infty} p(v-u)q(v)dv.$$

În particular, dacă $p = q$ este continuă și G este funcția de repartição (comună) a v.a. X și X atunci

$$\begin{aligned} F(0) &= \int_{-\infty}^{\infty} \left[p(y) \int_{-\infty}^y p(x)dx \right] dy = \int_{-\infty}^{\infty} p(y)G(y)dy = \\ &= \int_{-\infty}^{\infty} G(y)G'(y)dy = \frac{G^2(y)}{2} \Big|_{-\infty}^{\infty} = \frac{1}{2}. \end{aligned}$$

Deci $P(X \leq Y) = \frac{1}{2}$.

Exemplul 6. Fie X_1, X_2, \dots, X_n v.a. independente având funcțiile de repartição F_1, F_2, \dots, F_n . Se consideră v.a.

$$M = \max(X_1, X_2, \dots, X_n)$$

$$m = \min(X_1, X_2, \dots, X_n).$$

Să se determine funcțiile lor de repartiție F_{\max} , respectiv F_{\min} . Se obține

$$\begin{aligned} F_{\max}(x) &= P(M \leq x) = P(X_1 \leq x, X_2 \leq x, \dots, X_n \leq x) = \\ &= P(X_1 \leq x)P(X_2 \leq x), \dots, P(X_n \leq x) = F_1(x)F_2(x)\dots F_n(x) \end{aligned}$$

pentru orice $x \in \mathbb{R}$. În particular, dacă F_i , $i = \overline{1, n}$, sunt egale, atunci $F_{\max}(x) = F^n(x)$.

Pentru a determina F_{\min} este convenabil să se introducă funcția G_i , corespunzătoare fiecărei F_i astfel

$$G_i(x) = P(X_i > x) = 1 - F_i(x).$$

Atunci se obține

$$\begin{aligned} G_{\min}(x) &= P(m > x) = P(X_1 > x, X_2 > x, \dots, X_n > x) = \\ &= P(X_1 > x)P(X_2 > x)\dots P(X_n > x) = \\ &= G_1(x)G_2(x)\dots G_n(x). \end{aligned}$$

Dacă F_i , $i = \overline{1, n}$, sunt egale, atunci

$$G_{\min}(x) = G^n(x), \quad F_{\min}(x) = 1 - G^n(x).$$

2.4 Valori medii și valori medii condiționate

O altă noțiune fundamentală în teoria probabilităților este noțiunea de medie sau speranță matematică a unei v.a.

Dacă X este o v.a. discretă cu repartiția $p_X(x_i) = p_i$, iar f o funcție reală sau complexă arbitrară definită pe mulțimea valorilor lui X , se definește *valoarea medie* a lui $f(X)$, notată $E(f(X))$, ca suma seriei $\sum_i f(x_i)p_i$ (presupunând seria absolut convergentă⁷, adică $\sum_i |f(x_i)|p_i < \infty$).

Dacă X este o v.a. continuă cu densitatea p , iar f o funcție reală sau complexă măsurabilă de variabilă reală, se definește valoarea medie a lui $f(X)$, notată $E(f(X))$, ca valoarea integrală $\int_{-\infty}^{\infty} f(x)p(x)dx$ (presupunând integrala absolut convergentă, adică $\int_{-\infty}^{\infty} |f(x)|p(x)dx < \infty$).

Integrala este concepută în sens Lebesgue. Prin urmare, dacă $f : \mathbb{R} \rightarrow \mathbb{R}$, atunci f trebuie să fie măsurabilă Borel; dacă $f : \mathbb{R} \rightarrow \mathbb{C}$, atunci Ref și

⁷Această condiție este întotdeauna satisfăcută în cazul în care mulțimea valorilor lui X este finită.

Imf trebuie să fie măsurabile Borel. Cazurile cele mai întâlnite care asigură existența valorii medii sunt aceleia în care integrala impropriu (în sens Riemann) $\int_{-\infty}^{\infty} f(x)dx$ este absolut convergentă sau când f este mărginită și integrabilă Riemann pe orice compact din \mathbf{R} . Definițiile din acest paragraf sunt date numai pentru v.a. discrete sau care admit densitate de probabilitate, care reprezintă cazurile cele mai frecvente.

Valoarea medie corespunzătoare alegerii $f(x) = x^m$, $m \in \mathbf{N}^*$, se numește *momentul de ordinul m* al lui X (presupusă reală) și se notează $E(X^m)$ sau $M_m(X)$. Prin urmare momentul de ordinul m se calculează prin formulele

$$E(X^m) = \sum_i x_i^m p_i, \quad \text{dacă } X \text{ este o v.a. discretă}$$

$$E(X^m) = \int_{-\infty}^{\infty} x^m p(x)dx, \quad \text{dacă } X \text{ este o v.a. continuă}$$

cu densitatea p .

Valoarea medie corespunzătoare alegerii $f(x) = |x|^r$, $r > 0$, se numește *momentul absolut de ordinul r* al lui X și se notează $E(|X|^r)$ sau $\bar{M}_r(X)$. Prin urmare

$$E(|X|^r) = \sum_i |x_i|^r p_i$$

sau

$$E(|X|^r) = \int_{-\infty}^{\infty} |x|^r p(x)dx.$$

Pentru $m = 1$ se obține *valoarea medie* sau *media* lui X , notată $E(X)$. Deci

$$E(X) = \sum_i x_i p_i \quad \text{sau} \quad E(X) = \int_{-\infty}^{\infty} x p(x)dx.$$

O v.a. X se numește *P-integrabilă* dacă $E(X^+) < \infty$ și $E(X^-) < \infty$, unde

$$X^+ = \sup(X, 0), \quad \text{iар} \quad X^- = \sup(-X, 0) = -\inf(X, 0).$$

Aplicațiile X^+ și X^- sunt pozitive, $X = X^+ - X^-$, iar $E(X) = E(X^+) - E(X^-)$.

O v.a. X se numește *P-sumabilă* dacă $E(X^+) < \infty$ sau $E(X^-) < \infty$. De remarcat este faptul că *P-sumabilitatea* este condiția cea mai generală care permite să se definească $E(X)$ ca $E(X^+) - E(X^-)$.

Plecând de la definiția mediei, se deduc următoarele proprietăți:

- a) dacă $X = c = \text{const.}$, atunci $E(X) = c$;
 - b) (*monotonie*) dacă $X \leq Y$, atunci $E(X) \leq E(Y)$;
 - c) $E(aX) = aE(X)$ pentru orice număr real a ;
 - d) (*aditivitatea*) $E(X + Y) = E(X) + E(Y)$;
- (2.14)

e) dacă X și Y sunt independente, atunci $E(XY) = E(X)E(Y)$.

Proprietățile d) și e) pot fi extinse și pentru un număr finit de v.a. De asemenea, se remarcă că dacă aditivitatea mediei E este un rezultat general, deja cunoscut din teoria integrării, e) este specific teoriei probabilităților, necesitând independența v.a. Dacă în particular, se consideră $X_i = \chi_{A_i}$ ($i = \overline{1, n}$), atunci extensia proprietății e) se reduce la

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1)P(A_2) \dots P(A_n)$$

dacă $\{A_i | i = \overline{1, n}\}$ este o familie de evenimente independente, în timp ce

$$E(\chi_{A_1} + \chi_{A_2} + \dots + \chi_{A_n}) = P(A_1) + P(A_2) + \dots + P(A_n),$$

fără să se impună condiții suplimentare pentru evenimentele A_i . Mult timp, acest fapt, cunoscut ca paradoxul lui Cardano⁸, a creat confuzie.

Este important de semnalat, altă proprietate a mediei și anume proprietatea de *continuitate monoton secvențială*, enunțată astfel:

f) dacă $\{X_n | n \geq 1\}$ este un sir crescător de v.a. P -integrabile, convergent la o v.a. X , atunci

$$X_n \uparrow X (n \rightarrow \infty) \Rightarrow E(X_n) \uparrow E(X);$$

f') dacă $\{X_n | n \geq 1\}$ este un sir crescător de v.a. convergent la o v.a. X , astfel încât X_n^- este P -integrabilă pentru cel puțin un indice n , atunci

$$X_n \uparrow X (n \rightarrow \infty) \Rightarrow E(X_n) \uparrow E(X).$$

Dacă (X_1, X_2, \dots, X_n) este un vector aleator cu densitatea de probabilitate $p(x_1, x_2, \dots, x_n)$, iar $h : \mathbf{R}^n \rightarrow \mathbf{R}$ este o funcție măsurabilă Borel, atunci valoarea medie a v.a. $Y = h(X_1, X_2, \dots, X_n)$ este

$$E(Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} h(x_1, x_2, \dots, x_n) p(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n.⁹$$

Pentru un vector aleator (X_1, X_2, \dots, X_n) , media este vectorul valorilor medii $(E(X_1), E(X_2), \dots, E(X_n))$.

Momentul de ordinul m , $m \in \mathbf{N}^*$, al v.a. $X - E(X)$ se numește *momentul centrat de ordinul m* al lui X .

Momentul absolut de ordinul r , $r > 0$, al v.a. $X - E(X)$ se numește *momentul centrat absolut de ordinul r* al lui X .

⁸Gerolamo Cardano (1501-1576) a scris prima carte despre jocurile de noroc.

⁹Se deduce din relația (2.7).

Momentul centrat de ordinul 2 se numește *varianță* sau *dispersia* lui X și se notează $\text{Var}(X)$ sau $D(X)$. Deci

$$\text{Var}(X) = \sum_i (x_i - E(X))^2 p_i$$

sau

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - E(X))^2 p(x) dx.$$

Varianța este un indicator important al impreăstierii valorilor v.a. după cum rezultă din *inegalitatea lui Cebîșev*¹⁰.

$$P(|X - E(X)| > \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}, \quad \forall \varepsilon > 0. \quad (2.15)$$

Proprietățile varianței sunt:

- a) $\text{Var}(X) = E(X^2) - (E(X))^2$;
- b) dacă $X = c = \text{const.}$, atunci $\text{Var}(X) = 0$;
- c) $\text{Var}(aX) = a^2 \text{Var}(X)$ pentru orice număr real a ;
- d) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2E((X - E(X))(Y - E(Y)))$;
- e) dacă X și Y sunt independente, atunci $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

Proprietatea e) poate fi extinsă și pentru un număr finit de v.a. independente.

Valoarea $\sigma(X) = \sqrt{\text{Var}(X)}$ se numește *abatere medie pătratică*.

Mediană unei funcții de repartiție F este valoarea m pentru care au loc inegalitățile $F(m - 0) \leq \frac{1}{2} \leq F(m)$. Dacă F este continuă atunci există cel puțin o valoare m pentru care $F(m) = \frac{1}{2}$.

Dacă în relația de definiție a medianei se pune în loc de $\frac{1}{2}$ valoarea $\frac{1}{n}$, $n \in \mathbb{N}$, $n > 2$, se obține definiția *cuantilei de ordin n*.

Modul unei repartiții se definește pentru v.a. discrete, precum și pentru v.a. care admit densitate de probabilitate. Astfel, pentru o v.a. discretă modul este valoarea care are cea mai mare probabilitate de realizare. În cazul existenței densității, modul este maximul funcției de densitate.

Repartițiile pot fi *unimodale* sau *multimodale*.

Valoarea medie a produsului $(X - E(X))(Y - E(Y))$ se numește *corelația* sau *covarianța* v.a. X și Y și se notează $\text{cov}(X, Y)$. Evident $\text{cov}(X, X) = \text{Var}(X)$ și

$$\text{cov}(X, Y) = E(XY) - E(X) \cdot E(Y).$$

¹⁰P.L.Cebîșev (1821-1894) a fost un mare matematician rus.

Acest concept servește la caracterizarea dependenței a două v.a. Dacă v.a. X și Y au corelația nulă, se mai spune că sunt *necorelate*. Condiția necesară și suficientă ca v.a. X și Y să fie necorelate este ca $E(XY) = E(X) \cdot E(Y)$. Rezultă că două v.a. independente sunt necorelate. Reciproca acestei afirmații nu este adevărată. Ea va fi justificată prin exemplul 10.

Fie (X_1, X_2, \dots, X_n) un vector aleator. Matricea cu elementele $\text{cov}(X_i, X_j)$, $1 \leq i, j \leq n$, se numește *matrice de corelație (covarianță)*.

Raportul

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}, \quad \text{Var}(X) \neq 0, \quad \text{Var}(Y) \neq 0,$$

se numește *coeficientul de corelație* al v.a. X și Y . Coeficientul de corelație are valori cuprinse între -1 și 1. Valorile extreme corespund cazului în care între X și Y există legătura funcțională de forma

$$Y = E(Y) + \left(\frac{\text{Var}(Y)}{\text{Var}(X)} \right)^{1/2} \cdot (X - E(X)).$$

Valorile pozitive ale lui $\rho(X, Y)$ pot indica existența unei tendințe ca la valorile mari ale lui Y să corespundă valori mari ale lui X . Valorile negative ale lui $\rho(X, Y)$ pot indica existența unei tendințe ca la valorile mici ale lui Y să corespundă valori mari ale lui X , iar la valorile mari ale lui Y valori mici pentru X . Valorile lui $\rho(X, Y)$ apropiate de zero pot indica faptul că aceste tendințe sunt slabe, în timp ce valorile lui $\rho(X, Y)$ apropiate de ± 1 pot indica faptul că aceste tendințe sunt puternice.

Fie X și Y două v.a. discrete cu valorile x_1, x_2, \dots , respectiv y_1, y_2, \dots , iar f o funcție reală sau complexă arbitrară definită pe mulțimea valorilor lui X . Se definește *valoarea medie a lui $f(X)$ condiționată de $Y = y_j$* , $j = 1, 2, \dots$, notată $E(f(X)|Y = y_j)$, ca media v.a. discrete ce ia valorile $f(x_1), f(x_2), \dots$ cu probabilitățile

$$p(x_i|y_j) = P(X = x_i|Y = y_j), \quad i = 1, 2, \dots$$

Prin urmare

$$E(f(X)|Y = y_j) = \sum_i f(x_i)p(x_i|y_j).$$

Se verifică imediat că

$$E(f(X)) = \sum_j E(f(X)|Y = y_j) \cdot P(Y = y_j). \quad (2.17)$$

Fie (X, Y) un vector aleator cu densitatea de probabilitate $p(x, y)$, iar f o funcție reală sau complexă de variabilă reală¹¹. *Valoarea medie a lui $f(X)$*

¹¹Se presupune că f (respectiv Ref și $\text{Im}f$) este măsurabilă Borel.

condiționată de $Y = y$, notată $E(f(X)|Y = y)$, se definește prin egalitatea

$$E(f(X)|Y = y) = \frac{\int_{-\infty}^{\infty} f(x)p(x, y)dx}{\int_{-\infty}^{\infty} p(x, y)dx} = \frac{\int_{-\infty}^{\infty} f(x)p(x, y)dx}{p_Y(y)}$$

și are loc relația

$$E(f(X)) = \int_{-\infty}^{\infty} E(f(X)|Y = y)p_Y(y)dy, \quad (2.18)$$

unde s-a notat cu p_Y densitatea de probabilitate a v.a. Y .

De asemenea, dacă $a, b \in \mathbb{R}$, atunci probabilitatea evenimentului $\{a \leq X \leq b\}$ condiționată de $Y = y$, notată $P(a \leq X \leq b|Y = y)$, se definește prin egalitatea

$$P(a \leq X \leq b|Y = y) = \frac{\int_a^b p(x, y)dx}{p_Y(y)}$$

și are loc relația

$$P(a \leq X \leq b) = \int_{-\infty}^{\infty} P(a \leq X \leq b|Y = y)p_Y(y)dy. \quad (2.19)$$

Evenimentul $\{a \leq X \leq b\}$ se poate înlocui, în general, cu un eveniment de forma $\{X \in A\}$, unde $A \in \mathcal{B}$ și în acest caz

$$P(X \in A|Y = y) = \frac{\int_A p(x, y)dx}{p_Y(y)}.$$

În particular, $P(X \leq x|Y = y)$ este *repartiția lui X condiționată Y = y*. Funcția de repartiție F_X a v.a. X poate fi calculată prin utilizarea relației

$$F_X(x) = \int_{-\infty}^{\infty} P(X \leq x|Y = y)p_Y(y)dy. \quad (2.20)$$

Exemplul 1. Fie L un întreg pozitiv și $p_n = \frac{1}{L}$, $1 \leq n \leq L$. V.a. discretă care ia valorile $1, 2, \dots, L$ cu probabilitățile p_n , $1 \leq n \leq L$, are valoarea medie

$$E(X) = \frac{1}{L} \cdot \sum_{n=1}^L n = \frac{1}{L} \cdot \frac{L(L+1)}{2} = \frac{L+1}{2}.$$

În acest caz al v.a. X , uniform repartizată pe mulțimea $\{1, 2, \dots, L\}$, se observă că valoarea medie a lui X este egală cu media aritmetică a celor L valori ale v.a.

Exemplul 2. Se presupune că o monedă nedeformată este aruncată de un număr de ori până la apariția stemei. Fie X v.a. ce reprezintă numărul de aruncări până la apariția stemei, adică $\{X = n\}$ înseamnă că în primele $(n - 1)$ aruncări s-a obținut valoarea. Atunci

$$p_n = P(X = n) = \frac{1}{2^n}$$

deoarece rezultatul favorabil este reprezentat de secvența $\underbrace{v v \dots v}_{n-1 \text{ ori}} s$, unde $v =$ valoarea și $s =$ stema. Valoarea medie este

$$E(X) = \sum_{n=1}^{\infty} \frac{n}{2^n}.$$

Pentru a calcula suma seriei se pleacă de la seria

$$\sum_{n=0}^{\infty} x^n = 1 + x + \dots + x^n + \dots = \frac{1}{1-x} \quad \text{pentru } |x| < 1.$$

Prin derivare termen cu termen (seria precedentă fiind uniform convergentă pentru $|x| < 1$) se obține

$$\sum_{n=0}^{\infty} (n+1)x^n = 1 + 2x + \dots + nx^{n-1} + \dots = \frac{1}{(1-x)^2}, \quad |x| < 1.$$

Apoi luând $x = \frac{1}{2}$ se obține

$$4 = \sum_{n=0}^{\infty} (n+1) \cdot \left(\frac{1}{2}\right)^n,$$

de unde

$$4 = \sum_{n=0}^{\infty} \frac{n}{2^n} + \sum_{n=0}^{\infty} \frac{1}{2^n} = \sum_{n=1}^{\infty} \frac{n}{2^n} + 2.$$

Atunci $E(X) = 2$.

Se poate generaliza problema dacă se consideră o monedă deformată. În acest caz probabilitatea apariției stemei este p și a valorii este $q = 1 - p$. Atunci

$$p_n = \underbrace{(q \dots q)}_{n-1 \text{ ori}} p = q^{n-1} p$$

și valoarea medie devine

$$\sum_{n=1}^{\infty} nq^{n-1} \cdot p = p \sum_{n=0}^{\infty} (n+1)q^n = \frac{p}{(1-q)^2} = \frac{p}{p^2} = \frac{1}{p}.$$

V.a. X se numește "timpul de așteptare pentru apariția stemei" sau, mai general, pentru a avea "succes".

Exemplul 3. O monedă nedeformată este aruncată de n ori. Se consideră X_i rezultatul aruncării de rang i , cuantificat prin 1 sau 0, în acord cu obținerea stemei sau a valorii. Cu aceste notații, v.a. $S_n = X_1 + \dots + X_n$ reprezintă numărul de apariții ale stemei în n aruncări. Atunci rezultă

$$p_k = P(S_n = k) = C_n^k \cdot \frac{1}{2^n}, \quad 0 \leq k \leq n$$

și

$$E(S_n) = \sum_{k=0}^n C_n^k \frac{k}{2^n} = \frac{n}{2}.$$

Considerând o monedă deformată se poate din nou generaliza problema regăsind repartitia

$$P(S_n = k) = C_n^k p^k q^{n-k}, \quad 0 \leq k \leq n,$$

dacă

$$X_i = \begin{cases} 1, & \text{cu probabilitatea } p \\ 0, & \text{cu probabilitatea } q = 1 - p \end{cases} \quad \forall i = \overline{1, n}.$$

V.a. X_i , $i = \overline{1, n}$, se mai numesc și variabile bernoulliene. Atunci ținând seama că $E(X_i) = p$, $i = \overline{1, n}$, rezultă

$$E(S_n) = \sum_{i=1}^n E(X_i) = n p.$$

V.a. X_i , $i = \overline{1, n}$, fiind independente rezultă

$$\text{Var}(S_n) = \text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n) = npq,$$

deoarece $\text{Var}(X_i) = p - p^2 = pq$, $\forall i = \overline{1, n}$. $E(S_n)$ și $E(S_n^2)$ se pot calcula direct, dar este mult mai complicat.

Exemplul 4. Funcția de frecvență a v.a. X este

$$X : \begin{pmatrix} 0 & 1 & 2 & 3 \\ 0,216 & 0,432 & 0,288 & 0,064 \end{pmatrix}.$$

Conform definițiilor prezentate rezultă

$$E(X) = 0 \cdot 0,216 + 1 \cdot 0,432 + 2 \cdot 0,288 + 3 \cdot 0,064 = 1,2.$$

$$\begin{aligned} \text{Var}(X) &= (0 - 1,2)^2 \cdot 0,216 + (1 - 1,2)^2 \cdot 0,432 + \\ &+ (2 - 1,2)^2 \cdot 0,288 + (3 - 1,2)^2 \cdot 0,064 = 0,72. \end{aligned}$$

Exemplul 5. V.a. X are densitatea de probabilitate

$$p(x) = \begin{cases} ax, & 0 \leq x \leq 1 \\ 0, & x < 0 \text{ sau } x > 1. \end{cases}$$

Pentru ca p să fie o densitate de probabilitate se impune condiția $\int_{-\infty}^{\infty} p(x)dx = 1$, de unde $a = 2$. Așadar

$$E(X) = \int_{-\infty}^{\infty} xp(x)dx = 2 \int_0^1 x^2 dx = \frac{2}{3},$$

$$E(X^2) = \int_{-\infty}^{\infty} x^2 p(x)dx = 2 \int_0^1 x^3 dx = \frac{1}{2}$$

și prin urmare

$$\text{Var}(X) = \frac{1}{2} - \left(\frac{2}{3}\right)^2 = \frac{1}{18}.$$

Exemplul 6. V.a. X ia valorile 0 sau 1 după cum un circuit electronic este în stare de funcționare sau defect. Circuitul este conectat la o sursă a cărei tensiune U este o v.a. reală și pozitivă cu densitatea de probabilitate $p(x) = e^{-x}$, $x > 0$. Probabilitatea de defectare a circuitului este direct proporțională cu tensiunea U , fiind egală cu zero pentru $U = u_0$ și egală cu 1 pentru $U = u_1$. Se cere probabilitatea de defectare, adică $P(X = 1)$.

În condițiile date rezultă

$$P(X = 1 | U = u) = \begin{cases} 0, & u < u_0 \\ \frac{u - u_0}{u_1 - u_0}, & u_0 \leq u \leq u_1 \\ 1, & u > u_1. \end{cases}$$

Utilizând relația (2.19) rezultă

$$\begin{aligned} P(X = 1) &= \int_0^{\infty} P(X = 1 | U = u) e^{-u} du = \frac{1}{u_1 - u_0} \int_{u_0}^{u_1} (u - u_0) e^{-u} du + \\ &+ \int_{u_1}^{\infty} e^{-u} du = \frac{e^{-u_0} - e^{-u_1}}{u_1 - u_0}. \end{aligned}$$

Exemplul 7. Un dispozitiv are 4 siguranțe. În cazul suprasolicitărilor se arde o siguranță și este schimbată cu alta nouă. Să se determine valoarea medie a numărului de suprasolicitări N , după care în dispozitiv sunt schimbate toate siguranțele fixate inițial, dacă ieșirea din aparat în momentul solicitării uneia din cele n siguranțe este egal probabilă (siguranța neschimbată este considerată nouă).

Fie $E(N|k)$ valoarea medie a numărului de suprasolicitări, după care toate cele n siguranțe fixate inițial vor arăta schimbate, dacă au rămas neschimbate k siguranțe.

Dacă au rămas neschimbate k siguranțe ($k \geq 1$), atunci pentru deteriorarea uneia din ele este nevoie de o suprasolicitare următoare. În funcție de rezultatele suprasolicitării următoare vor fi diferite medii ale numărului de suprasolicitări necesare pentru arderea siguranțelor rămase din numărul celor fixate inițial. Deci pentru suprasolicitarea următoare se pot produce două evenimente

A_1 - a ars una din siguranțele fixate inițial

A_2 - a ars o siguranță schimbată.

Se obține

$$P(A_1) = \frac{k}{n} \quad \text{și} \quad P(A_2) = 1 - \frac{k}{n}.$$

Dacă prin solicitarea următoare se produce A_1 , atunci valoarea medie a numărului de solicitări pentru schimbarea tuturor celor k siguranțe neschimbate până la solicitarea următoare va fi

$$1 + E(N|k-1).$$

Dacă prin solicitarea următoare se produce A_2 , atunci valoarea medie este

$$1 + E(N|k).$$

Se obține

$$E(N|k) = 1 + \frac{k}{n}E(N|k-1) + \frac{n-k}{n}E(N|k).$$

Deci

$$E(N|k) - E(N|k-1) = \frac{n}{k}.$$

Dacă $k = 1$, adică a rămas numai o siguranță neschimbată, atunci probabilitatea schimbării ei este $\frac{1}{n}$, deci

$$E(N|1) = n.$$

Rezultă următorul sir de egalități:

$$E(N|n) - E(N|n-1) = \frac{n}{n}$$

$$E(N|n-1) - E(N|n-2) = \frac{n}{n-1}$$

.....

$$E(N|3) - E(N|2) = \frac{n}{3}$$

$$E(N|2) - E(N|1) = \frac{n}{2}$$

$$E(N|1) = n$$

care prin sumare dau

$$E(N|n) = \frac{n}{n} + \frac{n}{n-1} + \frac{n}{n-2} + \dots + \frac{n}{2} + n$$

și

$$E(N) = E(N|n) = n \left(1 + \frac{1}{2} + \dots + \frac{1}{n} \right).$$

Exemplul 8. Fie X o v.a. cu densitatea de probabilitate p . Să se verifice faptul că, dacă m este mediana lui X , iar $a \in \mathbb{R}$, atunci valoarea medie a v.a. $Y = |X - a|$ este minimă pentru $a = m$.

Se obține

$$\begin{aligned} E(Y) = E(|X - a|) &= \int_{-\infty}^{\infty} |x - a| p(x) dx = \\ &= \int_{-\infty}^a (a - x) p(x) dx + \int_a^{\infty} (x - a) p(x) dx = \\ &= a - E(X) - 2a \int_a^{\infty} p(x) dx + 2 \int_a^{\infty} x p(x) dx. \end{aligned}$$

Dacă $a = m$ se obține

$$E(|X - m|) = 2 \int_m^{\infty} x p(x) dx - E(X),$$

deoarece prin definiția medianei

$$\int_m^{\infty} p(x) dx = \int_{-\infty}^m p(x) dx = \frac{1}{2}.$$

Așadar

$$E(|X - a|) = a + E(|X - m|) = -2 \int_m^{\infty} x p(x) dx + 2 \int_a^{\infty} (x - a) p(x) dx$$

sau

$$E(|X - a|) = E(|X - m|) + 2 \int_a^m (x - a) p(x) dx.$$

Întrucât $\int_a^m (x - a) p(x) dx \geq 0$ pentru orice $a \in \mathbb{R}$, rezultă că $E(|X - a|)$ este minimă pentru $a = m$.

Exemplul 9. Se consideră v.a. X cu densitatea de probabilitate

$$p(x) = \begin{cases} 3e^{-3x}, & x \geq 0 \\ 0, & x < 0. \end{cases}$$

Să se determine mediana și cuantila de ordin 4. Funcția de repartiție este

$$F(x) = \begin{cases} 1 - e^{-3x}, & x \geq 0 \\ 0, & x < 0. \end{cases}$$

Mediana m se determină din relația $F(m) = \frac{1}{2}$, de unde rezultă $1 - e^{-3m} = \frac{1}{2}$ și deci $m = \frac{1}{3} \ln 2$. Cuantila de ordin 4 se obține rezolvând ecuația $F(q_4) = \frac{1}{4}$, care conduce la $q_4 = \frac{1}{3} \ln \frac{4}{3}$.

Exemplul 10. Fie v.a. X și Y cu repartițiile

$$X : \begin{pmatrix} -2 & -1 & 1 & 2 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix} \quad \text{și} \quad Y : \begin{pmatrix} -1 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

V.a. XY va lua valorile $z_{ij} = x_i y_j$, $1 \leq i \leq 4$, $1 \leq j \leq 2$. Concret se obțin:

$$z_{11} = 2, z_{21} = 1, z_{31} = -1, z_{41} = -2, z_{12} = -2, z_{22} = -1, z_{32} = 1, z_{42} = 2.$$

Acstea valori au probabilitățile următoare:

$$r_{11} = 0, r_{21} = \frac{1}{4}, r_{31} = \frac{1}{4}, r_{41} = 0, r_{12} = \frac{1}{4}, r_{22} = 0, r_{32} = 0, r_{42} = \frac{1}{4}.$$

Cum $E(X) = 0$, $E(Y) = 0$ și $E(XY) = 0$, rezultă că $E(XY) = E(X)E(Y)$. Deci $\text{cov}(X, Y) = 0$. Dar

$$p_{ij}q_j = \frac{1}{8} \neq r_{ij} \quad \forall (i, j) \in \{1, 2, 3, 4\} \times \{1, 2\},$$

unde $(p_i)_{1 \leq i \leq 4}$ și $(q_j)_{1 \leq j \leq 2}$ reprezintă repartițiile v.a. X , respectiv Y . În concluzie, X și Y sunt necorelate, dar nu sunt independente.

Exemplul 11. Se consideră v.a. X și Y , unde $Y = aX + b$, $a \neq 0$, $b \in \mathbb{R}$. Să se determine coeficientul de corelație $\rho(X, Y)$.

Dacă $\mu = E(X)$, atunci $E(Y) = a\mu + b$ (conform (2.14)). De asemenea, dacă $\sigma^2 = \text{Var}(X)$, atunci $\text{Var}(Y) = a^2\sigma^2$ (conform (2.16)) și $E(XY) = E(aX^2 + bX) = a(\sigma^2 + \mu^2) + b\mu$ (conform (2.14)). Prin urmare

$$\text{cov}(X, Y) = E(XY) - E(X)E(Y) = a(\sigma^2 + \mu^2) + b\mu - \mu(a\mu + b) = a\sigma^2$$

și deci

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{a\sigma^2}{\sqrt{a^2\sigma^4}} = \frac{a}{|a|} = \text{sgn } a.$$

Exemplul 12. V.a. Y are densitatea de probabilitate

$$p(y) = \begin{cases} 1, & y \in [0, 1] \\ 0, & \text{în rest.} \end{cases}$$

Dacă X este o altă v.a., atunci probabilitatea evenimentului $\{a \leq X \leq b\}$ condiționată de Y este dată de relația

$$P(A \leq X \leq b | Y = y) = y^2, \quad y \in [0, 1].$$

Să se calculeze $P(a \leq X \leq b)$.

Utilizând relația (2.19) se obține

$$P(a \leq X \leq b) = \int_0^1 y^2 dy = \frac{1}{3}.$$

Exemplul 13. Fie X o v.a. pozitivă, iar F funcția sa de repartiție care îndeplinește condiția $\lim_{x \rightarrow \infty} x[1 - F(x)] = 0$. Să se arate că

$$E(X) = \int_0^\infty [1 - F(x)] dx.$$

Se demonstrează această relație pentru cazul în care X admite o densitate de probabilitate continuă p ; în acest caz

$$F'(x) = p(x), \quad x \geq 0$$

$$\begin{aligned} E(X) &= \int_0^\infty x p(x) dx = - \int_0^\infty x \frac{d}{dx} [1 - F(x)] dx = \\ &= -x[1 - F(x)] \Big|_0^\infty + \int_0^\infty [1 - F(x)] dx = \\ &= \int_0^\infty [1 - F(x)] dx. \end{aligned}$$

Mai general, se poate arăta că, dacă X este o v.a. oarecare (nu neapărat pozitivă) cu funcția de repartiție F care îndeplinește condițiile

$$\lim_{x \rightarrow -\infty} x F(x) = 0 \quad \text{și} \quad \lim_{x \rightarrow \infty} x[1 - F(x)] = 0,$$

atunci

$$E(X) = - \int_0^\infty F(x) dx + \int_0^\infty [1 - F(x)] dx.$$

2.5 Funcția generatoare și funcția caracteristică

Un instrument foarte eficace și în același timp comod de utilizat este funcția generatoare introdusă de Euler¹².

Fie X o v.a. discretă cu valori întregi nenegative. Se numește *funcție generatoare* a v.a. X funcția

$$g_X(t) = E(t^X) = \sum_{n=0}^{\infty} t^n P(X = n),$$

fiind privită ca funcție de variabilă reală t ¹³.

Se observă că funcția generatoare este definită cel puțin pentru $|t| < 1$. De asemenea

$$g_X(1) = \sum_{n=0}^{\infty} P(X = n) = 1.$$

Propoziția 2.1. Fie X și Y două v.a. discrete cu valori întregi nenegative. Dacă $g_X = g_Y$, atunci $p_X = p_Y$.

Enunțul propoziției 2.1 se poate reformula astfel: repartitia de probabilitate a unei v.a. discrete cu valori întregi nenegative este determinată în mod unic de funcția sa generatoare.

Propoziția 2.2. Fie X_1, X_2, \dots, X_n v.a. independente luând valori întregi nenegative. Se consideră v.a. $S_n = X_1 + X_2 + \dots + X_n$. Atunci

$$g_{S_n}(t) = \prod_{k=1}^n g_{X_k}(t).$$

Se remarcă că funcția generatoare (de probabilitate) g_X generează probabilitățile $P(X = n)$, $n \in \mathbb{N}$, ceea ce justifică chiar denumirea acordată transformației. Probabilitățile $P(X = n)$, $n \in \mathbb{N}$, se determină din relația

$$P(X = n) = \frac{g_X^{(n)}(0)}{n!}, \quad \text{unde} \quad g_X^{(n)}(t) = \frac{d^n g_X(t)}{dt^n}. \quad (2.21)$$

Cu ajutorul funcției generatoare se pot calcula următoarele

- a) $E(|X|) < \infty \Rightarrow E(X) = g'_X(1);$
 - b) $E(X^2) < \infty \Rightarrow E(X^2) = g''_X(1) + g'_X(1),$
- (2.22)

$$\text{Var}(X) = g''_X(1) + g'_X(1) - (g'_X(1))^2.$$

Deși funcția generatoare de probabilitate este un instrument matematic eficace, totuși utilizarea ei este limitată, fiind definită numai pentru v.a. discrete cu valori întregi nenegative. De aceea, această inconveniență trebuie

¹²Leonhard Euler (1707-1783) prolific matematician elvețian.

¹³Uneori, în alte situații, este avantajos ca variabila t să fie considerată variabilă complexă.

depășită. Avantajul expresiei funcției generatoare ca medie a v.a. t^X ¹⁴, este acela de a permite unele extensi. Astfel dacă X este o v.a. cu valori reale arbitrar se introduce următoarea definiție. Se numește *funcție generatoare de momente* a lui X funcția

$$\psi_X(t) = E(e^{tX}),$$

cu condiția să existe $h > 0$, astfel încât valoarea medie să existe și să fie finită pentru $|t| < h$ ¹⁵.

Se observă că pentru v.a. nenegativă, X , $E(e^{tX})$ există pentru orice $t \leq 0$. Ca să existe funcția generatoare de momente, se cere în plus existența lui $E(e^{tX})$ pentru $0 < t < h$ și un anume $h > 0$.

Se observă în plus că dacă X este o v.a. cu valori întregi, atunci $\psi_X(t) = g_X(e^t)$ pentru $|t| < h$, (cu condiția ca funcția generatoare de momente să existe pentru $|t| < h$).

Proprietăile de unicitate și multiplicare sunt prezente din nou și se pot enunța astfel.

Propoziția 2.3. Fie X și Y două v.a. Dacă există $h > 0$, astfel încât $\psi_X(t) = \psi_Y(t)$ pentru $|t| < h$, atunci X și Y sunt identic repartizate.

Propoziția 2.4. Fie X_1, X_2, \dots, X_n v.a. independente, ale căror funcții generatoare de momente există pentru $|t| < h$ și un anume $h > 0$. Fie v.a. $S_n = X_1 + X_2 + \dots + X_n$. Atunci

$$\psi_{S_n}(t) = \prod_{k=1}^n \psi_{X_k}(t), \quad |t| < h.$$

S-a văzut că derivatele de ordinul n ale funcției generatoare (de probabilitate), calculate în zero, furnizează probabilităile $P(X = n)$, $n \in \mathbb{N}$. În continuare se va stabili că derivatele funcției generatoare de momente, calculate în zero, generează momente, ceea ce sugerează însăși denumirea transformatei.

Propoziția 2.5. Fie X o v.a. a cărei funcție generatoare de momente, $\psi_X(t)$, există pentru $|t| < h$ și un anume $h > 0$. Atunci

- a) $E(|X|^r) < \infty, \quad \forall r > 0;$
- b) $E(X^n) = \psi_X^{(n)}(0), \quad \forall n \in \mathbb{N}^*$.

Dacă funcția generatoare de momente este dată sub forma

$$\psi_X(t) = E(e^{tX}) = 1 + \sum_{n=1}^{\infty} \frac{t^n}{n!} E(X^n), \quad |t| < h,$$

¹⁴ Formă în care Euler nu ar fi recunoscut-o, deoarece conceptul de v.a. apare nu mult înainte de anul 1930.

¹⁵ Se remarcă legătura strânsă între funcția generatoare de momente și transformata Laplace a funcțiilor cu valori reale.

atunci momentele de ordinul n , $E(X^n)$, $n \in \mathbb{N}^*$, reprezintă coeficienții termenilor $\frac{t^n}{n!}$, $n \in \mathbb{N}^*$, din dezvoltarea în serie.

Fie $X = (X_1, X_2, \dots, X_n)$ un vector aleator. Funcția generatoare de momente a lui X este

$$\psi_X(t_1, t_2, \dots, t_n) = E(e^{t_1 X_1 + t_2 X_2 + \dots + t_n X_n})$$

cu condiția să existe $h_1, h_2, \dots, h_n > 0$ astfel încât să existe media pentru $|t_k| < h_k$, $k = \overline{1, n}$.

Deși avantajul funcției generatoare de momente este mare în comparație cu cel al funcției generatoare de probabilitate, totuși, există cazuri în care funcția generatoare de momente nu există¹⁶.

În continuare se va introduce o transformată care există pentru toate repartițiile. Dezavantajul acestei transformate constă în faptul că ia valori complexe și deci necesită un aparat matematic mai sofisticat.

Se numește *funcție caracteristică*¹⁷ a v.a. X funcția

$$\varphi_X(t) = E(e^{itX}) = E(\cos(tX) + i \sin(tX)),$$

unde i este unitatea imaginară, $i^2 = -1$.

Întrucât

$$|E(e^{itX})| \leq E(|e^{itX}|) = E(1) = 1,$$

rezultă că funcția caracteristică există pentru orice t și pentru orice v.a. X .

Următoarele propoziții stabilesc câteva proprietăți elementare ale funcției caracteristice.

Propoziția 2.6. *Funcția caracteristică a unei v.a. X are proprietățile:*

- a) $|\varphi_X(t)| \leq \varphi_X(0) = 1$, $\forall t \in \mathbb{R}$;
- b) $\varphi_X(t) = \varphi_X(-t)$, $\forall t \in \mathbb{R}$;
- c) $\varphi_X(t)$ este uniform continuă pe \mathbb{R} .

Propoziția 2.7. *Fie X și Y două v.a. Dacă $\varphi_X = \varphi_Y$, atunci X și Y sunt identic repartizate.*

Teorema 2.8 (Teorema de inversiune). *Fie X o v.a. cu funcția de repartiție F și funcția caracteristică φ_X . Dacă F este continuă în a și b ($a < b$), atunci*

$$F(b) - F(a) = \lim_{c \rightarrow \infty} \frac{1}{2\pi} \int_{-c}^c \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt.$$

¹⁶ Un exemplu de acest gen este repartiția Cauchy $C(0, 1)$ (vezi §3.18).

¹⁷ Abstracție, făcând de un minus la exponent și de un factor $\frac{1}{\sqrt{2\pi}}$, funcția caracteristică coincide cu transformata Fourier în cazul continuu și cu seria Fourier în cazul discret.

Se observă că propoziția 2.7 este un corolar al teoremei 2.8, funcția de repartiție fiind complet determinată de funcția caracteristică. Într-adevăr rezultă

$$F(b) = \lim_{a \rightarrow -\infty} \lim_{c \rightarrow \infty} \frac{1}{2\pi} \int_{-c}^c \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt,$$

a parcurgând o mulțime de continuitate a funcției F .

Corolarul 2.9. *Funcția F este derivabilă în punctul x și derivata ei în acest punct este dată de formula*

$$p(x) = F'(x) = \lim_{h \rightarrow \infty} \lim_{c \rightarrow \infty} \frac{1}{2\pi} \int_{-c}^c \frac{1 - e^{ith}}{ith} \cdot e^{-itx} \varphi_X(t) dt$$

dacă și numai dacă expresia din membrul drept există.

În particular, dacă φ_X este absolut integrabilă pe \mathbf{R} (adică $\int_{-\infty}^{\infty} |\varphi_X(t)| dt < \infty$), atunci densitatea de probabilitate p există, este mărginită, continuă și

$$p(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi_X(t) dt. \quad (2.23)$$

Propoziția 2.10. *Fie X_1, X_2, \dots, X_n v.a. independente. Atunci funcția caracteristică a v.a. $S_n = X_1 + X_2 + \dots + X_n$ este*

$$\varphi_{S_n}(t) = \prod_{k=1}^n \varphi_{X_k}(t).$$

Propoziția 2.11. *Fie X o v.a., astfel încât $E(|X|^n) < \infty$ pentru un anume $n \in \mathbf{N}^*$. Atunci*

a) $\varphi_X^{(k)}(0) = i^k E(X^k)$ pentru $k = \overline{1, n}$;

b) $\varphi_X(t) = \sum_{n=0}^{\infty} E(X^n) \cdot \frac{(it)^n}{n!}$ în intervalul de convergență al seriei.

Propoziția 2.12. *Fie X o v.a. și $a, b \in \mathbf{R}$. Atunci*

$$\varphi_{aX+b}(t) = e^{ibt} \cdot \varphi_X(at).$$

Făcând o comparație între propoziția 2.5 (b) și propoziția 2.11 (a), am fi tentați să spunem că ambele rezultate pot fi obținute unul din celălalt, pe baza relației $\varphi_X(t) = \psi_X(it)$. Totuși această relație nu este în general valabilă, deoarece există v.a. care nu au funcții generatoare de momente.

Fie $X = (X_1, X_2, \dots, X_n)$ un vector aleator. Funcția caracteristică a lui X este

$$\varphi_X(t_1, t_2, \dots, t_n) = E(e^{i(t_1 X_1 + t_2 X_2 + \dots + t_n X_n)}).$$

Exemplul 1. Pentru v.a. bernoulliene X_1, X_2, \dots, X_n , din exemplul 3, §2.4, funcția generatoare comună este

$$g_X(t) = q + pt$$

pentru că $P(X = 0) = q$ și $P(X = 1) = p$. Atunci $g'_X(t) = p$ și $g''_X(t) = 0$, de unde rezultă conform relațiilor (2.22)

$$E(X) = g'_X(1) = p,$$

$$\text{Var}(X) = g''_X(1) + g'_X(1) - (g'_X(1))^2 = p - p^2 = p(1 - p) = pq.$$

Pentru $S_n = X_1 + X_2 + \dots + X_n$ (unde X_i , $i = \overline{1, n}$, sunt v.a. independente) se obțin conform propoziției 2.2

$$\begin{aligned} g_{S_n}(t) &= (q + pt)^n, \\ g'_{S_n}(t) &= np(q + pt)^{n-1}, \\ g''_{S_n}(t) &= n(n - 1)p^2(q + pt)^{n-2}, \end{aligned}$$

de unde rezultă

$$E(S_n) = np,$$

$$\text{Var}(S_n) = n(n - 1)p^2 + np - (np)^2 = npq,$$

deja calculate în §2.4.

Exemplul 2. V.a. X are funcția generatoare g_X . Să se determine funcția generatoare corespunzătoare v.a. $X + 1$ și $2X$.

Probabilitățile v.a. $X + 1$ sunt

$$P(X + 1 = n) = P(X = n - 1) = p_{n-1}.$$

Atunci funcția generatoare este dată de

$$g_{X+1}(t) = \sum_{n=1}^{\infty} p_{n-1} t^n = t \sum_{n=1}^{\infty} p_{n-1} t^{n-1},$$

de unde rezultă că $g_{X+1}(t) = tg_X(t)$, deoarece $g_X(t) = \sum_{n=0}^{\infty} p_n t^n$ și

$$p_n = P(X = n), \quad n \in \mathbb{N}.$$

Analog, se observă că

$$P(2X = n) = p_{2n},$$

deci

$$g_{2X}(t) = \sum_{n=0}^{\infty} p_{2n} t^n = g_X(t^2).$$

Exemplul 3. Fie $(X_n)_n$ un sir de v.a. independente, care iau valorile $0, 1, 2, \dots, a-1$ cu probabilitatile $\frac{1}{a}$. Fie v.a. $S_n = X_1 + X_2 + \dots + X_n$. Să se calculeze functia generatoare a v.a. S_n si functia generatoare corespunzatoare probabilitatilor $P(S_n \leq j)$.

Cum $(X_n)_n$ sunt v.a. independente identic repartizate, rezulta că

$$g_{S_n}(t) = (g_{X_i}(t))^n.$$

Deoarece

$$g_{X_i}(t) = \frac{1}{a} \sum_{n=0}^{a-1} t^n = \frac{1-t^a}{a(1-t)}$$

se obtine

$$g_{S_n}(t) = \left[\frac{1-t^a}{a(1-t)} \right]^n.$$

Se observă că

$$P(S_n \leq j) + P(S_n > j) = 1.$$

Înmulțind cu t^n și sumând, se obtine

$$\sum_{j=0}^{\infty} P(S_n \leq j) t^j = \frac{1}{1-t} g_{S_n}(t).$$

Exemplul 4. Dintr-o urnă conținând bile albe și bile negre se fac extrageri succesive, de fiecare dată punându-se bila extrasă înapoi în urnă. Se extrage o bilă albă cu probabilitatea p , iar o bilă neagră cu probabilitatea $q = 1 - p$. Fie X o v.a. care ia valoarea n dacă pentru prima oară se obține o bilă albă, urmată de una neagră în extragerile de rang $n-1$ și n . Să se determine funcția generatoarea a v.a. X .

Succesiunea cea mai generală care poate conduce la apariția unei bile albe, urmată de una neagră, la extragerile $n-1$ și n este

$$\underbrace{NN\dots NA}_{n-1 \text{ ori}} \quad \underbrace{AA\dots AN}_{n-1 \text{ ori}}$$

unde am notat prin A , respectiv N apariția unei bile albe, respectiv negre. Se poate scrie $X = X_1 + X_2$, unde X_1 și X_2 sunt v.a. egale cu rangul extragerii în cazul în care s-a obținut prima bilă albă, respectiv neagră. X_1 și X_2 sunt v.a. independente. Atunci funcția generatoare a v.a. X va fi egală cu produsul

funcțiilor generatoare corespunzătoare v.a. X_1 și X_2 . Cum $P(X_1 = k) = q^{k-1} \cdot p$, funcția generatoare a v.a. X_1 este

$$g_{X_1}(t) = \sum_{k=1}^{\infty} q^{k-1} pt^k = pt \sum_{k=1}^{\infty} (qt)^{k-1} = \frac{pt}{1-qt}.$$

Cum $P(X_2 = k) = p^{k-1} \cdot q$, funcția generatoare a v.a. X_2 este

$$g_{X_2}(t) = \sum_{k=1}^{\infty} p^{k-1} qt^k = qt \sum_{k=1}^{\infty} (pt)^{k-1} = \frac{qt}{1-pt}.$$

Atunci funcția generatoare a v.a. X este

$$g_X(t) = \frac{pq t^2}{(1-qt)(1-pt)}.$$

Exemplul 5. V.a. discretă X are funcția generatoare $g_X(t) = ke^{t^2+t}$. Să se determine k și să se găsească

a) $P(X = 0)$, $P(X = 1)$, $P(X = 2)$;

b) $E(X)$ și $\text{Var}(X)$;

c) cea mai mică valoare $n_0 \in \mathbb{N}$ pentru care $P(X > n_0) < \frac{2}{5}$.

Din relația $g_X(1) = 1$ rezultă $ke^2 = 1$ și deci $k = e^{-2}$. Din relațiile (2.22) se obține

$$P(X = 0) = g_X(0) = e^{-2}, \quad P(X = 1) = e^{-2},$$

$$P(X = 2) = \frac{3k}{2} = \frac{3e^{-2}}{2}.$$

Relațiile (2.22) dau $E(X) = 3ke^2 = 3$ și $\text{Var}(X) = 11ke^2 + 3 - 9 = 5$.

Conform relației (2.21) se obține

$$P(X > n) = 1 - P(X \leq n) = 1 - \sum_{k=0}^n P(X = k) = 1 - \sum_{k=0}^n \frac{g_X^{(k)}(0)}{k!}.$$

Valoarea minimă n_0 pentru care

$$1 - \sum_{k=0}^n \frac{g_X^{(k)}(0)}{k!} < \frac{2}{5}$$

este $n_0 = 3$.

Exemplul 6. Dacă X este o v.a. bernoulliană, atunci

$$\psi_X(t) = q + pe^t, \quad E(X) = \psi'_X(0) = p, \quad E(X^2) = \psi''_X(0) = p$$

și

$$\text{Var}(X) = p - p^2 = p(1 - p) = pq.$$

Din dezvoltarea în serie Taylor a lui e^t în jurul originii rezultă

$$\psi_X(t) = q + p \sum_{n=0}^{\infty} \frac{t^n}{n!} = 1 + \sum_{n=1}^{\infty} \frac{t^n}{n!} \cdot p.$$

Deci $E(X^n) = p$, $\forall n \in \mathbb{N}^*$.

Exemplul 7. Se consideră funcția $p : \mathbf{R} \rightarrow \mathbf{R}$, $p(x) = \frac{a}{\pi(x^2 + a^2)}$, $a > 0$.

Să se determine constanta a astfel încât p să fie densitatea de repartiție¹⁸ a unei v.a. X . Să se determine apoi funcția caracteristică corespunzătoare.

Impunând condiția $\int_{-\infty}^{\infty} p(x)dx = 1$ se obține

$$\frac{a}{\pi} \int_{-\infty}^{\infty} \frac{dx}{x^2 + a^2} = \frac{2a}{\pi} \int_0^{\infty} \frac{dx}{x^2 + a^2} = 1$$

și deci $\frac{2}{\pi} \arctg \frac{x}{a} \Big|_0^\infty = 1$ care este adevărată pentru orice $a > 0$. Funcția caracteristică φ_X este prin definiție

$$\varphi_X(t) = \frac{a}{\pi} \int_{-\infty}^{\infty} \frac{e^{itx}}{x^2 + a^2} dx.$$

Pentru calculul acestei integrale se poate utiliza teorema reziduurilor și se obține

$$\varphi_X(t) = \begin{cases} 2ai \operatorname{Res} \left(\frac{e^{itx}}{x^2 + a^2}, x = ia \right), & t \geq 0 \\ -2ai \operatorname{Res} \left(\frac{e^{itx}}{x^2 + a^2}, x = -ia \right), & t < 0. \end{cases}$$

După calculul reziduurilor se obține

$$\varphi_X(t) = \begin{cases} e^{-at}, & t \geq 0 \\ e^{at}, & t < 0 \end{cases}$$

și deci $\varphi_X(t) = e^{-a|t|}$, $t \in \mathbf{R}$.

Exemplul 8. Să se determine funcția de repartiție a v.a. X care are funcția caracteristică

$$\varphi_X(t) = \frac{1}{4}(1 + e^{it})^2.$$

¹⁸ Densitatea de repartiție în cauză reprezintă densitatea de repartiție Cauchy $C(0, a)$, unde $a > 0$ (vezi §3.18).

Întrucât

$$\varphi_X(t) = \frac{1}{4} + \frac{1}{2}e^{it} + \frac{1}{4}e^{2it}$$

rezultă că X este o v.a. discretă cu funcția de frecvență

$$X : \begin{pmatrix} 0 & 1 & 2 \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \end{pmatrix}.$$

Deci funcția de repartiție este

$$F_X(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{4}, & 0 \leq x < 1 \\ \frac{3}{4}, & 1 \leq x < 2 \\ 1, & x \geq 2. \end{cases}$$

Exemplul 9. Să se determine funcția de repartiție a v.a. X care are funcția caracteristică

$$\varphi_X(t) = \frac{\lambda}{\lambda - it}, \quad \lambda > 0.$$

Utilizând relația (2.23) rezultă că densitatea de probabilitate corespunzătoare este

$$p(x) = \frac{\lambda}{2\pi} \int_{-\infty}^{\infty} \frac{e^{-itx}}{\lambda - it} dt.$$

Această integrală poate fi calculată cu teorema reziduurilor și se obține

$$p(x) = \begin{cases} -\lambda i \operatorname{Res} \left(\frac{e^{-itx}}{\lambda - it}, t = -\lambda i \right), & x \geq 0 \\ 0, & x < 0. \end{cases}$$

Deci

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0. \end{cases}$$

Exemplul 10. Să se determine funcția caracteristică $\varphi(t_1, t_2)$ a vectorului aleator (X, Y) , dacă acesta admite o densitate de probabilitate $p(x, y) = f(r)$, unde $r = \sqrt{x^2 + y^2}$. Să se studieze cazul particular

$$f(r) = \begin{cases} \frac{1}{\pi a^2}, & 0 \leq r \leq a \\ 0, & r > a. \end{cases}$$

Prin definiție

$$\varphi(t_1, t_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{i(t_1x+t_2y)} p(x, y) dx dy.$$

Făcând o schimbare de coordonate polare

$$x = \rho \cos \theta, \quad y = \rho \sin \theta \quad \rho > 0, \quad 0 < \theta < 2\pi$$

se obține

$$\begin{aligned} \varphi(t_1, t_2) &= \int_0^{\infty} d\rho \int_0^{2\pi} e^{i\rho(t_1 \cos \theta + t_2 \sin \theta)} \rho f(\rho) d\theta = \\ &= \int_0^{\infty} \rho f(\rho) d\rho \int_0^{2\pi} e^{i\rho(t_1 \cos \theta + t_2 \sin \theta)} d\theta. \end{aligned}$$

Pentru calculul celei de a doua integrale se procedează astfel

$$\begin{aligned} \int_0^{2\pi} e^{i\rho(t_1 \cos \theta + t_2 \sin \theta)} d\theta &= \int_{|z|=1} \frac{\exp\left(\left(\frac{i\rho}{2}\right)(t_1 + (z + \frac{1}{z}) - it_2(z - \frac{1}{z}))\right)}{iz} dz = \\ &= 2\pi \operatorname{Res}\left(\frac{\exp\left(\frac{i\rho}{2}\right)((t_2 + it_1)z - (\frac{1}{z})(t_2 - it_1))}{z}, z = 0\right) = \\ &= 2\pi \operatorname{Res}\left(\frac{\exp\left(\frac{i\rho T}{2}\right)(zt - \frac{1}{zt})}{z}, z = 0\right) = 2J_0(\rho T), \end{aligned}$$

unde

$$T = \sqrt{t_1^2 + t_2^2}, \quad t = \frac{t_2 + it_1}{T}, \quad \text{iar} \quad J_n, \quad n \in \mathbb{N},$$

sunt funcțiile Bessel de speță întâi. Prin urmare

$$\varphi(t_1, t_2) = 2\pi \int_0^{\infty} \rho f(\rho) J_0(\rho T) d\rho.$$

În cazul particular dat

$$\varphi(t_1, t_2) = \left(\frac{2}{a^2}\right) \int_0^a \rho J_0(\rho T) d\rho = \left(\frac{2}{a^2 T}\right) \int_0^a \frac{d}{d\rho}(\rho J_1(\rho T)) d\rho = \left(\frac{2}{a T}\right) J_1(a T).$$

Aici s-a folosit relația

$$\frac{d}{dz}(z J_1(z)) = z J_0(z).$$

Exemplul 11. Să se determine funcția caracteristică $\varphi(t_1, t_2)$ a vectorului aleator (X, Y) , dacă acesta admite densitatea de probabilitate

$$p(x, y) = \begin{cases} 0, & \min(x, y) < 0 \\ xy e^{-(x+y)}, & \min(x, y) \geq 0. \end{cases}$$

Funcția caracteristică a vectorului aleator (X, Y) este

$$\begin{aligned}\varphi(t_1, t_2) &= \int_0^\infty \int_0^\infty e^{i(t_1 x + t_2 y)} x y e^{-(x+y)} dx dy = \\ &= \int_0^\infty x e^{-(1-i t_1)x} dx \int_0^\infty y e^{-(1-i t_2)y} dy = \\ &= (1 - i t_1)^{-2} (1 - i t_2)^{-2}.\end{aligned}$$

Exemplul 12. Densitatea de probabilitate a vectorului aleator $X = (X_1, \dots, X_n)$ este

$$p(x_1, \dots, x_n) = \frac{1}{\pi^n} \cdot \frac{1}{(1+x_1^2) \dots (1+x_n^2)}.$$

Să se determine funcția caracteristică a lui X și să se studieze independența v.a. X_1, \dots, X_n .

Funcția caracteristică a lui X este

$$\begin{aligned}\varphi(t_1, \dots, t_n) &= \int_{-\infty}^\infty \dots \int_{-\infty}^\infty e^{i \sum_{k=1}^n t_k x_k} p(x_1, \dots, x_n) dx_1 \dots dx_n = \\ &= \frac{1}{\pi^n} \int_{-\infty}^\infty \frac{e^{it_1 x_1}}{1+x_1^2} dx_1 \dots \int_{-\infty}^\infty \frac{e^{it_n x_n}}{1+x_n^2} dx_n.\end{aligned}$$

Cu ajutorul formulei rezidurilor rezultă

$$\frac{1}{\pi} \int_{-\infty}^\infty \frac{e^{itx}}{1+x^2} dx = e^{-|t|}.$$

Deoarece

$$\varphi(t_1, \dots, t_n) = e^{-\sum_{k=1}^n |t_k|} = \prod_{k=1}^n \varphi_{X_k}(t_k)$$

rezultă că v.a. X_1, \dots, X_n sunt independente.

2.6 Cumulanți (semi-invariante)

Fie $X = (X_1, \dots, X_k)$ un vector aleator și $\varphi(t_1, \dots, t_k) = E(e^{i(t_1 X_1 + \dots + t_k X_k)})$, funcția sa caracteristică. Presupunem că există $n \in \mathbb{N}^*$ astfel încât $E(|X_i|)^n < \infty$, $i = 1, 2, \dots, k$. Rezultă că există momentele

$$m_X^{(\nu_1, \dots, \nu_k)} = E(X_1^{\nu_1} \dots X_n^{\nu_k})$$

pentru orice $\nu_1, \dots, \nu_k \in \mathbb{N}$, $\nu_1 + \dots + \nu_k \leq n$. Aceasta implică existența și continuitatea derivatelor parțiale

$$\frac{\partial^{\nu_1 + \dots + \nu_k}}{\partial t_1^{\nu_1} \dots \partial t_k^{\nu_k}} \varphi(t_1, \dots, t_k)$$

pentru $\nu_1 + \dots + \nu_k \leq n$. Așadar, dacă dezvoltăm $\varphi(t_1, \dots, t_k)$ în serie Taylor obținem

$$\varphi(t_1, \dots, t_k) = \sum_{\nu_1 + \dots + \nu_k \leq n} \frac{i^{\nu_1 + \dots + \nu_k}}{\nu_1! \dots \nu_k!} m_X^{(\nu_1, \dots, \nu_k)} t_1^{\nu_1} \dots t_k^{\nu_k} + o(|t|^n)$$

unde $|t| = |t_1| + \dots + |t_k|$.

Deoarece φ este continuă și $\varphi(0, \dots, 0) = 1$, rezultă că φ este diferită de zero într-o vecinătate $|t| < \delta$ a originii. Deci, în această vecinătate, derivatele parțiale

$$\frac{\partial^{\nu_1 + \dots + \nu_k}}{\partial t_1^{\nu_1} \dots \partial t_k^{\nu_k}} \ln \varphi(t_1, \dots, t_k)$$

există și sunt continue. Așadar, putem considera dezvoltarea Taylor¹⁹

$$\ln \varphi(t_1, \dots, t_k) = \sum_{\nu_1 + \dots + \nu_k \leq n} \frac{i^{\nu_1 + \dots + \nu_k}}{\nu_1! \dots \nu_k!} s_X^{(\nu_1, \dots, \nu_k)} t_1^{\nu_1} \dots t_k^{\nu_k} + o(|t|^n),$$

unde coeficienții $s_X^{(\nu_1, \dots, \nu_k)}$ sunt numiți *cumulanți* (sau *semi-invarianti*).

Observăm că, dacă X și Y sunt independenți, atunci

$$\ln \varphi_{X+Y}(t) = \ln \varphi_X(t) + \ln \varphi_Y(t)$$

și de aceea

$$s_{X+Y}^{(\nu_1, \dots, \nu_k)} = s_X^{(\nu_1, \dots, \nu_k)} + s_Y^{(\nu_1, \dots, \nu_k)}$$

care justifică denumirea de semi-invariant. Dacă $\nu = (\nu_1, \dots, \nu_k)$ introducem următoarele notații

$$\nu! = \nu_1! \dots \nu_k!; |\nu| = \nu_1 + \dots + \nu_k; t^\nu = t_1^{\nu_1} \dots t_k^{\nu_k}.$$

Între momentele $m_X^{(\nu_1, \dots, \nu_k)} = m_X^{(\nu)}$ și cumulanții $s_X^{(\nu_1, \dots, \nu_k)} = s_X^{(\nu)}$ există următoarele relații care permit exprimarea unora în funcție de ceilalți

$$m_X^{(\nu)} = \sum \frac{1}{q!} \frac{\nu!}{\lambda^{(1)}! \dots \lambda^{(q)}!} \prod_{p=1}^q s_X^{(\lambda^{(p)})},$$

$$s_X^{(\nu)} = \sum \frac{(-1)^{q-1}}{q} \frac{\nu!}{\lambda^{(1)}! \dots \lambda^{(q)}!} \prod_{p=1}^q m_X^{(\lambda^{(p)})},$$

unde sumarea se face după toate multimile ordonate de vectori $(\lambda^{(1)}, \dots, \lambda^{(q)})$ (cu componente din N), astfel încât

$$|\lambda^{(p)}| > 0 \quad \text{și} \quad \lambda^{(1)} + \dots + \lambda^{(q)} = \nu.$$

¹⁹Dacă $z = re^{i\theta}$, se ia $\ln z = \ln r + i\theta$.

Utilizând aceste relații obținem

$$\begin{aligned}m_X^{(1)} &= s_X^{(1)} \\m_X^{(1,2)} &= s_X^{(1,2)} + s_X^{(1)} s_X^{(2)} \\m_X^{(1,2,3)} &= s_X^{(1,2,3)} + s_X^{(1,2)} s_X^{(3)} + s_X^{(1,3)} s_X^{(2)} + \\&\quad + s_X^{(2,3)} s_X^{(1)} + s_X^{(1)} s_X^{(2)} s_X^{(3)}\end{aligned}$$

.....

Pentru $k = 1$ avem

$$\begin{aligned}m_1 &= s_1 \\m_2 &= s_2 + s_1^2 \\m_3 &= s_3 + 3s_1s_2 + s_1^3 \\m_4 &= s_4 + 3s_2^2 + 4s_1s_3 + 6s_1^2s_2 + s_1^4\end{aligned}$$

Capitolul 3

Repartiții clasice

3.1 Repartiția binomială

Fie X o v.a. discretă care ia valorile $0, 1, \dots, n$, cu funcția de frecvență

$$P(X = k) = C_n^k p^k q^{n-k}, \quad p + q = 1, \quad p > 0, \quad q > 0.$$

Se observă că $P(X = k)$ este egală cu termenul general al dezvoltării binomului $(p + q)^n$. V.a. X reprezintă numărul de apariții ale unui eveniment A în n experimente independente cum ar fi experimentul Bernoulli repetat (vezi exemplul 2, §1.3), unde p este probabilitatea realizării evenimentului A , iar q este probabilitatea realizării evenimentului contrar \bar{A} .

Se demonstrează că (*teorema limită locală De Moivre-Laplace*)

$$P(X = k) \cong \frac{1}{\sqrt{2\pi npq}} e^{-\frac{l_n^2}{2npq}} \quad (3.1)$$

unde $l_n = k - np$; $a\sqrt{n} \leq l_n \leq b\sqrt{n}$, $a, b, n = \text{constante}$.

Caracteristici principale:

- Media $E(X) = np$;
- Varianța $\text{Var}(X) = npq$;
- Funcția caracteristică $\varphi_X(t) = (pe^{it} + q)^n$, $t \in \mathbb{R}$;
- Modul (valoarea cea mai probabilă M_0) este numărul întreg care satisface relațiile $np - q \leq M_0 \leq np + p$.

Observație. Se consideră n v.a. independente X_1, X_2, \dots, X_n cu funcțiile de frecvență

$$X_j : \begin{pmatrix} 1 & 0 \\ p_j & q_j \end{pmatrix} \quad p_j + q_j = 1, \quad j = \overline{1, n}.$$

Repartiția v.a. $X = X_1 + X_2 + \dots + X_n$ este numită *repartiția binomială generalizată a lui Poisson*. Multimea valorilor lui X este $\{0, 1, 2, \dots, n\}$.

Dacă $p_1 = p_2 = \dots = p_n$, atunci v.a. X va fi repartizată binomial.

Se poate imagina că X desemnează numărul de bile albe extrase în ipoteza că probabilitățile de extragere a unei bile albe în cele n extrageri sunt respectiv p_1, p_2, \dots, p_n (diferă de la o extragere la alta, păstrându-se însă independența lor). Funcția de frecvență a v.a. X , adică $P(X = k)$, $k = 1, n$, este coeficientul lui t^k din dezvoltarea

$$(p_1 t + q_1)(p_2 t + q_2) \dots (p_n t + q_n).$$

Caracteristici principale:

- Media $E(X) = \sum_{j=1}^n p_j$;

- Varianța $\text{Var}(X) = \sum_{j=1}^n p_j q_j$;

- Funcția caracteristică $\varphi_X(t) = \prod_{j=1}^n (p_j e^{it} + q_j)$, $t \in \mathbb{R}$.

Exemplul 1. Un număr de k mesaje, conținând n_1, n_2, \dots, n_k simboluri binare, sunt transmise (independent între ele) printr-un canal de comunicație. Probabilitatea de a transmite un simbol eronat este p . Când mesajele sunt decodificate, se pot corecta erori la cel mult două simboluri pentru fiecare din cele k mesaje. O eroare la cel puțin un simbol (după corectare) face ca întregul mesaj să fie eronat. Să se găsească probabilitatea q ca cel puțin unul dintre cele k mesaje să fie eronat.

Fie X_i , $1 \leq i \leq k$, v.a. ce desemnează numărul simbolurilor eronate în cel de-al i -lea mesaj. X_i are o repartiție binomială cu parametrii n_i și p . Cum

$$P(X_i \leq 2) = \sum_{j=0}^2 C_{n_i}^j p^j (1-p)^{n_i-j}$$

rezultă

$$q = 1 - \prod_{i=1}^k \sum_{j=0}^2 C_{n_i}^j p^j (1-p)^{n_i-j}.$$

Exemplul 2. Se presupune că sunt date un număr de relee de transmisie care sunt "nesigure" în sensul următor: dacă este aplicată o tensiune releul închide și transmite tensiunea în 90% din timpul de aplicare al acesteia. Se pune problema de a găsi un număr minim de relee, care montate în paralel, să asigure o transmitere a tensiunii timp de 99,99% din timpul de aplicare a tensiunii. Se va presupune că starea de funcționare sau nefuncționare a unui releu este independentă de starea celorlalte relee.

Dacă tensiunea este aplicată în intervalul $[0, T]$, atunci se admite că probabilitatea ca un releu să fie în funcțiune la momentul t ($0 \leq t \leq T$) este 0,9.

Dacă numărul de relee este n , atunci probabilitatea ca cel puțin un releu să fie în funcțiune la momentul t este

$$\sum_{k=1}^n C_n^k (0,9)(0,1)^{n-k} = 1 - C_n^0 (0,9)^0 (0,1)^n = 1 - (0,1)^n.$$

Trebuie găsit n în aşa fel ca $1 - (0,1)^n = 0,9999$, de unde rezultă $n = 4$.

Exemplul 3. Un lot de produse de un anumit tip nu trebuie să conțină mai mult de 10% produse defecte. La controlul de calitate se iau la întâmplare 100 de produse și întregul lot este respins, dacă se găsesc 5 sau mai multe produse defecte. Să se găsească probabilitatea ca un lot cu 10% defecte să fie acceptat.

Se consideră că lotul este suficient de mare, pentru ca probabilitatea de extragere a unui produs defect să rămână neschimbătă după fiecare extragere.

Lotul este acceptat dacă din 100 de produse extrase sunt defecte cel mult 4. Considerând deci, o repartiție binomială cu $p = 0,1$ și $q = 0,9$, se obține probabilitatea de a extrage cel mult 4 produse defecte

$$\sum_{k=0}^4 C_{100}^k p^k q^{n-k} \cong 0,024.$$

Exemplul 4. Se consideră două recipiente A și B , fiecare având $1dm^3$, conținând $2,7 \cdot 10^{22}$ molecule de gaz. Recipientele sunt puse în contact, astfel ca între ele să existe un schimb liber de molecule. Se cere probabilitatea ca după 24 ore unul din recipiente să conțină cu $2,7 \cdot 10^{12}$ mai multe molecule de gaz decât celălalt.

Se admite că probabilitatea ca, după 24 ore, o moleculă să se afle într-unul sau altul din cele două recipiente, este egală cu $\frac{1}{2}$ (această ipoteză este traducerea matematică a afirmației "între recipiente există un schimb liber de molecule"). Astfel, dacă k este numărul de molecule din A , atunci în B se vor găsi $5,4 \cdot 10^{22} - k$ molecule.

Probabilitatea ca în recipientul A să se găsească k molecule, conform repartiției binomiale este

$$p(k) = C_{5,4 \cdot 10^{22}}^k \left(\frac{1}{2}\right)^k \left(\frac{1}{2}\right)^{5,4 \cdot 10^{22}-k} = C_{5,4 \cdot 10^{22}}^k \left(\frac{1}{2}\right)^{5,4 \cdot 10^{22}}.$$

Probabilitatea căutată va fi $\sum_k p(k)$, unde suma se ia după acei indici k pentru care

$$|k - (5,4 \cdot 10^{22} - k)| \geq 5,4 \cdot 10^{12},$$

adică după acei k pentru care

$$|k - 2,7 \cdot 10^{22}| \geq 2,7 \cdot 10^{12}.$$

Exemplul 5. Prinț-un canal de comunicații se transmit 4 mesaje. Fiecare din ele, independent de celelalte, poate fi distorsionat. Probabilitățile de distorsione pentru cele 4 mesaje sunt p_1 , respectiv p_2, p_3, p_4 . Se consideră v.a. X care desemnează numărul de mesaje distorsionate. Pentru $p_1 = 0,1; p_2 = 0,2; p_3 = 0,3; p_4 = 0,4$ se cere:

- probabilitatea ca cel puțin un mesaj să fie distorsionat;
- probabilitatea ca mai mult de trei mesaje să fie distorsionate;
- $E(X)$ și $\text{Var}(X)$.

Se vor utiliza rezultatele corespunzătoare repartiției binomiale generalizate. Avem $q_1 = 0,1; q_2 = 0,8; q_3 = 0,7; q_4 = 0,6$. Funcția de frecvență a v.a. X se obține din dezvoltarea

$$(0,9 + 0,1t)(0,8 + 0,2t)(0,7 + 0,3t)(0,6 + 0,4t)$$

$$X : \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 0,3024 & 0,4404 & 0,2144 & 0,0404 & 0,0021 \end{pmatrix}.$$

- $P(X \geq 1) = 0,6976$;
- $P(X \geq 3) = 0,2572$;
- $E(X) = \sum_{i=1}^4 p_i = 1; \quad \text{Var}(X) = \sum_{i=1}^4 p_i q_i = 0,7$.

3.2 Repartiția binomial negativă

Fie $c \in \mathbb{N}^*$, $p > 0$, $q > 0$, $p + q = 1$. Se consideră v.a. X care ia valorile $c, c+1, \dots$ și a cărei funcție de frecvență este dată de

$$P(X = n) = C_{n-1}^{c-1} p^c q^{n-c}, \quad n \geq c,$$

adică termenul general din dezvoltarea în serie de puteri ale lui q a funcției $p^c(1-q)^{-c}$.

V.a. X poate fi definită ca numărul de extrageri din urna lui Bernoulli cu bila repetată (vezi exemplul 2, §1.3) necesar pentru a obține de c ori bila albă.

Caracteristici principale:

- Media $E(X) = \frac{c}{p}$;
- Varianța $\text{Var}(X) = \frac{cq}{p^2}$;
- Modul M_0 : $\frac{c-1}{p} \leq M_0 \leq \frac{c-q}{p}$;
- Funcția caracteristică $\varphi_X(t) = p^c e^{itc} (1 - qe^{it})^{-c}$, $t \in \mathbb{R}$.

Exemplul 1 (Problema cutiei de chibrituri a lui Banach). O persoană are în buzunarele din stânga și din dreapta câte o cutie cu chibrituri, conținând

fiecare N chibrituri. De fiecare dată când are nevoie de un chibrit, persoana alege la întâmplare (cu probabilitatea $\frac{1}{2}$) una din cutii, din care ia chibrituri. Se cere probabilitatea ca în momentul în care persoana respectivă descoperă că o cutie este goală, cealaltă să conțină exact r chibrituri.

Alegerea succesivă a buzunarului este asimilată cu o urnă Bernoulli; bila albă va reprezenta buzunarul stâng. Cutia din buzunarul stâng va fi goală în momentul când cutia din buzunarul drept conține exact r chibrituri dacă și numai dacă a $(N + 1)$ -a alegere a buzunarului stâng este precedată de $N - r$ alegeri ale buzunarului drept. Dacă X reprezintă v.a. ce desemnează numărul total de chibrituri consumate, atunci se poate considera că X urmează o repartiție binomial negativă cu

$$c = N + 1, \quad p = \frac{1}{2},$$

$$P(X = 2N - r + 1) = C_{2N-r}^N \left(\frac{1}{2}\right)^{N+1} \left(\frac{1}{2}\right)^{N-r} = C_{2N-r}^N 2^{-2N+r}.$$

Același raționament se aplică și dacă prima cutie goală este cea din buzunarul drept. Prin urmare

$$p = 2C_{2N-r}^N 2^{-2N+r} = C_{2N-r}^N 2^{-2N+r+1}.$$

3.3 Repartiția geometrică

Fie $p > 0$, $q > 0$, $p + q = 1$. Se consideră v.a. X având funcția de frecvență

$$P(X = k) = pq^{k-1}, \quad k \in \mathbb{N}^*.$$

V.a. X reprezintă numărul de extrageri din urna lui Bernoulli cu bila repetată (vezi exemplul 2, §1.3), în care se obține bila albă pentru prima dată. Legea geometrică se obține din legea binomial negativă (vezi §3.2) pentru $c = 1$.

Caracteristici principale:

- Media $E(X) = \frac{1}{p}$;
- Varianța $\text{Var}(X) = \frac{q}{p^2}$;
- Funcția generatoare $g_X(t) = \frac{pt}{1 - qt}$;
- Funcția caracteristică $\varphi_X(t) = \frac{pe^{it}}{1 -qe^{it}}$.

Exemplul 1. La fiecare ciclu de imagine pe ecranul unui radar (independent de alte cicluri) un obiect este descoperit cu probabilitatea $p = 0.2$. Să

se determine valoarea medie și varianța v.a. X care desemnează numărul de cicluri necesar până la obținerea primei imagini a obiectului. Să se determine numărul minim de cicluri, după executarea cărora obiectul nu este descoverit cu o probabilitate mai mică sau egală cu 0,02.

Dacă $q = 1 - p = 0,8$ se obține

$$E(X) = \frac{1}{p} = 5, \quad \text{Var}(X) = \frac{q}{p^2} = 20.$$

Apoi trebuie determinat numărul minim de cicluri n cu proprietatea $P(X > n) \leq 0,02$. Întrucât

$$P(X > n) = 1 - P(X \leq n) = 1 - \sum_{k=1}^n pq^{k-1} = q^n$$

rezultă că n se determină din inegalitatea $q^n \leq 0,02$ și se obține $n \geq 17,5$. Deci valoarea căutată este $n = 18$.

Exemplul 2. Într-un stoc se află n becuri; fiecare bec este defect cu probabilitatea p . Pentru a alege un bec, se încearcă pe rând la rețea până se găsește un bec fără defect. Fie Z v.a. care desemnează numărul de becuri probate.

Se cere funcția de frecvență a v.a. Z și valoarea ei medie.

$P(Z = m)$ pentru $m < n$ se obține utilizând repartiția geometrică; $P(Z = n)$ este probabilitatea ca toate cele n becuri să fie probate, deci primele $n - 1$ sunt defecte. Prin urmare

$$P(Z = n) = p^{n-1},$$

iar dacă $q = 1 - p$, funcția de frecvență a lui Z este

$$Z : \begin{pmatrix} 1 & 2 & 3 & \dots & m & \dots & n-1 & n \\ q & pq & p^2q & \dots & p^{m-1}q & \dots & p^{n-2}q & p^{n-1} \end{pmatrix}.$$

Funcția generatoare (vezi §2.5) corespunzătoare va fi

$$g_Z(t) = \sum_{m=1}^{n-1} qp^{m-1}t^m + p^{n-1}t^n = \frac{qt - qp^{n-1}t^n}{1-pt} + p^{n-1}t^n.$$

Deci

$$E(Z) = g'_Z(1) = \frac{1-p^n}{1-p}.$$

3.4 Repartiția hipergeometrică

Se consideră o urnă cu a bile albe și b bile negre. Se fac n extrageri succesive, fără a pune înapoi în urnă bila după fiecare extragere (*urna lui Bernoulli cu bila nerepetată*).

Fie X v.a. care desemnează numărul de bile albe extrase și care poate lua valorile $0, 1, 2, \dots, \min(a, n)$. Se demonstrează că

$$P(X = k) = \frac{C_a^k C_b^{n-k}}{C_{a+b}^n}, \quad 0 \leq k \leq \min(a, n).$$

Caracteristici principale:

- Media $E(X) = np$;
- Varianța $\text{Var}(X) = npq \frac{a+b-n}{a+b-1}$,

unde

$$p = \frac{a}{a+b} \quad \text{și} \quad q = \frac{b}{a+b}.$$

Exemplul 1. Se spune despre un complex, format din 10 unități, că este în stare de funcționare, dacă la orice moment de timp cel puțin 5 unități funcționează. La o verificare se inspectează 4 din cele 10 unități. Complexul este considerat în stare de funcționare, dacă cel puțin 3 din cele 4 unități verificate funcționează. Dacă, în realitate, numai 4 din cele 10 unități sunt în funcțiune, care este probabilitatea ca, în urma verificării, complexul să fie considerat în stare de funcționare?

Se notează cu $p(m)$ probabilitatea ca, din cele 4 unități inspectate, m să nu funcționeze ($0 \leq m \leq 4$).

Utilizând repartiția hipergeometrică, în care $a = 6$, $b = 4$, probabilitatea căutată are valoarea

$$p(0) + p(1) \cong 0,12.$$

Exemplul 2. Un lot ce conține 40 de produse este considerat acceptabil, dacă nu conține mai mult de 5 produse defecte. Pentru a lua o decizie, se verifică la întâmplare, produs cu produs, până când este găsit un produs defect. Dacă aceasta se întâmplă în primele 6 verificări, atunci lotul este respins. Să se găsească o margine superioară pentru probabilitatea ca un lot necorespunzător să fie acceptat, respectiv pentru probabilitatea ca un lot corespunzător să fie respins.

Este clar că probabilitatea de a accepta un lot necorespunzător este cu atât mai mică, cu cât numărul de produse defecte din lot este mai mare. Deci pentru prima cestiune, se utilizează repartiția hipergeometrică cu $a = 34$, $b = 6$, $n = 6$, $k = 6$ și se obține probabilitatea căutată $\frac{C_{34}^6 \cdot C_6^2}{C_{40}^6} \cong 0,35$.

Pentru cea de-a doua chestiune, un raționament analog arată că probabilitatea căutată este

$$\sum_{k=1}^5 \frac{C_a^k C_b^{n-k}}{C_{a+b}^n},$$

dacă $a = 5$, $b = 35$, $n = 6$; se obține că ea este aproximativ 0,42.

Exemplul 3. Într-un lac se pescuiesc 1000 de pești. Fiecare pește prins este marcat și apoi este aruncat din nou în lac. La un al doilea pescuit se prind tot 1000 de pești și se constată că dintre aceștia 100 sunt marcați. Se poate trage de aici o concluzie relativă la numărul de pești din lac ?

Aceasta este o problemă de *estimare statistică* (vezi cap. 12). Se va presupune că pescuitul, în fiecare din cele două etape, este o selecție întâmplătoare din colectivitatea generală a peștilor din lac (vezi §11.2) și că numărul de pești rămâne constant între cele două momente când se pescuiesc. Se fac următoarele notări:

a - numărul de pești prinși prima dată, deci marcați (care joacă rolul bilelor albe)

n - numărul de pești prinși a doua oară

k - numărul de pești marcați prinși a doua oară

b - numărul de pești din lac nemarcați (care este necunoscut)

$P_b(k)$ - probabilitatea ca o două oară să fie prinși k pești mărcăți.

Cu aceste notări, probabilitatea $P_b(k)$ poate fi calculată utilizând repartiția hipergeometrică.

Numărul de pești din lac este $a + b$ și este evident că $a + b \geq a + n - k$.

În exemplul nostru $a = k = 1000$ și $k = 100$; deci numărul de pești din lac este cel puțin 1900.

Dacă se acceptă că numărul de pești este chiar 1900, atunci

$$P_b(k) = \frac{C_{1000}^{100} C_{900}^{900}}{C_{1900}^{1000}} = \frac{(1000!)^2}{100! 1900!}.$$

Această probabilitate are ordinul de mărime 10^{-430} , ceea ce ne îndreptățește să admitem că această ipoteză este foarte puțin plauzibilă (este neverosimilă).

La aceeași concluzie se ajunge, dacă am presupune că numărul de pești este foarte mare (de ordinul 10^6).

Aceste considerații ne conduc la alegerea acelei valori a lui b , pentru care $P_b(k)$ este maxim. Acest procedeu pentru estimarea lui b este cunoscut sub denumirea de *metoda verosimilității maxime* (vezi §12.2).

Astfel dacă se consideră raportul

$$\frac{P_b(k)}{P_{b-1}(k)} = \frac{b(a+b-n)}{(b-n+k)(a+b)}$$

se observă că acest raport este mai mare ca 1 pentru $b < \frac{a(n-k)}{k}$ și este mai mic ca 1 pentru $b > \frac{a(n-k)}{k}$.

Rezultă că $P_b(k)$, ca funcție de b , este crescătoare pentru $b < \frac{a(n-k)}{k}$ și apoi descrescătoare pentru $b > \frac{a(n-k)}{k}$. Maximul are loc când $b = \left\lfloor \frac{a(n-k)}{k} \right\rfloor$ (cel mai mare număr întreg mai mic sau egal cu $\frac{a(n-k)}{k}$).

Pentru exemplul nostru se găsește că valoarea cea mai verosimilă pentru b este $\hat{b} = 10000$.

3.5 Repartiția Poisson

Pentru $\lambda > 0$ se consideră v.a. X cu valori în \mathbb{N} și cu funcția de frecvență

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \in \mathbb{N}.$$

Repartiția Poisson mai este numită *repartiția evenimentelor rare* și se obține ca un caz limită al legii binomiale cu parametrii n și p . Mai precis, pentru n suficient de mare, p mic, astfel încât să se poată considera produsul $np = \lambda$ de valoare constantă, sirul (X_n) de v.a. repartizate binomial cu parametrii n și p , converge în repartiție (vezi exemplul 8 §4.1) către X . Pe de altă parte, legea Poisson poate fi aproximată de o lege normală (vezi exemplul 9 §4.1).

În multe situații practice, numărul de defecțiuni ale unui utilaj, într-un interval de timp fixat, urmează o repartiție Poisson (vezi exemplul 1).

Caracteristici principale:

- Media $E(X) = \lambda$;
 - Varianța $\text{Var}(X) = \lambda$;
 - Funcția caracteristică $\varphi_X(t) = \exp \lambda(e^{it} - 1)$, $t \in \mathbb{R}$.
- (3.5)

Exemplul 1. Se studiază numărul de defecțiuni ale unui utilaj în intervalul de timp $[0, T]$ și fie X v.a. care desemnează acest număr. Se notează $P(m) = P(X = m)$, $m = 0, 1, 2, \dots$

Se fac următoarele ipoteze:

- repararea utilajului se face instantaneu (adică prin înlocuire din punct de vedere practic);
- defectarea utilajului într-un interval de timp Δt este independentă de defectarea aparatului în orice interval de timp disjunct de acesta (nu se ține seama de fenomene de uzură în timp);

c) probabilitatea de a avea o defecțiune în intervalul Δt este $p(\Delta t)$; iar funcția $p(\Delta t)$ îndeplinește condiția

$$\lim_{\Delta t \rightarrow 0} \frac{T}{\Delta t} p(\Delta t) = \lambda > 0,$$

(prin urmare, probabilitatea unei defecțiuni într-un interval mic este proporțională cu lungimea sa);

d) dacă $q(\Delta t)$ este probabilitatea ca în intervalul Δt să aibă loc două sau mai multe defecțiuni, atunci

$$\lim_{\Delta t \rightarrow 0} \frac{q(\Delta t)}{\Delta t} = 0,$$

(aceasta înseamnă că nu se iau în considerație defectări simultane).

Intervalul $[0, T]$ se împarte în n subintervale de lungime Δt ; deci $n = \frac{T}{\Delta t}$. Dacă se notează $p_n = p(\Delta t)$, atunci

$$\lim_{n \rightarrow \infty} n p_n = \lambda.$$

Se notează cu $p(m, n)$ probabilitatea ca în m din cele n subintervale să se înregistreze câte o defecțiune și fie $a_n = np_n$. Înțând seamă de ipotezele făcute, se poate utiliza repartitia binomială (vezi §3.1) pentru evaluarea lui $p(m, n)$. Se obține

$$\begin{aligned} p(m, n) &= C_n^m p_n^m (1 - p_n)^{n-m} = \frac{n(n-1)\dots(n-m+1)}{m!} \left(\frac{a_n}{n}\right)^m \left(1 - \frac{a_n}{n}\right)^{n-m} = \\ &= \frac{a_n^m}{m!} \left(1 - \frac{a_n}{n}\right)^n \frac{\left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \dots \left(1 - \frac{m-1}{n}\right)}{\left(1 - \frac{a_n}{n}\right)^m}. \end{aligned}$$

Conform ipotezei (d) rezultă

$$|P(m) - p(m, n)| \leq n q(\Delta t) = \frac{q(\Delta t)}{\Delta t} T \rightarrow 0$$

când $\Delta t \rightarrow 0$, deci când $n \rightarrow \infty$. Așadar

$$P(m) = \lim_{n \rightarrow \infty} p(m, n) = \frac{\lambda^m}{m!} e^{-\lambda}.$$

Prin urmare, X urmează o repartie Poisson. Se observă că, în virtutea ipotezelor (c) și (d), numărul mediu de defecțiuni în intervalul $[0, T]$ este aproximativ egal cu $p(\Delta t) \frac{T}{\Delta t} \cong \lambda$. Aceasta ne determină ca, în diversele exemple

practice, ce se modelează cu ajutorul repartiției Poisson, să alegem pe λ ca fiind numărul mediu de apariții ale respectivului eveniment. Pe de altă parte, rezultă că

$$p(\Delta t) \cong \frac{\lambda}{T} \Delta t,$$

constantele λ și T fiind fixate. Așadar probabilitatea $p(\Delta t)$ este de ordinul de mărime al lui Δt , deci mică. De aici provine numele de repartitie a evenimentelor rare.

Exemplul 2. Un numărător de particule se blochează, dacă mai mult de 10 particule sunt într-o milisecundă. Numărul mediu de particule emise este de una pe milisecundă. Se cere probabilitatea ca numărătorul de particule să se blocheze într-un interval de timp de o milisecundă fixat în prealabil.

Se notează cu $p(k)$, probabilitatea ca numărul de particule emise în interval dat să fie k și se calculează cu ajutorul repartiției Poisson pentru $\lambda = 1$.

Probabilitatea de blocare este

$$\sum_{k=11}^{\infty} p(k) = 1 - \sum_{k=0}^{10} p(k) = 1 - \sum_{k=0}^{10} \frac{e^{-1}}{k!} \cong 10^{-7}.$$

Exemplul 3. Se consideră o centrală telefonică cu un mare număr de abonați, caracterizată de un trafic mediu de 50000 apeluri telefonice pe zi. Se numește nivel de supraîncărcare cel mai mic număr N , cu proprietatea că probabilitatea a N sau mai multe apeluri pe secundă este mai mică decât 0,001.

Se cere nivelul de supraîncărcare.

Numărul mediu de apeluri pe secundă este $\frac{50}{24 \cdot 3600} \cong 0,58$.

Probabilitatea $p(k)$, de a avea k apeluri într-un interval de timp de p secunde fixat, se calculează utilizând repartiția Poisson cu $\lambda = 0,58$.

Nivelul de supraîncărcare va fi cel mai mic număr întreg N pentru care

$$p(N) + p(N+1) + \dots \leq 0,001.$$

Întrucât λ este subunitar, termenii sumei de mai sus începând cu al doilea sunt neglijabili în primă aproximare, în raport cu $p(N)$. Astfel N se determină din inegalitatea $p(N) \leq 0,001$ și se găsește $N = 5$.

Exemplul 4. Particulele cosmice, care întâlnesc un satelit, generează un câmp cu densitatea a (particule/ m^2).

Un agregat al satelitului, care se găsește în câmpul de particule, are suprafața S (m^2). Pentru ieșirea din funcțiune a acestui agregat este suficient să fie bombardat de 2 particule; dacă este bombardat de o singură particulă, atunci eliese din funcțiune cu probabilitatea p .

Se cere probabilitatea ieșirii din funcțiune. Numărul mediu de particule, care bombardează aggregatul respectiv, este $\lambda = as$.

Se consideră următoarele evenimente:

A - agregatuliese din funcțiune,

H_0 - agregatul nu este lovit de nici o particulă,

H_1 - agregatul este lovit de o singură particulă,

H_2 - agregatul este lovit de două sau mai multe particule.

Admitând că fluxul particulelor ce lovesc agregatul este poissonian rezultă

$$P(H_0) = e^{-\lambda}, \quad P(H_1) = \lambda e^{-\lambda}, \quad P(H_2) = 1 - e^{-\lambda} - \lambda e^{-\lambda} = 1 - e^{-\lambda}(1 + \lambda).$$

Din ipoteze rezultă

$$P(A | H_0) = 0, \quad P(A | H_1) = p, \quad P(A | H_2) = 1.$$

Utilizând formula probabilității totale (vezi teorema 1.2, §1.3) se obține

$$\begin{aligned} P(A) &= P(H_0)P(A|H_0) + P(H_1)P(A|H_1) + P(H_2)P(A|H_2) = \\ &= p\lambda e^{-\lambda} + 1 - e^{-\lambda}(1 + \lambda). \end{aligned}$$

3.6 Repartiția normală

Densitatea de repartiție normală cu parametrii $m \in \mathbf{R}$ și $\sigma > 0$, notată $N(m, \sigma)$, este

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}, \quad x \in \mathbf{R}.$$

Caracteristici principale:

- Valoarea medie $E(X) = m$;

- Varianța $\text{Var}(X) = \sigma^2$;

- Funcția caracteristică $\varphi_X(t) = e^{itm - \frac{\sigma^2 t^2}{2}}$, $t \in \mathbf{R}$.

Graficul densității de repartiție $p(x)$ pentru $m = 0$ și $\sigma = 1$ este dat în fig. 3.1. În general, pentru diverse valori ale lui $m \in \mathbf{R}$ și $\sigma > 0$, graficul este simetric față de $x = m$, are un maxim de coordonate $\left(m, \frac{1}{\sigma\sqrt{2\pi}}\right)$ și două puncte de inflexiune pentru $x = m \pm \sigma$. Graficul este cunoscut sub numele de *clopotul lui Gauss*.

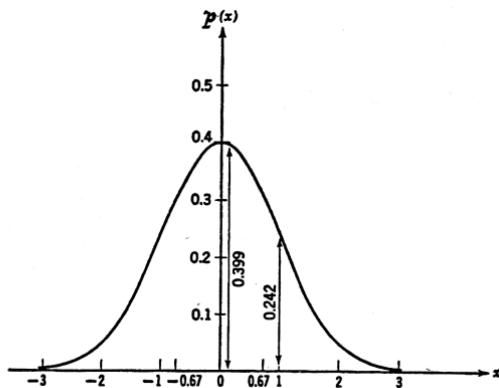


Fig. 3.1.

Legea normală normată (standard sau redusă) $N(0, 1)$ are funcția de repartiție

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt,$$

care se numește *funcția lui Laplace* și este tabelată (vezi anexa 1). Graficul ei este dat în fig. 3.2.

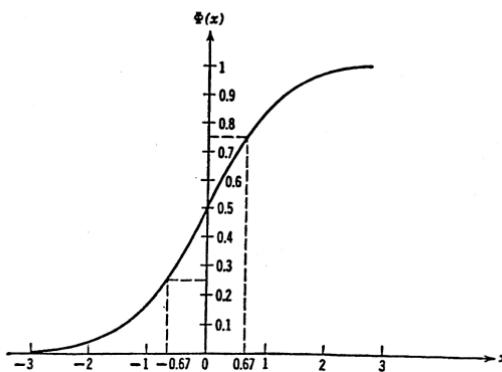


Fig. 3.2

Se observă că $\Phi(-x) = 1 - \Phi(x)$, $x \geq 0$; iar dacă X este repartizată $N(m, \sigma)$, atunci

$$P(a \leq X \leq b) = \Phi\left(\frac{b-m}{\sigma}\right) - \Phi\left(\frac{a-m}{\sigma}\right), \quad a < b.$$

În particular

$$P(m - \alpha \leq X \leq m + \alpha) = 2\Phi\left(\frac{\alpha}{\sigma}\right) - 1, \quad \alpha > 0. \quad (3.6)$$

Densitatea normală a fost introdusă de Gauss¹, ca densitatea căreia trebuie să î se supună erorile de observație, pentru ca media aritmetică a unei mulțimi de măsurări să fie cea mai apropiată de valoarea adevărată. Deși, în realitate, nu există o lege normală a erorilor, după cum s-a observat, totuși densitatea normală are o importanță teoretică foarte mare, fiind întâlnită în problemele asimptotice din teoria probabilităților.

Exemplul 1. Fie X o v.a. repartizată $N(m, \sigma)$. Să se determine probabilitatea ca X să se abată de la valoarea sa medie m cu mai mult de 3σ .

Conform relației (3.6) se obține

$$\begin{aligned} P(|X - m| > 3\sigma) &= 1 - P(|X - m| \leq 3\sigma) = \\ &= 1 - P(m - 3\sigma \leq X \leq m + 3\sigma) = 1 - 2\Phi(3). \end{aligned}$$

Din tabele (vezi anexa 1) se găsește $\Phi(3) \cong 0,49865$. Prin urmare

$$P = (|X - m| > 3\sigma) \cong 0,0027.$$

Exemplul 2. O uzină produce bile pentru rulmeji cu diametrul nominal 10(mm). În realitate diametrul este o v.a. repartizată $N(10; 0,4)$. La controlul de calitate se acceptă doar bilele cu diametrul cuprins între 9,3 și 10,7. Să se determine procentul de rebuturi.

Probabilitatea ca o bilă să fie rebutată este

$$\begin{aligned} P(|X - m| > 0,7) &= 1 - P(|X - m| \leq 0,7) = \\ &= 1 - \left(2\Phi\left(\frac{0,7}{0,4}\right) - 1\right) = 2(1 - \Phi(1,75)) \cong 0,08. \end{aligned}$$

Prin urmare există aproximativ 8% rebuturi.

¹Carl Friedrich Gauss (1777-1855) a fost un mare matematician german.

3.7 Repartiția lognormală

Densitatea de repartiție a v.a. X este lognormală, dacă este de forma

$$p(x) = \begin{cases} \frac{1}{(x - \theta)\sigma\sqrt{2\pi}} e^{-\frac{\ln(x-\theta)-m^2}{2\sigma^2}}, & x > 0 \\ 0, & x \leq 0. \end{cases}$$

Prin urmare v.a. $Y = \ln(x - \theta)$ este repartizată $N(m, \sigma)$.

Caracteristici principale:

- Media $E(X) = \theta + e^{m+\frac{\sigma^2}{2}}$;
- Varianță $\text{Var}(X) = e^{2m}e^{\sigma^2}(e^{\sigma^2}-1)$.

3.8 Repartiția uniformă

Se spune că v.a. X este uniform repartizată pe intervalul $[a, b]$, dacă are densitatea de repartiție

$$p(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & x < a \text{ sau } x > b. \end{cases}$$

Prin urmare funcția de repartiție va fi

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b. \end{cases}$$

Caracteristici principale:

- Media $E(X) = \frac{a+b}{2}$;
- Varianță $\text{Var}(X) = \frac{(b-a)^2}{12}$; (3.7)
- Funcția caracteristică $\varphi_X(t) = \frac{e^{itb} - e^{ita}}{(b-a)it}$, $t \in \mathbb{R}$.

Exemplul 1. Să se determine probabilitatea ca o v.a. X , repartizată uniform pe $[a, b]$, să se abată de la valoarea medie cu mai mult de 3σ , unde $\sigma = \frac{2}{\sqrt{3}}$. Valoarea medie $m = \frac{(a+b)}{2}$ conform (3.7). Se obține

$$P(|X - m| > 3\sigma) = 1 - P(|X - m| \leq 3\sigma) = 1 - F(m + 3\sigma) + F(m - 3\sigma) =$$

$$= 1 - F\left(\frac{b(1 + \sqrt{3}) + a(1 - \sqrt{3})}{2}\right) + F\left(\frac{b(1 - \sqrt{3}) + a(1 + \sqrt{3})}{2}\right) = 1 - 1 + 0 = 0$$

întrucât $\frac{b(1 + \sqrt{3}) + a(1 - \sqrt{3})}{2} > b$ și $\frac{b(1 - \sqrt{3}) + a(1 + \sqrt{3})}{2} < a$; F reprezintă funcția de repartiție uniformă.

Exemplul 2. Între orele 7 și 8 un tren (metrou) pleacă dintr-o stație la 3; 5; 8; 10; 13; 15; 18; 20 ... minute după ora 7. Să se determine probabilitatea ca o persoană ce sosește în stație să aștepte mai puțin de un minut pînă la plecarea primului tren, dacă se presupune că momentul de sosire al persoanei urmează o repartiție uniformă în intervalul de timp de la 7 la 8.

Fie A evenimentul a cărui probabilitate ne interesează. Acest eveniment constă în faptul că persoana sosește într-unul din intervalele 2 la 3, 4 la 5, 7 la 8, 9 la 10, s.a.m.d. Întrucât funcția de repartiție a momentului sosirii este

$$F(x) = \begin{cases} 0, & x < 0 \\ \frac{x}{60}, & 0 \leq x \leq 60 \\ 1, & x > 60 \end{cases}$$

rezultă conform (2.1)

$$P(A) = [F(3) - F(2)] + [F(5) - F(4)] + \dots = \frac{24}{60} = \frac{2}{5}.$$

Se remarcă asemănarea dintre acest exemplu și exemplul 4, §1.2, precum și posibilitatea utilizării sale în practică, așa cum s-a menționat în exemplul citat.

Exemplul 3. Un mecanism, ce urmează o repartiție uniformă pe intervalul $[0, 1]$, alege la întâmplare un număr din acest interval. Se cere probabilitatea ca cea de-a doua zecimală a rădăcinii pătrate a numărului ales să fie egală cu k , $k = 0, 1, 2, \dots, 9$. Se notează cu A_k evenimentul a cărui probabilitate ne interesează. Se observă că $x \in A_k$ dacă și numai dacă există $m = 0, 1, 2, \dots, 9$ astfel încât

$$m + \frac{k}{10} \leq 10\sqrt{x} < m + \frac{k+1}{10},$$

adică dacă și numai dacă există $m = 0, 1, \dots, 9$ astfel încât

$$\frac{1}{100} \left(m + \frac{k}{10}\right)^2 \leq x < \frac{1}{100} \left(m + \frac{k+1}{10}\right)^2.$$

Lungimea acestui interval este

$$\frac{1}{10000}(20m + 2k + 1)$$

și deci

$$P(A_k) = \frac{1}{10000} \sum_{m=0}^9 (20m + 2k + 1) = 0,001 + 0,0002k.$$

3.9 Repartiția exponențială

Densitatea de probabilitate exponențială este

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}, \quad \lambda > 0.$$

Caracteristici principale:

- Media $E(X) = \frac{1}{\lambda}$;

- Varianța $\text{Var}(X) = \frac{1}{\lambda^2}$;

- Funcția caracteristică $\varphi_X(t) = \frac{\lambda}{\lambda - it}$, $t \in \mathbf{R}$.

Repartiția exponențială are un rol important în teoria fiabilității. Astfel, repartiția duratei de funcționare neîntreruptă a unei instalații (dacă nu se ia în considerație uzura în timp) este exponențială.

De asemenea, dacă numărul de defecțiuni în orice interval $[0, t]$ este repartizat Poisson cu parametrul λt , atunci intervalul între două defecțiuni succesive este repartizat exponențial cu parametrul λ .

Repartiția exponențială reprezintă un model în diferite probleme ce se referă la durata de aşteptare, de exemplu, în telefonie, rețele de servire și aprovisionare etc.

Dacă X este o v.a. cu densitate exponențială, atunci pentru orice numere reale nenegative s și t se obține

$$P(X > s + t | X > s) = \frac{\lambda \int_{s+t}^{\infty} e^{-\lambda u} du}{\lambda \int_s^{\infty} e^{-\lambda u} du} = e^{-\lambda t} = P(X > t). \quad (3.8)$$

Semnificația probabilistă a relației (3.8) este următoarea: faptul că am așteptat un anumit timp, nu are nici o influență asupra duratei ulterioare a așteptării (ca și cum am așteptat în zadar). Acest fapt poate fi exprimat în mod sugestiv, spunând că X nu are memorie. Lipsa de memorie a densității exponențiale este o proprietate caracteristică a acesteia în sensul următor: o v.a. nenegativă X satisfacă condiția

$$P(X > s + t | X > s) = P(X > t), \quad s \geq 0, \quad t \geq 0,$$

dacă și numai dacă este o variabilă exponențială.

În fapt, se arată că dacă funcția f definită pe $[0, \infty)$ este descrescătoare și satisface ecuația funcțională a lui Cauchy

$$f(s+t) = f(s) \cdot f(t), \quad s \geq 0, \quad t \geq 0,$$

atunci $f(t) = e^{-\lambda t}$, unde $\lambda \geq 0$.

Se observă, în plus, că repartiția geometrică (vezi §3.3) furnizează doar în cazul discret prin relația

$$P(X > m+n | X > m) = \frac{q^{m+n}}{q^m} = q^n = P(X > n), \quad m, n \in \mathbb{N},$$

un analog al relației (3.8), deoarece lipsa de memorie poate deveni falsă dacă m și n nu sunt numere întregi (de exemplu pentru $m = n = 1/2$).

Exemplul 1. Se presupune că durata de funcționare neîntreruptă a unui utilaj este o v.a. T , ce urmează o repartiție exponentială cu parametrul λ (semnificația fizică pentru λ , numită *intensitate de avarie*, este dată de faptul că probabilitatea de defectare într-un interval de lungime Δt este $\lambda \Delta t + o(\Delta t)$)².

Presupunând că utilajul a funcționat fără defectiuni până la momentul τ , să se determine repartiția v.a. T_τ , care reprezintă intervalul până la prima defectare după momentul τ .

Pentru $t > 0$ se obține

$$P(T_\tau \leq t) = P(\tau < T \leq t + \tau | T > \tau) = \frac{e^{-\lambda \tau} - e^{-\lambda(t+\tau)}}{e^{-\lambda \tau}} = 1 - e^{-\lambda t}.$$

Prin urmare, repartiția timpului rămas până la prima defecțiune nu depinde de cât timp era utilajul în funcțiune (se exclude fenomenul de uzură în timp).

Exemplul 2. Făcând un studiu pe un număr mare de tranzistori de același tip, s-a constatat că intensitatea de defectare este constantă, adică raportul

$$\frac{N(t) - N(t + \Delta t)}{N(T)},$$

unde $N(t)$ este numărul de tranzistori în stare de funcționare la momentul t , este aproximativ același pentru toate valorile lui t .

Calculând

$$\lim_{\Delta t \rightarrow 0} \frac{N(t) - N(t + \Delta t)}{N(t)} = - \frac{dN(t)}{dt}$$

² $o(\Delta t)$ este neglijabilă în raport cu Δt , adică $\lim_{\Delta t \rightarrow \infty} \frac{o(\Delta t)}{\Delta t} = 0$.

în ipoteza făcută, rezultă că

$$\frac{dN(t)}{dt} = -\lambda, \quad \lambda > 0,$$

de unde

$$N(t) = Ce^{-\lambda t}, \quad C = \text{const.}$$

Scriind că probabilitatea $p(t)$ de defectare în intervalul $[0, t]$ este aproximativ egală cu frecvența relativă, se obține

$$p(t) = \frac{N(0) - N(t)}{N(0)} = \frac{C - Ce^{-\lambda t}}{C} = 1 - e^{-\lambda t}.$$

Prin urmare, durata de funcționare neîntreruptă urmează o repartiție exponentională.

3.10 Repartiția Weibull

Densitatea de repartiție Weibull este

$$p(x) = \frac{\beta}{\eta} \left(\frac{x - \gamma}{\eta} \right)^{\beta-1} \cdot \exp \left[- \left(\frac{x - \gamma}{\eta} \right)^\beta \right], \quad \gamma \leq x < \infty,$$

unde β , γ și η reprezintă parametri pozitivi (β -parametrul de formă, η -parametrul de scală, γ -parametrul de locație).

Caracteristici principale:

- Media $E(X) = \gamma + \eta \Gamma \left(1 + \frac{1}{\beta} \right)^{-1};$
- Varianță $\text{Var}(X) = \eta^2 \left[\Gamma(1 + 4\beta) - \Gamma^2 \left(1 + \frac{1}{\beta} \right) \right];$ (3.9)
- Modul $M_0 = \gamma + \eta \left(1 - \frac{1}{\beta} \right)^{1/\beta};$

- Mediana $m = \gamma + \eta (\ln 2)^{1/\beta}.$

Pentru $\beta = 1$ se obține repartiția exponentională.

Funcția de repartiție este

$$F(x) = 1 - e^{-\left(\frac{x-\gamma}{\eta}\right)^\beta}.$$

³Funcția Γ este funcția euleriană $\Gamma : (0, \infty) \rightarrow \mathbb{R}$, $\Gamma(t) = \int_0^\infty x^{t-1} \cdot e^{-x} dx.$

Legea Weibull se mai poate prezenta astfel:

$$F(x) = 1 - e^{-(\frac{x}{a})^b} \quad x \geq 0 \quad a, b > 0;$$

$$F(x) = 1 - e^{-\frac{x^k}{\lambda}} \quad x \geq 0 \quad k, \lambda > 0;$$

$$F(x) = 1 - e^{-\theta x^k} \quad x \geq 0 \quad \theta, k > 0.$$

Dacă X este repartizată Weibull (cu parametri θ, k), atunci X^k este repartizată exponențial.

Legea Weibull este utilizată în teoria fiabilității, atunci când se iau în considerație și fenomenele de uzură.

3.11 Repartiția Rayleigh

Repartiția Rayleigh este un caz particular al legii Weibull pentru $\beta = 2$ (vezi §3.10). Funcția de repartiție este

$$F(x) = 1 - e^{-\theta x^2}, \quad x > 0, \quad \theta > 0.$$

3.12 Repartiția Gamma

Densitatea de repartiție Gamma este

$$p(x) = \begin{cases} 0, & x \leq 0 \\ \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax}, & x > 0 \end{cases}$$

unde $a, p > 0$, iar Γ este funcția euleriană

$$\Gamma(t) = \int_0^\infty t^{x-1} e^{-x} dx, \quad t > 0.$$

Caracteristici principale:

- Media $E(X) = \frac{p}{a}$;

- Varianța $\text{Var}(X) = \frac{p}{a^2}$;

- Funcția caracteristică $\varphi_X(t) = \frac{1}{\left(1 - \frac{it}{a}\right)^p}$, $t \in \mathbf{R}$.

Pentru $p = 1$ se obține legea exponențială cu parametrul a .

Pentru $p = k \in \mathbf{N}$ și $a = \lambda k$ se obține

$$p(x) = \begin{cases} 0, & x \leq 0 \\ \frac{(\lambda k)^k}{\Gamma(k)} x^{k-1} e^{-\lambda k x}, & x > 0 \end{cases}$$

care este numită *repartiția Erlang*. Pentru $p = \frac{n}{2}$ și $a = \frac{1}{2\sigma^2}$ ($\sigma > 0$) se obține repartiția χ^2 (vezi §3.14).

3.13 Repartiția Beta

V.a. X este repartizată Beta cu parametrii $\mu, \nu > 0$, dacă are densitatea de repartiție

$$p(x) = \begin{cases} \frac{\Gamma(\mu + \nu)}{\Gamma(\mu)\Gamma(\nu)} x^{\mu-1} (1-x)^{\nu-1}, & x \in (0, 1) \\ 0, & x \notin (0, 1). \end{cases}$$

Funcția de repartiție este

$$F(x) = \begin{cases} 0, & x \leq 0 \\ \frac{\int_0^x y^{\mu-1} (1-y)^{\nu-1} dy}{B(\mu, \nu)}, & 0 < x < 1 \\ 1, & x \geq 1 \end{cases}$$

unde funcția B este funcția euleriană

$$B(p, q) = \int_0^1 x^{p-1} (1-x)^{q-1} dx, \quad \text{cu } p > 0, q > 0.$$

Caracteristici principale:

- Media $E(X) = \frac{\mu}{\mu + \nu}$;
- Varianța $\text{Var}(X) = \frac{\mu\nu}{(\mu + \nu)^2(\mu + \nu + 1)}$; (3.10)
- Momentul de ordinul r $E(X^r) = \frac{\Gamma(\mu + \nu)\Gamma(\mu + r)}{\Gamma(\mu)\Gamma(\mu + \nu + r)}$.

Pentru $\mu = \nu = 1$ se obține legea uniformă (vezi §3.8).

3.14 Repartiția χ^2 (hi pătrat)

Densitatea de repartiție χ^2 este

$$p(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{2^{n/2}\sigma^n \Gamma\left(\frac{n}{2}\right)} x^{n/2-1} e^{-x/2\sigma^2}, & x \geq 0. \end{cases}$$

unde $n \in \mathbb{N}^*$ reprezintă numărul gradelor de libertate și $\sigma > 0$.

Caracteristici principale:

- Media $E(X) = n\sigma^2$;
- Varianță $\text{Var}(X) = 2n\sigma^4$;
- Momentul de ordinul r $E(X^r) = 2^r \left(\frac{n}{2} + r - 1\right) \dots \left(\frac{n}{2} + 1\right) \left(\frac{n}{2}\right) \sigma^{2r}$;
- Funcția caracteristică $\varphi_X(t) = (1 - 2\sigma^2 it)^{-n/2}$, $t \in \mathbb{R}$.

Fie X_1, X_2, \dots, X_n v.a. independente repartizate $N(m, \sigma)$ (vezi §3.6). Se consideră v.a. $Y = \frac{1}{\sigma^2} \sum_{k=1}^n (X_k - m)^2$ a cărei repartiție se cere. Să calculăm funcția de repartiție $F_Y(x)$ a v.a. Y . Este evident că $F_Y(x) = 0$ pentru $x < 0$; pentru $x \geq 0$, conform relației (2.7) rezultă

$$F_Y(x) = \int \dots \int p(x_1, \dots, x_n) dx_1 \dots dx_n.$$

$$\left\{ \sum_{k=1}^n (x_k - m)^2 \leq \sigma^2 x \right\}$$

Deoarece v.a. X_1, X_2, \dots, X_n sunt independente și identic repartizate $N(m, \sigma)$, rezultă că

$$p(x_1, \dots, x_n) = \left(\frac{1}{\sigma \sqrt{2\pi}} \right)^n e^{-\sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2}}$$

și se obține

$$F_Y(x) = \int \dots \int \left(\frac{1}{\sqrt{2\pi}} \right)^n e^{-\sum_{i=1}^n \frac{y_i^2}{2}} dy_1 \dots dy_n,$$

$$\left\{ \sum_{k=1}^n y_k^2 \leq x \right\}$$

în urma schimbării de variabile $\frac{x_i - m}{\sigma} = y_i$, $i = \overline{1, n}$. Pentru a calcula integrala se trece la coordonate sferice generalizate, adică

$$y_1 = \rho \cos \theta_1 \cos \theta_2 \dots \cos \theta_{n-1}$$

$$y_2 = \rho \cos \theta_1 \cos \theta_2 \dots \sin \theta_{n-1}$$

.....

$$y_n = \rho \sin \theta_1$$

unde

$$\rho > 0, \theta_1, \dots, \theta_{n-2} \in \left(\frac{-\pi}{2}, \frac{\pi}{2} \right), \quad \theta_{n-1} \in (0, 2\pi)$$

și se obține

$$\begin{aligned} F_Y(x) &= \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} \cdots \int_0^{2\pi} \int_0^{\sqrt{x}} \frac{1}{(\sqrt{2\pi})^n} e^{-\frac{\rho^2}{2}} \rho^{n-1} D(\theta_1, \dots, \theta_{n-1}) d\rho d\theta_{n-1} \dots d\theta_1 = \\ &= C_n \int_0^{\sqrt{x}} e^{-\frac{\rho^2}{2}} \rho^{n-1} d\rho, \end{aligned}$$

unde $\rho^{n-1} D(\theta_1, \dots, \theta_{n-1})$ este valoarea absolută a jacobianului transformării și

$$C_n = \frac{1}{(\sqrt{2\pi})^n} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} \cdots \int_0^{2\pi} D(\theta_1, \dots, \theta_{n-1}) d\theta_{n-1} \dots d\theta_1.$$

Constanta C_n se determină utilizând ecuația

$$F_Y(+\infty) = 1 = C_n \int_0^\infty e^{-\frac{\rho^2}{2}} \rho^{n-1} d\rho = C_n \Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}-1}.$$

Prin urmare

$$F_Y(x) = \frac{1}{2^{n/2-1} \Gamma\left(\frac{n}{2}\right)} \int_0^{\sqrt{x}} \rho^{n-1} e^{-\frac{\rho^2}{2}} d\rho$$

și prin derivare se găsește densitatea de repartiție a v.a. Y

$$p_Y(x) = \frac{1}{2^{n/2} \Gamma\left(\frac{n}{2}\right)} x^{n/2-1} e^{-x/2}, \quad x > 0.$$

Deci Y urmează o repartiție χ^2 cu n grade de libertate.

3.15 Repartiția t a lui Student

V.a. X este repartizată Student cu s ($s > 0$) grade de libertate, dacă are densitatea de repartitie

$$p(x) = \frac{\Gamma\left(\frac{s+1}{2}\right)}{\sqrt{\pi s} \Gamma\left(\frac{s}{2}\right)} \left(1 + \frac{x^2}{s}\right)^{-(s+1)/2}, \quad x \in \mathbb{R}.$$

Momentele de ordin impar sunt nule, iar cele de ordin par sunt

$$E(X^{2p}) = s^p \frac{\Gamma\left(\frac{p+1}{2}\right) \Gamma\left(\frac{s}{2} - p\right)}{\sqrt{\pi} \Gamma\left(\frac{s}{2}\right)}, \quad p < \frac{s}{2}.$$

Prin urmare $E(X) = 0$ și $\text{Var}(X) = \frac{s}{(s-2)}$.

3.16 Repartiția F a lui Snedecor-Fisher

Densitatea de repartiție Snedecor-Fisher este

$$p(x) = \begin{cases} 0, & x < 0 \\ \frac{\Gamma\left(\frac{s_1 + s_2}{2}\right)}{\Gamma\left(\frac{s_1}{2}\right)\Gamma\left(\frac{s_2}{2}\right)} \left(\frac{s_1}{s_2}\right)^{\frac{s_1}{2}} x^{\frac{s_1}{2}-1} \left(1 + \frac{s_1}{s_2}x\right)^{-\frac{s_1 + s_2}{2}}, & x \geq 0 \end{cases}$$

unde $s_1, s_2 > 0$ sunt grade de libertate.

Caracteristici principale:

- Media $E(X) = \frac{s_2}{s_2 - 2}$, $s_2 > 2$;

- Varianță $\text{Var}(X) = \frac{2s_2^2(s_1 + s_2 - 2)}{s_1(s_2 - 2)^2(s_2 - 4)}$, $s_2 > 4$. (3.11)

3.17 Repartiția Z a lui Fisher

Se consideră v.a. $Y = \frac{1}{2} \ln X$, unde X este o v.a. repartizată F , cu s_1 și s_2 grade de libertate (vezi §3.16). Atunci densitatea de repartiție Z a lui Fisher este

$$p_Y(x) = 2 \frac{\Gamma\left(\frac{s_1 + s_2}{2}\right)}{\Gamma\left(\frac{s_1}{2}\right)\Gamma\left(\frac{s_2}{2}\right)} \left(\frac{s_1}{s_2}\right)^{\frac{s_1}{2}} e^{s_1 x} \left(1 + \frac{s_1}{s_2} e^{2x}\right)^{-\frac{s_1 + s_2}{2}}.$$

3.18 Repartiția Cauchy

Densitatea de repartiție Cauchy $C(m, a)$ este

$$p(x) = \frac{1}{\pi} \cdot \frac{a}{a^2 + (x - m)^2}, \quad x \in \mathbf{R},$$

unde $a > 0$ și $m \in \mathbf{R}$.

Funcția caracteristică este

$$\varphi_X(t) = e^{imt - a|t|}, \quad t \in \mathbf{R}.$$

Această repartiție are media infinită.

3.19 Repartitia Pareto

Densitatea de repartiție Pareto $Pa(k, \alpha)$ este

$$p(x) = \frac{\alpha k^\alpha}{x^{\alpha+1}}, \quad x > k,$$

unde $k > 0$ și $\alpha > 0$.

Caracteristici principale:

- Media $E(X) = \frac{\alpha k}{\alpha - 1}$, $\alpha > 1$;
- Varianța $\text{Var}(X) = \frac{\alpha k^2}{(\alpha - 2)(\alpha - 1)^2}$, $\alpha > 2$.

3.20 Repartitia normală n-dimensională

Vectorul aleator $X = (X_1, X_2, \dots, X_n)$ are repartiția normală n -dimensională dacă densitatea sa de repartiție este

$$p(x_1, \dots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}} \sqrt{\det A}} e^{-\frac{1}{2}(x-m)^t A^{-1}(x-m)},$$

unde

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix},$$

m este un vector $n \times 1$, $A = (\sigma_{ij})_{1 \leq i,j \leq n}$ este o matrice $n \times n$ pozitiv definită, iar $(x - m)^t$ este transpusul lui $(x - m)$.

Caracteristici principale:

- Media $E(X) = m^t = \begin{pmatrix} m_1 \\ \vdots \\ m_n \end{pmatrix}^t$;

- Matricea de covarianță are elementele

$$\text{cov}(X_i, X_j) = \sigma_{ij}, \quad 1 \leq i, j \leq n$$

(vezi §2.4).

Dacă matricea de covarianță este astfel încât $\sigma_{ij} = 0$, $i \neq j$, atunci $p(x_1, \dots, x_n)$ este produsul densităților a n v.a. necorelate X_1, X_2, \dots, X_n , repartizate respectiv $N(m_i, \sigma_i)$, $i = \overline{1, n}$, ($\sigma_i = \sigma_{ii}$).

3.21 Repartiția multinomială

Se consideră vectorul aleator $X = (X_1, X_2, \dots, X_m)$, fiecare din v.a. discrete X_i , $i = \overline{1, m}$ putând lua valorile întregi $0, 1, 2, \dots, n$, astfel încât

$$X_1 + X_2 + \dots + X_m = n.$$

Presupunem că funcția de frecvență a vectorului aleator $(X_1, X_2, \dots, X_{m-1})$ este

$$\begin{aligned} P(X_1 &= k_1, X_2 = k_2, \dots, X_{m-1} = k_{m-1}) = \\ &= P(X_1 = k_1, \dots, X_{m-1} = k_{m-1}, X_m = k_m) = \\ &= \frac{n!}{k_1! k_2! \dots k_m!} p_1^{k_1} p_2^{k_2} \dots p_m^{k_m}, \end{aligned} \quad (3.12)$$

unde

$$k_1 + k_2 + \dots + k_m = n, \quad p_j, \quad j = \overline{1, m},$$

sunt numere pozitive date și $\sum_{j=1}^m p_j = 1$.

Expresia din membrul drept al relației (3.12) este termenul general al dezvoltării $(p_1 + p_2 + \dots + p_m)^n$.

Observație. Experimentul ce servește drept model de repartiție multinomială genera-lizează schema lui Bernoulli cu bila repetată (vezi §3.1 și exemplul 2, §1.3). Generalizarea constă în faptul că urna conține bile de m culori, iar probabilitatea de a extrage o bilă de culoare j este p_j , $j = \overline{1, m}$. Prin urmare, X_j desemnează numărul de bile de culoare j , obținute după n extrageri, punându-se bila în urnă după fiecare extragere.

Caracteristici principale:

- Media $E(X_j) = np_j \quad 1 \leq j \leq m;$
- Varianță $\text{Var}(X_j) = np_j(1 - p_j) \quad 1 \leq j \leq m;$
- Covarianță $\text{cov}(X_i, X_j) = -np_i p_j, \quad 1 \leq i, j \leq n.$
- Funcția caracteristică este

$$\varphi_X(t_1, t_2, \dots, t_m) = (p_1 e^{it_1} + p_2 e^{it_2} + \dots + p_m e^{it_m})^n.$$

Fie $l_j = k_j - np_j$ și $a, b \in \mathbf{R}_+$ astfel încât

$$a\sqrt{n} \leq l_j \leq b\sqrt{n}, \quad j = \overline{1, m}.$$

Atunci pentru $n \rightarrow \infty$

$$P(X_1 = k_1, X_2 = k_2, \dots, X_m = k_m) \cong \frac{e^{-\frac{1}{2} \sum_{j=1}^m \frac{l_j^2}{np_j}}}{(2\pi n)^{\frac{(m-1)}{n}} \sqrt{p_1 p_2 \dots p_m}}. \quad (3.14)$$

Relația (3.14) reprezintă *expresia asimptotică pentru repartiția multinomială*.

De asemenea, vectorul aleator

$$\left(\frac{X_1 - np_1}{\sqrt{np_1}}, \frac{X_2 - np_2}{\sqrt{np_2}}, \dots, \frac{X_{m-1} - np_{m-1}}{\sqrt{np_{m-1}}} \right)$$

urmează la limită (convergență în repartiție conform §4.1) o repartiție normală $(m-1)$ -dimensională (vezi §3.20).

Observație. Experimentul urnei de mai sus poate fi generalizat, înălțând presupunerea referitoare la punerea bilei în urnă după fiecare extragere. În acest fel, se obține și o generalizare a experimentului ce conduce la repartiția hipergeometrică (vezi §3.4).

Funcția de frecvență corespunzătoare va fi

$$P(X_1 = k_1, X_2 = k_2, \dots, X_m = k_m) = \frac{C_{N_1}^{k_1} C_{N_2}^{k_2} \dots C_{N_m}^{k_m}}{C_N^n} p_1^{k_1} \dots p_m^{k_m},$$

unde $k_1 + k_2 + \dots + k_m = n$; N este numărul total de bile din urnă, iar N_j este numărul de bile de culoare j ; $N_1 + \dots + N_m = N$.

Caracteristici principale:

- Media $E(X_j) = np_j$;
- Varianța $\text{Var}(X_j) = np_j(1-p_j)\frac{N-n}{N-1}$;
- Covarianța $\text{cov}(X_i, X_j) = np_i p_j \frac{N-n}{N-1}$.

3.22 Repartiția Poisson multidimensională

Se consideră vectorul aleator $X = (X_1, X_2, \dots, X_n)$, fiecare din v.a. X_i luând valori în mulțimea \mathbb{N} . Atunci funcția de frecvență este dată de

$$P(X_1 = k_1, X_2 = k_2, \dots, X_n = k_n) = \frac{\lambda_1^{k_1} \lambda_2^{k_2} \dots \lambda_n^{k_n}}{k_1! k_2! \dots k_n!} e^{-\sum_{j=1}^n \lambda_j},$$

unde $k_j \in \mathbb{N}$, $j = \overline{1, n}$, iar $\lambda_j > 0$, $j = \overline{1, n}$, sunt constante date.

Repartiția Poisson multidimensională se obține ca un caz limită al repartiției multinomiale pentru $p_i \rightarrow 0$ ($i = \overline{1, n}$), $p_{n+1} \rightarrow 1$ când $n \rightarrow \infty$, astfel încât $np_i = \lambda_i$, $i = \overline{1, n}$.

Capitolul 4

Șiruri de variabile aleatoare

4.1 Tipuri de convergență

În teoria probabilităților există diverse tipuri de convergență. Deoarece v.a. sunt funcții măsurabile particulare, rezultă că pentru ele au sens tipurile de convergență definite pentru funcțiile măsurabile. Trei dintre acestea și anume convergență în probabilitate, aproape sigură, în medie de ordinul r , sunt importante în teoria probabilităților. Un alt tip de convergență, specifică teoriei probabilităților, este convergența în repartiție sau slabă.

Fie X_n , ($n \in \mathbf{N}^*$) și X v.a. reale definite pe un câmp de probabilitate (Ω, \mathcal{K}, P) . Problema convergenței șirului $(X_n)_{n \in \mathbf{N}^*}$ către v.a. X este concepută în următoarele moduri:

1) Șirul $(X_n)_{n \in \mathbf{N}^*}$ converge în probabilitate către X ($X_n \xrightarrow{P} X$, $n \rightarrow \infty$), dacă

$$\forall \varepsilon > 0 \quad P(|X_n - X| > \varepsilon) \rightarrow 0, \quad n \rightarrow \infty.$$

2) Șirul $(X_n)_{n \in \mathbf{N}^*}$ converge aproape sigur¹ către X ($X_n \xrightarrow{\text{a.s.}} X$, $n \rightarrow \infty$), dacă

$$P(\{\omega | X_n(\omega) \rightarrow X(\omega), \quad n \rightarrow \infty\}) = 1.$$

3) Șirul $(X_n)_{n \in \mathbf{N}^*}$ converge în medie de ordinul r ² către X ($X_n \xrightarrow{r} X$, $n \rightarrow \infty$), dacă există momentele absolute $E(|X_n|^r)$, $n \in \mathbf{N}^*$ și $E(|X|)$ și dacă

$$E(|X_n - X|^r) \rightarrow 0, \quad n \rightarrow \infty.$$

4) Șirul $(X_n)_{n \in \mathbf{N}^*}$ converge în repartiție sau slab către X ($X_n \xrightarrow{w} X$, $n \rightarrow \infty$), dacă

$$F_{X_n}(x) \rightarrow F_X(x), \quad n \rightarrow \infty \quad \forall x \in C(F_X),$$

¹Convergența aproape sigură se mai numește și convergență cu probabilitate 1.

²Convergența în medie de ordinul r se mai numește și convergență în r -medie. Dacă $r = 2$, convergența în 2-medie se mai numește și convergență în medie pătratică.

unde F_{X_n} , $n \in \mathbb{N}^*$ și F_X sunt funcțiile de repartiție ale v.a. X_n , $n \in \mathbb{N}^*$ și respectiv X , iar $C(F_X) = \{x | F_X(x) \text{ este continuă în } x\}$ reprezintă mulțimea de continuitate a lui F_X .

Trebuie remarcat că v.a. limită este unic definită în sensul următor. Dacă $X_n \rightarrow X$ și $X_n \rightarrow Y$, $n \rightarrow \infty$, aproape sigur, în probabilitate sau în r -medie, atunci $X = Y$ aproape sigur (a.s.), adică $P(X = Y) = 1$ (echivalent cu $P(\{\omega | X(\omega) \neq Y(\omega)\}) = 0$). Pentru convergența în repartiție, unicitatea limitei se traduce prin $F_X(x) = F_Y(x)$ pentru orice x , adică X și Y sunt identic repartizate. Aceste precizări fiind făcute, se poate enunța următoarea teoremă.

Teorema 4.1. *Dacă $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur, în probabilitate, în r -medie sau în repartiție, atunci v.a. limită este unică.*

Se pune, evident, întrebarea dacă tipurile de convergență, introduse mai sus, sunt într-adevăr diferite și dacă sunt, în ce relație se află unele față de celelalte. Compararea acestor moduri de convergență a dus la următoarele rezultate secundare

- a) dacă $X_n \xrightarrow{a.s.} X$, $n \rightarrow \infty$, atunci $X_n \xrightarrow{p} X$, $n \rightarrow \infty$ ³ ;
- b) dacă $X_n \xrightarrow{p} X$, $n \rightarrow \infty$, atunci există un subșir $(X_{n_k})_{k \in \mathbb{N}^*}$ astfel încât $X_{n_k} \xrightarrow{a.s.} X$, $k \rightarrow \infty$;
- c) dacă $X_n \xrightarrow{r} X$, $n \rightarrow \infty$, atunci $X_n \xrightarrow{p} X$, $n \rightarrow \infty$ ⁴ ;
- d) dacă $X_n \xrightarrow{r} X$, $n \rightarrow \infty$, atunci $X_n \xrightarrow{r'} X$, $n \rightarrow \infty$, pentru $r' < r$;
- e) dacă $X_n \xrightarrow{p} X$, $n \rightarrow \infty$, atunci $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Observație. Conceptele de convergență aproape sigură și convergență în r -medie nu pot fi comparate, deoarece nici unul nu-l implică pe celălalt (vezi exemplul 2).

În fine, se poate conchide cu următorul rezultat

Teorema 4.2. *Dacă X și X_1, X_2, \dots sunt v.a. definite pe același câmp de probabilitate (Ω, \mathcal{K}, P) , atunci au loc următoarele implicații când $n \rightarrow \infty$*

$$\begin{aligned} X_n \xrightarrow{a.s.} X \Rightarrow \quad X_n \xrightarrow{p} X \quad \Rightarrow X_n \xrightarrow{w} X \\ \uparrow \\ X_n \xrightarrow{r} X. \end{aligned}$$

În plus, față de acest rezultat general, se mai poate stabili echivalența convergențelor în probabilitate și în repartiție, dacă v.a. limită este degenerată

³Exemplul 1, §4.1, arată că cele două tipuri de convergență nu sunt echivalente.

⁴Implicația reciprocă nu are loc, în mod banal, deoarece $E(|X_n - X|')$ s-ar putea să nu existe (vezi exemplul 2 și exemplul 5, §4.1).

(adică este o constantă). Dacă v.a. limită X este constanta c , atunci funcția de repartiție corespunzătoare ei este δ_c , unde

$$\delta_c(x) = \begin{cases} 1, & x = c \\ 0, & x \neq c. \end{cases}$$

În §2.5 s-a văzut utilitatea transformelor în determinarea repartițiilor unor v.a. În acest paragraf se va stabili că transformatele sunt utile în demonstrarea convergenței în repartiție. Astfel pentru a arăta că $X_n \xrightarrow{w} X$, $n \rightarrow \infty$, este suficient să demonstreăm că transformatele v.a. X_n converg la transformata v.a. X . Au loc următoarele rezultate⁵.

Teorema 4.3. Fie X, X_1, X_2, \dots v.a. discrete cu valori întregi nenegative. Dacă $g_{X_n}(t) \rightarrow g_X(t)$, $n \rightarrow \infty$, atunci $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Teorema 4.4. Fie X, X_1, X_2, \dots v.a. astfel încât $\psi_{X_n}(t)$ există pentru $|t| < h$, pentru un anume $h > 0$ și orice $n \in \mathbb{N}^*$. Dacă funcția generatoare de momente a v.a. X , $\psi_X(t)$, există pentru $|t| \leq h_1 < h$, $h_1 > 0$ și $\psi_{X_n}(t) \rightarrow \psi_X(t)$, $n \rightarrow \infty$, pentru $|t| \leq h_1$, atunci $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Teorem 4.5 (Helly). Dacă $X_n \xrightarrow{w} X$, $n \rightarrow \infty$, atunci sirul $(\varphi_{X_n})_{n \in \mathbb{N}^*}$ converge uniform în orice interval mărginit către φ_X . Reciproc, dacă sirul $(\varphi_{X_n})_{n \in \mathbb{N}^*}$ converge punctual pe \mathbf{R} către o funcție φ continuă în origine, atunci există o v.a. X cu funcția caracteristică $\varphi_X = \varphi$ astfel încât $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Exemplul 1. Fie X_1, X_2, \dots v.a. independente astfel încât $P(X_n = 1) = 1 - \frac{1}{n}$ și $P(X_n = n) = \frac{1}{n}$, $n > 1$. Să se arate că $X_n \xrightarrow{P} 1$, $n \rightarrow \infty$, dar X_n nu converge aproape sigur la 1, când $n \rightarrow \infty$ ($X_n \xrightarrow{a.s.} 1$, $n \rightarrow \infty$).

Evident pentru orice $\varepsilon > 0$

$$P(|X_n - 1| > \varepsilon) = P(X_n = n) = \frac{1}{n} \rightarrow 0, \quad n \rightarrow \infty.$$

Deci $X_n \xrightarrow{P} 1$, $n \rightarrow \infty$. Pentru a arăta că $X_n \xrightarrow{a.s.} 1$, $n \rightarrow \infty$, este necesar să facem apel la următoarea condiție: $X_n \xrightarrow{a.s.} X$, $n \rightarrow \infty$, dacă și numai dacă pentru orice $\varepsilon > 0$ și δ , $0 < \delta < 1$, există n_0 astfel încât pentru orice $n > n_0$

$$P\left(\bigcap_{m>n} \{|X_m - X| < \varepsilon\}\right) > 1 - \delta \tag{4.1}$$

sau echivalent

$$P\left(\bigcup_{m>n} \{|X_m - X| > \varepsilon\}\right) < \delta.$$

⁵Astfel de rezultate sunt cunoscute sub denumirea de "teoreme de continuitate". Două aplicații importante vor fi date în paragrafele următoare și anume legea numerelor mari și teorema limită centrală.

Cum pentru orice $\varepsilon > 0$, $\delta \in (0, 1)$ și $N > n$ se obține

$$\begin{aligned} P\left(\bigcap_{m>n} \{|X_m - 1| < \varepsilon\}\right) &\leq P\left(\bigcap_{m=n+1}^N \{|X_m - 1| < \varepsilon\}\right) = \\ &= \prod_{m=n+1}^N P(|X_m - 1| < \varepsilon) = \prod_{m=n+1}^N P(X_m = 1) = \prod_{m=n+1}^N \left(1 - \frac{1}{m}\right) = \frac{n}{N} < 1 - \delta \end{aligned}$$

cu condiția să alegem N astfel încât $N > \frac{n}{1 - \delta}$, rezultă că nu există nici un n_0 , pentru care să aibă loc relația (4.1). Deci X_n nu converge a.s.

Exemplul 2. Fie $\alpha > 0$ și X_1, X_2, \dots v.a. astfel încât $P(X_n = 1) = 1 - \frac{1}{n^\alpha}$ și $P(X_n = n) = \frac{1}{n^\alpha}$, $n > 1$. Să se arate că $X_n \xrightarrow{p} 1$, $n \rightarrow \infty$ și $X_n \xrightarrow{r} 1$, $n \rightarrow \infty$, când $r < \alpha$, dar X_n nu converge în r -medie când $r \geq \alpha$.

Cum $P(|X_n - 1| > \varepsilon) = P(X_n = n) = \frac{1}{n^\alpha} \rightarrow 0$, $n \rightarrow \infty$, rezultă că $X_n \xrightarrow{p} 1$, $n \rightarrow \infty$. Deoarece

$$E(|X_n - 1|^r) = 0 \cdot \left(1 - \frac{1}{n^\alpha}\right) + |n - 1|^r \cdot \frac{1}{n^\alpha} = \frac{(n - 1)^r}{n^\alpha},$$

rezultă că

$$E(|X_n - 1|^r) \rightarrow \begin{cases} 0, & r < \alpha \\ 1, & r = \alpha, \quad n \rightarrow \infty, \\ +\infty, & r > \alpha \end{cases}$$

ceea ce implică concluzia dorită.

Dacă $\alpha = 1$ și în plus X_1, X_2, \dots sunt v.a. independente atunci se observă că: $X_n \xrightarrow{p} 1$; X_n nu converge aproape sigur; $E(X_n) \rightarrow 2$, $n \rightarrow \infty$; $X_n \xrightarrow{r} 1$, $n \rightarrow \infty$ pentru $0 < r < 1$ și X_n nu converge în r -medie pentru $r \geq 1$.

Dacă $\alpha = 2$ și X_1, X_2, \dots sunt v.a. independente atunci se observă că: $X_n \xrightarrow{p} 1$, $n \rightarrow \infty$; $X_n \xrightarrow{a.s.} 1$, $n \rightarrow \infty$; $E(X_n) \rightarrow 1$ și $\text{Var}(X_n) \rightarrow 1$, $n \rightarrow \infty$; $X_n \xrightarrow{r} 1$, $n \rightarrow \infty$, pentru $0 < r < 2$ și X_n nu converge în r -medie pentru $r \geq 2$.

În concluzie, în cazul $\alpha = 1$ X_n converge în r -medie pentru $0 < r < 1$, dar nu converge aproape sigur; în cazul $\alpha = 2$ X_n converge aproape sigur, în timp ce X_n nu converge în r -medie pentru $r \geq 2$.

Exemplul 3. Se consideră câmpul de probabilitate (Ω, \mathcal{K}, P) unde $\Omega = [0, 1]$, $\mathcal{K} = \mathcal{B}_{[0,1]}$ și P este măsura Lebesgue pe dreapta. Fie șirul de v.a. $(X_n)_{n \in \mathbb{N}}$ definit astfel

$$X_n(\omega) = \begin{cases} 0, & 0 \leq \omega < \frac{1}{2} \\ 1, & \frac{1}{2} \leq \omega \leq 1 \end{cases}$$

și v.a.

$$X(\omega) = \begin{cases} 1, & 0 \leq \omega < \frac{1}{2} \\ 0, & \frac{1}{2} \leq \omega \leq 1. \end{cases}$$

Să se arate că X_n nu converge în probabilitate către X , dar $X_n \xrightarrow{w} X$, $n \rightarrow \infty$. Cum $P(|X_n - X| = 1) = 1$, rezultă concluzia dorită. Funcțiile de repartiție ale v.a. X_n , $n \in \mathbb{N}^*$ și X sunt

$$F_{X_n}(x) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2}, & 0 < x \leq 1 \\ 1, & x > 1 \end{cases}$$

și respectiv

$$F_X(x) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2}, & 0 < x \leq 1 \\ 1, & x > 1. \end{cases}$$

Cum $F_{X_n}(x) = F_X(x) \forall x \in \mathbb{R}$, $n \in \mathbb{N}^*$, rezultă că $F_{X_n}(x) \rightarrow F_X(x)$, $n \rightarrow \infty$, $x \in \mathbb{R}$. Deci $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Exemplul 4. Se consideră câmpul de probabilitate (Ω, \mathcal{K}, P) , unde $\Omega = [0, 1]$, $\mathcal{K} = \mathcal{B}_{[0,1]}$ și P este măsura Lebesgue de dreapta. Pentru orice $m \in \mathbb{N}^*$, se consideră v.a. $X_1^{(m)}, \dots, X_m^{(m)}$ definite astfel

$$X_i^{(m)}(\omega) = \begin{cases} 1, & \frac{i-1}{m} \leq \omega < \frac{i}{m}, \quad i = \overline{1, m} \\ 0, & \text{în rest} \end{cases}$$

Să se arate că sirul de v.a.

$$X_1^{(1)}, X_1^{(2)}, X_2^{(2)}, X_1^{(3)}, X_2^{(3)}, X_3^{(3)}, \dots, X_1^{(n)}, X_2^{(n)}, \dots, X_n^{(n)}, \dots$$

unde $X_1^{(1)}(\omega) = 1 \quad \forall \omega \in [0, 1)$, converge în probabilitate către zero, dar nu converge aproape sigur către zero.

Cum pentru orice $\varepsilon > 0$

$$P(|X_k^{(n)}| \geq \varepsilon) = P\left(\left[\frac{k-1}{n}, \frac{k}{n}\right)\right) = \frac{1}{n},$$

iar $P(|X_k^{(n)}| \geq \varepsilon) < \eta$ dacă $n > N(\varepsilon, \eta)$, rezultă că $X_k^{(n)} \xrightarrow{p} 0$, $k, n \rightarrow \infty$.

Dacă $\omega_0 \in [0, 1)$, atunci pentru orice m există un i astfel încât $\omega_0 \in \left[\frac{i-1}{m}, \frac{i}{m}\right)$ și deci $X_i^{(m)}(\omega_0) = 1$. Rezultă că în sirul

$$X_1^1(\omega_0), X_1^{(2)}(\omega_0), X_2^{(2)}(\omega_0), X_1^{(3)}(\omega_0), X_2^{(3)}(\omega_0), X_3^{(3)}(\omega_0), \dots$$

oricare ar fi rangul termenului din ſir, găsim după el termeni ai ſirului egali cu 1. Deci $X_k^{(n)}$ nu converge aproape sigur către zero.

Exemplul 5. Fie $(X_n)_{n \in \mathbb{N}^*}$ un ſir de v.a. astfel încât fiecare v.a. X_n poate lua numai valorile 0, $-n$ și n cu probabilitățile

$$P(X_n = 0) = 1 - \frac{1}{n^2}, \quad P(X_n = -n) = P(X_n = n) = \frac{1}{2n^2}.$$

Să se arate că ſirul $(X_n)_{n \in \mathbb{N}^*}$ converge în probabilitate către zero, dar nu converge în medie pătratică către zero.

Cum pentru orice $\varepsilon > 0$ și $\eta > 0$ există $N(\varepsilon, \eta)$ astfel încât

$$P(|X_n| > \varepsilon) = \frac{1}{2n^2} < \eta \quad \forall n > N(\varepsilon, \eta),$$

rezultă că $X_n \xrightarrow{p} 0$, $n \rightarrow \infty$. Deoarece

$$E(|X_n - 0|^2) = E(X_n^2) = 0 \cdot \left(1 - \frac{1}{n^2}\right) + n^2 \cdot \frac{1}{2n^2} + n^2 \cdot \frac{1}{2n^2} = 1$$

rezultă că X_n nu converge în medie pătratică către zero.

Exemplul 6. Fie $(X_n)_{n \in \mathbb{N}^*}$ un ſir de v.a. independente, care au repartiție exponențială, iar $E(X_k) = ck^\alpha$, unde $c > 0$ și $0 < \alpha < \frac{1}{2}$. Să se arate că ſirul $\left(\bar{X}_n - \frac{cn^\alpha}{\alpha+1}\right)_{n \in \mathbb{N}^*}$, unde $\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$, converge în probabilitate către zero.

Fie v.a. $Y_n = \bar{X}_n - \frac{cn^\alpha}{\alpha+1}$. Atunci se obține

$$E(Y_n) = E(\bar{X}_n) - \frac{cn^\alpha}{\alpha+1} = \frac{c}{n} \sum_{k=1}^n k^\alpha - \frac{cn^\alpha}{\alpha+1} = c \frac{n^\alpha}{n} \left(\frac{1}{n^\alpha} \sum_{k=1}^n k^\alpha - \frac{n}{\alpha+1} \right).$$

Cum X_k are repartiție exponențială cu media ck^α , rezultă că densitatea de probabilitate a v.a. X_k este

$$p_{X_k}(x) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{ck^\alpha} e^{-\frac{x}{ck^\alpha}}, & x > 0. \end{cases}$$

Prințr-un calcul simplu rezultă că $E(X_k^2) = 2c^2k^{2\alpha}$ și $\text{Var}(X_k) = c^2k^{2\alpha}$. Atunci

$$\text{Var}(Y_n) = \text{Var}\left(\frac{1}{n} \sum_{k=1}^n X_k - \frac{cn^\alpha}{\alpha+1}\right) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{c^2}{n^2} \sum_{k=1}^n k^{2\alpha}.$$

Cum

$$\lim_{n \rightarrow \infty} \frac{1}{n^{2\alpha+1}} \sum_{k=1}^n k^{2\alpha} = \frac{1}{2\alpha+1}$$

și $0 < \alpha < \frac{1}{2}$, rezultă că

$$\lim_{n \rightarrow \infty} \text{Var}(Y_n) = \lim_{n \rightarrow \infty} \frac{c^2}{n^2} \sum_{k=1}^n k^{2\alpha} = c^2 \lim_{n \rightarrow \infty} \frac{1}{n^{1-2\alpha}} \cdot \frac{1}{n^{2\alpha+1}} \sum_{k=1}^n k^{2\alpha} = 0.$$

Din inegalitățile

$$P(|Y_n| \geq \varepsilon) \leq P\left(|Y_n - E(Y_n)| > \frac{\varepsilon}{2}\right) \leq \frac{4\text{Var}(Y_n)}{\varepsilon^2}$$

rezultă că $Y_n \xrightarrow{P} 0$, $n \rightarrow \infty$.

Exemplul 7. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente pentru care

$$P(X_n = 3^{n-1}) = P(X_n = -3^{n-1}) = \frac{1}{2}, \quad n \in \mathbb{N}^*.$$

Să se arate că sirul de v.a.

$$Y_n = \frac{1}{\sigma_n} \sum_{k=1}^n X_k, \quad n \in \mathbb{N}^*,$$

unde $\sigma_n^2 = \text{Var}\left(\sum_{k=1}^n X_k\right)$, nu converge în probabilitate către zero.

Se observă că $|X_n| = 3^{n-1}$, $n \in \mathbb{N}^*$. Cum

$$\begin{aligned} |X_n| &= |X_n + X_{n-1} - X_{n-1}| \leq |X_n + X_{n-1}| + |X_{n-1}| \leq \\ &\leq |X_n + X_{n-1} + \dots + X_1| + |X_{n-1}| + \dots + |X_1| \end{aligned}$$

rezultă că

$$|Y_n| \geq \frac{|X_n| - |X_1| - |X_2| - \dots - |X_{n-1}|}{\sigma_n}.$$

V.a. X_n , $n \in \mathbb{N}^*$, fiind independente se obține

$$\text{Var}\left(\sum_{k=1}^n X_k\right) = \sum_{k=1}^n \text{Var}(X_k) = \sum_{k=1}^n 3^{2(k-1)} = \frac{3^{2n} - 1}{3^2 - 1} = \frac{9^n - 1}{8}$$

deoarece $E(X_k) = 0$ și $E(X_k^2) = 3^{2(k-1)}$. Atunci $\sigma_n = \sqrt{\frac{9^{n-1}}{8}}$ și

$$|Y_n| \geq \frac{3^{n-1} - (1 + 3 + \dots + 3^{n-2})}{\sqrt{\frac{9^n - 1}{8}}} > \frac{\sqrt{2}}{3}.$$

Deci $P\left(|Y_n| > \frac{\sqrt{2}}{3}\right) = 1$. În concluzie $P(|Y_n| > \varepsilon) \rightarrow 0$ dacă $\varepsilon \leq \frac{\sqrt{2}}{3}$, adică Y_n nu converge în probabilitate către zero.

Exemplul 8. Un fapt important este aproximarea repartiției Poisson de parametru λ (vezi §3.5) cu repartitia binomială de parametri n și p (vezi §3.1). Mai precis, pentru n suficient de mare, p mic, astfel încât să se poată considera produsul $np = \lambda$ de valoare constantă, řirul $(X_n)_{n \in \mathbb{N}^*}$ de v.a. repartizate binomial de parametri n și p converge în repartitie către o v.a. X repartizată Poisson. Cum

$$g_{X_n}(t) = \left(1 - \frac{\lambda}{n} + \frac{\lambda}{n}t\right)^n = \left(1 + \frac{\lambda(t-1)}{n}\right)^n \rightarrow e^{\lambda(t-1)}, \quad n \rightarrow \infty,$$

iar $g(t) = e^{\lambda(t-1)}$ reprezintă funcția generatoare a unei v.a. X repartizată Poisson, rezultă conform teoremei 4.3 că $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Exemplul 9. Fie $(\lambda_n)_{n \in \mathbb{N}^*}$ un řir strict crescător de numere strict pozitive ce tinde la $+\infty$, iar $(X_n)_{n \in \mathbb{N}^*}$ un řir de v.a. astfel încât, pentru fiecare $n \in \mathbb{N}^*$, v.a. X_n este repartizată Poisson cu parametrul λ_n (vezi §3.5). Să se arate că řirul de v.a.

$$Y_n = \frac{X_n - \lambda_n}{\sqrt{\lambda_n}}, \quad n \in \mathbb{N}^*,$$

converge în repartitie către o v.a. Y repartizată normal $N(0, 1)$.

Funcția cáracteristică $\varphi_{Y_n}(t)$ a v.a. Y_n (vezi §2.5 și §3.5) este

$$\varphi_{Y_n}(t) = e^{-i\sqrt{\lambda_n}t} \exp[\lambda_n(e^{it/\sqrt{\lambda_n}} - 1)].$$

Folosind dezvoltarea în serie Maclaurin a funcției exponențiale se obține

$$\begin{aligned} \varphi_{Y_n}(t) &= \exp\left[-i\sqrt{\lambda_n}t + \lambda_n\left(\frac{it}{\sqrt{\lambda_n}} - \frac{t^2}{2\lambda_n} + o\left(\frac{1}{\lambda_n}\right)\right)\right] \\ &= \exp\left[-\frac{t^2}{2} + \lambda_n o\left(\frac{1}{\lambda_n}\right)\right] \end{aligned}$$

și prin urmare $\varphi_{Y_n}(t) \rightarrow e^{-\frac{t^2}{2}}$, $n \rightarrow \infty$, pentru orice $t \in \mathbb{R}$. Cum $\varphi(t) = e^{-\frac{t^2}{2}}$, $t \in \mathbb{R}$, reprezintă funcția caracteristică a unei v.a. Y repartizată normal $N(0, 1)$ (vezi §3.6), rezultă conform teoremei 4.5 că $Y_n \xrightarrow{w} Y$, $n \rightarrow \infty$.

Exemplul 10 (Teorema integrală De Moivre-Laplace). Se consideră v.a. bernoulliene X_1, X_2, \dots, X_n , $n \in \mathbb{N}^*$, (vezi exemplul 3, §2.4), adică

$$X_i = \begin{cases} 1, & \text{cu probabilitatea } p \\ 0, & \text{cu probabilitatea } q = 1 - p \end{cases}$$

$\forall i = \overline{1, n}$ și v.a. $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Să se arate că sirul $(Y_n)_{n \in \mathbb{N}^*}$ de v.a.

$$Y_n = \frac{S_n - np}{\sqrt{npq}}, \quad n \in \mathbb{N}^*,$$

converge în repartīție către o v.a. repartizată normal $N(0, 1)$ (vezi §3.6).

Deoarece v.a. X_n , $n \in \mathbb{N}^*$, sunt independente (vezi §3.1) și fiecare din ele are funcția caracteristică $\varphi(t) = pe^{it} + q$, rezultă conform propoziției 2.10 că funcția caracteristică a v.a. $Y_n = \sum_{i=1}^n \frac{X_i - p}{\sqrt{npq}}$ este

$$\varphi_{Y_n}(t) = \left(qe^{-it\sqrt{\frac{p}{nq}}} + pe^{it\sqrt{\frac{p}{nq}}} \right)^n.$$

Folosind dezvoltarea în serie Maclaurin a funcției exponențiale se obține

$$\begin{aligned} \varphi_{Y_n}(t) &= \left[q \left(1 - it\sqrt{\frac{p}{nq}} - t^2 \frac{p}{2nq} + o\left(\frac{1}{n}\right) \right) + p \left(1 + it\sqrt{\frac{p}{nq}} - \right. \right. \\ &\quad \left. \left. - t^2 \frac{q}{2np} + o\left(\frac{1}{n}\right) \right) \right]^n = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n. \end{aligned}$$

Deci

$$\varphi_{Y_n}(t) = e^{-n\left[\frac{t^2}{2n}+o\left(\frac{1}{n}\right)\right]} \rightarrow e^{-\frac{t^2}{2}}, \quad n \rightarrow \infty.$$

Prin urmare pentru fiecare $t \in \mathbb{R}$, $\varphi_{Y_n}(t)$ converge către funcția caracteristică a repartiției normale $N(0, 1)$ și conform teoremei 4.5 rezultă că Y_n converge în repartīție către o v.a. repartizată $N(0, 1)$.

4.2 Legea numerelor mari

Legătura dintre frecvență ca v.a. și probabilitate constituie elementul de bază al aplicațiilor practice ale teoriei probabilităților. Diversele rezultate privind această problemă fundamentală sunt cunoscute sub numele de *variante ale legii numerelor mari*.

Fie (Ω, \mathcal{K}, P) un câmp de probabilitate, $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. reale definite pe acest câmp și $(\tau_n)_{n \in \mathbb{N}^*}$ un sir de aplicații ale lui \mathbb{R}^n în \mathbb{R} , măsurabile Borel, simetrice în argumentele lor. Se consideră sirul de v.a. $\tau_n(X_1, \dots, X_n)$, $n \in \mathbb{N}^*$.

În acest paragraf se studiază condițiile în care există un sir de numere reale $(a_n)_{n \in \mathbb{N}^*}$ astfel încât

$$1) \tau_n(X_1, \dots, X_n) - a_n \xrightarrow{p} 0, \quad n \rightarrow \infty$$

sau

$$2) \tau_n(X_1, \dots, X_n) - a_n \xrightarrow{a.s.} 0, \quad n \rightarrow \infty.$$

În cazul 1 (2) se spune că sirul $(X_n)_{n \in \mathbb{N}^*}$ satisfacă *legea slabă a numerelor mari* (*legea tare a numerelor mari*) sau că $(X_n)_{n \in \mathbb{N}^*}$ este *slab stabil* (*tare stabil*) în raport cu (τ_n, a_n) . De obicei se consideră cazul în care

$$\tau_n(X_1, \dots, X_n) = \frac{1}{n} \sum_{k=1}^n X_k \text{ și } a_n = \frac{1}{n} \sum_{k=1}^n E(X_k), \quad n \in \mathbb{N}^*.$$

În această situație, pentru simplificarea scrierii, se adoptă notațiile

$$S_n = \sum_{k=1}^n X_k,$$

$$\bar{X}_n = \tau(X_1, \dots, X_n) = \frac{S_n}{n}.$$

Pentru a descrie o situație concretă de la care provine formularea problemei de mai sus, enunțăm în condiții destul de restrictive următoarea teoremă, cunoscută sub denumirea *legea slabă a numerelor mari*.

Teorema 4.6 (Hincin)⁶. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente, identic repartizate, având valoarea medie, m , finită ($m < \infty$). Atunci $\bar{X}_n \xrightarrow{p} m$, $n \rightarrow \infty$.

Observația 1. Cazul particular al teoremei 4.6, în care v.a. sunt bernouliliene, a fost demonstrat prima oară de Bernoulli⁷. Pentru timpul respectiv, acest rezultat a fost considerat un foarte mare succes. Teorema Bernoulli explică stabilitatea frecvenței relative (vezi §1.2) pentru un număr mare de experimente. O formulare a teoremei Bernoulli este următoarea: dacă se fac n experimente independente, în fiecare experiment probabilitatea evenimentului A fiind p , atunci cu o probabilitate oricât de apropiată de 1, abaterea frecvenței relative de apariție a evenimentului A față de p , va fi oricât de mică în valoare absolută cu condiția ca numărul n al experimentelor să fie suficient de mare.

Uneori această teoremă se enunță și sub forma: frecvența tinde în probabilitate către probabilitate (evident în această formulare cuvântul probabilitate intervine în două sensuri diferite, însă bine definite). Deci

$$\frac{N_n(A)}{n} \xrightarrow{p} p, \quad n \rightarrow \infty,$$

⁶A. Ja. Hincin (1894-1959) a fost unul din probabilistii de seamă ai școlii rusești.

⁷Jakob Bernoulli (1654-1705), matematician și fizician elvețian, a pus bazele calculului probabilităților în tratatul său apărut postum *Ars Conjectandi* (1713).

unde $N_n(A)$ reprezintă numărul de apariții ale evenimentului A în cele n experimente, $\frac{N_n(A)}{n}$ frecvența relativă de apariție a evenimentului A , iar p probabilitatea evenimentului A .

Trebuie remarcat că teorema Bernoulli nu afirmă faptul că $\lim_{n \rightarrow \infty} \frac{N_n(A)}{n} = p$, ci numai că pentru n suficient de mare frecvența relativă se va deosebi oricât de puțin de probabilitatea p .

O extensie a teoremei 4.6 constă în următoarea teoremă, în care v.a. X_n , $n \in \mathbb{N}^*$, nu mai sunt neapărat identic repartizate.

Teorema 4.7 (Cebîșev). *Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente astfel încât*

$$E(X_i) = m_i, \quad \text{Var}(X_i) = \sigma_i^2, \quad \forall i \in \mathbb{N}^*.$$

Dacă există o constantă $M < \infty$ astfel încât $\sigma_i^2 \leq M \forall i \in \mathbb{N}^$, atunci*

$$\bar{X}_n \xrightarrow{p} \frac{m_1 + \dots + m_n}{n}, \quad n \rightarrow \infty.$$

Observația 2. În ce constă esența teoremei lui Cebîșev? În virtutea ei, deși v.a. independente pot lua valori depărtate de mediile lor, media aritmetică a unui număr suficient de mare de astfel de v.a. ia cu o probabilitate mare valori apropiate de un număr constant și anume $\frac{m_1 + \dots + m_n}{n}$. În acest fel, între comportarea fiecărei v.a. și a mediei lor aritmetice există o mare deosebire: nu este posibil să se prevadă ce valoare va lua fiecare dintre v.a., însă cu o probabilitate mare se poate prevedea ce valoare va lua media aritmetică a acestor v.a. În concluzie, media aritmetică a unui număr suficient de mare de v.a. (având bineînțeles varianțe mărginite) își pierde caracterul de v.a. Explicația acestui fapt constă în aceea că abaterile diverselor v.a. sunt unele negative, altele pozitive și astfel ele se compensează.

Demonstrația⁸ teoremei 4.7 se bazează pe inegalitatea lui Cebîșev (vezi (2.15), §2.4). Acest rezultat celebru, dar simplu, are din punct de vedere teoretic o mare importanță. În schimb, pentru practică, are o importanță limitată deoarece dă o evaluare grosolană (uneori banală). De exemplu, dacă $E(X^2) \leq a^2$ ($a = \text{constantă}$) rezultă

$$P(|X| \geq a) \leq \frac{E(X^2)}{a^2} \leq \frac{a^2}{a^2} = 1 \quad (\text{nimic util}).$$

Alte extensiile importante ale teoremei lui Hincin sunt următoarele

⁸Demonstrațiile teoremelor 4.6 și 4.7 sunt relativ simple, de aceea pare surprinzător că au trecut două secole de la Bernoulli, până când Cebîșev a descoperit teorema care îi poartă numele. Însuși Cebîșev și-a îngreunat demonstrația cu detalii laborioase și inutile. Succesorii lui au redactat demonstrația teoremei într-o formă mult simplificată.

Teorema 4.8. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente două căte două astfel încât

$$E(X_i) = m_i, \quad \text{Var}(X_i) = \sigma_i^2, \quad \forall i \in \mathbb{N}^*.$$

Dacă

$$\lim_{n \rightarrow \infty} \text{Var}(\bar{X}_n) = \lim_{n \rightarrow \infty} \frac{1}{n^2} \sum_{k=1}^n \sigma_k^2 = 0,$$

atunci

$$\bar{X}_n \xrightarrow{p} \frac{m_1 + \dots + m_n}{n}, \quad n \rightarrow \infty.$$

Teorema 4.9 (Markov⁹). Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. astfel încât

$$E(X_i) = m_i, \quad \text{Var}(X_i) = \sigma_i^2, \quad \forall i \in \mathbb{N}^*.$$

Dacă

$$\lim \text{Var}(\bar{X}_n) = \lim_{n \rightarrow \infty} \frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) = 0,$$

atunci

$$\bar{X}_n \xrightarrow{p} \frac{m_1 + \dots + m_n}{n}, \quad n \rightarrow \infty.$$

Teorema 4.10. Condiția necesară și suficientă ca un sir de v.a. $(X_n)_{n \in \mathbb{N}^*}$ să satisfacă legea slabă a numerelor mari este

$$\lim_{n \rightarrow \infty} E\left[\frac{\left(\sum_{k=1}^n (X_k - E(X_k))\right)^2}{n^2 + \left(\sum_{k=1}^n (X_k - E(X_k))\right)^2}\right] = 0.$$

În cazul bernoullian, E. Borel a descoperit în 1909 un rezultat celebru ce se poate formula astfel

$$\frac{N_n(A)}{n} \xrightarrow{\text{a.s.}} p, \quad n \rightarrow \infty,$$

ceea ce este echivalent cu

$$P\left(\lim_{n \rightarrow \infty} \frac{N_n(A)}{n} = p\right) = 1.$$

Această esențială îmbunătățire a legii slabe a numerelor mari, în forma Bernoulli, stabilește existența limitei frecvenței, fiind egală cu probabilitatea teoretică p , pentru orice eveniment elementar ω , cu excepția unei mulțimi de probabilitate nulă.

⁹P.L.Cebîșev (1821-1894) împreună cu A.A. Markov (1856-1922) și A.M. Liapunov (1857-1918) au fost fondatorii solui rusești de teoria probabilităților.

Astfel printr-o sofisticată teoremă se justifică teoria empirică a frecvenței. De aceea legea tare a numerelor mari reprezintă fundamental teoriei matematice a probabilităților, bazată pe conceptul de frecvență. Legea tare a numerelor mari este indispensabilă unor investigații teoretice, fiind într-un sens mai bună decât legea slabă, deși părerile multor matematicieni sunt controverse în legătură cu acest subiect (vezi p.152 [Feller] și p.98 [van der Waerden, Mathematische Statistik, Springer-Verlag, 1971]).

Teoreme similare celor prezentate mai sus, dar în care convergența în probabilitate este înlocuită cu convergența aproape sigură au fost demonstreate de Kolmogorov.

Teorema 4.11 (Kolmogorov). *Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente astfel încât*

$$E(X_i) = m_i, \quad \text{Var}(X_i) = \sigma_i^2 < \infty, \quad \forall i \in \mathbb{N}^*.$$

Dacă

$$\sum_{n \in \mathbb{N}^*} \frac{\sigma_i^2}{n^2} < \infty, \quad \text{atunci} \quad \bar{X}_n \xrightarrow{a.s.} \frac{m_1 + \dots + m_n}{n}, \quad n \rightarrow \infty.$$

Corolarul 4.12 *Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente astfel încât*

$$E(X_i) = m_i, \quad \text{Var}(X_i) \leq M < \infty, \quad \forall i \in \mathbb{N}^*.$$

Atunci

$$\bar{X}_n \xrightarrow{a.s.} \frac{m_1 + \dots + m_n}{n}, \quad n \rightarrow \infty.$$

Teorema 4.13 (Kolmogorov). *Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente, identic repartizate, având valoarea medie m . Atunci $\bar{X}_n \xrightarrow{a.s.} m$, $n \rightarrow \infty$, dacă și numai dacă $m < \infty$.*

Observația 3. Înțând seama de rezultatele prezentate în §4.1 referitoare la compararea tipurilor de convergență rezultă că un sir de v.a. ce satisface legea tare a numerelor mari, satisface și legea slabă a numerelor mari.

Exemplul 1. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente care pot lua valorile $\pm\sqrt{n}$ și 0 cu probabilitățile $P(X_1 = 0) = 1$ și

$$P(X_k = \sqrt{k}) = P(X_k = -\sqrt{k}) = \frac{1}{k}, \quad P(X_k = 0) = 1 - \frac{2}{k}, \quad k = 2, 3, \dots$$

Să se arate că sirul dat satisface legea slabă a numerelor mari.

Deoarece $E(X_k) = 0$, $k = 1, 2, 3, \dots$ și $\text{Var}(X_k) = 2$, $k = 2, 3, \dots$ rezultă că sunt îndeplinite condițiile teoremei 4.7. Deci sirul $(X_n)_{n \in \mathbb{N}^*}$ satisface legea slabă a numerelor mari.

Exemplul 2. Fie $(X_n)_{n \in \mathbb{N}^*}$ un ſir de v.a. independente care pot lua valorile $\pm\sqrt{\ln n}$ cu probabilitățile $P(X_1 = 0) = 1$ și

$$P(X_k = \sqrt{\ln k}) = P(X_k = -\sqrt{\ln k}) = \frac{1}{2}, \quad k = 2, 3, \dots$$

Să se arate că ſirul dat ſatisfacă legea slabă a numerelor mari

Deoarece $E(X_k) = 0$ și $\text{Var}(X_k) = \ln k$, $k = 2, 3, \dots$ rezultă

$$E(\bar{X}_n) = \frac{1}{n} \sum_{k=1}^n E(X_k) = 0,$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{1}{n^2} \sum_{k=1}^n \ln k.$$

Însă $\text{Var}(\bar{X}_n)$ poate fi majorată după cum urmează

$$\sum_{k=1}^n \ln k < \int_1^{n+1} \ln x dx = x \ln x|_1^{n+1} - \int_1^{n+1} dx = (n+1) \ln(n+1) - n.$$

Deci

$$\text{Var}(\bar{X}_n) < \frac{(n+1) \ln(n+1) - n}{n^2},$$

de unde urmează că $\lim_{n \rightarrow \infty} \text{Var}(\bar{X}_n) = 0$. Atunci conform teoremei 4.8, ſirul $(X_n)_{n \in \mathbb{N}^*}$ ſatisfacă legea slabă a numerelor mari.

Exemplul 3. Fie $(X_n)_{n \in \mathbb{N}^*}$ un ſir de v.a. independente de valori medii $E(X_n) = 0$, $n \in \mathbb{N}^*$ și varianțe $\text{Var}(X_n) = n^\lambda$, $n \in \mathbb{N}^*$, unde $0 < \lambda < 1$. Să se arate că ſirul dat ſatisfacă legea slabă a numerelor mari.

Din condițiile cuprinse în enunț rezultă

$$E(\bar{X}_n) = 0 \quad \text{și} \quad \text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{k=1}^n k^\lambda.$$

Iar din majorarea

$$\sum_{k=1}^n k^\lambda < \int_1^{n+1} x^\lambda dx = \frac{(n+1)^{\lambda+1} - 1}{\lambda + 1}$$

rezultă că

$$\text{Var}(\bar{X}_n) < \frac{(n+1)^{\lambda+1} - 1}{(\lambda + 1)n^2} \rightarrow 0, \quad n \rightarrow \infty,$$

întrucât $\lambda + 1 < 2$. Atunci conform teoremei 4.8, ſirul $(X_n)_{n \in \mathbb{N}^*}$ ſatisfacă legea slabă a numerelor mari.

Exemplul 4. Fie $(X_n)_{n \in \mathbb{N}^*}$ un şir de v.a. independente cu densităţile de repartiţie

$$p_{X_n}(x) = \frac{1}{\sqrt{\pi} \sqrt[n]{n}} \exp \left[-\frac{(x - a^n)^2}{\sqrt{n}} \right], \quad 0 \leq a < 1, \quad n \in \mathbb{N}^*.$$

Să se arate că şirul dat satisface legea slabă a numerelor mari.

Se obține

$$E(X_k) = \int_{-\infty}^{\infty} x p_{X_k}(x) dx = \frac{1}{\sqrt{\pi} \sqrt[k]{k}} \int_{-\infty}^{\infty} x \exp \left[-\frac{(x - a^k)^2}{\sqrt{k}} \right] dx = a^k,$$

$$\text{Var}(X_k) = E(X_k - a^k)^2 = \int_{-\infty}^{\infty} (x - a^k)^2 p_{X_k}(x) dx = \frac{\sqrt{k}}{2}, \quad k \in \mathbb{N}^*.$$

Cum

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{1}{n^2} \sum_{k=1}^n \frac{\sqrt{k}}{2} < \frac{n\sqrt{n}}{2n^2} = \frac{1}{2\sqrt{n}}$$

rezultă că $\lim_{n \rightarrow \infty} \text{Var}(\bar{X}_n) = 0$. Atunci conform teoremei 4.8 şirul $(X_n)_{n \in \mathbb{N}^*}$ satisface legea slabă a numerelor mari.

Exemplul 5. Fie S_n numărul de apariţii ale unui eveniment A în n experimente independente și p_k probabilitatea lui A în experimentul de rang k . Acest model este o generalizare a modelului lui Bernoulli cu bila repetată în care $p_k = p$, pentru orice $k \in \mathbb{N}^*$ (vezi §3.1). Considerând v.a. independente X_k , $k \in \mathbb{N}^*$, ce semnifică rezultatul experimentului de rang k , cuantificat prin 1 sau 0, în acord cu apariţia evenimentului A sau a evenimentului contrar \bar{A} , se obține $S_n = X_1 + \dots + X_n$. Deoarece $E(X_k) = p_k$ și $\text{Var}(X_k) = p_k(1 - p_k) \leq \frac{1}{4}$ pentru orice $k \in \mathbb{N}^*$, rezultă conform corolarului 4.12 că

$$\bar{X}_n = \frac{S_n}{n} \xrightarrow{\text{a.s.}} \frac{p_1 + \dots + p_n}{n}, \quad n \rightarrow \infty.$$

Deci şirul $(X_n)_{n \in \mathbb{N}^*}$ satisface legea tare a numerelor mari.

4.3 Problema limită centrală

Problema limită centrală este un caz particular dintr-o problematică mai generală și anume aceea a studiului repartiției limită a sumelor de v.a. independente.

O multitudine de aplicații, în special în statistica matematică, arată importanța acestei probleme.

Rezolvarea ei a fost, o lungă perioadă de timp, problema cheie a teoriei probabilită̄ilor.

În acest paragraf se vor considera numai ſiruri de v.a. independente $(X_n)_{n \in \mathbb{N}^*}$ care admit varianțe finite. Se introduc notațiile

$$a_k = E(X_n), \quad \sigma_k^2 = \text{Var}(X_k), \quad \sigma_{(n)}^2 = \sum_{k=1}^n \sigma_k^2.$$

Problema limită centrală constă în stabilirea condițiilor în care funcția de repartiție $F_{(n)}$ a v.a. normate (pentru că are valoarea medie nulă și varianța egală cu 1)

$$X_{(n)} = \frac{1}{\sigma_{(n)}} \sum_{k=1}^n (X_k - a_k)$$

converge către funcția de repartiție normală $N(0, 1)$, deci către funcția

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt, \quad \text{când } n \rightarrow \infty.$$

Așadar, este vorba despre o convergență în repartiție. Teoremele care stabilesc aceste condiții de convergență se numesc *teoreme limită centrale*. Spre exemplu, teorema De Moivre-Laplace¹⁰ (vezi exemplul 10, §4.1) este o teoremă limită centrală.

Teorema 4.14 (Lindeberg-Feller). Fie $(X_n)_{n \in \mathbb{N}^*}$ un ſir de v.a. independente. Pentru ca

$$\lim_{n \rightarrow \infty} F_{(n)}(x) = \Phi(x), \quad x \in \mathbf{R} \quad \text{și} \quad \lim_{n \rightarrow \infty} \max_{1 \leq k \leq n} \frac{\sigma_k^2}{\sigma_{(n)}^2} = 0$$

este necesar și suficient ca pentru orice $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} \frac{1}{\sigma_{(n)}^2} \sum_{k=1}^n \int_{\{|x-a_k| > \varepsilon \sigma_{(n)}\}} (x - a_k)^2 dF_k(x) = 0^{11}$$

unde F_k este funcția de repartiție a v.a. X_k , $k \in \mathbb{N}^*$.

Corolarul 4.15. Dacă v.a. $(X_n)_{n \in \mathbb{N}^*}$, sunt independente, identic repartizate și admit varianțe finite, atunci $\lim_{n \rightarrow \infty} F_{(n)}(x) = \Phi(x)$, $x \in \mathbf{R}$.

¹⁰Cazul particular, în care v.a. X_1, X_2, \dots sunt bernoulliene a fost tratat prima oară de Abraham De Moivre ((1667-1754) considerat succesorul lui Newton) în lucrarea sa "Doctrină a řanselor" (1714). Mai târziu, Laplace a extins și a realizat importanța acestui rezultat în tratatul său "Teoria analitică a probabilită̄ilor" (1812).

¹¹Integrala este Lebesgue-Stieltjes (vezi Gnedenko 1969). Dacă F_k admite densitatea de repartiție p_k , atunci $dF_k(x)$ se înlocuiește cu $p_k(x)dx$.

Corolarul 4.16. Dacă v.a. $(X_n)_{n \in \mathbb{N}^*}$, sunt independente și $|X_n| \leq M < \infty$ pentru orice $n \in \mathbb{N}^*$, iar $\lim_{n \rightarrow \infty} \sigma_{(n)} = \infty$, atunci $\lim_{n \rightarrow \infty} F_{(n)}(x) = \Phi(x)$, $x \in \mathbb{R}$.

Teorema 4.17 (Liapunov). Dacă pentru sirul de v.a. independente $(X_n)_{n \in \mathbb{N}^*}$ se poate alege un număr $\eta > 0$ astfel încât

$$\lim_{n \rightarrow \infty} \frac{1}{\sigma_{(n)}^{\eta+2}} \sum_{k=1}^n E(|X_k - a_k|^{\eta+2}) = 0,$$

atunci

$$\lim_{n \rightarrow \infty} F_{(n)}(x) = \Phi(x), \quad x \in \mathbb{R}.$$

Corolarul 4.18. Dacă pentru sirul de v.a. independente $(X_n)_{n \in \mathbb{N}^*}$ există $\rho_k^3 = E(|X_k - a_k|^3)$, $k \in \mathbb{N}^*$, și dacă $\lim_{n \rightarrow \infty} \frac{\rho_{(n)}}{\sigma_{(n)}} = 0$, unde $\rho_{(n)}^3 = \sum_{k=1}^n \rho_k^3$, atunci

$$\lim_{n \rightarrow \infty} F_{(n)}(x) = \Phi(x), \quad x \in \mathbb{R}.$$

Teorema 4.19 (Cebibșev). Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de funcții de repartiție care admit momente de orice ordin, adică există mărimile $\alpha_j^{(n)} = \int_{-\infty}^{\infty} x^j dF_n(x)$, $j, n \in \mathbb{N}^*$.

Dacă $\lim_{n \rightarrow \infty} \alpha_j^{(n)} = \alpha_j$, $j \in \mathbb{N}^*$, unde α_j , $j \in \mathbb{N}^*$, sunt momentele funcției de repartiție normală $N(0, 1)$, atunci

$$\lim_{n \rightarrow \infty} F_{(n)}(x) = \Phi(x), \quad x \in \mathbb{R}.$$

Exemplul 1. În multe ramuri ale industriei se produc mari cantități de produse identice. Să presupunem că ne interesează o caracteristică numerică a unui astfel de produs. Cu toate că produsul este fabricat după anumite standarde, există întotdeauna o anumită abatere de la această valoare standard. Această abatere este provocată de un număr mare de factori aleatori, acțiunea fiecărui din ei luat separat fiind neglijabilă. Totuși însumarea efectelor tuturor acestor factori poate fi observabilă. În loc de a studia suma unui mare număr de v.a. (suma abaterilor) se va considera un sir de sume cu un număr din ce în ce mai mare de termeni și se va studia repartitia limită a funcțiilor de repartiție ale sumelor. Prin urmare, dacă se consideră un sir de v.a. independente X_1, X_2, \dots , atunci

$$\frac{1}{\sigma_{(n)}} \sum_{k=1}^n (X_k - a_k)$$

apreciază abaterea de la norma standard.

Exemplul 2. Fie $\lambda > 0$. Se consideră sirul de v.a. independente $(X_n)_{n \in \mathbb{N}^*}$ cu funcțiile de frecvență

$$X_k : \begin{pmatrix} k^\lambda & -k^\lambda \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}, \quad k \in \mathbb{N}^*.$$

Se obține $a_k = E(X_k) = 0$, $\sigma_k^2 = k^{2\lambda}$ și

$$\sigma_{(n)}^2 = 1^{2\lambda} + 2^{2\lambda} + \dots + n^{2\lambda} \sim \frac{n^{2\lambda+1}}{2\lambda+1}.^{12}$$

Se observă că dacă $\lambda < \frac{1}{2}$, atunci este îndeplinită condiția din teorema 4.8, ceea ce arată că în acest caz sirul $(X_n)_{n \in \mathbb{N}^*}$ satisfacă legea slabă a numerelor mari.

De asemenea, avem $|X_k| = k^\lambda \leq n^\lambda$ pentru $k = \overline{1, n}$ și există $n_0 \in \mathbb{N}^*$ astfel încât

$$\sigma_{(n)}^2 \geq \frac{n^{2\lambda+1}}{2(2\lambda+1)}$$

pentru orice $n \geq n_0$.

Prin urmare, pentru $n \geq \max(n_0, 2(2\lambda+1)\varepsilon^{-2})$ și $\varepsilon > 0$ rezultă

$$|X_k|^2 \leq n^{2\lambda} \leq \frac{\varepsilon^2 n^{2\lambda+1}}{2(2\lambda+1)} \leq \varepsilon^2 \sigma_{(n)}^2, \quad k = \overline{1, n},$$

ceea ce arată că este îndeplinită condiția din teorema 4.14 astfel că

$$\lim_{n \rightarrow \infty} P\{\alpha \leq X(n) \leq \beta\} = \Phi(\beta) - \Phi(\alpha), \quad \alpha, \beta \in \mathbb{R},$$

unde

$$X_{(n)} = \left(\frac{2\lambda+1}{n^{2\lambda+1}} \right)^{\frac{1}{2}} (X_1 + X_2 + \dots + X_n).$$

Această relație arată că suma $X_1 + X_2 + \dots + X_n$ are același ordin de mărime ca $n^{\lambda+\frac{1}{2}}$ pentru $n \rightarrow \infty$; deci pentru $\lambda \geq \frac{1}{2}$ nu poate fi îndeplinită condiția din teorema 4.10.

În concluzie teorema limită centrală este adevărată pentru orice $\lambda > 0$, în timp ce legea slabă a numerelor mari numai pentru $\lambda < \frac{1}{2}$.

Exemplul 3. Se consideră experimentul ce constă în aruncarea de n ori a unui zar. Fie X_k v.a. ce reprezintă numărul de puncte obținut la aruncarea de rang k . Se obține

$$E(X_k) = \frac{(1+2+3+4+5+6)}{6} = 3,5$$

¹²Scriem $a_n \sim b_n$ dacă $\lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 1$.

și

$$\text{Var}(X_k) = \frac{(1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2)}{6} - (3,5)^2 = \frac{35}{12}.$$

Valoarea $\frac{X_1 + \dots + X_n}{n}$ reprezintă numărul mediu de puncte obținut. Întrucât sunt îndeplinite condițiile din corolarul 4.15 rezultă că

$$\lim_{n \rightarrow \infty} P \left\{ |x_1 + \dots + X_n - 3,5n| \leq \alpha \left(\frac{3,5n}{12} \right)^{\frac{1}{2}} \right\} = \Phi(\alpha) - \Phi(-\alpha), \quad \alpha \in \mathbb{R}.$$

Dacă $n = 1000$ și $\alpha = 1$ se obține $P(3450 < X_1 + \dots + X_n < 3550) \simeq 0,68$. Dacă $\alpha_0 = 0,6744$, valoare ce îndeplinește condiția $\Phi(\alpha_0) - \Phi(-\alpha_0) = \frac{1}{2}$, se obține că probabilitatea ca suma $X_1 + \dots + X_n$ să fie în intervalul $(3500 - 36, 3500 + 36)$ este egală cu probabilitatea ca suma să se afle în afara acestui interval.

Exemplul 4. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente cu funcțiile de frecvență

$$X_n : \begin{pmatrix} \frac{1}{n^\beta} & \frac{-1}{n^\beta} & 0 \\ p & p & 1-2p \end{pmatrix}, \quad n \in \mathbb{N}^*,$$

unde $\frac{1}{3} < \beta \leq \frac{1}{2}$ și $0 < p < \frac{1}{2}$. Deoarece

$$E(X_k) = 0, \quad E(X_k^2) = \frac{2p}{n^{2\beta}}, \quad E(|X_k|^3) = \frac{2p}{n^{3\beta}}, \quad k \in \mathbb{N}^*$$

rezultă

$$\sigma_{(n)}^2 = \sum_{k=1}^n E(X_k^2) = 2p \sum_{k=1}^n \frac{1}{k^{2\beta}}, \quad \rho_{(n)}^3 = \sum_{k=1}^n E(|X_k|^3) = 2p \sum_{k=1}^n \frac{1}{k^{3\beta}}.$$

Din felul cum a fost ales β rezultă că seria $\sum_{k \in \mathbb{N}^*} \frac{1}{k^{2\beta}}$ este divergentă, iar seria $\sum_{k \in \mathbb{N}^*} \frac{1}{k^{3\beta}}$ este convergentă. Prin urmare $\lim_{n \rightarrow \infty} \frac{\rho_{(n)}}{\sigma_{(n)}} = 0$. Astfel condițiile corolarului 4.18 sunt îndeplinite.

4.4 Legea logaritmului iterat

În acest paragraf $(X_n)_{n \in \mathbb{N}^*}$ va fi un sir de v.a. independente și identic repartizate, definite pe (Ω, \mathcal{K}, P) , cu $E(X_n) = 0$, $n \in \mathbb{N}^*$. Se notează $S_n = X_1 + \dots + X_n$.

În aceste condiții (vezi teorema 4.13) rezultă că $S_n = o(n)$ a.s.¹³. Însă, uneori suntem interesăți în aproximări mai exacte ale lui S_n , ceea ce se poate obține în condiții destul de generale.

Teorema 4.20.

a) (Hausdorff). *Dacă repartiția comună a v.a. X_i , $1 \leq i \leq n$, pentru orice $n \in \mathbb{N}^*$, are momente finite și pozitive de orice ordin, atunci $S_n = o(n^{1/2+\varepsilon})$ a.s. pentru orice $\varepsilon > 0$.*

b) (Hardy și Littlewood). *Dacă $|X_i| \leq M$ a.s. $i = 1, 2, \dots$, atunci*

$$S_n = o(\sqrt{n \ln n}) \quad \text{a.s.}$$

c) (Hincin). *Dacă $|X_i| \leq M$ a.s. și $\text{Var}(X_i) = \sigma^2 < \infty$, $i = 1, 2, \dots$, atunci*

$$\limsup_{n \rightarrow \infty} \frac{S_n(\omega)}{\sigma \sqrt{2n \ln \ln n}} = 1, \quad \liminf_{n \rightarrow \infty} \frac{S_n(\omega)}{\sigma \sqrt{2n \ln \ln n}} = -1$$

în toate punctele ω cu eventual excepția unei mulțimi de puncte, constituind un eveniment de probabilitate nulă.

Prima dintre relațiile de la punctul c) arată că, pentru $\lambda > 1$, cu probabilitatea 1, inegalitatea $S_n > \lambda(2n\sigma^2 \ln \ln n)^{1/2}$ are loc pentru un număr finit de valori ale lui n , în timp ce, pentru $\lambda < 1$, această inegalitate are loc pentru o infinitate de valori ale lui n .

¹³Dacă $(Y_n)_{n \in \mathbb{N}^*}$ este un sir de v.a. pentru care $\frac{Y_n}{n^\alpha} \xrightarrow{\text{a.s.}} 0$, când $n \rightarrow \infty$, se scrie $Y_n = o(n^\alpha)$ a.s. ($\alpha > 0$). De asemenea, dacă există $M > 0$ și $A \in \mathcal{K}$ cu $P(A) = 0$ astfel încât pentru orice $\omega \in \Omega \setminus A$, sirul $|Y_n(\omega)/n^\alpha| \leq M$, atunci scriem $Y_n = o(n^\alpha)$ a.s.

Capitolul 5

Functii aleatoare de ordinul al doilea

5.1 Conceptul de proces stocastic (funcție aleatoare)

Fie (Ω, \mathcal{K}, P) un câmp de probabilitate și T o mulțime nevidă. O funcție $\xi : \Omega \times T \rightarrow S$, unde S (*spațiul stărilor*) este o mulțime pe care s-a introdus o σ -algebră, se numește *proces stocastic (funcție aleatoare)* dacă pentru fiecare $t \in T$, fixat, $\xi(\cdot, t) = \xi_t(\cdot)$ este o v.a. pe (Ω, \mathcal{K}, P) , iar pentru fiecare $\omega \in \Omega$, fixat, $\xi(\omega, \cdot) = \xi_\omega(\cdot)$ este o funcție definită pe T .

De obicei un proces stocastic se notează prin $\{\xi_t | t \in T\}$ sau $\{\xi(t) | t \in T\}$. Funcțiile $\xi_\omega(\cdot)$ definite pe T se numesc *traiectorii* ale procesului, iar T se numește *mulțimea parametrilor*.

Remarcăm deci, că un proces stocastic apare fie ca o familie de v.a. $\{\xi_t | t \in T\}$, fie ca o familie de funcții $\{\xi_\omega(\cdot) | \omega \in \Omega\}$, ce urmează o lege probabilistă.

Dacă T este o mulțime discretă, de exemplu, $T = \{0, 1, 2, \dots\}$, atunci spunem că $\{\xi_t | t \in T\}$ este un *proces stocastic cu parametru discret* sau *lanț*. În acest caz traiectoriile sunt siruri.

Dacă T este un interval, atunci spunem că $\{\xi_t | t \in T\}$ este un *proces stocastic cu parametru continuu*. Cazul particular $T = [0, \infty)$ are o mare importanță în aplicații, parametrul t având de cele mai multe ori o interpretare temporală.

Cea mai importantă clasificare a proceselor stocastice este făcută pe baza interdependențelor existente între repartițiile v.a. ξ_t , care alcătuiesc procesul.

Un exemplu foarte simplu de proces stocastic îl constituie un șir $\{\xi_n | n \in \mathbb{N}\}$ de v.a. independente.

5.2 Funcția de corelație

Să presupunem că, pentru $t \in T \subset \mathbf{R}$ fixat, v.a. reală $\xi(t)$ admite densitatea de probabilitate $p_1(x; t)$ (*densitatea de probabilitate unidimensională a funcției aleatoare*), iar pentru $t_1, t_2 \in T$ fixați, v.a. $\xi(t_1)$ și $\xi(t_2)$ admit densitatea comună de probabilitate $p_2(x_1, x_2; t_1, t_2)$ (*densitatea de probabilitate bidimensională a funcției aleatoare*). Atunci (vezi relația (2.5))

$$p_1(x_1; t_1) = \int_{-\infty}^{\infty} p_2(x_1, x_2; t_1, t_2) dx_2. \quad (5.1)$$

Densitatea de probabilitate n -dimensională a funcției aleatoare se definește similar.

Dacă spațiul stărilor este mulțimea numerelor reale sau complexe și $E(|\xi(t)|^2) < \infty$ pentru orice $t \in T$, atunci funcția $K(s, t) = E(\xi(s)\overline{\xi(t)})$ ¹ definită pentru orice $t, s \in T$ este numită *funcția de corelație* a procesului. Descrierea procesului $\{\xi(t) | t \in T\}$, care este bazată în întregime pe funcția K , depinde numai de densitatea bidimensională $p_2(x_1, x_2; t_1, t_2)$. Studiul acestui aspect al proceselor stocastice este denumit uneori *teoria funcțiilor aleatoare de ordin doi* sau *teoria corelației funcțiilor aleatoare*.

Funcția de corelație are următoarele proprietăți

- 1) $K(t, t) \geq 0$ pentru orice $t \in T$.
- 2) $K(s, t) = \overline{K(t, s)}$ pentru orice $s, t \in T$.
- 3) $|K(s, t)| \leq \sqrt{K(s, s)}\sqrt{K(t, t)}$ pentru orice $s, t \in T$.
- 4) Pentru orice numere complexe x_j și pentru orice numere reale t_j , $1 \leq j \leq n$, are loc relația

$$\sum_{i=1}^n \sum_{j=1}^n K(t_i, t_j) x_i \bar{x}_j \geq 0.$$

Această proprietate exprimă faptul că funcția $K : T \times T \rightarrow \mathbf{C}$ este o *funcție de tip pozitiv*. Este adevărată și reciproca acestei afirmații și anume că orice funcție de tip pozitiv este o funcție de corelație.

- 5) Fie funcțiile $\varphi_j : T \rightarrow \mathbf{C}$, $1 \leq j \leq n$. Se consideră funcția aleatoare

$$\eta(t) = \sum_{j=1}^n \varphi_j(t) \xi(t_j), \quad t \in T,$$

cu funcția de corelație $K_1(s, t)$. Atunci are loc relația

$$K_1(s, t) = \sum_{j=1}^n \varphi_j(s) K(s, t) \overline{\varphi_j(t)}, \quad s, t \in T.$$

¹ $\overline{\xi(t)}$ este complex conjugatul lui $\xi(t)$.

- 6) Suma și produsul a două funcții de corelație este o funcție de corelație.
 7) Orice combinație liniară finită cu coeficienți pozitivi de funcții de corelație este o funcție de corelație.

5.3 Staționaritatea

Să presupunem că $T \subset \mathbf{R}$ este un interval și că spațiul stărilor este \mathbf{R} . Pentru orice $n \in \mathbf{N}^*$ și $t_1, t_2, \dots, t_n \in T$ considerăm funcțiile de repartiție n -dimensionale

$$F(x_1, x_2, \dots, x_n; t_1, t_2, \dots, t_n) = P(\xi(t_1) \leq x_1, \dots, \xi(t_n) \leq x_n).$$

Aceste funcții caracterizează complet funcția aleatoare $\xi(t)$.

Funcția aleatoare $\xi(t)$ este *staționară în sens restrâns* dacă pentru orice $\tau \in \mathbf{R}$ și $n \in \mathbf{N}^*$

$$F(x_1, \dots, x_n; t_1 + \tau, t_2 + \tau, \dots, t_n + \tau) = F(x_1, \dots, x_n; t_1, t_2, \dots, t_n)$$

oricare ar fi $x_1, x_2, \dots, x_n \in \mathbf{R}$ și $t_1, t_2, \dots, t_n \in T$.

Din această definiție rezultă că, pentru o funcție aleatoare staționară în sens restrâns, $\xi(t)$, funcțiile de repartiție unidimensionale coincid, adică $F(x; t)$ nu depinde de t , iar funcțiile de repartiție bidimensionale depind numai de diferența $t_2 - t_1$. De asemenea, funcția de corelație $K(s, t)$ a unei funcții aleatoare staționare în sens restrâns depinde numai de diferența $t - s$.

Funcția aleatoare $\xi(t)$ este *staționară în sens larg* dacă $E(|\xi(t)|) < \infty$, $E(|\xi(t)|^2) < \infty$, $E(\xi(t))$ nu depinde de t , iar funcția de corelație $K(s, t)$ depinde numai de diferența $t - s$. Evident, o funcție aleatoare staționară în sens restrâns este staționară și în sens larg, în timp ce reciprocă nu este în general adevărată.

5.4 Derivata și integrala în medie de ordinul al doilea

O funcție aleatoare $\xi(t)$ este continuă în medie de ordinul al doilea în punctul $t_0 \in T$, dacă

$$\lim_{h \rightarrow 0} E(|\xi(t_0 + h) - \xi(t_0)|^2) = 0.$$

O funcție aleatoare $\xi(t)$ este *derivabilă în medie de ordinul al doilea* în punctul $t_0 \in T$, dacă există v.a. $\xi'(t_0)$ astfel încât

$$\lim_{h \rightarrow 0} E \left(\left| \frac{\xi(t_0 + h) - \xi(t_0)}{h} - \xi'(t_0) \right|^2 \right) = 0.$$

În acest caz, $\xi'(t_0) = \frac{d\xi(t)}{dt} \Big|_{t=t_0}$ este derivata în medie a lui $\xi(t)$ în punctul t_0 .

Dacă $T = [T_1, T_2]$, fie $T_1 = t_0 < t_1 < \dots < t_p = T_2$ o diviziune δ a lui T , iar $t_j \leq \tau_j < t_{j+1}$, $0 \leq j \leq p - 1$; se consideră v.a.

$$I(\delta, \tau_j) = \sum_{j=1}^{p-1} \xi(\tau_j)(t_{j+1} - t_j).$$

Funcția aleatoare $\xi(t)$ este integrabilă Riemann în medie de ordinul al doilea dacă există o v.a. I , notată $\int_{T_1}^{T_2} \xi(t) dt$, astfel încât

$$\lim_{\|\delta\| \rightarrow 0} E(|I(\delta, \tau_j) - I|^2) = 0,$$

unde

$$\|\delta\| = \max_{0 \leq j \leq p-1} (t_{j+1} - t_j).$$

Această integrală are proprietăți analoage celor ale integralei obișnuite. Astfel, de exemplu, să presupunem că funcția aleatoare $\xi(t)$ este integrabilă Riemann în medie de ordinul al doilea pe T ; pentru $t \in T$ considerăm integrala nedefinită $I(t) = \int_{T_1}^t \xi(u) du$; această integrală este pentru orice t fixat o v.a., deci când t variază obținem o funcție aleatoare. Dacă funcția aleatoare $\xi(t)$ este continuă în medie, deci integrabilă în medie, atunci $I(t)$ este derivabilă în medie și $\frac{dI(t)}{dt} = \xi(t)$ a.s. De asemenea, are loc relația

$$\int_T E(\xi(t)) dt = E \left(\int_T \xi(t) dt \right),$$

unde prima integrală este cea riemanniană obișnuită, iar a doua integrală este riemanniană în medie de ordinul al doilea.

Teorema 5.1. Pentru ca funcția aleatoare $\xi(t)$ să fie derivabilă în medie în punctul $t \in T$, este necesar și suficient ca derivata a doua generalizată² a funcției sale de corelație K să existe și să fie finită în punctul $(t, t) \in T \times T$.

Pentru ca o funcție aleatoare $\xi(t)$ să fie integrabilă Riemann în medie de ordinul al doilea pe T , este necesar și suficient ca funcția sa de corelație K să fie integrabilă Riemann pe $T \times T$.

²Prin derivata a doua generalizată în raport cu s și t a unei funcții $K : T \times T \rightarrow \mathbb{C}$ înțelegem limita

$$\frac{\partial^2 K(s, t)}{\partial s \partial t} = \lim_{(h, k) \rightarrow (0, 0)} \frac{1}{hk} [K(t + h, s + k) - K(t + h, s) - K(t, s + k) + K(t, s)].$$

Această noțiune se extinde imediat pentru derivata de orice ordin (pentru ordinul întâi derivata generalizată coincide cu derivata ordinată); toate derivelele generalizate ale lui K vor fi note cu simbolurile pentru derivarea obișnuită. Dacă derivata ordinată există și este continuă, atunci derivata generalizată există de asemenea și este egală cu ea.

5.5 Reprezentarea canonica

Dacă funcția aleatoare $\xi(t)$ poate fi scrisă sub forma

$$\xi(t) = E(\xi(t)) + \sum_{k \in \mathbb{N}^*} \nu_k X_k(t)$$

unde ν_k , ($E(\nu_k) = 0$, $E(\nu_i \nu_j) = 0$, $i \neq j$), sunt v.a. necorelate cu valori complexe, atunci expresia de mai sus poartă denumirea de *reprezentarea (descompunerea) canonica a funcției aleatoare* $\xi(t)$. Funcțiile $X_k(t)$ (care nu sunt aleatoare) se numesc *coordonatele reprezentării*, iar ν_k *coeficienții reprezentării*. Pentru funcția de corelație avem

$$K(s, t) = \sum_{k \in \mathbb{N}^*} \text{Var}_k X_k(s) X_k(t),$$

unde $\text{Var}_k = \text{Var}(\nu_k)$, numită *reprezentarea canonica a funcției de corelație*.

O funcție aleatoare este numită *zgomot alb* dacă funcția de corelație are forma $K(s, t) = G(t)\delta(t-s)$, unde $\delta(t-s) = 0$ pentru $t \neq s$. Dacă *intensitatea* $G(t)$ a zgomotului alb este constantă, atunci zgomotul alb este *staționar în sens larg*. Reprezentarea funcției aleatoare $\xi(t)$ sub forma

$$\xi(t) = E(\xi(t)) + \int_{\lambda_1}^{\lambda_2} \nu(\lambda) X(t, \lambda) d\lambda,$$

unde $\nu(\lambda)$ este zgomotul alb cu parametrul $\lambda \in [\lambda_1, \lambda_2]$, poartă denumirea de *reprezentare canonica integrală*. Pentru funcția de corelație vom avea

$$K(s, t) = \int_{\lambda_1}^{\lambda_2} G(\lambda) X(s, \lambda) \overline{X(t, \lambda)} d\lambda.$$

Orice funcție aleatoare staționară în sens larg admite reprezentarea (descompunerea spectrală)

$$\xi(t) = E(\xi(t)) + \int_{-\infty}^{\infty} \nu(\omega) e^{i\omega t}. \quad (5.2)$$

Aici funcția aleatoare $\nu(\omega)$ are valoarea medie nulă și funcția de corelație

$$K_\nu(\omega, \omega') = S(\omega) S(\omega - \omega'),$$

unde

$$S(\omega) = \frac{1}{2\pi} \int_{-\infty}^{\infty} B(\tau) e^{-i\omega\tau} d\tau$$

(densitatea spectrală a funcției aleatoare $\xi(t)$). Mai au loc relațiile

$$B(\tau) = \int_{-\infty}^{\infty} S(\omega) e^{i\omega\tau} d\omega, \quad \text{Var}(\xi(t)) = B(0) = \int_{-\infty}^{\infty} S(\omega) d\omega.$$

O clasă de funcții aleatoare staționare în sens larg sunt cele de forma $\eta(t) = f(t)\xi(t) + g(t)$, unde $\xi(t)$ este o funcție aleatoare în sens larg, iar $f(t)$ și $g(t)$ sunt funcții reale nealeatoare. Pentru aceste funcții aleatoare avem relațiile

$$E(\eta(t)) = f(t)E(\xi(t)) + g(t); \quad K_\eta(s, t) = f(s)f(t)B_\xi(s - t),$$

$$\text{Var}(\eta(t)) = f^2(t)B_\xi(0).$$

Dacă

$$\eta(t) = \text{Var}(\eta(t)) + \sum_{k \in \mathbf{Z}} \nu_k Y_k(t)$$

este reprezentarea canonica a funcției $\eta(t)$, atunci coeficienții acestei reprezentări sunt dați de

$$Y_k(t) = f(t)e^{i\omega_k t}, \quad \omega_k = \frac{\pi k}{2T}, \quad k \in \mathbf{Z}.$$

În ceea ce privește descompunerea spectrală avem

$$\eta(t) = E(\eta(t)) + \int_{-\infty}^{\infty} \nu(\omega)Y(t, \omega)d\omega,$$

unde

$$Y(t, \omega) = f(t)e^{i\omega t}.$$

Exemplul 1. Emisia de semnale a unui telegraf poate fi descrisă de o funcție aleatoare $\xi(t)$ cu proprietatea că, pentru t fixat, $\xi(t)$ ia, cu probabilități egale, valorile 1 sau 0 după cum la momentul t , telegraful emite sau nu semnal. Evident, traiectoria lui $\xi(t)$ este o funcție ce ia valorile 0 și 1. Presupunem că numărul de salturi ale acestei funcții în intervalul $[0, T]$ este repartizat Poisson; mai precis, probabilitatea de a avea k salturi în intervalul $[0, T]$ este

$$P(k, T) = \frac{(aT)^k}{k!} e^{-aT}, \quad a > 0.$$

De asemenea, presupunem că salturile se produc independent. În aceste ipoteze avem

$$E(\xi(t)) = 0 \cdot P(\xi(t) = 0) + 1 \cdot P(\xi(t) = 1) = 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = \frac{1}{2}$$

$$K(s, t) = (0 \cdot 0)P(\xi(s) = 0, \xi(t) = 0) + (0 \cdot 1)P(\xi(s) = 0, \xi(t) = 1) + \\ + (1 \cdot 0)P(\xi(s) = 1, \xi(t) = 0) + (1 \cdot 1)P(\xi(s) = 1, \xi(t) = 1) = P(\xi(s) = 1, \xi(t) = 1).$$

Probabilitatea $P(\xi(s) = 1, \xi(t) = 1)$ este egală cu probabilitatea ca $\xi(t) = 1$ și ca în intervalul de lungime $t - s = \tau$ să aibă loc un număr par de salturi. Deci

$$P(\xi(s) = 1, \xi(t) = 1) = \frac{1}{2} \sum_{s \in \mathbb{N}} \frac{(a|\tau|)^{2s}}{(2s)!} e^{-a|\tau|}.$$

Prin urmare

$$B(\tau) = \frac{1}{4}(1 + e^{-2a|\tau|}).$$

Exemplul 2. Fie $\xi(t) = \xi f(t)$, unde ξ este o v.a. reală, iar $f(t)$ este o funcție cu valori complexe.

Se va studia în ce condiții funcția aleatoare $\xi(t)$ este staționară în sens larg. Din condiția $E(\xi(t)) = 0$ rezultă $E(\xi) = 0$; apoi

$$E[\xi(t + \tau)\overline{\xi(t)}] = f(t + \tau)\overline{f(t)}E(|\xi|^2)$$

și prin urmare, este necesar ca produsul $f(t + \tau)\overline{f(t)}$ să nu depindă de t . Punând $\tau = 0$ obținem $|f(t)|^2 = r^2 = \text{const}$. Deci $f(t) = r e^{i\varphi(t)}$, unde $r \in \mathbb{R}$, iar φ este o funcție reală. Așadar

$$E[\xi(t + \tau)\overline{\xi(t)}] = r^2 e^{i[\varphi(t+\tau) - \varphi(t)]} E(|\xi|^2),$$

de unde rezultă că diferența $\varphi(t + \tau) - \varphi(t)$ nu trebuie să depindă de t ; dacă presupunem că φ este derivabilă, vom avea

$$\frac{d}{dt}[\varphi(t + \tau) - \varphi(t)] = 0,$$

adică $\varphi'(t + \tau) = \varphi'(t)$ și cum τ este arbitrar avem $\varphi'(t) = \lambda$, de unde $\varphi(t) = \lambda t + \mu$. În concluzie

$$f(t) = r e^{i(\lambda t + \mu)}, \quad \lambda, \mu \in \mathbb{R}.$$

Exemplul 3. Procesul aleator $\xi(t)$ se numește *gaussian* dacă repartițiile sale finit dimensionale sunt normale (vezi §3.6). Dacă procesul gaussian este staționar în sens larg, atunci el este staționar și în sens restrâns. Un proces gaussian este definit dacă î se cunoaște valoarea medie și funcția de corelație.

Vectorul aleator $(\xi(t_1), \xi(t_2), \dots, \xi(t_n))$ are densitatea de probabilitate de forma

$$p(x_1, \dots, x_n) = \frac{1}{(2\pi)^n D} e^{-\frac{1}{2D} \sum_{i,j=1}^n A_{ij}(x_i - m_i)(x_j - m_j)},$$

unde

$$D = \begin{vmatrix} k_{11} & k_{12} & \dots & k_{1n} \\ k_{21} & k_{22} & \dots & k_{2n} \\ \dots & \dots & \dots & \dots \\ k_{n1} & k_{n2} & \dots & k_{nn} \end{vmatrix} \quad (k_{ij} = k_{ji}, \quad D > 0)$$

122 CAPITOLUL 5. FUNCȚII ALEATOARE DE ORDINUL AL DOILEA

este matricea de corelație,

$$k_{ij} = K(t_i, t_j),$$

iar $\frac{A_{ij}}{D}$ sunt elementele inversei matricei $(k_{ij})_{1 \leq i, j \leq n}$. Pentru procese staționare avem

$$K(t_i, t_j) = K(t_i - t_j) = B(\tau_{ij}), \quad \tau_{ij} = t_i - t_j.$$

Capitolul 6

Teoria reînnoirii

6.1 Funcția de reînnoire

Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v.a. independente, identic repartizate cu funcția de repartiție F , $F(0) = 0$, definite pe un spațiu de probabilitate (Ω, \mathcal{K}, P) . Sirul $(S_n)_{n \in \mathbb{N}}$, unde

$$S_n = X_1 + X_2 + \dots + X_n, \quad n \in \mathbb{N}^*, \quad S_0 = 0,$$

se numește *sir de reînnoire*.

În problemele practice care au condus la constituirea teoriei reînnoirii, v.a. S_1, S_2, \dots reprezintă momentele în care are loc înlocuirea (reînnoirea) componentei defecte, iar X_1, X_2, \dots sunt duratele de funcționare. Valoarea medie $\mu = E(X_k)$, care există putând fi eventual infinită, se numește *durata medie de funcționare*.

Din punct de vedere practic, este important de luat în considerare v.a. $N(t)$, ce desemnează *numărul de reînnoiri* într-un interval de timp $[0, t]$. Mai precis,

$$N(t) = \max\{n | S_n \leq t\}.$$

Se demonstrează că

$$P(N(t) = n) = F^{(n)}(t) - F^{(n+1)}(t), \quad (6.1)$$

unde $F^{(n)}(t)$ este conoluția de ordinul n a funcției F ¹;

$$E(N(t)) = \sum_{n \in \mathbb{N}^*} F^{(n)}(t). \quad (6.2)$$

¹Mai precis, $F^{(n)}$ se definește prin recurență astfel:

$$F^{(1)} = F; \quad F^{(n)}(t) = \int_0^t F^{(n-1)}(t-y)dF(y), \quad n \geq 2.$$

Integrala este Lebesgue-Stieltjes. Dacă F admite densitatea p , $dF(y)$ se înlocuiește cu $p(y)dy$.

Funcția $U(t) = E(N(t))$, dată de relația (6.2), se numește *funcție de reînnoire*. Funcția de reînnoire verifică relația

$$U(t) = F(t) + \int_0^t U(t-y)dF(y), \quad (6.3)$$

numită *ecuația de reînnoire*.

În legătură cu funcția de reînnoire există următorul rezultat.

Teorema 6.1 (Blackwell). *Dacă F nu este aritmetică², atunci pentru orice $h > 0$,*

$$\lim_{t \rightarrow \infty} [U(t) - U(t-h)] = \frac{h}{\mu}, \quad \text{unde } \mu = E(X_n)$$

cu convenția $\frac{1}{\infty} = 0$.

6.2 Extinderi ale conceptului de reînnoire

În teoria reînnoirii sunt întâlnite următoarele două generalizări.

1. Admitem posibilitatea ca la fiecare moment de reînnoire procesul să poată fi oprit cu probabilitatea $q \in (0, 1)$ și continuat cu probabilitatea $p = 1 - q$, independent de evoluția procesului până la acel moment. Fie $(\tau_n)_{n \in \mathbb{N}}$ un sir de v.a. independente și identic repartizate cu

$$P(\tau_n = 0) = q, \quad P(\tau_n = 1) = 1 - q, \quad n \in \mathbb{N}^*.$$

Presupunem că sirurile (τ_n) și (X_n) sunt independente. V.a. τ_n ia valorile 0 sau 1, după cum la cea de a n -a reînnoire se decide stoparea sau respectiv continuarea procesului. Fie

$$G(t) = P(X_n \leq t, \tau_n = 1) = P(X_n \leq t)p = pF(t),$$

de unde $G(\infty) = p$. Prin urmare, se poate considera că evoluția procesului ce poate fi stopat este descrisă de un sir de v.a. independente și identic repartizate, ce pot lua valoarea $+\infty$, având funcția de repartiție G . Dacă $X_n = +\infty$ înseamnă că procesul a fost oprit la cea de a n -a reînnoire.

Funcția de reînnoire verifică și în acest caz o ecuație de reînnoire de forma (6.3) și numărul mediu de reînnoiri în intervalul $[0, \infty)$ este

$$U(\infty) = \frac{1}{1-p}.$$

²O funcție de repartiție F , nulă pe semiaxă negativă, se numește *aritmetică* dacă există o constantă $d > 0$ astfel încât F să fie constantă pe orice interval deschis de forma $(nd, (n+1)d)$, $n \in \mathbb{N}$.

De asemenea, probabilitatea ca procesul să fie stopat până la momentul t este $qU(t)$, deci $H(t) = qU(t)$ este repartitia "timpului de viață" al procesului. Funcția H verifică ecuația de reînnoire

$$H(t) = 1 - G(\infty) + \int_0^t H(t-y)dG(y).$$

2. V.a. X_1 , deși independentă de celelalte, are o altă repartitie F_1 . Aceasta corespunde situației în care momentul începerii observării procesului este ulterior momentului intrării în funcțiune a componentei respective. Dacă $V(t)$ este numărul mediu de reînnoiri în intervalul $[0, t]$, atunci $V(t)$ verifică ecuația de reînnoire

$$V(t) = F_1(t) + \int_0^t V(t-y)dF(y).$$

De asemenea, se demonstrează că dacă F nu este aritmetică, atunci

$$V(t) \sim \mu^{-1}t,$$

când $t \rightarrow \infty$, unde

$$\mu = E(X_n), \quad n \geq 2, \quad (\text{adică } \lim_{t \rightarrow \infty} \frac{V(t)}{\mu^{-1}t} = 1),$$

rezultat cunoscut sub numele de *teorema elementară a reînnoirii*.

Următoarele trei v.a. prezintă interes în aplicațiile teoriei reînnoirii.

a.
$$Y(t) = S_{N(t)+1} - t$$

reprezintă timpul rezidual de așteptare de la momentul t până la următoarea reînnoire. Dacă prima v.a. X_1 are repartitia F_1 , iar $V(t)$ este funcția de reînnoire, atunci repartitia v.a. $Y(t)$ este dată de

$$\begin{aligned} P(Y(t) \leq y) &= [V(t+y) - V(t)][1 - F(y)] + \\ &+ \int_0^y [V(t+y) - V(t+y-s)]dF(s). \end{aligned}$$

Dacă F nu este aritmetică, atunci

$$\lim_{t \rightarrow \infty} P(Y(t) \leq y) = \int_0^y \frac{1 - F(s)}{\mu} ds.$$

b.
$$X(t) = t - S_{N(t)}$$

reprezintă timpul scurs de la ultima reînnoire până la momentul t . În ceea ce privește repartiția v.a. $X(t)$, au loc relațiile

$$P(X(t) \leq x | X(0) = x_0) = \begin{cases} \int_{t-x}^t [1 - F(t-s)]dU(s), & 0 \leq x < t \\ \frac{F(x_0+t) - F(x_0)}{1 - F(x_0)}, & t \leq x < t + x_0 \\ 1, & x \geq t + x_0 \end{cases}$$

$$\lim_{t \rightarrow \infty} P(X(t) \leq x | X(0) = x_0) = \frac{1}{\mu} \int_0^x [1 - F(s)]ds,$$

limita fiind nulă dacă $\mu = \infty$.

$$c. \quad L(t) = S_{N(t)+1} - S_{N(t)} = X_{N(t)+1}$$

reprezintă durata dintre acele reînnoiri consecutive între care se află momentul t .

Funcția de repartiție a v.a. $L(t)$ este

$$P(L(t) \leq x) = \begin{cases} \int_{t-x}^t [F(x) - F(t-y)]dU(y), & 0 < x \leq t \\ F(x) - F(t) + \int_0^t [F(x) - F(t-y)]dU(y), & x > t. \end{cases}$$

Dacă F nu este aritmetică, atunci

$$\lim_{t \rightarrow \infty} P(L(t) \leq x) = \frac{1}{\mu} \int_0^x y dF(y),$$

limita fiind nulă dacă $\mu = \infty$.

Exemplul 1. Se consideră un proces de reînnoire pentru care funcția de repartiție F este exponențială cu parametrul $\lambda > 0$. În acest caz

$$F^{(n)}(t) = \int_0^t \frac{\lambda^n x^{n-1}}{(n-1)!} e^{-\lambda x} dx,$$

de unde se poate deduce că

$$P(N(t) = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}; \quad \text{deci} \quad U(t) = E(N(t)) = \lambda t.$$

De asemenea,

$$P(X(t) \leq x | X(0) = x_0) = \begin{cases} 1 - e^{-\lambda x}, & 0 \leq x < t \\ 1 - e^{-\lambda t}, & t \leq x < t + x_0 \\ 1, & x \geq t + x_0 \end{cases}$$

$$P(Y(t) \leq y) = 1 - e^{-\lambda y},$$

$$P(L(t) \leq x) = \begin{cases} 1 - (1 - \lambda x)e^{-\lambda x}, & 0 < x \leq t \\ 1 - (1 + \lambda t)e^{-x}, & x > t. \end{cases}$$

Exemplul 2. Presupunem că X_1, X_2, \dots reprezintă duratele de viață ale unei componente care în momentul defectării este înlocuită instantaneu cu una identică. Prin urmare, v.a. pozitive X_1, X_2, \dots sunt independente și identic repartizate cu funcția de repartiție F și valoarea medie μ .

Numărul mediu de înlocuiri în intervalul $[0, t]$ este $U(t)$, iar teorema elementară a reînnoirii arată că

$$\lim_{t \rightarrow \infty} \frac{U(t)}{t} = \frac{1}{\mu}$$

și deci, pentru valori mari ale lui t , rata (intensitatea) înlocuirilor este $\frac{1}{\mu}$. Așadar, orice strategie de înlocuire, care prescrie înlocuirea componentei înainte de defectare, va conduce la folosirea în medie a mai mult de $\frac{1}{\mu}$ componente pe unitatea de timp. Cu toate acestea, există situații în care trebuie evitată defectarea în timpul serviciului (căi ferate, echipamente aeronautice etc.)

Să considerăm strategia înlocuirii la o vârstă fixată T , în care componenta este înlocuită fie la vârsta T , fie la momentul defectării, dacă aceasta are loc înaintea împlinirii vârstei T .

Pentru valori mari ale lui t , ne așteptăm ca procentul de componente înlocuite până la momentul t din cauza defectării lor să fie $F(T)$, iar a celor înlocuite datorită vârstei să fie $1 - F(T)$. Notăm

$$F_T(x) = \begin{cases} F(x), & x < T \\ 1, & x \geq T. \end{cases}$$

Atunci valoarea medie corespunzătoare este

$$\mu_T = \int_0^\infty [1 - F_T(x)]dx = \int_0^T [1 - F(x)]dx < \mu.$$

Prin urmare, pentru t suficient de mare, rata înlocuirilor în cadrul strategiei va fi

$$\frac{1}{\mu_T} > \frac{1}{\mu}.$$

Se poate arăta că rata înlocurilor datorate defectărilor este (pentru valori mari ale lui t) mai mică decât $\frac{1}{\mu_T}$; de asemenea, pentru anumite repartiții, această rată este mai mică chiar decât $\frac{1}{\mu}$. În cazul în care F este exponențială cele două rate sunt egale.

Capitolul 7

Lanțuri Markov finite

Lanțul Markov constituie cel mai simplu tip de proces stocastic cu v.a. dependente dar, în același timp, este tipul fundamental de astfel de proces. Este de remarcat faptul că puține concepte matematice se bucură de potențialități comparabile cu cele ale conceptului de dependență markoviană¹. În afară de potențialități matematice incontestabile, conceptul de dependență markoviană are și importante potențialități aplicative. Astfel, teoria dependenței markoviene a fost aplicată în diverse domenii ca: controlul statistic al calității producției industriale, siguranța în funcționare a sistemelor tehnice complexe, biologie și medicină, demografie, geografie, geofizică, teoria mobilității sociale, sisteme de educație, economie, poluare, marketing, operații financiare, mobilitatea forței de muncă, circulația bancnotelor, teoria metrică a numerelor.

7.1 Proprietatea Markov. Matricea de trecere

Fie $(\xi_n)_{n \in \mathbb{N}}$ un proces stocastic cu parametru discret și cu valori într-o mulțime finită S , numită *spațiu stăriilor*.

Dacă pentru orice stări $i_1, i_2, \dots, i_n, i_{n+1} \in S$ și orice $n \in \mathbb{N}^*$ este verificată relația (numită *proprietatea Markov*)

$$P(\xi_{n+1} = i_{n+1} | \xi_n = i_n, \dots, \xi_1 = i_1) = P(\xi_{n+1} = i_{n+1} | \xi_n = i_n),$$

atunci $(\xi_n)_{n \in \mathbb{N}}$ este numit *lanț Markov finit*.

Se poate spune că un lanț Markov finit păstrează despre evoluția trecută amintirea cea mai recentă.

¹Conceptul de dependență markoviană a fost introdus pentru prima dată într-o formă explicită de matematicianul rus A.A. Markov (1856-1922) în anul 1906. Dar cu mult timp înainte, au fost întâlnite siruri de v.a. care sunt lanțuri Markov în terminologia actuală. Astfel, un exemplu celebru este lanțul Markov asociat modelului Bernoulli expus în exemplul 2, §7.4.

Dacă probabilitatea condiționată $p_{ij} = P(\xi_{n+1} = j \mid \xi_n = i)$ depinde numai de stările $i, j \in S$ și este independentă de n , atunci lanțul Markov este numit *omogen*. În acest caz, matricea $P = (p_{ij})$, $i, j \in S$, este numită *matricea probabilităților de trecere*. În continuare se va presupune că lanțul Markov este omogen.

Este evident că $\sum_{j \in S} p_{ij} = 1$, $i \in S$, motiv pentru care P este numită *matrice stocastică*.

Se observă că, dacă pentru orice $i, j \in S$, fixați, notăm

$$p_{ij}^{(n)} = P(\xi_{m+n} = j \mid \xi_m = i),$$

$(p_{ij}^{(n)})$ se numește *probabilitate de trecere din starea i în starea j după n pași*, atunci $p_{ij}^{(n)}$ este elementul din linia i și coloana j al matricei P^n , puterea a n -a a matricei de trecere P .

Înținând seama de aceasta, rezultă că

$$p_{ij}^{(m+n)} = \sum_{k \in S} p_{ik}^{(m)} p_{kj}^{(n)}, \quad i, j \in S, \quad m, n \in \mathbb{N}^*.$$

Această relație se numește *relația Chapman-Kolmogorov*.

Dacă $p = (p_i)$, $i \in S$, este o repartiție de probabilitate pe S , adică $p_i \geq 0$, $i \in S$, $\sum_{i \in S} p_i = 1$ și dacă $P(\xi_0 = i) = p_i$, $i \in S$, atunci p este numită *repartiția inițială a lanțului Markov*.

Orice lanț Markov finit cu r stări poate fi reprezentat cu ajutorul unui sistem de urne astfel: considerăm r urne numerotate 1, 2, ..., r care conțin fiecare bile de r tipuri diferite marcate de asemenea 1, 2, ..., r . Probabilitatea de a extrage o bilă de tipul j din urna i este egală cu p_{ij} . La momentul inițial alegem o urnă conform repartiției de probabilitate $(p_i)_{1 \leq i \leq r}$. Apoi din această urnă extragem o bilă, pe care o reintroducem în urnă. Dacă bila extrasă a fost de tipul i , atunci extragerea următoare o vom face din urna i , §.a.m.d. Astfel, sirul tipurilor de bile extrasă succesiv este un lanț Markov cu spațiul stărilor $S = \{1, 2, \dots, r\}$, repartiția inițială $(p_i)_{1 \leq i \leq r}$ și probabilitățile de trecere p_{ij} .

În continuare vom discuta câteva consecințe imediate ale proprietății Markov.

Spunem că un eveniment A este *anterior* momentului $n \geq 0$ într-un lanț $(\xi_n)_{n \in \mathbb{N}}$ dacă este determinat de v.a. ξ_0, \dots, ξ_n ale lanțului.

Spunem că un eveniment B este *posterior* momentului $n \geq 0$ într-un lanț Markov $(\xi_n)_{n \in \mathbb{N}}$ dacă este determinat de v.a. ξ_n, ξ_{n+1}, \dots

Pentru un lanț Markov, se poate arăta imediat următoarea egalitate care generalizează proprietatea Markov și anume

$$P(\xi_{n+1} = i_{n+1} \mid \xi_n = i_n, A) = P(\xi_{n+1} = i_{n+1} \mid \xi_n = i_n)$$

²Sydney Chapman (1888-1970), matematician englez.

oricare ar fi evenimentul A anterior momentului n , ori de câte ori membrul întâi este definit.

Mai mult, proprietatea Markov poate fi extinsă în continuare considerând evenimentele A și B , anterior și respectiv posterior momentului n , astfel

$$P(B | \xi_n = i_n, A) = P(B | \xi_n = i_n).$$

Se remarcă că extinderile succesive ale proprietății Markov sunt de fapt echivalente cu aceasta; de aceea, oricare din ele poate fi luată ca definiție. O extensie a proprietății Markov, dar calitativ diferită, este proprietatea tare Markov.

O v.a. $\tau : \Omega \rightarrow \mathbf{N} \cup \{\infty\}$ se numește *timp de oprire* (sau *optională*) pentru un lanț Markov $(\xi_n)_{n \in \mathbf{N}}$ dacă oricare ar fi $k = 0, 1, 2, \dots$ evenimentul $\{\tau = k\}$ este anterior momentului k în lanțul considerat, adică este determinat de v.a. $\xi_0, \xi_1, \dots, \xi_k$.

Spunem că un eveniment A este *anterior timpului de oprire* τ dacă oricare ar fi $k = 0, 1, \dots$ evenimentul $A \cap \{\tau = k\}$ este anterior momentului k în lanțul Markov considerat, adică A este determinat de v.a. ξ_0, \dots, ξ_τ . Analog, un eveniment B este *posterior timpului de oprire* τ dacă este determinat de v.a. $\xi_\tau, \xi_{\tau+1}, \dots$

Se poate arăta că proprietatea Markov rămâne adevărată și pentru timpii de oprire. Fie τ un timp de oprire pentru lanțul Markov $(\xi_n)_{n \in \mathbf{N}}$. Dacă A este un eveniment anterior lui τ , atunci

$$P(\xi_{\tau+1} = j | \xi_\tau = i, A) = P(\xi_{\tau+1} = j | \xi_\tau = i) = p_{ij}$$

oricare ar fi $i, j \in S$, ori de câte ori membrul întâi este definit. Dacă A și B sunt evenimente anterior, respectiv posterior lui τ , atunci

$$P(B | \xi_\tau = i, A) = P(B | \xi_\tau = i) \quad \forall i \in S,$$

ori de câte ori membrul întâi este definit. Această relație reprezintă *proprietatea tare Markov*. Să remarcăm că ea este implicată de proprietatea Markov și se reduce la aceasta în cazul în care τ este un timp nealeator. Rezultă că cele două proprietăți sunt, în fapt, echivalente.

7.2 Clasificarea stărilor

Stările unui lanț Markov pot fi grupate în clase după criteriul comunicării. Vom spune că starea j este *accesibilă* din starea i și vom scrie $i \rightarrow j$ dacă există $n \in \mathbf{N}^*$ astfel încât $p_{ij}^{(n)} > 0$. Se observă că această relație este tranzitivă. Starea i este *reflexivă* dacă $i \rightarrow i$ și *nereflexivă* în caz contrar, deci, dacă $p_{ii}^{(n)} = 0$ pentru orice $n \in \mathbf{N}^*$. Un caz particular de stare reflexivă este starea

absorbantă; se spune că o stare i este absorbantă dacă $p_{ii} = 1$. Pentru o stare reflexivă i , se definește perioada d_i a sa, ca cel mai mare divizor comun al numerelor $n \geq 1$ pentru care $p_{ii}^{(n)} > 0$.

O stare i se numește *periodică* sau *aperiodică* după cum $d_i > 1$ sau $d_i = 1$. Vom spune că stările i și j *comunică* și vom scrie $i \leftrightarrow j$ dacă $i \rightarrow j$ și $j \rightarrow i$. Se observă că relația \leftrightarrow este o relație de echivalență în mulțimea stărilor reflexive din S . Cu ajutorul acestei relații, mulțimea stărilor reflexive din S se împarte în clase, astfel încât două stări aparțin aceleiași clase dacă și numai dacă ele comunică. Prin definiție, orice stare nereflexivă formează ea însăși o clasă.

O proprietate a stărilor unui lanț Markov se numește *proprietate de clasă* dacă verificarea ei pentru o stare $i \in S$, atrage după sine verificarea ei pentru toate stările din clasa care conține starea i .

O stare i se numește *esențială* dacă relația $i \rightarrow j$ atrage după sine $j \rightarrow i$; în caz contrar, starea se numește *neesențială*.

Proprietatea unei stări de a fi esențială (neesențială), precum și proprietatea de a avea perioada d sunt proprietăți de clasă.

Un lanț pentru care spațiul stărilor formează o singură clasă esențială se numește *ireductibil*. Un lanț ireductibil se numește *aperiodic* dacă o stare a sa (și deci toate) are perioada 1.

Fie $f_{ij}^{(n)}$ probabilitatea ca lanțul să ajungă pentru prima dată în starea j după n pași, știind că a pornit din starea i ; deci

$$f_{ij}^{(n)} = P(\xi_n = j, \xi_k \neq j, \quad 1 \leq k \leq n-1 \mid \xi_0 = i).$$

Să notăm cu $f_{ij} = \sum_{n \in \mathbb{N}^*} f_{ij}^{(n)}$ probabilitatea ca lanțul să ajungă vreodată în starea j , știind că a pornit din starea i . O stare i se numește *recurentă* sau *nerecurentă (tranzientă)* după cum $f_{ii} = 1$ sau $f_{ii} < 1$. Recurența sau nerecurența sunt proprietăți de clasă. Lanțul se numește *recurent* dacă toate stările sale sunt recurente.

Dacă lanțul Markov pleacă dintr-o stare nerecurentă, atunci cu probabilitatea 1, el face un număr finit de pași în mulțimea stărilor nerecurente, după care intră într-una din clasele recurente unde rămâne la nesfârșit.

Se poate demonstra că o stare recurrentă este esențială, iar o stare neesențială este nerecurentă.

Pentru $j \in S$, fixat, fie τ_j v.a. care indică momentul primei trecheri a lanțului prin starea j . Se arată că

$$P(\tau_j = n \mid \xi_0 = i) = f_{ij}^{(n)}, \quad P(\tau_j = \infty \mid \xi_0 = i) = 1 - f_{ij},$$

iar valoarea medie a v.a. τ_j condiționată de $(\xi_0 = i)$ este

$$\nu_{ij} = E(\tau_j \mid \xi_0 = i) = \sum_{n \in \mathbb{N}^*} n f_{ij}^{(n)} + \infty \cdot (1 - f_{ij}).^3$$

Cantitatea ν_{ij} se numește *durata medie a primei treceri* din starea i în starea j , iar $m_{ij} = \frac{1}{\nu_{ij}}$ (cu convenția $\frac{1}{0} = \infty$, $\frac{1}{\infty} = 0$) se numește *frecvență medie a primei treceri* din starea i în starea j . În particular $m_i = m_{ii}$ se numește *temp mediu de recurență* al stării i . O stare $i \in S$ se numește *pozitivă sau nulă* după cum $m_i > 0$ sau $m_i = 0$. Proprietatea de a fi pozitivă sau nulă este o proprietate de clasă.

7.3 Teoreme limită

Un lanț Markov se numește *regulat* dacă limita $\pi_j = \lim_{n \rightarrow \infty} p_{ij}^{(n)}$, $i, j \in S$, există, este strict pozitivă și independentă de $i \in S$.

În notația matriceală, regularitatea unui lanț Markov finit revine la convergența matricei P^n către o matrice A care are toate liniile identice și strict pozitive.

Se spune că repartiția inițială $p = (p_i)_{i \in S}$ a unui lanț Markov este *staționară* dacă $p_i = \sum_{j \in S} p_j p_{ji}$ pentru orice $i \in S$.

Teorema 7.1. Dacă $(\xi_n)_{n \in \mathbb{N}}$ este un lanț Markov finit atunci:

1) Există totdeauna limitele

$$\pi_{ij} = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n p_{ij}^{(k)}, \quad i, j \in S.$$

Dacă aceste limite sunt strict pozitive și nu depind de i , $i \in S$, lanțul se numește *ergodic*.

2) Lanțul Markov este ergodic dacă și numai dacă este ireductibil și pozitiv recurrent.

3) Lanțul Markov este regulat dacă și numai dacă este ergodic și aperiodic, caz în care $\pi_{jj} = \frac{1}{m_j}$.

4) Lanțul Markov este regulat dacă și numai dacă există $r \in \mathbb{N}^*$ astfel încât matricea P^r să aibă toate elementele strict pozitive. În aceste condiții, cantitățile $|p_{ij}^{(n)} - \pi_{jj}|$, $i, j \in S$, converg exponențial către zero.

5) Dacă lanțul este ireductibil pozitiv recurrent (în particular dacă lanțul este regulat), există o repartiție unică staționară ale cărei componente sunt $\pi_i = \frac{1}{m_i}$, $i \in S$.

³Prin convenție se consideră $0 \cdot \infty = 0$.

7.4 Lanțuri Markov absorbante

Un lanț Markov finit în care toate stările recurente sunt absorbante se numește *lanț absorbant*. În acest caz matricea lanțului are forma canonică

$$P = \begin{pmatrix} I & 0 \\ R & T \end{pmatrix},$$

unde I este matricea unitate, iar R și T sunt matrice ce corespund probabilităților de trecere din stări tranziente în stări absorbante și respectiv în stări de asemenea tranziente.

Dacă notăm cu ν_j numărul aparițiilor stării tranziente j , atunci se demonstrează că $E(\nu_j | \xi_0 = i)$ (deci valoarea medie a lui ν_j condiționată de faptul că lanțul a plecat din i) este elementul ce se află la intersecția dintre linia i și coloana j din matricea $N = (I - T)^{-1}$ numită *matricea fundamentală*.

Dacă se notează cu a_{ik} probabilitatea ca lanțul Markov, plecând din starea tranzientă i , să ajungă în starea absorbantă k , atunci are loc egalitatea matriceală

$$(a_{ik})_{i \in T, k \in S \setminus T} = NR.$$

Exemplul 1. (*Mers la întâmplare cu frontiere absorbante*). Ne imaginăm un sir infinit de experimente Bernoulli independente E_1, E_2, \dots având fiecare două rezultate posibile α și $\bar{\alpha}$ cu probabilitățile p , respectiv q , ($p + q = 1$) (vezi exemplul 2, §1.3.). Se consideră o particulă care se poate deplasa pe o axă orientată, putând ocupa numai punctele de abscisă întreagă $0, 1, 2, \dots, l$; la fiecare moment n particula rămâne imobilă dacă se află într-unul din punctele 0 sau 1, iar, în caz contrar, ea face un salt de o unitate spre dreapta sau spre stânga după cum E_n a avut rezultatul α sau $\bar{\alpha}$. Poziția particulei poate fi reprezentată de un lanț Markov cu spațiul stărilor $S = \{0, 1, \dots, l\}$ și cu matricea de trecere

$$P = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 & 0 & 0 \\ q & 0 & p & \dots & 0 & 0 & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & 0 & \dots & q & 0 & p \\ 0 & 0 & 0 & \dots & 0 & 0 & 1 \end{pmatrix}.$$

Stările 0 și 1 sunt absorbante, iar celelalte sunt tranziente. Matricea T din

forma canonica este

$$T = \begin{pmatrix} 0 & p & 0 & \dots & 0 & 0 \\ q & 0 & p & \dots & 0 & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & 0 & \dots & 0 & p \\ 0 & 0 & 0 & \dots & q & 0 \end{pmatrix}$$

și prin calcul direct se arată că elementele n_{ij} ale matricei fundamentale N au valorile

$$n_{ij} = \frac{1}{(p-q)(a^l - 1)} \cdot \begin{cases} (a^j - 1)(a^{l-1} - 1), & j \leq i \\ (a^i - 1)(a^{l-i} - a^{j-i}), & j > i \end{cases}$$

pentru $p \neq \frac{1}{2}$, unde $a = \frac{p}{q}$ și

$$n_{ij} = \frac{2}{l} \cdot \begin{cases} j(l-i), & j \geq i \\ i(l-j), & j > i \end{cases}$$

pentru $p = \frac{1}{2}$. Matricea R este dată de

$$R = \begin{pmatrix} q & 0 \\ 0 & 0 \\ \cdot & \cdot \\ \cdot & \cdot \\ \cdot & \cdot \\ 0 & 0 \\ 0 & p \end{pmatrix}.$$

Se verifică imediat că elementele a_{ij} ale matricei NR sunt

$$a_{i0} = \begin{cases} \frac{a^{l-i} - 1}{a^l - 1}, & p \neq \frac{1}{2} \\ 1 - \frac{i}{l}, & p = \frac{1}{2} \end{cases}$$

$$a_{il} = 1 - a_{i0}, \quad 1 \leq i \leq l-1,$$

care reprezintă probabilitățile ca lanțul să fie absorbit de 0, respectiv de 1.

Mersul la întâmplare cu frontiere absorbante poate fi formulat sub forma așa numitei *probleme a ruinei jucătorului*: doi jucători care dispun împreună de un capital de l unități monetare, joacă un anumit joc pe care unul dintre ei îl câștigă cu probabilitatea p , iar celălalt cu probabilitatea q , $p+q=1$. Jucătorul care pierde dă celuilalt o unitate monetară. Jocul se repetă până când unul din jucători intră în posesia întregului capital l , iar celălalt se ruinează.

Exemplul 2 (Modele fizice de tip mers la întâmplare). Un mers la întâmplare mai general decât cel din exemplul precedent se obține presupunând că ori de câte ori particula se află într-o poziție $i \neq 0, l$, ea face un salt de o unitate spre dreapta sau spre stânga cu probabilitățile p_i , respectiv q_i , sau rămâne pe loc cu probabilitatea r_i , $p_i + q_i + r_i = 1$. Din poziția 0 particula face un salt în poziția 1 cu probabilitatea p_0 , rămânând pe loc cu probabilitatea r_0 ; analog, din poziția l particula face un salt în poziția $l-1$ cu probabilitatea q_l , rămânând pe loc cu probabilitatea r_l . Evident, $p_0 + r_0 = q_l + r_l = 1$. Lanțul Markov descriind mișcarea particulei va avea matricea de trecere

$$P = \begin{pmatrix} r_0 & p_0 & 0 & \dots & 0 & 0 & 0 \\ q_1 & r_1 & p_1 & \dots & 0 & 0 & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & 0 & \dots & q_{l-1} & r_{l-1} & p_{l-1} \\ 0 & 0 & 0 & \dots & 0 & q_l & r_l \end{pmatrix}.$$

Există două modele celebre ale unor fenomene fizice care sunt mersuri la întâmplare de acest tip (și care au fost concepute fără nici o legătură cu lanțurile Markov).

Primul model, propus de Daniel Bernoulli (1700-1782) în anul 1769, descrie difuzia a două lichide incompresibile între două containere. Acestea sunt reprezentate prin două urne, fiecare conținând l bile. Bilele joacă rolul moleculelor celor două lichide. Dintre cele $2l$ bile, l bile sunt albe, iar l bile sunt negre. Deoarece bilele reprezintă moleculele de lichide incompresibile, ele se pot mișca între cele două urne astfel încât la orice moment, fiecare urnă conține l bile. Putem imagina această mișcare a biletelor dintr-o urnă în celălaltă în felul următor: din ambele urne se extrage câte o bilă la fiecare moment; bila extrasă din prima urnă se introduce în a doua urnă și invers. Putem caracteriza starea sistemului astfel: spunem că sistemul se află în starea i , $0 \leq i \leq l$,

dacă prima urnă conține i bile albe și a doua urnă conține $l - i$ bile albe. Este ușor de văzut că probabilitățile de trecere într-un pas sunt

$$p_{ii-1} = q_i = \frac{i}{l} \cdot \frac{i}{l} = \left(\frac{i}{l}\right)^2, \quad 1 \leq i \leq l,$$

$$p_{ii+1} = p_i = \frac{l-i}{l} \cdot \frac{l-i}{l} = \left(1 - \frac{i}{l}\right)^2, \quad 1 \leq i \leq l-1,$$

$$p_{ii} = r_i = \frac{i}{l} \cdot \frac{l-i}{l} + \frac{l-i}{l} \cdot \frac{i}{l} = 2 \frac{i}{l} \left(1 - \frac{i}{l}\right), \quad 0 \leq i \leq l.$$

Astfel lanțul Markov ce descrie mișcarea moleculelor va avea matricea de trecere

$$\begin{pmatrix} r_0 & p_0 & 0 & \dots & 0 & 0 & 0 \\ q_1 & r_1 & p_1 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & q_{n-1} & r_{n-1} & p_{n-1} \\ 0 & 0 & 0 & \dots & 0 & q_n & r_n \end{pmatrix}.$$

Să mai remarcăm că lanțul Markov asociat modelului Bernoulli este irreductibil.

Al doilea model propus de Tatiana și Paul Ehrenfest în anul 1907, descrie schimbul de căldură între două corperi izolate, de temperaturi diferite, din punctul de vedere al teoriei cinetice a materiei. Astfel temperaturile sunt reprezentate prin numerele de bile aflate în două urne care conțin în total $2l$ bile numerotate cu $1, 2, \dots, 2l$. Schimbul de căldură este imaginat astfel: la fiecare moment se alege la întâmplare un întreg între 1 și $2l$, iar bila numerotată astfel este mutată din urnă în care se află în cealaltă. Spunem că sistemul se află în starea i , $0 \leq i \leq 2l$, dacă prima urnă conține i bile (deci a doua urnă conține $2l - i$ bile). În acest caz, probabilitățile de trecere într-un pas sunt

$$p_{ii} = r_i = 0, \quad 0 \leq i \leq 2l,$$

$$p_{ii-1} = q_i = \frac{i}{2l}, \quad 1 \leq i \leq 2l,$$

$$p_{ii+1} = p_i = 1 - \frac{i}{2l}, \quad 0 \leq i < 2l.$$

De asemenea, lanțul Markov asociat modelului Ehrenfest este irreductibil. Modelul Ehrenfest poate fi folosit pentru a explica unele fenomene de reversibilitate din mecanica statistică.

Exemplul 3. Să presupunem că un proces de școlarizare constă din 5 stadii, fiecare având o durată de o unitate de timp, să spunem, un an. La sfârșitul fiecărui stadiu, promovarea în stadiul următor (sau terminarea școlarizării) se decide în urma unui examen.

Vom admite că un cursant se poate retrage de la cursuri în orice moment, dar odată retras el nu mai revine niciodată. Astfel, situația unui cursant la sfârșitul unui an de studii poate fi descrisă printr-o din următoarele alternative:

- cursantul promovează examenul și urmează să frecventeze stadiul următor;
- cursantul nu promovează examenul și repetă stadiul;
- cursantul se retrage înainte de a se prezenta la examen.

Să admitem că probabilitățile de promovare într-un stadiu superior, de repetare a stadiului încheiat sau de retragere, nu depind de rezultatele obținute de cursant în anii anteriori. În aceste condiții, procesul de parcursare a stadiilor succesive de către cursant, care se poate termina fie prin încheierea cu succes a școlarizării, fie prin retragere, poate fi descris de un lanț Markov cu stările 0,1,2,3,4,5,6. Starea 0 caracterizează un cursant în primul stadiu de școlarizare, starea 5 un cursant care a încheiat cu succes școlarizarea, starea 6 un cursant care s-a retras, iar o stare intermedieră $1 \leq i \leq 4$ un cursant care a promovat primele i stadii de școlarizare. Evident stările 5 și 6 sunt absorbante, iar celelalte tranziente. Matricea de trecere a lanțului va avea forma

$$P = \begin{pmatrix} r_1 & p_1 & 0 & 0 & 0 & 0 & q_1 \\ 0 & r_2 & p_2 & 0 & 0 & 0 & q_2 \\ 0 & 0 & r_3 & p_3 & 0 & 0 & q_3 \\ 0 & 0 & 0 & r_4 & p_4 & 0 & q_4 \\ 0 & 0 & 0 & 0 & r_5 & p_5 & q_5 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}.$$

probabilitățile p_i, r_i, q_i , $1 \leq i \leq 5$, fiind asociate alternativelor a, b, c de mai înainte. Matricea T corespunzătoare este

$$T = \begin{pmatrix} r_1 & p_1 & 0 & 0 & 0 \\ 0 & r_2 & p_2 & 0 & 0 \\ 0 & 0 & r_3 & p_3 & 0 \\ 0 & 0 & 0 & r_4 & p_4 \\ 0 & 0 & 0 & 0 & r_5 \end{pmatrix},$$

iar elementele matricei N vor fi

$$\begin{aligned} n_{ii} &= (1 - r_{i+1})^{-1}, & 0 \leq i \leq 4, \\ n_{ij} &= p_{i+1} p_{i+2} \dots p_j (1 - r_{i+1})^{-1} \dots (1 - r_{j+1})^{-1}, & i < j, \\ n_{ij} &= 0, & i > j. \end{aligned}$$

Întrucât matricea R este

$$R = \begin{pmatrix} 0 & q_1 \\ 0 & q_2 \\ 0 & q_3 \\ 0 & q_4 \\ 0 & q_5 \end{pmatrix},$$

rezultă că probabilitățile de absorbție sunt

$$a_{i5} = p_{i+1} \dots p_5 (1 - r_{i+1})^{-1} \dots (1 - r_5)^{-1}, \quad a_{i6} = 1 - a_{i5}, \quad 0 \leq i \leq 4.$$

Exemplu 4. (*Model de transmitere a unei boli contagioase într-o colectivitate mică*). Cadrul de dezvoltare a unui proces epidemiologic este o colectivitate presupusă de volum invariabil în timp care conține două categorii de indivizi: indivizii contaminați și indivizii necontaminați, dar susceptibili de contaminare. În modelul Greenwood, prezentat aici, dinamica procesului epidemiologic este următoarea: se presupune că există o perioadă de incubație de lungime fixă (folosită ca unitate de timp) și o perioadă de infecțiositate redusă la un singur punct, în care se pot realiza contaminări. Astfel dacă la momentul inițial 0 există un număr de indivizi infecțioși (adică contaminați și care pot transmite boala mai departe), următoarele cazuri de îmbolnăvire apar în grupuri la intervale egale cu perioada de incubație. Fie r volumul populației considerate și ξ_m , $m \in \mathbb{N}$, numărul indivizilor care devin infecțioși imediat după momentul m , iar X_n , $n \in \mathbb{N}$, numărul indivizilor rămași necontaminați la momentul n . Atunci avem $X_n = \xi_{n+1} + X_{n+1}$. Definim șansa de contagiune $0 < p = 1 - q < 1$ ca probabilitatea ca un contact între un individ necontaminat și unul infectios să ducă la contaminarea primului. Presupunând că toate contactele se realizează independent unul de altul, probabilitatea ca i contacte (individ necontaminat - individ infectios) să conducă la k contaminări, $k \leq i$, este egală cu $C_i^k p^k q^{i-k}$ (suntem în cazul experimentului Bernoulli repetat de i ori). Putem scrie

$$P(X_{n+1} = j \mid X_n = i) = P(\xi_{n+1} = X_n - j \mid X_n = i) =$$

$$P(\xi_{n+1} = i - j \mid X_n = i) = \begin{cases} C_i^j p^{i-j} q^j, & i \geq j \\ 0, & i < j \end{cases}.$$

Repartiția lui X_{n+1} nu depinde de valorile luate de v.a. X_m , $m < n$. Deci $(X_n)_{n \in \mathbb{N}}$ este un lanț Markov cu stările $0, 1, \dots, r$ și matricea de trecere

$$\begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ p & q & 0 & \dots & 0 \\ p^r & rp^{r-1}q & C_r^2 p^{r-2}q^2 & \dots & q^r \end{pmatrix}.$$

Observăm că lanțul are o stare absorbantă 0 și r clase formate din câte o stare i , $1 \leq i \leq r$.

Exemplul 5. În modelul stocastic de învățare bazat pe teoria selectării stimulilor propus de W.K. Estes în anul 1950, se consideră un lanț Markov cu două stări. Astfel starea 1 semnifică faptul că subiectul a învățat, de exemplu, să primească o alună sau să evite un soc electric. Starea 2 semnifică faptul că subiectul nu a învățat încă. Se presupune că de îndată ce subiectul a învățat el nu mai uită, iar dacă nu a învățat încă, el va reuși cu probabilitatea α să învețe după fiecare încercare. Să se determine matricea de trecere și să se calculeze $p_{21}^{(n)}$ și $f_{21}^{(n)}$ pentru orice $n \in \mathbb{N}^*$.

Avem $p_{11} = 1$, $p_{12} = 0$, $p_{21} = \alpha$ și $p_{22} = 1 - \alpha$. Deci matricea de trecere este

$$P = \begin{pmatrix} 1 & 0 \\ \alpha & 1 - \alpha \end{pmatrix}.$$

Pentru a obține $p_{21}^{(n)}$, probabilitățile de trecere din starea 2 în starea 1 după n pași, ridicăm matricea de trecere la puterea a n -a. Cum

$$P^n = \begin{pmatrix} 1 & 0 \\ 1 - (1 - \alpha)^n & (1 - \alpha)^n \end{pmatrix} \quad \forall n \in \mathbb{N}^*,$$

rezultă că $p_{21}^{(n)} = 1 - (1 - \alpha)^n$ pentru orice $n \in \mathbb{N}^*$.

Avem $f_{21}^{(1)} = p_{21} = \alpha$ și $f_{21}^{(n)} = P(\xi_v \neq 1, 1 \leq v \leq n-1, \xi_n = 1 | \xi_0 = 2)$, $n \geq 2$. Obținem $f_{21}^{(2)} = (1 - \alpha)\alpha$ și $f_{21}^{(3)} = (1 - \alpha)^2\alpha$. În fine, făcând un raționament prin inducție după $n \in \mathbb{N}^*$, obținem

$$f_{21}^{(n)} = (1 - \alpha)^{n-1}\alpha, \quad \forall n \in \mathbb{N}^*.$$

Exemplul 6. În urma unei reacții nucleare este posibil ca o particulă subatomică să sedezintegreze în alte particule; un copil de sex masculin, ducând mai departe numele de familie, poate avea sau nu descendenți de sex masculin. Asemenea procese care se pot repeta până la întrerupere sunt exemple de *procese de ramificare*. Să se calculeze probabilitatea de întrerupere a procesului.

Presupunem că la început a existat o singură particulă $X_0 = 1$, care a dat naștere la X_1 , descendenți din prima generație cu

$$P(X_1 = j) = a_j, \quad j = 0, 1, 2, \dots \quad (7.1)$$

În afară de cazul $X_1 = 0$, fiecare particulă din prima generație va da naștere la descendenți din a doua generație (al căror număr reprezintă v.a. a cărei repartiție este dată de (7.1)). De asemenea, presupunem că acțiunile diferenților descendenți sunt stocastic independente. Considerăm funcția generatoare g a v.a. X

$$g(t) = \sum_{j=0}^{\infty} a_j t^j.$$

Presupunem că numărul de particule din prima generație este j . Considerăm v.a. Z_1, \dots, Z_j care reprezintă numărul descendenților fiecărei particule din prima generație. V.a. Z_1, \dots, Z_j sunt independente și au aceeași funcție generatoare g . Apoi, numărul total de particule din generația a doua este

$$X_2 = Z_1 + \dots + Z_j.$$

V.a. X_2 are funcția generatoare g^j , datorită independenței v.a. Z_1, \dots, Z_j . Obținem

$$E(t^{X_2} | X_1 = j) = [g(t)]^j \quad (7.2)$$

și prin urmare

$$\begin{aligned} E(t^{X_2}) &= \sum_{j=0}^{\infty} P(X_1 = j) \cdot E(t^{X_2} | X_1 = j) = \\ &= \sum_{j=0}^{\infty} a_j \cdot [g(t)]^j = g(g(t)). \end{aligned}$$

Fie g_n funcția generatoare a v.a. X_n astfel încât $g_1 = g$. Atunci conform celor obținute mai sus, avem $g_2 = g(g_1)$. Același argument dă

$$g_n = g(g_{n-1}) = \underbrace{g \circ g \dots \circ g}_{n \text{ ori}}.$$

Avem

$$g_n(t) = E(t^{X_n}) = \sum_{k=0}^{\infty} P(X_n = k) t^k. \quad (7.3)$$

Întrucât repartitia numărului de descendenți din fiecare generație este determinată numai de numărul de descendenți din generația anterioară, este evident că sirul $(X_n)_{n \geq 0}$ are proprietatea Markov. Cum legea de reproducere

este aceeași la fiecare generație, atunci $(X_n)_{n \geq 0}$ este un lanț Markov omogen. De fapt, din relația (7.2) observăm că probabilitatea de trecere p_{jk} reprezintă coeficientul lui t^k din seria de puteri $[g(t)]^j$.

Excluzând cazurile triviale, să presupunem că $0 < a_0 < a_0 + a_1 < 1$. Atunci mulțimea stăriilor este mulțimea numerelor întregi nenegative. Ipoteza precedentă implică faptul să toate stările conduc la starea 0, care este o stare absorbantă. Deci toate stările cu excepția lui 0 sunt stări tranziente. Făcând $t = 0$ în relația (7.3) obținem $g_n(0) = p_{10}^{(n)}$. Atunci probabilitatea de intrerupere a procesului, notată cu α , este

$$\alpha = \lim_{n \rightarrow \infty} p_{10}^{(n)} = \lim_{n \rightarrow \infty} g_n(0). \quad (7.4)$$

Întrucât $g_n(0) = g(g_{n-1}(0))$, făcând $n \rightarrow \infty$, obținem

$$\alpha = g(\alpha). \quad (7.5)$$

Astfel α este soluția ecuației $\varphi(t) = g(t) - t = 0$. Pentru că $g(1) = 1$, o soluție este $t = 1$. Apoi

$$\varphi''(t) = g''(t) = \sum_{j=2}^{\infty} j(j-1)a_j t^{j-2} > 0, \quad t > 0.$$

Deci φ' este o funcție monoton crescătoare. Rezultă că $\varphi = 0$ are cel mult două soluții în $[0,1]$. Astfel $\varphi = 0$ are cel mult o soluție diferită de 1 în $[0,1]$.

Cazul 1. $\varphi = 0$ nu are nici o soluție în $[0,1]$. Cum $\varphi(0) = a_0 > 0$, trebuie ca $\varphi(t) > 0 \forall t \in [0, 1]$. Obținem

$$\varphi(1) - \varphi(t) < \varphi(1) = 0, \quad 0 \leq t < 1$$

și rezultă că

$$\varphi'(1) = \lim_{t \uparrow 1} \frac{\varphi(1) - \varphi(t)}{1 - t} \leq 0.$$

Deci $g'(1) \leq 1$.

Cazul 2. $\varphi = 0$ are o unică soluție în $[0,1]$. Atunci $\varphi' = 0$ are o soluție s în $[r, 1]$, adică $\varphi'(s) = g'(s) - 1 = 0$ și cum g' este o funcție crescătoare obținem $g'(1) > g'(s) = 1$. Rezumând, ecuația $g(t) = t$ are o soluție pozitivă mai mică decât 1 dacă și numai dacă $g'(1) > 1$.

În cazul 1, trebuie să avem $\alpha = 1$ deoarece $0 \leq \alpha \leq 1$ și α este soluție conform (7.5).

În cazul 2, vom arăta că α este soluția $r < 1$. Avem $g(0) < g(r) = r$. Presupunând $g_{n-1}(0) < r$ rezultă

$$g_n(0) = g(g_{n-1}(0)) < g(r) = r$$

deoarece g este o funcție crescătoare. Astfel $g_n(0) < r$ pentru orice n și conform (7.4) obținem $\alpha \leq r$. Dar α trebuie să fie egală cu r , ambele fiind soluții din $[0, 1]$ ale ecuației.

Capitolul 8

Procese Markov omogene

8.1 Funcția matriceală de trecere

Fie S o mulțime cel mult numărabilă¹, iar $P(t) = (p_{ij}(t))_{i,j \in S}$, $t \in \mathbf{R}_+$, o matrice de funcții cu proprietățile

$$\begin{aligned} p_{ij}(t) &\geq 0, \quad i, j \in S, \quad t \in \mathbf{R}_+ \\ \sum_{j \in S} p_{ij}(t) &= 1, \quad i \in S, \quad t \in \mathbf{R}_+ \\ \lim_{t \rightarrow +0} p_{ij}(t) &= p_{ij}(0) = \delta_{ij}, \quad i, j \in S \end{aligned} \tag{8.1}$$

(δ_{ij} este simbolul lui Kronecker).

O familie de v.a. $(\xi_t)_{t \in \mathbf{R}_+}$ cu valori în S este numită *proces Markov omogen în timp* cu mulțimea de stări S , dacă

$$\begin{aligned} P(\xi_{t_n+t} = j \mid \xi_{t_n} = i, \xi_{t_k} = i_k, \quad 0 \leq k \leq n-1) &= \\ = P(\xi_{t_n+t} = j \mid \xi_{t_n} = i) &= p_{ij}(t) \end{aligned} \tag{8.2}$$

pentru orice $0 \leq t_0 < t_1 < \dots < t_n$, $t \geq 0$, $i_0, i_1, \dots, i_{n-1}, i, j \in S$, $n \in \mathbf{N}^*$.

Prima egalitate (8.2), numită *proprietatea Markov*, se poate interpreta sub forma

$$P(\text{viitor} \mid \text{prezent, trecut}) = P(\text{viitor} \mid \text{prezent}),$$

dacă se convine că momentul t_n să fie cel prezent.

Cea de-a doua egalitate (8.2) este proprietatea de *omogenitate temporală*.

Matricea P , numită *funcția matriceală de trecere* a procesului, verifică relația *Chapman-Kolmogorov*

$$p_{ij}(s+t) = \sum_{k \in S} p_{ik}(s)p_{kj}(t), \quad i, j \in S, \quad s, t \geq 0 \tag{8.3}$$

¹Finită sau numărabilă.

care în formă matriceală se scrie

$$P(s+t) = P(s) \cdot P(t), \quad s, t \geq 0.$$

Funcțiile $p_{ij}(t)$ au câteva proprietăți remarcabile:

- 1) Pentru orice $i, j \in S$, funcția $p_{ij}(t)$ este uniform continuă pe $[0, \infty)$.
- 2) Pentru orice $i, j \in S$, funcția $p_{ij}(t)$ este fie identic nulă, fie strict pozitivă pe $(0, \infty)$.

- 3) Pentru $i \neq j \in S$, $q_{ij} = p'_{ij}(0) = \lim_{t \rightarrow 0^+} \frac{p_{ij}(t)}{t}$ există și este finită.
- 4) Pentru orice $i \in S$, $q_i = -p'_{ii}(0) = \lim_{t \rightarrow 0^+} \frac{1 - p_{ii}(t)}{t}$ există și $\frac{1 - p_{ii}(t)}{t} \leq q_i$. Dacă S este finită, atunci $q_i < \infty$.

8.2 Ecuațiile lui Kolmogorov

Dacă $q_i < \infty$, $i \in S$, atunci matricea $Q = (q_{ij})$, $i, j \in S$, unde $q_{ii} = -q_i$ (vezi §8.1) este numită *matricea intensităților de trecere*. În general, avem $q_{ij} \geq 0$ dacă $i \neq j$, $q_{ij} \leq 0$ dacă $i \neq j$ și

$$\sum_{j \neq i} q_{ij} \leq -q_{ii}. \quad (8.4)$$

Dacă S este finită, atunci (8.4) devine

$$\sum_{j \neq i} q_{ij} = -q_{ii} < \infty, \quad i \in S. \quad (8.5)$$

Relația (8.5) reprezintă o condiție necesară și suficientă pentru ca $p_{ij}(t)$ să verifice ecuațiile diferențiale

$$p'_{ij}(t) = \sum_{k \in S} q_{ik} p_{kj}(t), \quad i, j \in S, \quad t \geq 0 \quad (8.6)$$

care se scriu matriceal

$$P'(t) = Q P(t), \quad t \geq 0.$$

Ecuațiile (8.6) sunt numite *ecuațiile lui Kolmogorov inverse*.

De asemenea, dacă $q_j < \infty$, $j \in S$ și limita

$$\lim_{h \rightarrow 0^+} \frac{p_{ij}(h)}{h} = q_{ij}, \quad j \in S$$

este uniformă în raport cu $i \neq j$, atunci avem

$$p'_{ij}(t) = \sum_{k \in S} p_{ik}(t) q_{kj}, \quad i, j \in S, \quad t \geq 0. \quad (8.7)$$

Ecuațiile (8.7) sunt numite *ecuațiile lui Kolmogorov directe*.

Trebuie remarcat faptul important că, dacă S este finită, atunci au loc atât ecuațiile (8.6), cât și ecuațiile (8.7). În acest caz, prin rezolvarea acestor sisteme de ecuații cu condițiile inițiale $p_{ij}(0) = \delta_{ij}$, $i, j \in S$ (sau matriceal $P(0) = I$), se obține

$$P(t) = \exp(Qt) = I + \sum_{n \in N} \frac{Q^n t^n}{n!}, \quad t \in \mathbf{R}_+.$$

Deci, matricea intensităților de trecere Q determină în mod unic funcția matriceală de trecere $P(t)$.

Fie $p_i(t) = P(\xi_t = i)$, $i \in S$, $t \geq 0$, numite *probabilități absolute*, iar $(p_j)_{j \in S}$ o probabilitate pe S , adică $p_j \geq 0$, $j \in S$, și $\sum_{j \in S} p_j = 1$, numită *repartiție inițială*.

Dacă $p_j = p_j(0) = P(\xi_0 = j)$, $j \in S$, atunci probabilitățile absolute verifică ecuațiile

$$p_j(t) = p_j + \sum_{k \in S} \int_0^t q_{kj} p_k(u) du, \quad j \in S. \quad (8.8)$$

O probabilitate $(p_j)_{j \in S}$ pe S va fi numită *repartiție staționară* dacă $p_j(t) = P(\xi_t = j) = P(\xi_0 = j) = p_j$, $j \in S$, $t \geq 0$. Din (8.8) se deducă că $(p_j)_{j \in S}$ este o repartiție staționară dacă și numai dacă $\sum_{k \in S} q_{kj} p_k = 0$, $j \in S$.

8.3 Câteva clase remarcabile de procese Markov

1. Procesul Poisson

Se consideră un proces Markov omogen în timp, $\xi(t)$, $t \in \mathbf{R}_+$, cu mulțimea de stări N care verifică axioamele:

(1) Dacă la momentul t procesul se găsește în starea $i \in N$, atunci probabilitatea ca la momentul $t + \Delta t$ să se găsească în starea $i + 1$ este $\lambda \Delta t + o(\Delta t)$, unde $\lambda > 0$ este o constantă dată; deci $p_{ii+1}(\Delta t) = \lambda \Delta t + o(\Delta t)$.

(2) Dacă la momentul t procesul se găsește în starea $i \in N$, atunci probabilitatea ca în intervalul $(t, t + \Delta t)$ să se petreacă mai multe trecheri dintr-o stare în alta sau ca la momentul $t + \Delta t$ să se găsească într-o stare $j \neq i + 1$, $j \neq i$, este $o(\Delta t)$; deci $p_{ij}(\Delta t) = o(\Delta t)$, $j \neq i$, $j \neq i + 1$.

(3) Dacă la momentul t procesul se găsește în starea $i \in N$, atunci probabilitatea ca la momentul $t + \Delta t$ să se găsească tot într-o stare i este $1 - \lambda \Delta t + o(\Delta t)$; deci $p_{ii}(\Delta t) = 1 - \lambda \Delta t + o(\Delta t)$.

Se observă imediat că matricea intensităților de trecere este dată de

$$q_{ii} = -\lambda, \quad i \in N,$$

$$q_{ij} = \begin{cases} \lambda, & j \neq i+1 \\ 0, & j = i+1 \end{cases}$$

și din (8.6) și (8.7) rezultă

$$\begin{aligned} p'_{ij}(t) &= -\lambda p_{ij}(t) + \lambda p_{i+1j}(t), \quad i, j \in \mathbb{N}, \\ p'_{ij}(t) &= -\lambda p_{ij}(t) + \lambda p_{ij-1}(t), \quad i \in \mathbb{N}, \quad j \in \mathbb{N}^*, \\ p'_{i0}(t) &= -\lambda p_{i0}(t), \quad i \in \mathbb{N}. \end{aligned}$$

Se verifică cu ușurință că soluția acestor ecuații cu condiția inițială $p_{ij}(0) = \delta_{ij}$ este

$$p_{ij}(t) = \begin{cases} \frac{(\lambda t)^{j-i}}{(j-i)!} e^{-\lambda t}, & j \geq 1 \\ 0, & j < i. \end{cases}$$

Relația (8.8) pentru procesul Poisson devine

$$\begin{aligned} p_j(t) &= p_j - \lambda \int_0^t [p_j(u) + p_{j-1}(u)] du, \quad j \geq 1, \\ p_0(t) &= -\lambda \int_0^t p_0(u) du \end{aligned}$$

și prin derivare

$$\begin{aligned} p'_j(t) &= -\lambda p_j(t) + \lambda p_{j-1}(t), \quad j \geq 1, \\ p'_0(t) &= -\lambda p_0(t). \end{aligned}$$

Întrucât

$$p_j(0) = \begin{cases} 1, & j = 0 \\ 0, & j = 1, 2, \dots \end{cases}$$

rezultă $p_0(t) = e^{-\lambda t}$, apoi $p_1(t) = \lambda t e^{-\lambda t}$ și în general

$$p_j(t) = \frac{(\lambda t)^j}{j!} e^{-\lambda t}, \quad t \geq 0,$$

ceea ce arată că v.a. $\xi(t)$ urmează o repartiție Poisson (vezi §3.5) cu parametrul λt . Se spune că $\xi(t)$ generează un *flux poissonian*.

2. Procesul de naștere

Se consideră un proces Markov omogen $\xi(t)$, $t \in \mathbf{R}_+$, cu spațiul stărilor \mathbb{N} . Axiomele (1)-(3) verificate de procesul Poisson sunt verificate și de către procesul de naștere cu deosebire că probabilitățile de la (1) și (3) vor fi $\lambda_i \Delta t + o(\Delta t)$ și respectiv $1 - \lambda_i \Delta t + o(\Delta t)$, unde λ_i , $i \in \mathbb{N}$, este un sir de constante pozitive; trecerea procesului din starea i în starea $i+1$ este "o naștere".

Se deduce cu ușurință că matricea intensităților de trecere este

$$q_{ij} = \begin{cases} -\lambda_i, & j = i \\ \lambda_i, & j = i + 1 \\ 0, & \text{în rest.} \end{cases}$$

Prin urmare, ecuațiile (8.6) și (8.7) devin

$$\begin{aligned} p'_{ij}(t) &= -\lambda_i p_{ij}(t) + \lambda_i p_{i+1j}(t), & i, j \in \mathbb{N}, \\ p'_{ij}(t) &= -\lambda_j p_{ij}(t) + \lambda_{j-1} p_{ij-1}(t), & i \in \mathbb{N}, j \in \mathbb{N}^*, \\ p'_{i0}(t) &= -\lambda_0 p_{i0}(t), & i \in \mathbb{N}. \end{aligned} \quad (8.9)$$

Dacă constantele λ_i , $i \in \mathbb{N}$, sunt distințe și strict pozitive, atunci soluția acestui sistem, cu condițiile $p_{ij}(0) = \delta_{ij}$, $i, j \in \mathbb{N}$, este

$$p_{ij}(t) = \begin{cases} \left(\prod_{k=i}^{j-1} \lambda_k \right) \sum_{k=i}^j \frac{e^{-\lambda_k t}}{\prod_{r=i, r \neq k}^j (\lambda_r - \lambda_k)}, & j > i \\ e^{-\lambda_i t}, & j = i \\ 0, & j < i. \end{cases}$$

Pentru probabilitățile absolute, din (8.8) se obțin ecuațiile

$$\begin{aligned} p'_i(t) &= -\lambda_i p_i(t) + \lambda_{i-1} p_{i-1}(t), & i \in \mathbb{N}^*, \\ p'_0(t) &= -\lambda_0 p_0(t). \end{aligned} \quad (8.10)$$

Soluția acestor ecuații cu condițiile initiale $p_0(0) = 1$, $p_i(0) = 0$, $i \in \mathbb{N}^*$, este

$$p_0(t) = e^{-\lambda_0 t},$$

$$p_i(t) = \lambda_{i-1} e^{-\lambda_i t} \int_0^t e^{\lambda_x x} p_{i-1}(x) dx, \quad i \in \mathbb{N}^*.$$

Dacă $\sum_{k=0}^{\infty} p_k(t) = 1$ pentru orice $t \in \mathbb{R}_+$, atunci procesul de naștere se numește *regulat*. O condiție necesară și suficientă care asigură regularitatea este

$$\sum_{k=0}^{\infty} \frac{1}{\lambda_k} = +\infty. \quad (8.11)$$

Un caz particular important este acela pentru care $\lambda_i = i\lambda$, $i \in \mathbb{N}$, $\lambda > 0$. În acest caz, procesul este numit *proces liniar de naștere* (sau *proces Yule-Furry*).

Din (8.11) rezultă că acest proces este regulat. Relațiile (8.9) devin

$$\begin{aligned} p'_{ij}(t) &= -i\lambda p_{ij}(t) + i\lambda p_{i+1j}(t), & i, j \in \mathbb{N}, \\ p'_{ij}(t) &= -j\lambda p_{ij}(t) + (j-1)\lambda p_{ij-1}(t), & i \in \mathbb{N}, j \in \mathbb{N}^*, \\ p'_{i0}(t) &= 0, & i \in \mathbb{N}, \end{aligned}$$

cu soluția

$$p_{ij}(t) = \begin{cases} C_{j-1}^{j-i} e^{-i\lambda t} (1 - e^{-\lambda t})^{j-i}, & j \geq i \\ 0, & j < i. \end{cases}$$

De asemenea, relațiile (8.10) se scriu astfel

$$\begin{aligned} p'_i(t) &= -i\lambda p_i(t) + (i-1)\lambda p_{i-1}(t), & i \in \mathbb{N}^*, \\ p'_0(t) &= 0. \end{aligned}$$

Întrucât $p_0(t) = \text{const.}$ există două posibilități: $p_0(t) = 1, t \in \mathbb{R}_+$, ceea ce înseamnă că procesul nu părăsește starea 0 sau $p_0(t) = 0, t \in \mathbb{R}_+$, ceea ce înseamnă că spațiul stărilor este de fapt \mathbb{N}^* . În cea de-a doua ipoteză² se consideră $p_1(0) = 1$ și soluția sistemului este

$$p_j(t) = e^{-\lambda t} (1 - e^{-\lambda t})^{j-1}, \quad j \in \mathbb{N}^*.$$

3. Procesul de moarte

Fie $n_0 \in \mathbb{N}^*$ și $S = \{0, 1, 2, \dots, n_0\}$. Se consideră un proces Markov omogen $\xi(t), t \in \mathbb{R}_+$, cu spațiul stărilor S care verifică axiomele:

$$(1) \xi(0) = n_0.$$

(2) Dacă la momentul t procesul se găsește în starea i , ($i = 1, 2, \dots, n_0$), atunci probabilitatea ca la momentul $t + \Delta t$ să se găsească în starea $i - 1$ este $\mu_i \Delta t + o(\Delta t)$, unde $\mu_1, \mu_2 \dots \mu_{n_0}$ sunt constante date; deci $p_{ii-1}(\Delta t) = \mu_i \Delta t + o(\Delta t)$.

(3) Dacă la momentul t procesul se găsește în starea i , ($i = 1, 2, \dots, n_0$), atunci probabilitatea ca la momentul $t + \Delta t$ să se găsească tot în starea i este $1 - \mu_i \Delta t + o(\Delta t)$; deci $p_{ii}(\Delta t) = 1 - \mu_i \Delta t + o(\Delta t)$.

(4) Probabilitatea ca în intervalul $(t, t + \Delta t)$ să aibă loc mai multe treceri dintr-o stare în alta sau să aibă loc o trecere diferită de cele descrise la (2) și (3) este $o(\Delta t)$; deci $p_{ij}(\Delta t) = o(\Delta t)$, $j \neq i - 1, j \neq i$.

Din (2) - (4) se deduce că matricea intensităților de trecere este

$$q_{ij} = \begin{cases} -\mu_i, & j = i; i = 1, 2, \dots, n_0 \\ \mu_i, & j = i - 1; i = 1, 2, \dots, n_0 \\ 0, & \text{în celelalte cazuri.} \end{cases}$$

²Se observă că (8.11) rămâne adevărată pentru că $\sum_{k=1}^{\infty} \frac{1}{k} = +\infty$.

Din (8.6) și (8.7) rezultă

$$\begin{aligned} p'_{ij}(t) &= -\mu_i p_{i-1,j}(t) - \mu_j p_{ij}(t), \quad i = 1, 2, \dots, n_0, \quad j \in S, \\ p'_{0j}(t) &= 0, \quad j \in S \end{aligned} \quad (8.12)$$

și

$$\begin{aligned} p'_{ij}(t) &= -\mu_{j+1} p_{ij+1}(t) - \mu_j p_{ij}(t), \quad i, j \in S, \\ p'_{i0}(t) &= \mu_1 p_{i1}(t), \quad j \in S. \end{aligned} \quad (8.13)$$

Ecuatiile (8.12) și (8.13), cu conditiile initiale $p_{ij}(0) = \delta_{ij}$, se pot rezolva utilizând transformata Laplace.

Din (8.8) rezultă că probabilitățile absolute verifică ecuațiile

$$\begin{aligned} p'_i(t) &= -\mu_i p_i(t) + \mu_{i+1} p_{i+1}(t), \quad i = 0, 1, \dots, n_0 - 1, \\ p'_{n_0}(t) &= -\mu_{n_0} p_{n_0}(t), \end{aligned}$$

cu condiția inițială $p_{n_0}(0) = 1$; rezultă $p_{n_0}(t) = e^{-\mu_{n_0} t}$ și apoi celelalte probabilități absolute se deduc prin recurență.

Pentru cazul particular în care $\mu_i = i\mu$, $\mu > 0$, $i \in S$, probabilitățile absolute sunt

$$p_i(t) = C_{n_0}^i e^{-n_0 \mu t} (e^{\mu t} - 1)^{n_0 - i}, \quad i \in S.$$

4. Procesul de naștere și de moarte.

Se consideră un proces Markov omogen $\xi(t)$, $t \in \mathbf{R}_+$, cu spațiul stărilor N , care verifică următoarele axiome:

(1) Dacă la momentul t procesul se găsește în starea $i \in N$, atunci probabilitatea ca la momentul $t + \Delta t$ să se afle în starea $i + 1$ este $\lambda_i \Delta t + o(\Delta t)$, unde λ_i , $i \in N$, sunt constante strict pozitive date; deci $p_{ii+1}(\Delta t) = \lambda_i \Delta t + o(\Delta t)$.

(2) Dacă la momentul t procesul se găsește în starea $i \in N^*$, atunci probabilitatea ca la momentul $t + \Delta t$ să se afle în starea $i - 1$ este $\mu_i \Delta t + o(\Delta t)$, unde μ_i , $i \in N^*$, sunt constante strict pozitive date; deci $p_{ii-1}(\Delta t) = \mu_i \Delta t + o(\Delta t)$.

(3) Dacă la momentul t procesul se află în starea $i \in N$, atunci probabilitatea ca la momentul $t + \Delta t$ să se afle tot în starea i este

$$1 - (\lambda_i + \mu_i) \Delta t + o(\Delta t), \quad i \in N^*; \quad 1 - \lambda_0 \Delta t + o(\Delta t), \quad i = 0;$$

deci

$$p_{ii}(\Delta t) = 1 - (\lambda_i + \mu_i) \Delta t + o(\Delta t), \quad i \in N^*; \quad p_{00}(\Delta t) = 1 - \lambda_0 \Delta t + o(\Delta t).$$

(4) Probabilitatea ca în intervalul $(t, t + \Delta t)$ să aibă loc mai multe treceri dintr-o stare în alta sau să aibă loc o trecere diferită de cele descrise la (1), (2) și (3) este $o(\Delta t)$; deci $p_{ij}(\Delta t) = o(\Delta t)$; $j \neq i - 1$, $j \neq i + 1$.

Se deduce că matricea intensităților de trecere este

$$q_{ij} = \begin{cases} -(\lambda_i + \mu_i), & j = i \neq 0 \\ -\lambda_0, & j = i = 0 \\ \lambda_i, & j = i + 1, \quad i \in \mathbb{N} \\ \mu_i, & j = i - 1, \quad i \in \mathbb{N}^* \\ 0, & \text{în celelalte cazuri.} \end{cases}$$

Din (8.6) și (8.7) rezultă

$$\begin{aligned} p'_{ij}(t) &= \mu_i p_{i-1j}(t) - (\lambda_i + \mu_i) p_{ij}(t) + \lambda_i p_{i+1j}(t), \quad i \in \mathbb{N}^*, \quad j \in \mathbb{N}, \\ p'_{0j}(t) &= -\lambda_0 p_{0j}(t) + \lambda_0 p_{1j}(t), \quad j \in \mathbb{N} \end{aligned}$$

și

$$\begin{aligned} p'_{ij}(t) &= \lambda_{j-1} p_{ij-1}(t) - (\lambda_j + \mu_j) p_{ij}(t) + \mu_{j+1} p_{ij+1}(t), \quad i \in \mathbb{N}, \quad j \in \mathbb{N}^*, \\ p'_{i0}(t) &= -\lambda_0 p_{i0}(t) + \mu_1 p_{i1}(t), \quad i \in \mathbb{N}. \end{aligned}$$

Soluțiile se pot obține utilizând transformata Laplace. Conform relației (8.8) probabilitățile absolute verifică

$$\begin{aligned} p'_i(t) &= \lambda_{i-1} p_{i-1}(t) - (\lambda_i + \mu_i) p_i(t) + \mu_{i+1} p_{i+1}(t), \quad i \in \mathbb{N}^*, \\ p'_0(t) &= \mu_1 p_1(t). \end{aligned} \tag{8.14}$$

Dacă la momentul $t = 0$ procesul se găsește în starea $k_0 \in \mathbb{N}$, atunci aceste ecuații se rezolvă cu condiția inițială $p_i(0) = \delta_{ik_0}$.

Dacă se notează

$$u_0 = 1, \quad u_k = \frac{\lambda_0 \lambda_1 \dots \lambda_{k-1}}{\mu_1 \mu_2 \dots \mu_k}, \quad k \in \mathbb{N}^*,$$

atunci $(u_i)_{i \in \mathbb{N}}$ este o repartiție staționară (vezi §8.2). Mai mult, dacă $\sum_{i \in \mathbb{N}} u_i < \infty$ avem

$$\lim_{t \rightarrow \infty} p_{ij}(t) = \frac{u_j}{\sum_{k \in \mathbb{N}} u_k}.$$

Un caz particular important al procesului de naștere și moarte este *procesul liniar de naștere și de moarte* (procesul Feller-Arley) pentru care $\lambda_i = i\lambda$, $\mu_i = i\mu$, $i \in \mathbb{N}$, $\lambda, \mu > 0$.

Să considerăm funcția generatoare (vezi §2.5)

$$g(s, t) = \sum_{k=0}^{\infty} p_k(t) s^k.$$

Din (8.14) se deduce

$$\frac{\partial g(s, t)}{\partial t} = [\lambda s^2 - (\lambda + \mu)s + \mu] \frac{\partial g(s, t)}{\partial s}.$$

Soluția generală a acestei ecuații este

$$g(s, t) = f \left(\frac{\mu - \lambda s}{1 - s} e^{-(\lambda - \mu)t} \right),$$

unde f este o funcție arbitrară de clasă C^1 . Dacă $\xi(0) = 1$, atunci $g(s, 0) = s$, adică $s = f \left(\frac{\mu - \lambda s}{1 - s} \right)$ și prin urmare $f(x) = \frac{\mu - x}{\lambda - x}$.

Deci

$$g(s, t) = \frac{\mu(1 - e^{(\lambda - \mu)t}) - (\lambda - \mu e^{(\lambda - \mu)t})s}{\mu - \lambda e^{(\lambda - \mu)t} - \lambda(1 - e^{(\lambda - \mu)t})s}. \quad (8.15)$$

După dezvoltarea în serie de puteri a funcției (8.15), după puterile lui s , se obține, pentru $\lambda \neq \mu$,

$$\begin{aligned} p_k(t) &= [1 - \alpha(t)][1 - \beta(t)][\beta(t)]^{k-1}, \quad k \in \mathbb{N}^*, \\ p_0(t) &= \alpha(t), \end{aligned} \quad (8.16)$$

unde

$$\alpha(t) = \frac{\mu(e^{(\lambda - \mu)t} - 1)}{\lambda e^{(\lambda - \mu)t} - \mu}, \quad \beta(t) = \frac{\lambda(e^{(\lambda - \mu)t} - 1)}{\lambda e^{(\lambda - \mu)t} - \mu}.$$

Tot cu ajutorul funcției (8.15) se obține $m(t) = E[\xi(t)] = e^{(\lambda - \mu)t}$,

$$\text{Var}[\xi(t)] = \frac{\lambda + \mu}{\lambda - \mu} e^{(\lambda - \mu)t} (e^{(\lambda - \mu)t} - 1), \quad \lambda \neq \mu. \quad (8.17)$$

Un proces liniar de naștere și moarte este numit *subcritic*, *critic* sau *superkritic* după cum $\lambda < \mu$, $\lambda = \mu$ sau $\lambda > \mu$.

Pentru procese subcritice sau supercritice varianța este dată de (8.17); în cazul critic $\text{Var}[\xi(t)] = 2\lambda t$. De asemenea,

$$\lim_{t \rightarrow \infty} m(t) = \begin{cases} 0, & \lambda < \mu \\ 1, & \lambda = \mu \\ \infty, & \lambda > \mu. \end{cases}$$

Pentru determinarea probabilității ca, pentru $t \rightarrow \infty$, procesul să intre în starea $i = 0$ (populația să dispară), se utilizează (8.16)

$$p_0(t) = \frac{\mu(e^{(\lambda - \mu)t} - 1)}{\lambda e^{(\lambda - \mu)t} - \mu},$$

de unde

$$\lim_{t \rightarrow \infty} p_0(t) = \begin{cases} 1, & \lambda < \mu \\ \frac{\mu}{\lambda}, & \lambda > \mu. \end{cases}$$

Exemplul 1. În multe cazuri, modelul adecvat pentru descrierea funcționării în timp a sistemelor complexe îl constituie procesele Markov finite, omogene. În decursul timpului, sistemul trece de la o stare la alta, pe măsură ce unele componente ale sale se defectează, iar altele sunt reparate. Așadar, defectarea și repararea diferitelor componente sunt evenimentele care marchează trecerea sistemului de la o stare la alta. Spre exemplu, dacă considerăm un sistem ale cărui componente funcționează în serie, atunci acest sistem se defectează odată cu defectarea oricărei componente. Se presupune că numai o singură componentă poate fi defectată la un moment oarecare t (celealte componente nu se pot defecta când sistemul nu funcționează). Dacă numărul componentelor sistemului este n , se disting $n + 1$ stări posibile în evoluția sistemului. Prin urmare, fenomenul fizic poate fi descris de un proces Markov $(\xi_t)_{t \in \mathbb{R}_+}$ cu mulțimea stărilor $S = \{0, 1, \dots, n\}$. Starea 0 semnifică faptul că toate componente sunt în stare de funcționare, iar starea i , $1 \leq i \leq n$, semnifică starea de defect a componentei a i -a.

Se va presupune că probabilitatea de defectare a componentei a i -a în intervalul Δt are forma $\lambda_i \Delta t + o(\Delta t)$, iar probabilitatea de reparare a aceleiași componente în intervalul Δt este $\mu_i \Delta t + o(\Delta t)$, unde $\lambda_i, \mu_i > 0$, $i = 1, 2, \dots, n$; probabilitatea a două sau mai multe defectiuni sau reparații în intervalul Δt este $o(\Delta t)$. Ne propunem să determinăm funcția de repartiție a perioadelor de funcționare neîntreruptă; vom lua deci în considerație numai evoluția procesului din starea 0 în stările i , $i = 1, 2, \dots, n$. De aici deducem că matricea intensităților de trecere este

$$q_{0i} = \lambda_i, \quad q_{00} = -\lambda_0, \quad \lambda_0 = \sum_{i=1}^n \lambda_i,$$

$$q_{ij} = 0, \quad i = 1, 2, \dots, n, \quad j = 0, 1, 2, \dots, n.$$

Pentru probabilitățile absolute, din (8.8) avem

$$p'_0(t) = -\lambda_0 p_0(t), \quad p_0(0) = 1,$$

$$p'_i(t) = \lambda_i p_0(t), \quad p_i(0) = 0, \quad i = 1, 2, \dots, n,$$

de unde se deduce

$$p_0(t) = e^{-\lambda_0 t}, \quad p_i(t) = \frac{\lambda_i}{\lambda_0} (1 - e^{-\lambda_0 t}), \quad i = 1, 2, \dots, n.$$

Deci o perioadă de funcționare neîntreruptă are funcția de repartiție

$$F(t) = 1 - p_0(t) = 1 - e^{-\lambda_0 t}.$$

De asemenea, se deduce că $p_i(t) = \frac{\lambda_i}{\lambda_0} F(t)$; $\frac{\lambda_i}{\lambda_0}$ semnifică probabilitatea ca o perioadă de funcționare să fie încheiată de defectarea componentei a i -a.

Pentru repartiția perioadei de avarie neîntreruptă, se va lua în considerație numai evoluția procesului din stările i , $i = 1, 2, \dots, n$ în starea 0. Matricea intensităților de trecere este $q_{0j} = 0$, $j = 0, 1, \dots, n$,

$$q_{i0} = \mu_i, \quad q_{ij} = -\mu_i \delta_{ij}, \quad i, j = 1, 2, \dots, n$$

și conduce la sistemul de ecuații diferențiale

$$p'_0(t) = \sum_{i=1}^n \mu_i p_i(t), \quad p_0(0) = 0,$$

$$p'_i(t) = -\mu_i p_i(t), \quad p_i(0) = \frac{\lambda_i}{\lambda_0}, \quad i = 1, 2, \dots, n,$$

cu soluția

$$p_0(t) = \sum_{i=1}^n \frac{\lambda_i}{\lambda_0} (1 - e^{-\mu_i t}), \quad p_i(t) = \frac{\lambda_i}{\lambda_0} e^{-\mu_i t}, \quad i = 1, 2, \dots, n.$$

Deci funcția de repartiție a perioadei de avarie neîntreruptă este

$$G(t) = p_0(t) = \sum_{i=1}^n \frac{\lambda_i}{\lambda_0} (1 - e^{-\mu_i t}).$$

Exemplul 2. Funcționarea unui sistem format din n elemente identice, care funcționează independent în paralel, poate fi descrisă de un proces de naștere și moarte. Starea k , $k = 0, 1, \dots, n$, semnifică faptul că sunt defecte k din cele n elemente. În acest caz, $\lambda_j = 0$ pentru $j \geq n$ și $\mu_j = 0$ pentru $j \geq n$ (vezi §8.3).

Exemplul 3. Pe un osciloscop sosesc impulsuri electrice de amplitudine aleatoare X_i la momente aleatoare de timp t_i , generând un flux poissonian; deci numărul de impulsuri $N(t)$ într-un interval $[0, t]$ verifică relația

$$P(N(t) = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}, \quad n \in \mathbb{N},$$

unde $\lambda > 0$ este o constantă dată.

După primirea impulsului de amplitudine X_i , pe ecranul osciloscopului se poate vizualiza funcția

$$X_i \exp[-\alpha(t - t_i)]_+ = \begin{cases} 0, & t < t_i \\ X_i \exp[-\alpha(t - t_i)], & t \geq t_i \end{cases}$$

unde α este o constantă dată. Prin urmare, după valoarea amplitudinii X_i urmează o scădere exponențială până la momentul următorului impuls (vezi fig. 8.1).

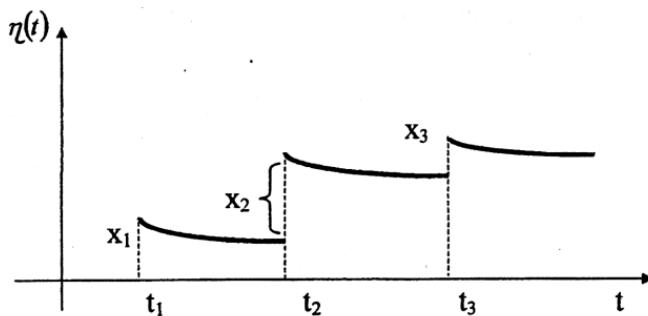


Fig. 8.1.

Dacă $\eta(t)$ este valoarea înregistrată la momentul t , atunci

$$\eta(t) = \sum_{i=1}^{N(t)} X_i \exp[-\alpha(t - t_i)].$$

În practică, ne interesează repartiția v.a. $\eta(t)$ sau echivalent funcția sa caracteristică $\varphi_t(s)$.

Se presupune că v.a. X_i sunt independente și identic repartizate cu densitatea de repartiție $h(x)$, deci cu funcția caracteristică

$$\psi(s) = \int_0^\infty e^{isx} h(x) dx.$$

Se poate demonstra că

$$\varphi_t(s) = \exp \left[-\lambda \int_0^t (1 - \psi(se^{-av})) dv \right]$$

și deci

$$E[\eta(t)] = \lambda E(X_k) \frac{1 - e^{-\alpha t}}{\alpha}.$$

Exemplu 4. Se consideră o populație formată din $n+1$ indivizi, omogenă, supusă riscului unei îmbolnăviri (epidemie). Fie $\xi(t)$ numărul de indivizi necontaminați la momentul t . Se presupune $\xi(0) = n$, deci la momentul inițial

$t = 0$ un singur individ este contaminat. Se admite că $\xi(t)$, $t \in \mathbf{R}_+$, este un proces de moarte cu

$$\mu_k = k\mu(n - k + 1), \quad k = 1, 2, \dots, n, \quad \mu > 0.$$

În acest caz, probabilitățile absolute ale procesului, $p_k(t)$, verifică ecuațiile (vezi §8.3 pct. 3) pentru $\mu = 1$

$$p'_k(t) = (k+1)(n-k)p_{k+1}(t) - k(n-k+1)p_k(t), \quad k = 0, 1, \dots, n-1,$$

$$p'_n(t) = -np_n(t).$$

Modelul prezentat se poate îmbunătăți luându-se în considerație și indivizii care nu mai sunt supuși riscului de contaminare datorită izolării, vaccinării sau decesului.

Exemplul 5. Fie $\{\xi_1(t), t \in \mathbf{R}_+\}$ și $\{\xi_2(t), t \in \mathbf{R}_+\}$ două procese Poisson independente de parametru λ_1 și respectiv λ_2 . Fie $\xi(t) = \xi_1(t) - \xi_2(t)$, $t \in \mathbf{R}_+$. Se cere:

a) $\{\xi(t), t \in \mathbf{R}_+\}$ este un proces cu creșteri independente ?

b) $\{\xi(t), t \in \mathbf{R}_+\}$ este un proces Poisson ?

c) $P(\xi(t) - \xi(s) = k)$ pentru $0 \leq s < t$ și $k = 0, \pm 1, \pm 2$;

a) Din definirea procesului $\xi(t)$ rezultă

$$\begin{aligned} \xi(t+s) - \xi(s) &= [\xi_1(t+s) - \xi_2(t+s)] - [\xi_1(s) - \xi_2(s)] = \\ &= [\xi_1(t+s) - \xi_1(s)] - [\xi_2(t+s) - \xi_2(s)], \end{aligned}$$

$$\begin{aligned} \xi(s) - \xi(0) &= [\xi_1(s) - \xi_2(s)] - [\xi_1(0) - \xi_2(0)] = \\ &= [\xi_1(s) - \xi_1(0)] - [\xi_2(s) - \xi_2(0)]. \end{aligned}$$

Deoarece cele patru v.a. care intervin sunt independente, rezultă că $\xi(t+s) - \xi(s)$ și $\xi(s) - \xi(0)$ sunt independente. Deci procesul este cu creșteri independente.

b) Deoarece $\xi(t)$ ia toate valorile întregi, pozitive, negative sau nule, nu poate fi un proces Poisson.

c) Avem

$$\begin{aligned} P(\xi(t) - \xi(s) = k) &= P([\xi_1(t) - \xi_1(s)] - [\xi_2(t) - \xi_2(s)] = k) = \\ &= \sum_{\nu=\sup(0,k)}^{\infty} P(\xi_1(t) - \xi_1(s) = \nu)P(\xi_2(t) - \xi_2(s) = \nu - k). \end{aligned}$$

Tinând seama că procesele $\xi_1(t)$ și $\xi_2(t)$ sunt staționare, obținem

$$\begin{aligned} P(\xi_1(t) - \xi_1(s) = k) &= P(\xi_1(t-s) - \xi_1(0) = k) = \\ &= P(\xi_1(t-s) = k), \end{aligned}$$

$$P(\xi_2(t) - \xi_2(s) = k) = P(\xi_2(t-s) = k).$$

Punând $t-s=u$, rezultă

$$\sum_{\nu=\sup(0,k)}^{\infty} P(\xi_1(u) = \nu) P(\xi_2(u) = \nu - k) = P(\xi(u) = k).$$

$\xi(t)$ este deci un proces staționar și

$$\begin{aligned} P(\xi(u) = k) &= \sum_{\nu=\sup(0,k)}^{\infty} e^{-\lambda_1 u} \frac{(\lambda_1 u)^\nu}{\nu!} e^{-\lambda_2 u} \frac{(\lambda_2 u)^{\nu-k}}{(\nu-k)!} \\ &= e^{-(\lambda_1 + \lambda_2)u} \sum_{\nu=\sup(0,k)}^{\infty} \frac{(\lambda_1 u)^\nu (\lambda_2 u)^{\nu-k}}{\nu! (\nu-k)!}, \end{aligned}$$

de unde

$$P(\xi(t) - \xi(s) = k) = e^{-(\lambda_1 + \lambda_2)(t-s)} \sum_{\nu=\sup(0,k)}^{\infty} \frac{(\lambda_1(t-s))^\nu (\lambda_2(t-s))^{\nu-k}}{\nu! (\nu-k)!}.$$

Capitolul 9

Procese semi-Markov

9.1 Matricea semi-Markov

Fie E o mulțime ce mult numărabilă. O matrice (eventual cu o infinitate de linii și coloane) de funcții pozitive $(Q_{ij}(t))_{i,j \in E}$ se numește *matrice semi-Markov* dacă

- $Q_{ij}(t) = 0, \quad t \leq 0, \quad i, j \in E;$
- $\sum_{j \in E} Q_{ij}(\infty) = 1, \quad i \in E;$
- $Q_{ij}(\cdot)$ este crescătoare și continuă la dreapta pentru $i, j \in E$.

Din aceste proprietăți rezultă:

- Matricea $p = (p_{ij})_{i,j \in E}$, unde $p_{ij} = Q_{ij}(\infty)$, este o matrice stocastică (vezi cap.7).
- $H_i(\cdot) = \sum_{j \in E} Q_{ij}(\cdot)$ este o funcție de repartiție (vezi §2.2) pentru $i \in E$.
- $F_{ij}(\cdot) = \frac{Q_{ij}(\cdot)}{p_{ij}}$ este o funcție de repartiție pentru $i, j \in E$.

Se observă că, pentru $i, j \in E$, funcția $Q_{ij}(\cdot)$ are toate proprietățile unei funcții de repartiție nule pe semiaxa negativă, cu excepția proprietății $Q_{ij}(\infty) = 1$, (în fapt, avem $Q_{ij}(\infty) \leq 1$). O astfel de funcție este numită *funcție de masă*.

Pentru matricea de funcții de masă, $(Q_{ij}(t))_{i,j \in E}$, se definește prin recurență convoluția de ordin n , $n \in \mathbb{N}$, notată $Q_{ij}^{(n)}(t)$, în felul următor.

$$Q_{ij}^{(0)}(t) = \begin{cases} 0, & t < 0 \\ \delta_{ij}, & t \geq 0 \end{cases}$$

$$Q_{ij}^{(1)}(t) = Q_{ij}(t), \quad t \in \mathbb{R},$$

iar pentru $n \geq 2$

$$Q_{ij}^{(n)}(t) = \begin{cases} 0, & t < 0 \\ \sum_{k \in E} \int_0^t Q_{kj}^{(n-1)}(t-x) Q_{ik}(dx), & t \geq 0. \end{cases}$$

9.2 Sisteme semi-Markov

Se consideră un sistem care în fiecare moment de timp se poate găsi într-o din stările mulțimii E . Funcționarea acestui sistem poate fi descrisă de un proces semi-Markov dacă:

- 1) la momentul inițial $t = 0$ sistemul se găsește într-o din stările din E , de exemplu, în starea $i \in E$, iar după surgerea timpului aleator X_1 sistemul trece în starea $j \in E$ (timpul X_1 petrecut în starea i , înainte de trecerea în starea j , are funcția de repartiție $F_{ij}(\cdot)$);
- 2) trecerea sistemului din starea i în starea j are loc cu probabilitatea $p_{ij} > 0$ ($\sum_{j \in E} p_{ij} = 1$ pentru orice $i \in E$)²;
- 3) dacă sistemul trece din starea j în starea k , atunci sistemul rămâne în starea j un timp aleator X_2 cu funcția de repartiție $F_{jk}(\cdot)$, s.a.m.d (vezi fig.9.1.).

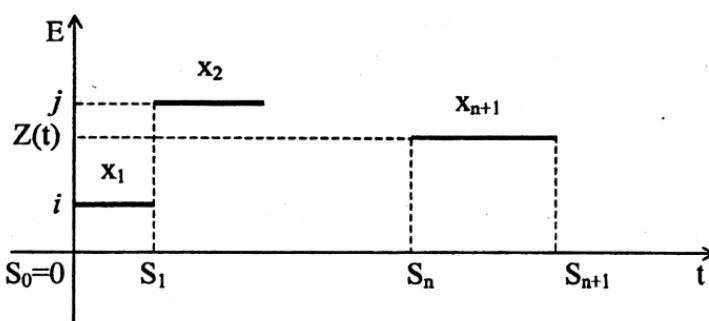


Fig. 9.1

¹Integrala este Lebesgue-Stieltjes. Dacă $Q_{ik}(\cdot)$ este derivabilă, atunci $Q_{ik}(dx)$ se înlocuiește cu $Q'_{ik}(x)dx$.

²Aici este luată în considerație posibilitatea trecerii din starea i în starea i , $i \in E$. În aplicațiile practice, deoarece aceasta nu reprezintă o schimbare de stare, se consideră de obicei $p_{ii} = 0$, $i \in E$.

Se observă că funcțiile $Q_{ij}(\cdot) = p_{ij}F_{ij}(\cdot)$, $i, j \in E$, sunt funcții de masă.

Momentele de "salt" (schimbarea de stare) ale sistemului sunt $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbf{N}^*$. Starea sistemului la momentul S_n , $n \in \mathbf{N}$, va fi notată cu J_n . Se va presupune că procesul bidimensional (J_n, X_n) , $n \in \mathbf{N}$, cu valori în $E \times \mathbf{R}_+$, verifică relația

$$P(J_{n+1}, X_{n+1} \leq t \mid J_0 = i_0, X_1 = x_1, \dots, J_{n-1} = i_{n-1}, X_{n-1} = x_{n-1}) = p_{ij}, \quad (9.1)$$

$$J_n = i, X_n = x_n = Q_{ij}(t); i_0, i_1, \dots, i_{n-1}, i, j \in E; x_1, x_2, \dots, x_{n-1} \in \mathbf{R}_+.$$

Relația (9.1) arată că (J_n, X_n) , $n \in \mathbf{N}$, este un proces Markov de o factură specială, în sensul că cea de a doua componentă X_n nu influențează evoluția viitoare a procesului; un proces stocastic $(J_n, X_n)_{n \in \mathbf{N}}$ care verifică relația (9.1) este numit *proces J - X*.

Din relația (9.1) rezultă:

- procesul $(J_n)_{n \in \mathbf{N}}$ este un lanț Markov cu spațiul sărilor E și matricea probabilităților de trecere $P = (p_{ij})_{i,j \in E}$, adică

$$P(J_{n+1} = j \mid J_n = i) = p_{ij}, \quad i, j \in E. \quad (9.2)$$

- procesul $(J_n, S_n)_{n \in \mathbf{N}}$ este un proces Markov, cu valori în $E \times \mathbf{R}_+$ numit *proces Markov de reinnoire* care verifică relația

$$P(J_n = j, S_n \leq t \mid J_0 = i) = Q_{ij}^{(n)}(t). \quad (9.3)$$

- în ceea ce privește procesul $(X_n)_{n \in \mathbf{N}}$ au loc relațiile

$$\begin{aligned} P(X_{n+1} \leq t \mid J_0 = i_0, J_1 = i_1, \dots, J_{n-1} = i_{n-1}, J_n = i) &= \\ &= H_i(t), \quad i_0, i_1, \dots, i_{n-1}, i \in E, t \in \mathbf{R}_+, \end{aligned} \quad (9.4)$$

$$P(X_{n+1} \leq t \mid J_n = i, J_{n+1} = j) = F_{ij}(t), \quad i, j \in E, t \in \mathbf{R}_+, \quad (9.5)$$

unde funcțiile $H_i(\cdot)$ și $F_{ij}(\cdot)$ au fost definite în paragraful precedent.

Dacă notăm cu Z_t , $t \in \mathbf{R}_+$, starea sistemului la momentul t , se vede că $Z_t = J_n$ dacă $S_n \leq t < S_{n+1}$. Procesul $(Z_t)_{t \in \mathbf{R}_+}$ este numit *proces semi-Markov*.

Numărul de treceri ale procesului Z_t prin starea i în intervalul de timp $[0, t]$ este o v.a. ce va fi notată cu $N_i(t)$. De asemenea, se notează cu $N(t)$ v.a. care desemnează numărul total de salturi în intervalul $[0, t]$. Evident,

$$N(t) = \sum_{i \in E} N_i(t) = \max_{n \in \mathbf{N}} \{S_n \leq t\}.$$

Dacă $P(N(t) < \infty \mid Z_0 = i) = 1$ pentru orice $t \in \mathbf{R}_+$ și $i \in E$, atunci procesul semi-Markov se numește *regulat*. O condiție suficientă pentru regularitate este ca mulțimea E să fie finită. În continuare se vor considera numai procese regulate.

Procesele semi-Markov reprezintă o generalizare atât a proceselor Markov, cât și a proceselor de reînnoire. Astfel, Z_t este un proces Markov dacă funcțiile de repartīție $F_{ij}(\cdot)$ sunt de tip exponential (vezi §3.9)

$$F_{ij}(t) = 1 - e^{-\lambda_i t}, \quad t \in \mathbf{R}_+; \quad \lambda_i > 0, \quad i, j \in E.$$

Pe de altă parte, dacă mulțimea E este formată dintr-un singur element, se demonstrează că sirul de v.a. $(S_n)_{n \in \mathbf{N}^*}$ este un sir de reînnoire (vezi §6.1).

9.3 Ecuația Markov de reînnoire

Se consideră ecuația integrală

$$U_i(t) - \sum_{j \in E} U_j(t-x)Q_{ij}(dx) = V_i(t), \quad i \in E, \quad (9.6)$$

scrisă pentru fiecare stare $i \in E$, cu $U_i(\cdot)$, $i \in E$, funcții necunoscute, iar $V_i(\cdot)$, $i \in E$, funcții date. O ecuație de forma (9.6) este numită *ecuație Markov de reînnoire*. Dacă mulțimea E este formată dintr-un singur element, atunci se obține ecuația clasică de reînnoire (6.3) (vezi §6.1).

Ecuația (9.6) poate fi rezolvată prin utilizarea transformatei Laplace; astfel, dacă

$$\begin{aligned} \tilde{U}_i(\lambda) &= \int_0^\infty e^{-\lambda t} U_i(t) dt, & \tilde{V}_i(\lambda) &= \int_0^\infty e^{-\lambda t} V_i(t) dt, \\ \tilde{Q}_{ij}(\lambda) &= \int_0^\infty e^{-\lambda t} Q_{ij}(dt), \end{aligned}$$

se obține sistemul algebric

$$\tilde{U}_i(\lambda) - \sum_{j \in E} \tilde{Q}_{ij}(\lambda) \tilde{U}_j(\lambda) = \tilde{V}_i(\lambda), \quad i \in E. \quad (9.7)$$

Procesul semi-Markov este caracterizat de următoarele mărimi:

$p_{ij}(t) = P(Z_t = j | Z_0 = i)$ - probabilitatea ca procesul să se afle în starea j la momentul t , știind că la momentul inițial $t = 0$ a fost în starea i ;

$U_{ij}(t) = E[T_j(t) | J_0 = i]$ - unde $T_j(t)$ este v.a. ce desemnează timpul din intervalul $[0, t]$ petrecut de proces în starea j ;

$R_{ij}(t) = E[N_j(t) | J_0 = i]$ - valoarea medie a numărului de treceri prin starea j în intervalul $[0, t]$, știind că la momentul inițial $t = 0$, procesul a fost în starea i .

Ecuațiile Markov de reînnoire corespunzătoare, pentru $i, j \in E$, sunt

$$p_{ij}(t) = \delta_{ij}[1 - H_i(t)] + \sum_{k \in E} \int_0^t p_{kj}(t-x)Q_{ik}(dx), \quad (9.10)$$

$$U_{ij}(t) - \sum_{k \in E} \int_0^t U_{kj}(t-x)Q_{ik}(dx) = \delta_{ij}[t(1 - H_i(t))] + \int_0^t xH_i(dx), \quad (9.11)$$

$$R_{ij}(t) = \delta_{ij} + \sum_{k \in E} \int_0^t R_{kj}(t-x)Q_{ik}(dx). \quad (9.12)$$

Exemplul 1. Se consideră un sistem complex a cărui funcționare este descrisă de un proces stocastic (vezi exemplul 1, cap. 8). În exemplul amintit s-a considerat că acest proces stocastic este un proces Markov cu număr finit de stări, ceea ce atrage după sine faptul că perioadele de funcționare neîntreruptă, precum și cele de reparație sunt repartizate exponențial. Dacă acest lucru nu poate fi acceptat (de exemplu, intervine fenomenul de uzură în timp a componentelor), atunci funcționarea sistemului poate fi descrisă de un proces semi-Markov. Pentru calculul indicatorilor de fiabilitate se pot folosi ecuațiile Markov de reînnoire (9.10) - (9.12).

Exemplul 2. Prin stoc se înțelege o cantitate de materiale (produse) păstrată în vederea unei viitoare vânzări sau necesară pentru producție. Mărimea stocului la momentul $n \in \mathbb{N}$ se notează cu Z_n . Sirul $(Z_n)_{n \in \mathbb{N}}$ verifică relația de recurență

$$Z_{n+1} = Z_n + \eta_{n+1} - f(Z_n + \eta_{n+1}, \xi_{n+1}), \quad n \in \mathbb{N},$$

unde η_{n+1} este cantitatea de materiale intrată în stoc la momentul $n+1$, ξ_{n+1} este cantitatea cerută spre vânzare în intervalul $(n, n+1]$, iar $f(Z_n + \eta_{n+1}, \xi_{n+1})$ este cantitatea vândută (ieșită din stoc) la momentul $n+1$. Se presupune că cererile succesive ξ_1, ξ_2, \dots formează un sir de v.a. independente și identic repartizate, intrările în stoc se fac după un anumit program de aprovizionare, iar funcția f este prescrisă ținând seama de acest program. Evident,

$$f(Z_n + \eta_{n+1}, \xi_{n+1}) \leq \xi_{n+1}.$$

O categorie importantă de modele de stocare sunt acelea pentru care intrările de materiale sunt aleatoare. Problema, care se pune, este de a optimiza cererile (ieșirile) pentru ca stocul să rămână la un nivel dorit. Aceste modele au aplicabilitate la rezervoarele de apă (sau lacuri de acumulare), motiv pentru care sunt de obicei numite "modele pentru rezervoare".

Fie Y_{n+1} cantitatea de apă furnizată în intervalul $(n, n+1]$, $n \in \mathbb{N}$; se presupune că v.a. Y_1, Y_2, \dots sunt independente și identic repartizate. Rezervorul

are o capacitate finită C . Atunci intrările efective de apă în rezervor sunt date de relația

$$\eta_{n+1} = \min(Y_{n+1}, C - Z_n), \quad n \in \mathbb{N},$$

unde Z_n este cantitatea de apă din rezervor la momentul $n \in \mathbb{N}$. Cererile de apă din rezervor la momentele $n = 1, 2, \dots$, sunt ξ_1, ξ_2, \dots ; aceste v.a. sunt, de asemenea, independente și identic repartizate. Se presupune, de asemenea, că sirul $(\xi_n)_{n \in \mathbb{N}}$ este independent de sirul $(Y_n)_{n \in \mathbb{N}}$. Livrările de apă din rezervor sunt date de

$$f(Z_n + \eta_{n+1}, \xi_{n+1}) = \min(Z_n + \eta_{n+1}, \xi_{n+1}), \quad n \in \mathbb{N}$$

și prin urmare

$$Z_{n+1} = \max(0, Z_n + \eta_{n+1} - \xi_{n+1}), \quad n \in \mathbb{N}.$$

Se notează cu S_n , $n \in \mathbb{N}$, momentele aleatoare la care are loc fie o intrare, fie o ieșire de apă. Se presupune că, în același moment, nu poate avea loc și o intrare și o ieșire, iar $S_0 = 0$.

Se definesc v.a. J_n , $n \in \mathbb{N}$, ce iau valorile 1 sau 2, după cum la momentul S_n a avut loc o intrare sau o ieșire.

Sirul (J_n, S_n) , $n \in \mathbb{N}$, este un proces Markov de reinnoire cu mulțimea stăriilor $\{1, 2\} \times \mathbb{R}_+$. Matricea semi-Markov corespunzătoare este

$$Q_{ij}(t) = P(J_{n+1} = j, \quad S_{n+1} - S_n \leq t \mid J_n = i), \quad i, j = 1, 2.$$

Capitolul 10

Sisteme aleatoare cu legături complete

Un concept de dependență mai general decât dependența markoviană îl reprezintă dependența cu legături complete¹. Mult timp, a existat prejudecata că teoria dependenței cu legături complete nu depășește cu mult teoria din cazul markovian sau chiar că se reduce la aceasta. Dar dezvoltarea, din ultimii ani, a acestei teorii a demonstrat prin rezultatele obținute importanța și potențialitățile sale aplicative.

10.1 Conceptul de sistem aleator cu legături complete

Fie T mulțimea numerelor întregi \mathbf{Z} sau mulțimea numerelor naturale \mathbf{N} . Se consideră (X, \mathcal{X}) și (W, \mathcal{W}) două spații măsurabile, $(u_t(\cdot, \cdot))_{t \in T}$ o familie de aplicații $u_t : W \times X \rightarrow W$, $(\mathcal{W} \otimes \mathcal{X}, \mathcal{W})$ -măsurabile și $(P(\cdot, \cdot))_{t \in T}$ o familie de funcții $P : W \times X \rightarrow \mathbf{R}$ astfel încât

a) $\{(w, x^{(n)}) \mid u_t(w, x^{(n)}) \in A\} \in \mathcal{W} \times \mathcal{X}^{(n)}$ pentru orice $t \in T$, $n \in \mathbf{N}^*$ și $A \in \mathcal{W}$, unde

$$u_t(\cdot, x^{(n)}) = u_{t+n-1}(\cdot, x_n) \circ \dots \circ u_t(\cdot, x_1)$$

cu $x^{(n)} = (x_1, \dots, x_n) \in X^{(n)}$ ²;

¹Teoria dependenței cu legături complete a fost inițiată de matematicienii români Octav Onicescu (1892-1893) și Gheorghe Mihoc (1906-1981) în anul 1935. Școala românească de teoria probabilităților a adus contribuții deosebit de importante în acest domeniu. Lucrările matematicienilor Marius Iosifescu și Ioan Cuculescu au o valoare remarcabilă.

² $(X^{(n)}, \mathcal{X}^{(n)}) = (\prod_n X, \bigotimes_n \mathcal{X}).$

b) tP este o probabilitate de trecere de la (W, \mathcal{W}) la (X, \mathcal{X}) pentru orice $t \in T$, adică ${}^tP(\cdot, \cdot) : W \times \mathcal{X} \rightarrow \mathbb{R}$ satisfacă condițiile

- $\forall w \in W$, ${}^tP(w, \cdot)$ este o probabilitate pe (X, \mathcal{X})
- $\forall A \in \mathcal{X}$, ${}^tP(\cdot, A)$ este o funcție măsurabilă pe (W, \mathcal{W}) .

Un cadruplu $\{(W, \mathcal{W}), (X, \mathcal{X}), (u_t)_{t \in T}, ({}^tP)_{t \in T}\}$ de spații măsurabile, aplicații măsurabile și probabilități de trecere care satisfac condițiile (a) și (b) se numește *sistem aleator cu legături complete*, pe scurt s.a.l.c.

Un s.a.l.c $\{(W, \mathcal{W}), (X, \mathcal{X}), (u_t)_{t \in T}, ({}^tP)_{t \in T}\}$ se numește *omogen* dacă aplicațiiile u_t și probabilitățile de trecere tP nu depind de t , adică

$$u_t(\cdot, \cdot) = u(\cdot, \cdot) \quad \text{și} \quad {}^tP(\cdot, \cdot) = P(\cdot, \cdot) \quad \forall t \in T.$$

Un s.a.l.c. omogen va fi notat $\{(W, \mathcal{W}), (X, \mathcal{X}), u, P\}$.

Teorema 10.1 (Teorema de existență). Fie $T = \mathbb{N}$; pentru orice s.a.l.c. și orice $w \in W$, fixat, există un câmp de probabilitate $(\Omega, \mathcal{K}, P_w)$ și un sir $(\xi_n)_{n \in \mathbb{N}^*}$ de v.a. definite pe Ω și cu valori în X astfel încât

$$P_w(\xi_1 \in A) = {}^0P(w, A),$$

$$P_w(\xi_{n+1} \in A \mid \xi_j, \quad 1 \leq j \leq n) = {}^nP(u_0(w, \xi^{(n)}), A) \quad P_w - a.s.$$

pentru orice $n \in \mathbb{N}^*$, $A \in \mathcal{X}$, unde $\xi^{(n)} = (\xi_1, \dots, \xi_n)$.

Astfel $\Omega = X^{\mathbb{N}^*}$ și $\xi_n(\omega) = x_n$, $n \in \mathbb{N}^*$, dacă $\omega = (x_n)_{n \in \mathbb{N}^*}$, iar

$$P_w(\xi_1 \in A_1, \dots, \xi_n \in A_n) = \begin{cases} {}^0P(w, A_1), & n = 1 \\ \prod_{i=0}^{n-1} \int_{A_{i+1}} {}^iP(u_0(w, x^{(i)}), dx_{i+1}), & n > 1 \end{cases}$$

unde $A_1, \dots, A_n \in \mathcal{X}$. Pentru orice $l \in \mathbb{N}^*$ și $t \in T$ se definește funcția tP_l pe $W \times \mathcal{X}^{(l)}$ prin relațiile

$${}^tP_l(w, A^{(l)}) = \begin{cases} {}^tP(w, A^{(1)}), & l = 1 \\ \prod_{i=0}^{l-1} \int_X {}^{t+i}P(u_t(w, x^{(i)}), dx_{i+1}) \chi_{A^{(i+1)}}(x^{(i+1)}), & l > 1. \end{cases}$$

Pentru orice $l, n \in \mathbb{N}^*$ și $t \in T$ se definește funcția ${}^tP_l^n$ pe $W \times \mathcal{X}^{(l)}$ prin relațiile

$${}^tP_l^n(w, A^{(l)}) = \begin{cases} {}^tP_l(w, A^{(1)}), & n = 1 \\ \int_X {}^tP(w, dx)^{t+1} P_l^{n-1}(u_t(w, x), A^{(l)}), & n > 1. \end{cases}$$

Evident, pentru orice $n \in \mathbb{N}^*$ se obține

$${}^tP_l^n(w, A^{(l)}) = {}^tP_{l+n-1}(w, X^{(n-1)} \times A^{(l)})$$

punând $X^{(0)} \times A^{(l)} = A^{(l)}$.

Se remarcă că pentru $1 \leq r \leq n$ are loc următoarea relație

$${}^t P_l^n(w, A^{(l)}) = \int_{X^{(r)}} {}^t P_r(w, dx^{(r)}) {}^{t+r} P_l^{n-r}(u_t(w, x^{(r)}), A^{(l)}). \quad (10.1)$$

Relația (10.1) reprezintă analogul relației Chapman-Kolmogorov. Evident, în cazul omogen, relația (10.1) devine

$$P_l^n(w, A^{(l)}) = \int_{X^{(r)}} P_r(w, x^{(r)}) P_l^{n-r}(u(w, x^{(r)}), A^{(l)}).$$

Dacă $T = \mathbb{N}$, interpretarea probabilistă a funcțiilor ${}^t P_l^n$ decurge din relațiile

$${}^t P_l^n(w, A^{(l)}) = \begin{cases} P_w([\xi_n, \dots, \xi_{n+l-1}] \in A^{(l)}), & t = 0 \\ P_{w,t}([\xi_{t+n}, \dots, \xi_{t+n+l-1}] \in A^{(l)} | \xi^{(t)}_{\xi^{(t)}=x^{(t)}}), & t \geq 1 \end{cases}$$

unde w, w' și $x^{(t)}$ satisfac relația $w = u_0(w', x^{(t)})$.

10.2 Lanțul Markov asociat

Fie $(\xi_n)_{n \in \mathbb{N}^*}$ sirul de v.a. pe câmpul de probabilitate $(\Omega, \mathcal{K}, P_w)$ construit în teorema 10.1. Pentru $w \in W$, fixat, se consideră sirul

$$\zeta_n = u_0(w, \xi^{(n)}), \quad n \in \mathbb{N}^*.$$

Evident, avem

$$P_w(\xi_1 \in A) = {}^0 P(w, {}^0 A_w),$$

$$P_w(\zeta_{n+1} \in A | \zeta_j, 1 \leq j \leq n) = P_w(\zeta_{n+1} \in A | \zeta_n) = {}^n P(\zeta_n, {}^n A_{\zeta_n}), \quad n \in \mathbb{N}^*,$$

unde ${}^t A_w = \{x | u_t(w, x) \in A\}$, pentru $A \in \mathcal{W}$, $w \in W$, $t \in T$.

Fie ${}^t Q(w, A) = {}^t P(w, {}^t A_w)$. Este ușor de văzut că pentru orice $t \in T$, ${}^t Q$ este o probabilitate de trecere de la (W, \mathcal{W}) la (W, \mathcal{W}) .

Propoziția 10.2. *Sirul $(\zeta_n)_{n \in \mathbb{N}^*}$ de v.a. pe câmpul de probabilitate $(\Omega, \mathcal{K}, P_w)$ este un lanț Markov având spațiul stărilor (W, \mathcal{W}) , probabilitățile de trecere $({}^t Q)_{t \in \mathbb{N}}$ și repartiția inițială de probabilitate concentrată în w .*

Probabilitățile de trecere în n pași se definesc prin

$${}^t Q^n(w, A) = {}^t P_n(w, {}^t A_w^{(n)}),$$

punând

$${}^t A_w^{(n)} = \{x^{(n)} | u_t(w, x^{(n)}) \in A\}$$

pentru orice $A \in \mathcal{W}$, $w \in W$, $t \in T$ și $n \in \mathbb{N}^*$.

Sistemul $\{(W, \mathcal{W})(^tQ)_{t \in T}\}$ se numește *sistemul Markov asociat s.a.l.c.*

$$\{(X, \mathcal{X}), (W, \mathcal{W}), (u_t)_{t \in T}, (^tP)_{t \in T}\}.$$

Sistemul Markov asociat unui s.a.l.c. omogen se reduce la $\{(W, \mathcal{W}), Q\}$, unde probabilitatea Q este definită prin

$$Q(w, A) = P(w, A_w),$$

cu $A_w = \{x \mid u(w, x) \in A\}$. În acest caz, probabilitățile de trecere în n pași sunt

$$Q^n(w, A) = P_n(w, A_w^{(n)})$$

cu

$$A_w^{(n)} = \{x^{(n)} \mid u(w, x^{(n)}) \in A\}.$$

Exemplul 1 (Aproximarea stocastică). Fie F_a , $a \in \mathbf{R}$, o familie de funcții de repartiție definite pe \mathbf{R} . Se presupune că

$$M(a) = \int_R y dF_a(y)$$

există și că ecuația $M(a) = 0$ are o unică soluție θ . Robbins și Monro au dat în anul 1951 o metodă statistică pentru estimarea soluției θ . Astfel, se alege $\theta_0 \in \mathbf{R}$, arbitrar, și se definesc v.a. θ_n prin relația de recurență

$$\theta_{n+1} = \theta_n - \frac{c}{n+1} \eta_{n+1},$$

unde c este o constantă pozitivă și η_{n+1} este o v.a. a cărei funcție de repartitie condiționată de $\theta_0, \dots, \theta_n$ este F_{θ_n} . În anumite condiții, se poate arăta că θ_n converge fie în probabilitate, fie aproape sigur către θ , când $n \rightarrow \infty$. Este clar că sirul $(\theta_n)_{n \in \mathbf{N}}$ este echivalent cu lanțul Markov asociat s.a.l.c. $\{(W, \mathcal{W}), (X, \mathcal{X}), (u_n)_{n \in \mathbf{N}}, P\}$ unde,

$$(W, \mathcal{W}) = (X, \mathcal{X}) = (\mathbf{R}, \mathcal{B}),$$

$$u_n(w, x) = w - \frac{c}{n+1} x, \quad n \in \mathbf{N}, \quad w, x \in \mathbf{R},$$

$$P(w, A) = \int_A dF_w(y), \quad w \in \mathbf{R}, \quad A \in \mathcal{B}.$$

Exemplul 2 (Fracții continue). Acest exemplu, propus de Iosifescu în anul 1974, arată că dependența cu legături complete joacă un rol important în teoria metrică a fracțiilor continue. Fie Ω mulțimea numerelor iraționale din

intervalul $I = [0, 1]$. Orice număr irațional $\omega \in \Omega$ poate fi reprezentat în mod unic printr-o fracție continuă infinită

$$\omega = \cfrac{1}{a_1(\omega) + \cfrac{1}{a_2(\omega) + \cfrac{1}{\ddots}}} = [a_1(\omega), a_2(\omega), \dots].$$

Numerele naturale $a_n(\omega)$, $n \in \mathbb{N}^*$, numite *câturile parțiale* din dezvoltarea lui ω în fracție continuă, sunt determinate în modul următor. Se definește aplicația

$$\tau : \Omega \rightarrow \Omega, \quad \tau(\omega) = \left\{ \frac{1}{\omega} \right\},$$

unde $\{\cdot\}$ reprezintă partea fractionară a unui număr real. Atunci se obține

$$a_{n+1}(\omega) = a_n(\tau(\omega)) = a_1(\tau^n(\omega)), \quad n \in \mathbb{N}^*,$$

$$a_1(\omega) = \frac{1}{\omega} - \tau(\omega) = \left[\frac{1}{\omega} \right],$$

unde $[\cdot]$ reprezintă partea întreagă a unui număr real.

Notând

$$[a_1, \dots, a_n] = \cfrac{1}{a_1 + \cfrac{1}{\ddots + \cfrac{1}{a_n}}}, \quad n \in \mathbb{N}^*,$$

obținem

$$\omega = \cfrac{1}{a_1(\omega) + \tau(\omega)} = [a_1(\omega), \dots, a_{n-1}(\omega), a_n(\omega) + \tau^n(\omega)]$$

pentru orice $n \geq 2$.

Numerelor raționale din $I = [0, 1]$ le corespund fracții continue finite. Deoarece, în continuare, vor fi considerate numai fracții continue infinite, acestea vor fi numite simplu *fracții continue*.

Dacă intervalul I este înzestrat cu σ -algebra \mathcal{B}_I a submulțimilor Borel din I , atunci a_n , $n \in \mathbb{N}^*$, sunt v.a. pe (I, \mathcal{B}_I) , definite aproape peste tot în raport cu orice probabilitate pe \mathcal{B}_I , ce asociază valoarea 0 mulțimii $I \setminus \Omega$ a numerelor raționale din I (în particular, în raport cu măsura Lebesgue μ pe I).

Se consideră sirul

$$r_n = a_n + [a_{n+1}, a_{n+2}, \dots], \quad n \in \mathbb{N}^*.$$

Evident, avem

$$r_n(\omega) = \frac{1}{\tau^{n-1}(\omega)}, \quad n \in \mathbb{N}^*, \quad \tau^\circ(\omega) = \omega, \quad \omega \in \Omega.$$

Pentru orice $n \in \mathbb{N}^*$ definim

$$y_n = \begin{cases} a_1, & n = 1 \\ a_n + [a_{n-1}, \dots, a_1], & n \geq 2 \end{cases}$$

$$s_n = \frac{1}{y_n} = [a_n, \dots, a_1], \quad u_n = r_n + s_{n-1}, \quad s_0 = 0.$$

Obținem relația de recurență

$$s_{n+1} = \frac{1}{s_n + a_{n+1}}, \quad n \in \mathbb{N}^*, \quad s_1 = \frac{1}{a_1}.$$

Pentru orice număr real $t \geq 1$ și pentru orice $i_1, \dots, i_n \in \mathbb{N}^*$ are loc formula, cunoscută sub numele de *formula Brodén-Borel-Lévy*

$$\mu(r_1 > t) = \mu\left([0, \frac{1}{t}]\right) = \frac{1}{t},$$

$$\mu(r_{n+1} > t | a_1 = i_1, \dots, a_n = i_n) = \frac{s_n + 1}{s_n + t}, \quad n \in \mathbb{N}^*.$$

Cum evenimentele $\{a_n = i\}$ și $\{i < r_n < i + 1\}$ sunt echivalente, utilizând formula anterioară obținem

$$\mu(a_1 = i) = \frac{1}{i(i+1)},$$

$$\mu(a_{n+1} = i | a_1 = i_1, \dots, a_n = i_n) = \frac{s_n + 1}{(s_n + i)(s_n + i + 1)},$$

pentru orice $n \in \mathbb{N}^*$ și $i, i_1, \dots, i_n \in \mathbb{N}^*$.

Se observă că $\{s_n | n \in \mathbb{N}^*\}$ este un lanț Markov omogen pe (I, \mathcal{B}_I, μ) cu următorul mecanism de trecere: din starea $s \in I$ se poate trece într-un singur pas doar într-o stare de forma $\frac{1}{s+i}$, cu probabilitatea

$$\frac{s+1}{(s+i)(s+i+1)}, \quad i \in \mathbb{N}^*.$$

Considerăm s.a.l.c. $\{(W, \mathcal{W})(X, \mathcal{X}), u, P\}$, unde

$$W = I, \quad \mathcal{W} = \mathcal{B}_I, \quad X = \mathbb{N}^*, \quad \mathcal{X} = \mathcal{P}(\mathbb{N}^*),$$

$$u(w, x) = \frac{1}{w+x}, P(w, x) = \frac{w+1}{(w+x)(w+x+1)}, \quad w \in I, \quad x \in \mathbb{N}^*.$$

Evident, sirul $(s_n)_{n \in \mathbb{N}^*}$ este echivalent cu lanțul Markov asociat s.a.l.c de mai sus.

Exemplul 3 (*Model pentru turbulența în sisteme dinamice cu fricțiune internă*). Pentru studiul turbulentei s-a adoptat următorul model. Pentru $x_0 \in \mathbb{R}^n$, se consideră

$$x_{n+1} = f_\mu(x_n) + \xi_{n+1}, \quad n \in \mathbb{N},$$

unde $f_\mu : \mathbb{R}^n \rightarrow \mathbb{R}^m$ este o funcție continuă depinzând de parametrul μ și $(\xi_n)_{n \in \mathbb{N}^*}$ un sir de vectori aleatori m -dimensionali, independenți, identic repartizați și având repartiția de probabilitate comună p . Atunci sirul $(x_n)_{n \in \mathbb{N}}$ este echivalent cu lanțul Markov $(\zeta_n)_{n \in \mathbb{N}}$, $\zeta_0 = x_0$, asociat s.a.l.c. $\{(W, \mathcal{W}), (X, \mathcal{X}), u, P\}$, unde

$$(W, \mathcal{W}) = (X, \mathcal{X}) = (\mathbb{R}^m, \mathcal{B}^m),$$

$$u(w, x) = f_\mu(w) + x, \quad w, x \in \mathbb{R}^m,$$

$$P(w, A) = p(A), \quad w \in \mathbb{R}^m, \quad A \in \mathcal{B}^m.$$

Exemplul 4 (*Formalizarea dinamicii dezbatelor în grupuri mici*). Se consideră o mulțime \mathcal{I} formată din h indivizi care au de îndeplinit o sarcină sau de rezolvat o problemă (de exemplu, de studiat o situație dată, de luat o decizie etc.).

Din momentul însușirii informației valabile, fiecare individ este caracterizat, în termenii psihologiei sociale, printr-o "atitudine", adică printr-o stare de spirit rezultată în cursul procesului de informare. (Starea de spirit este supusă schimbărilor, distorsiunilor, interferențelor etc). O asemenea structură subiectivă a informației, aflată în raport cu sarcina de îndeplinit, este rezumată prin ceea ce vom numi o *predispoziție*. Dacă se notează cu Z mulțimea (finită) a tuturor stărilor de spirit posibile, atunci $Z^\mathcal{I}$ reprezintă mulțimea tuturor predispozițiilor posibile. Un element $z_n \in Z^\mathcal{I}$ reprezintă predispoziția la momentul $n \in \mathbb{N}$.

Din punct de vedere etologic, în momentul întâlnirii celor h indivizi, începe și apare să funcționeze un sistem vast și dinamic de corelații și schimburi bazate pe o serie de comportamente. La nivel verbal acest fapt este exprimat prin compatibilități și incompatibilități, potriviri și dezacorduri, acceptarea sau respingerea altor percepții. Cu alte cuvinte, între oricare doi indivizi din grup se stabilesc, în mod spontan, legături emoționale; o asemenea legătură poate oscila în timp într-un registru bipolar de la simpatie la antipatie. Aceste legături pot fi reprezentate printr-o matrice pătratică de ordin h , $\theta = (\theta(i, j))_{i, j \in \mathcal{I}}$, numită *matrice de simpatie*. Elementele matricei

aparțin intervalului unitate $[0,1]$. De exemplu, $\theta(i,j) = 1$ semnifică acordul deplin al lui i față de afirmațiile făcute j . Evident, în general, $\theta(i,j) \neq \theta(j,i)$, $i \neq j$. În ceea ce privește relația între ceea ce gândește și spune individul i , putem presupune că $\theta(i,i)$ reprezintă o măsură a autenticității modului de exprimare a individului i . Astfel, $\theta(i,i) = 1$ semnifică autenticitatea deplină a exprimării lui i . Se notează cu $\theta_n = (\theta_n(i,j))_{i,j \in \mathcal{I}}$ matricea de simpatie la momentul $n \in \mathbb{N}$.

Un grup de indivizi poate exista și funcționa numai dacă există o oarecare coeziune între membrii grupului. Această coeziune - care poate fi percepță în mod obiectiv la nivelul funcționării grupului printr-o serie de reguli, valori și norme morale stabilite pentru întregul grup - apare ca un rezultat final al multor factori, cum ar fi, de exemplu, impactul prestigiului grupului asupra indivizilor săi, interesul față de scopurile urmărite de grup etc. Din acest motiv, fiecărui individ i se poate asocia o anume dorință de a participa la dezbatările grupului. De aceea, se poate considera un coeficient care descrie gradul de integrare al fiecarui individ în grup și măsura nivelului de adeziune și solidaritate față de grup. Coeficientul de integrare variază între 0 și 1. Notând cu $\alpha_n(i)$ coeficientul de integrare al individului i la momentul $n \in \mathbb{N}$, vectorul $\alpha_n = (\alpha_n(i))_{i \in \mathcal{I}} \in [0,1]^{\mathcal{I}}$ reprezintă coeziunea grupului la momentul $n \in \mathbb{N}$. De asemenea, se notează cu i_n individul care a intervenit în dezbatere la momentul n și cu $a_n \in A$ intervenția sa la acel moment $n \in \mathbb{N}^*$. (A reprezintă mulțimea finită a tuturor intervențiilor posibile în legătură cu problema dezbatută).

Considerând v.a. $z_n, \theta_n, \alpha_n, i_{n+1}, a_{n+1}, n \in \mathbb{N}$, se poate presupune că tripletul $(z_{n+1}, \theta_{n+1}, \alpha_{n+1})$ depinde atât de tripletul $(z_n, \theta_n, \alpha_n)$ la momentul anterior, cât și de individul i_{n+1} și intervenția acestuia a_{n+1} la momentul actual. Deci

$$(z_{n+1}, \theta_{n+1}, \alpha_{n+1}) = F[(z_n, \theta_n, \alpha_n), i_{n+1}, a_{n+1}], \quad n \in \mathbb{N}.$$

Un individ poate interveni în dezbatere, în orice moment, cu probabilitatea $P(i_{n+1} = i | z_n, \theta_n, \alpha_n) = Q(z_n, \theta_n, \alpha_n; i)$, iar probabilitatea oricărei intervenții este

$$P(a_{n+1} = a | z_n, \theta_n, \alpha_n) = m(z_n, \theta_n, \alpha_n, i_{n+1}; a), \quad n \in \mathbb{N}.$$

Atunci sirul $(z_n, \theta_n, \alpha_n)_{n \in \mathbb{N}}$ este echivalent cu lanțul Markov asociat s.a.l.c $\{(W, \mathcal{W}), (X, \mathcal{X}), u, P\}$, unde

$$W = Z^{\mathcal{I}} \times [0,1]^{\mathcal{I} \times \mathcal{I}} \times [0,1]^{\mathcal{I}}, \quad \mathcal{W} = \mathcal{P}(Z^{\mathcal{I}}) \otimes \mathcal{B}_{[0,1]}^{\mathcal{I} \times \mathcal{I}} \otimes \mathcal{B}_{[0,1]}^{\mathcal{I}},$$

$$X = \mathcal{I} \times A, \quad \mathcal{X} = \mathcal{P}(\mathcal{I} \times A),$$

$$u = F, \quad P(w, x) = m(z, \theta, \alpha, i; a)Q(z, \theta, \alpha; i), \quad w = (z, \theta, \alpha) \in W; x = (i, a) \in X.$$

Capitolul 11

Teoria sondajului

Determinarea legilor probabilistice de comportare a fenomenelor de masă se bazează pe date numerice, obținute în urma unor observații. Statistica matematică, prin metodele sale, urmărește să încadreze fenomenul studiat într-o din clasele de fenomene care se supun unor legi cunoscute sau să determine cu aproximație cât mai bună parametrii legii în care se încadrează fenomenul respectiv.

Datele culese se referă la una sau mai multe caracteristici comune unei mulțimi de elemente.

11.1 Prelucrarea datelor statistice

O mulțime de elemente care au cel puțin o însușire comună și este supusă unei prelucrări statistice se numește *populație statistică* sau *colectivitate statistică*. Populația poate fi alcătuită dintr-un ansamblu de persoane, obiecte, evenimente, idei sau opinii etc.

Numărul elementelor mulțimii se numește *volumul populației*. Volumul unei populații statistice poate fi finit sau infinit.

Elementul unei populații statistice asupra căruia se efectuează nemijlocit observarea este numit *unitate statistică*. Culegerea informației de la unitățile statistice reprezintă *observarea statistică*. De obicei, observarea statistică se referă la o însușire comună unităților unei populații numită *caracteristică statistică*.

Caracteristica statistică capată accepții sau valori diferite de la o unitate la alta sau de la un grup de unități la altul. Caracteristica este o v.a. discretă sau continuă. Însă, diverse motive cum ar fi facilitarea prelucrării ulterioare a datelor, precizia limitată a instrumentelor de măsură și interesul practic pentru un anumit grad de precizie, fac ca în statistică să se utilizeze v.a. discrete.

Pentru obținerea informațiilor referitoare la valorile unei caracteristici, nu

este posibilă cercetarea fiecărui element în parte al populației considerate. Astfel, în mod natural, s-a ajuns la ideea cercetării pe bază de *sondaj* (metoda sondajului s-a dovedit a fi adeseori singura metodă de cercetare practic posibilă). Se cercetează doar un număr limitat de elemente prelevate astfel încât sondajul să fie reprezentativ. Obiectul cercetării îl formează o subpopulație. În teoria sondajului această subpopulație (precum și valorile observate) se numește *eșantion* sau *selecție*. Numărul de elemente dintr-un eșantion se numește *volumul eșantionului*.

Sondajul se numește *repetat* (presupunem că sondajul se face luând câte un element al populației), dacă de fiecare dată elementul ales este reintrodus în populație, înainte de a se extrage următorul. În caz contrar, sondajul se numește *nerepetat*. Remarcăm că în cazul în care volumul populației este foarte mare în raport cu volumul eșantionului, neintroducerea imediată a elementului ales în populație este fără efect practic.

Dacă un număr mare de valori ale unei caracteristici au fost notate în ordinea arbitrară în care au apărut în realitate, va fi dificil să tragem vreo concluzie cu privire la semnificația acestor date. De aceea, *valorile observate* (ale caracteristicii studiate) x_1, \dots, x_n , obținute într-un eșantion de volum n , se ordonează crescător. Dacă nu sunt toate diferite între ele, vor rămâne $m < n$ distințe. Astfel, făcând o renotare vom avea, în general, valorile distințe y_1, y_2, \dots, y_m , $m \leq n$, ordonate crescător. Se face o fișă de observații cu două coloane, în prima coloană scriindu-se valorile y_k , iar în a doua de câte ori a apărut acea valoare.

Dacă volumul eșantionului este mare, se grupează valorile pe intervale. Astfel, se consideră un interval (a, b) în care se găsesc toate valorile x_i și se împarte acest interval în r subintervale

$$I_1 = (a_0, a_1), \quad I_k = [a_{k-1}, a_k), \quad k = \overline{2, r}, \quad a_0 = a, \quad a_r = b.$$

De obicei, subintervalele se iau de lungimi egale. Subintervalele alese pentru grupare se numesc *intervale de grupare*.

Fie n_k numărul valorilor x_i din eșantionul $E_n = \{x_1, \dots, x_n\}$ care aparțin subintervalului I_k . Numărul n_k se numește *frecvență absolută* a subintervalului I_k , înțelegând prin aceasta frecvența absolută a valorilor $x_i \in E_n$, $x_i \in I_k$.

Raportul $\nu_k = \frac{n_k}{n}$ se numește *frecvență relativă* sau *frecvență* lui I_k în cele n observații. Evident

$$\sum_{k=1}^r n_k = n, \quad \sum_{k=1}^r \nu_k = 1.$$

Numărul $\mu_k = \sum_{j=1}^k \nu_j$, adică frecvența valorilor $x_i \in E_n$, $x_i < a_k$, se numește *frecvență cumulată* corespunzătoare lui I_k . Datele se organizează ca în tabelul 11.1.

Intervale de grupare I_k	Frecvențe absolute n_k	Frecvențe relative $\nu_k = \frac{n_k}{n}$	Frecvențe cumulate $\mu_k = \sum_{j=1}^k \nu_j$
$I_1 = (a_0, a_1)$	n_1	ν_1	μ_1
$I_2 = [a_1, a_2)$	n_2	ν_2	μ_2
\vdots	\vdots	\vdots	\vdots
$I_r = [a_{r-1}, a_r)$	n_r	ν_r	μ_r
TOTAL	n	1	

Tabelul 11.1

Deseori este convenabilă întocmirea unor grafice pe baza tabelului anterior. Astfel, datele experimentale pot fi prezentate prin grafice ca: histograma frecvențelor relative, poligonul frecvențelor relative, ogiva sau poligonul frecvențelor cumulate.

Histograma frecvențelor relative se obține construind pe fiecare interval I_k câte un dreptunghi având baza segmentul de extremități a_{k-1} , a_k și înălțimea ν_k (sau un număr proporțional cu ν_k) (vezi fig. 11.1).

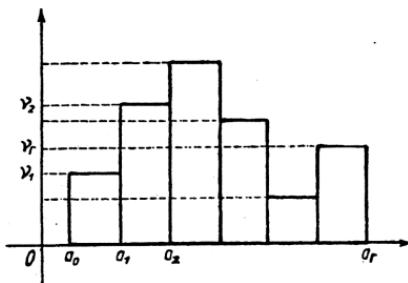


Fig. 11.1

Fie c_k centrul intervalului I_k . Se reprezintă punctele M_k de abscise c_k și ordonate numere egale sau proporționale cu frecvențele ν_k , $k = 1, 2, \dots, r$. Unind punctele consecutive prin segmente de dreapta, se obține *poligonul frecvențelor relative* (vezi fig. 11.2).

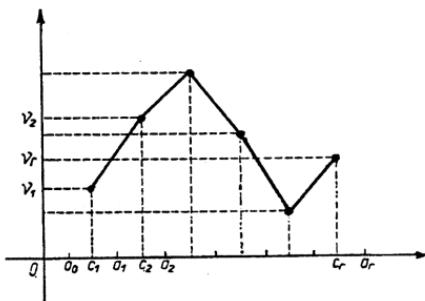


Fig. 11.2

Poligonul frecvențelor cumulate se construiește unind prin segmente de dreapta punctele consecutive $M_k(c_k, \mu_k)$, $k = 1, 2, \dots, r$. Ordonatele μ_k pot fi înlocuite prin numere proporționale cu acestea (vezi fig.11.3).

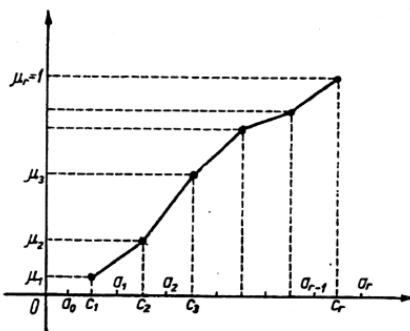


Fig. 11.3

11.2 Variabile de sondaj

Prin *experiment* vom înțelege un procedeu organizat, care poate fi repetat (ori de câte ori) în aceleasi condiții și în urma căruia se obțin rezultate ce pot fi observate, măsurate și apoi interpretate. Dacă rezultatele experimentului sunt complet determinate de condițiile în care se desfășoară, atunci avem de-a face cu un *experiment deterministic*. Dacă rezultatele nu pot fi prevăzute cu exactitate, știindu-se doar o clasă de realizări ale acestuia, atunci experimentul este *aleator*.

Fie ξ caracteristica unei populații (ξ este o v.a.). Notăm cu x_1, \dots, x_n valorile lui ξ obținute într-un eșantion de volum n . Cum aceste valori diferă, în general, de la un eșantion la altul, iar eșantioanele sunt alegeri întâmplătoare independente, valorile x_1, x_2, \dots, x_n pot fi considerate ca valori ale unor v.a. independente $\xi_1, \xi_2, \dots, \xi_n$, având aceeași repartiție ca și caracteristica ξ .

Valorile observate x_1, x_2, \dots, x_n , numite *date de observație*, reprezintă o realizare a v.a. $\xi_1, \xi_2, \dots, \xi_n$ numite *variabile de sondaj* sau *variabile de selecție* sau *variabilele eșantionului*.

Funcția empirică de repartiție corespunzătoare unui eșantion de volum n este definită prin relația

$$F_n(x) = \frac{n(x)}{n},$$

unde $n(x)$ este numărul v.a. ξ_i , $1 \leq i \leq n$, independente și identice repartizate cu ξ , pentru care s-au obținut valori mai mici sau egale cu $x \in \mathbb{R}$.

F_n este o funcție în trepte (etajată) și poate fi exprimată sub forma

$$F_n(x) = \frac{1}{n} \sum_{k=1}^n h(x - x_k),$$

unde x_1, x_2, \dots, x_n sunt datele de observație, iar h este *funcția lui Heaviside*

$$h(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0. \end{cases}$$

Pe de altă parte, $F_n(x)$ poate fi privită și ca o v.a. dacă o exprimăm cu ajutorul v.a. ξ_i , adică

$$F_n(x) = \frac{1}{n} \sum_{k=1}^n h(x - \xi_k).$$

În cazul datelor grupate pe intervale,

$$F_n(x) = \begin{cases} 0, & x < a_1 \\ \mu_k, & x \in I_{k+1}, \quad k = 1, 2, \dots, r-1, \\ \mu_r, & x \geq a_r, \end{cases}$$

unde μ_k este frecvența cumulată corespunzătoare intervalului I_k .

Legătura dintre F_n și funcția teoretică de repartiție F_ξ a v.a. ξ este data de următoarea teoremă.

Teorema 11.1 (Glivenko-Cantelli). *Cu notațiile de mai sus are loc relația*

$$P\left(\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |F_n(x) - F_\xi(x)| = 0\right) = 1,$$

adică $F_n(x) \xrightarrow{a.s.} F_\xi(x)$, uniform în $x \in \mathbf{R}$, când $n \rightarrow \infty$.

Teorema următoare evaluează distanța dintre $F_n(x)$ și $F_\xi(x)$.

Teorema 11.2 (Kolmogorov). Dacă F_ξ este o funcție continuă, atunci

$$\lim_{n \rightarrow \infty} P \left[\sup_{x \in \mathbf{R}} |F_n(x) - F_\xi(x)| \leq \frac{\lambda}{\sqrt{n}} \right] = K(\lambda) = \sum_{k \in \mathbf{Z}} (-1)^k e^{-2k^2 \lambda^2}$$

pentru $\lambda > 0$.

11.3 Valori tipice de sondaj (de selecție)

Prin analogie cu indicatorii repartițiilor teoretice se definesc diversi indicatori sau valori tipice empirice pentru repartitia empirică a unei caracteristici ξ .

Fie x_1, \dots, x_n datele de observație ale v.a. ξ într-un eșantion de volum n , (ξ_1, \dots, ξ_n) . O funcție $T(\xi_1, \dots, \xi_n)$ (sau $T(x_1, \dots, x_n)$), unde $T : \mathbf{R}^n \rightarrow \mathbf{R}$ este o funcție măsurabilă Borel se numește *statistică*.

Momentul de sondaj (sau *momentul empiric*) de ordinul k este prin definiție statistică

$$\bar{m}_k = \frac{\xi_1^k + \dots + \xi_n^k}{n}.$$

Dacă se notează cu m_k momentul teoretic de ordinul k (adică momentul de ordinul k al v.a. ξ), atunci au loc relațiile

$$E(\bar{m}_k) = m_k \quad \text{și} \quad \text{Var}(\bar{m}_k) = \frac{m_{2k} - m_k^2}{n}.$$

Momentul de sondaj de ordinul k converge în probabilitate (vezi §4.1) către momentul teoretic de ordinul k cu condiția ca momentele teoretice de ordinul k , respectiv $2k$ să existe.

Pentru $k = 1$ se obține *media de sondaj* sau *valoarea medie empirică* \bar{m}_1 , notată cu $\bar{\xi}$, care are proprietățile

$$E(\bar{\xi}) = E(\xi), \quad \text{Var}(\bar{\xi}) = \frac{\text{Var}(\xi)}{n}.$$

Trebuie remarcat că, în practică, momentul de sondaj de ordinul k este definit prin

$$\bar{m}_k = \frac{1}{n} \sum_{i=1}^l n_i x_i^k,$$

adică prin valorile x_1, \dots, x_l obținute într-un eșantion de volum $n \geq l$ și prin frecvențele absolute n_i , $i = \overline{1, l}$, ale valorilor x_i ; $\sum_{i=1}^l n_i = n$.

adică $F_n(x) \xrightarrow{a.s.} F_\xi(x)$, uniform în $x \in \mathbf{R}$, când $n \rightarrow \infty$.

Teorema următoare evaluează distanța dintre $F_n(x)$ și $F_\xi(x)$.

Teorema 11.2 (Kolmogorov). Dacă F_ξ este o funcție continuă, atunci

$$\lim_{n \rightarrow \infty} P \left[\sup_{x \in \mathbf{R}} |F_n(x) - F_\xi(x)| \leq \frac{\lambda}{\sqrt{n}} \right] = K(\lambda) = \sum_{k \in \mathbf{Z}} (-1)^k e^{-2k^2 \lambda^2}$$

pentru $\lambda > 0$.

11.3 Valori tipice de sondaj (de selecție)

Prin analogie cu indicatorii repartițiilor teoretice se definesc diversi indicatori sau valori tipice empirice pentru repartitia empirică a unei caracteristici ξ .

Fie x_1, \dots, x_n datele de observație ale v.a. ξ într-un eșantion de volum n , (ξ_1, \dots, ξ_n) . O funcție $T(\xi_1, \dots, \xi_n)$ (sau $T(x_1, \dots, x_n)$), unde $T : \mathbf{R}^n \rightarrow \mathbf{R}$ este o funcție măsurabilă Borel se numește statistică.

Momentul de sondaj (sau momentul empiric) de ordinul k este prin definiție statistică

$$\bar{m}_k = \frac{\xi_1^k + \dots + \xi_n^k}{n}.$$

Dacă se notează cu m_k momentul teoretic de ordinul k (adică momentul de ordinul k al v.a. ξ), atunci au loc relațiile

$$E(\bar{m}_k) = m_k \quad \text{și} \quad \text{Var}(\bar{m}_k) = \frac{m_{2k} - m_k^2}{n}.$$

Momentul de sondaj de ordinul k converge în probabilitate (vezi §4.1) către momentul teoretic de ordinul k cu condiția ca momentele teoretice de ordinul k , respectiv $2k$ să existe.

Pentru $k = 1$ se obține media de sondaj sau valoarea medie empirică \bar{m}_1 , notată cu $\bar{\xi}$, care are proprietățile

$$E(\bar{\xi}) = E(\xi), \quad \text{Var}(\bar{\xi}) = \frac{\text{Var}(\xi)}{n}.$$

Trebuie remarcat că, în practică, momentul de sondaj de ordinul k este definit prin

$$\bar{m}_k = \frac{1}{n} \sum_{i=1}^l n_i x_i^k,$$

adică prin valorile x_1, \dots, x_l obținute într-un eșantion de volum $n \geq l$ și prin frecvențele absolute n_i , $i = \overline{1, l}$, ale valorilor x_i ; $\sum_{i=1}^l n_i = n$.

Statistica $\bar{\mu}_k = \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{m}_1)^k$ se numește *momentul centrat de sondaj (momentul empiric centrat) de ordinul k*.

Pentru $k = 2$ se obține *varianța (dispersia) de sondaj*, notată cu s^2 .

Dacă se notează cu μ_k momentul centrat teoretic de ordinul k , atunci $E(\bar{\mu}_k) = \mu_k + o\left(\frac{1}{n}\right)$; iar, dacă $E(\xi) = 0$ avem și relația

$$\text{Var}(\bar{\mu}_k) = \frac{\mu_{2k} - \mu_k^2 - 2k\mu_{k-1}\mu_{k+1} + k^2\mu_2\mu_{k-1}^2}{n} + o\left(\frac{1}{n^2}\right).$$

În practică, se utilizează pentru varianța de sondaj valoarea $\bar{s}^2 = \frac{n}{n-1}s^2$, deoarece $E(\bar{s}^2) = \mu_2$, în timp ce $E(s^2) = \mu_2 + o\left(\frac{1}{n}\right)$.

Următoarea teoremă dă informații referitoare la legea de repartiție urmată de diverse statistici.

Teorema 11.3. 1) Dacă există valorile $E(\xi) = m$, $\text{Var}(\xi) = \sigma^2 \neq 0$ și $E(|\xi - m|^3)$, atunci v.a. $\frac{\bar{\xi} - m}{\frac{\sigma}{\sqrt{n}}}$ este asimptotic normală $N(0, 1)^1$, când $n \rightarrow \infty$.

2) Dacă există momentele $E(\xi^r) = m_r$, $E(\xi^{2r}) = m_{2r}$ și $E(|\xi^r - m_r|^3)$, atunci v.a. $\sqrt{\frac{\bar{m}_r - m_r}{m_{2r} - m_r^2}} \frac{\bar{\xi} - m_r}{r}$ este asimptotic normală $N(0, 1)$, când $r \rightarrow \infty$.

3) Dacă ξ este repartizată normal $N(m, \sigma)$, atunci $\bar{\xi}$ urmează legea

$$N\left(m, \frac{\sigma}{\sqrt{n}}\right).$$

4) Dacă ξ urmează legea $N(m, \sigma)$, atunci $\bar{\xi}$ și s^2 sunt independente, iar ns^2 este repartizată χ^2 cu $n-1$ grade de libertate și cu parametrul σ (vezi §3.14).

5) Dacă ξ urmează legea $N(m, \sigma)$, atunci $\sqrt{n-1} \cdot \frac{\bar{\xi}}{s}$ urmează legea t cu parametrul $n-1$ (vezi §3.15).

Exemplul 1. Piesele lucrate de o anumită mașină, pentru a fi acceptate, trebuie să îndeplinească unele condiții. Piesele acceptabile și neacceptabile

¹Aceasta înseamnă că sirul de v.a. $(\bar{\xi} - m)/\left(\frac{\sigma}{\sqrt{n}}\right)$ $n = 1, 2, \dots$, converge în repartiție (vezi §4.1) către o v.a. repartizată $N(0, 1)$.

se distribuie după o lege de repartiție, pe care presupunem că o cunoaștem în condiții normale de funcționare a mașinii. Pieselete formează o populație statistică, iar legea ne dă repartiția acestei populații. Cunoscând repartiția, putem determina valoarea medie a numărului de piese acceptabile produse într-un interval de timp dat și împrăștierea lor în jurul valorii medii, care poate fi considerată ca o piesă standard. De asemenea, putem sesiza momentul când mașina încețează să funcționeze în condiții normale.

Exemplul 2. Când medicul face o analiză a săngelui, el aplică metoda sondajului. El determină valoarea medie a diferiților corpusculi din sânge - valoarea medie a acestora fiind, în acest caz, caracteristica ce îl interesează - cercetând numai colectivitatea parțială de sânge luat pentru analiză.

Exemplul 3. Considerăm o producție de N metri de pânză realizată într-un timp dat, într-o fabrică de textile. Ne interesează coeficientul de rezistență al pânzei. Pentru aceasta, aplicăm metoda sondajului, luând la întâmplare diferite bucăți din pânză produsă și determinăm coeficientul de rezistență respectiv. Metoda sondajului este, în acest caz, singura posibilă din punct de vedere economic, deoarece determinarea directă a coeficientului de rezistență al pânzei ar implica distrugerea întregii producții.

Exemplul 4. Metoda sondajului este folosită și în practica recensămintelor. Astfel, să presupunem că se urmărește determinarea unei caracteristici, care ar putea fi obținută pe baza unui recensământ general, de exemplu, numărul animalelor dintr-o anumită regiune, folosite în agricultură. De multe ori, pentru realizarea acestui scop se folosește un recensământ parțial, considerându-se, la întâmplare numai 5% sau 10% din gospodăriile agricole din regiune. Se ajunge la un rezultat pe o cale mai rapidă, mai puțin costisitoare și de multe ori și mai exactă, pentru că reducerea materialului statistic de cules, la proporții mai restrânse, dă posibilitatea unei investigații statistice mai precise.

Exemplul 5. Fie dată repartiția discretă următoare

k	0	1	2	3	4	5	6	7	8	9
p_k	0,136	0,270	0,270	0,180	0,100	0,030	0,010	0,003	0,001	0

- a) Să se aproximeze repartiția dată cu ajutorul repartiției Poisson $P(\lambda)$.
 - b) Să se aproximeze repartiția dată cu ajutorul repartiției binomiale $B(100, p)$ cu $p = \frac{\lambda}{100}$.
 - c) Să se compare cele două aproximări cu repartiția dată.
- a) Media aritmetică a repartiției este $1,989 \approx 2$. Atunci recurgem la o repartiție Poisson cu media $\lambda = 2$, dată de următoarea tabelă de valori

k	0	1	2	3	4	5
p_k	0,13543	0,27067	0,27067	0,18045	0,09022	0,03608

k	6	7	8	9
p_k	0,01203	0,00343	0,0008	0,00019

b) Pentru calculul probabilităților p_k folosim formula $p_k = C_{100}^k p^k q^{100-k}$, unde $p = \frac{2}{100}$ și $q = \frac{98}{100}$. Pentru $k = 0$, probabilitatea corespunzătoare este $p_0 = \left(\frac{98}{100}\right)^{100} = 0,13180$. Celelalte probabilități se calculează cu ajutorul relației de recurență $p_{k+1} = \frac{100 - k}{k + 1} \cdot \frac{p}{q} \cdot p_k$. Rezultatele sunt date în tabela

k	0	1	2	3	4	5
p_k	0,13280	0,13315	0,00876	0,04392	0,01721	0,00556

k	6	7	8	9
p_k	0,00152	0,00033	0,00007	0,00001

c) Funcțiile de repartiție empirice, corespunzătoare celor trei repartiții, sunt date în tabela

x	$x < 0$	0	1	2	3	4
Repartiția dată F_n		0,136	0,406	0,676	0,856	0,956
Repartiția Poisson F'_n		0,13534	0,40601	0,67668	0,85713	0,94735
Repartiția binomială F''_n		0,13180	0,26495	0,35371	0,39763	0,41484

x	5	6	7	8	9	$x > 9$
Repartiția dată F_n	0,986	0,996	0,999	1	1	1
Repartiția Poisson F'_n	0,98343	0,99345	0,99889	0,99969	0,99988	1
Repartiția binomială F''_n	0,42040	0,42192	0,42225	0,42232	0,42233	1

Deoarece $\sup_x |F_n(x) - F'_n(x)| = 0,01065$ și $\sup_x |F_n(x) - F''_n(x)| = 0,57768$, rezultă că repartiția Poisson aproximează mai bine repartiția dată.

Exemplul 6. Dintr-un eșantion ordonat de 12 piese a căror caracteristică este înălțimea, s-au obținut următoarele date

Nr. pieselor în ordinea creşterii înălţimii	1	2	3	4	5	6
Înălţimea (mm)	31,50	31,60	31,65	31,70	32,20	32,40

Nr. pieselor în ordinea creşterii înălţimii	7	8	9	10	11	12
Înălţimea (mm)	32,45	32,50	32,60	32,65	32,70	32,75

Să se calculeze următoarele funcții empirice de repartiție: $F_{12}(30), F_{12}(32), F_{12}(32,5)$.

Deoarece $F_n(x) = \frac{n(x)}{n}$, unde $n(x)$ este numărul valorilor din eșantion situate la stânga lui x , iar $n = 12$, obținem $F_{12}(30) = 0$, $F_{12}(32) = \frac{4}{12}$, $F_{12}(32,5) = \frac{7}{12}$.

Să mai subliniem că, în prezent, nu ne putem imagina existența vreunui domeniu de cunoaștere în care să nu se folosească forme de observare și cercetare pe bază de sondaj. În acest sens, cuvintele lui Poincaré sunt semnificative: "Slăbiciunea noastră nu ne permite să îmbrățișăm tot universul și suntem obligați să-l descompunem în bucăți".

Capitolul 12

Teoria estimării

În problemele apărute în tehnică sau în științele experimentale, în care intervin legi de probabilitate, aceastea depind de unul sau mai mulți parametri.

Utilizarea în practică a unui proces stocastic pretinde nu numai cunoașterea naturii lui, exprimată într-o formă matematică, dar și valoarea exactă a parametrilor care intră în definiția sa.

Teoria estimării studiază ansamblul metodelor statisticii matematice, care permit determinarea valorilor parametrilor ce intră în alcătuirea unei repartiții.

12.1 Funcții de estimare (estimator)

Dacă repartitia fenomenului studiat este dată de o funcție cunoscută (de exemplu, lege de tip Poisson, lege normală) în care intră anumiți parametri necunoscuți, spunem că reprezintă o lege de *repartiție specificată*. În cazul când cunoaștem valorile numerice luate de parametru, deci când repartitia este cunoscută în întregime, avem o lege de *repartiție complet specificată*.

În continuare, vom presupune că avem de determinat un parametru al unei legi specificate, ceilalți (în caz că există) fiind cunoscuți. Estimarea parametrului $\theta \in \mathbb{R}^k$ al densității de repartitie $p(x; \theta)$ (sau al funcției de frecvență $p_i(\theta)$) urmată de v.a. ξ , se face pe baza rezultatelor experimentale sau a observațiilor unui eșantion din populația corespunzătoare v.a. ξ . Mai general, se estimează o funcție reală, măsurabilă, $g(\theta)$, care depinde de parametrul θ al legii respective.

Fie $(\xi_1, \xi_2, \dots, \xi_n)$ un eșantion de volum n corespunzător v.a. ξ (vezi §11.2). Un *estimator* (funcție de estimare) al lui $g(\theta)$ este o statistică $U = U(\xi_1, \xi_2, \dots, \xi_n)$ folosită pentru a determina funcția $g(\theta)$. Valoarea $U(x_1, \dots, x_n)$ pentru valorile observate x_i , $1 \leq i \leq n$, se numește *estimare*.

În continuare, valoarea medie și varianța corespunzătoare densității de repartitie $p(x; \theta)$ vor fi notate cu E_θ , respectiv Var_θ .

Estimatorul $U(\xi_1, \dots, \xi_n)$ se numește *nedeplasat* dacă $E_\theta(U(\xi_1, \dots, \xi_n)) = g(\theta)$ pentru orice θ , iar un estimator nedeplasat cu proprietatea

$$\text{Var}_\theta(U(\xi_1, \dots, \xi_n)) = o(1),$$

(unde $o(1) \rightarrow 0$ când $n \rightarrow \infty$) se numește *absolut corect*; în acest caz (vezi §4.1) rezultă că U converge în medie pătratică către g , când $n \rightarrow \infty$. Dacă $U(\xi_1, \dots, \xi_n)$ converge în probabilitate către $g(\theta)$, se spune că $U(\xi_1, \dots, \xi_n)$ este un *estimator consistent*. Întrucât convergența în medie pătratică implică convergență în probabilitate (vezi §4.1), rezultă că un estimator absolut corect este consistent.

Dacă $E_\theta(U(\xi_1, \dots, \xi_n)) = g(\theta) + o(1)$ și $\text{Var}_\theta(U(\xi_1, \dots, \xi_n)) = o(1)$, atunci $U(\xi_1, \dots, \xi_n)$ este numit *estimator corect*. Evident, un estimator absolut corect este corect.

Un estimator nedeplasat $U(\xi_1, \dots, \xi_n)$ al lui $g(\theta)$, care are proprietatea de a avea cea mai mică varianță în clasa tuturor estimatorilor nedeplasati ai lui $g(\theta)$ se numește *estimator eficient*. Valoarea minimă a varianței unui estimator eficient este dată de următoarea teoremă.

Teorema 12.1 (Rao-Cramér-Fréchet). *Cu notațiile precedente are loc relația*

$$\text{Var}_\theta(U) \geq \frac{1}{n E_\theta \left[\left(\frac{\partial \ln p(x; \theta)}{\partial \theta} \right)^2 \right]} = \frac{1}{n \int_{-\infty}^{\infty} \left(\frac{\partial \ln p(x; \theta)}{\partial \theta} \right)^2 p(x, \theta) dx}.$$

Teorema următoare arată că valorile tipice de sondaj prezentate în §11.3 furnizează exemple importante de estimatori.

Teorema 12.2. 1) *Momentele de sondaj sunt estimatori absoluci corecți ai momentelor teoretice.*

2) *Statistica s^2 este un estimator corect pentru $\text{Var}(\xi)$.*

3) *Statistica $\bar{s}^2 = \frac{n}{n-1} s^2$ este un estimator absolut corect pentru $\text{Var}(\xi)$.*

12.2 Metoda verosimilității maxime

Se consideră un eșantion $(\xi_1, \xi_2, \dots, \xi_n)$ de volum n corespunzător v.a. ξ și valorile observate x_1, x_2, \dots, x_n . Presupunem că densitatea de repartitie (sau, în cazul discret, funcția de frecvență) depinde de un parametru necunoscut θ care poate lua valori într-o mulțime $\Theta \subset \mathbf{R}^k$.

Vom numi *funcție de verosimilitate* corespunzătoare valorilor x_1, \dots, x_n o funcție $L(x_1, x_2, \dots, x_n; \theta)$, considerată ca funcție de θ , definită prin

$$L(x_1 \dots x_n; \theta) = \prod_{i=1}^n p(x_i; \theta),$$

unde $p(x; \theta)$ este fie densitatea de probabilitate a v.a. ξ , fie funcția sa de frecvență (adică $p(x; \theta) = P(\xi = x)$, dacă ξ este discretă).

Estimatorul de verosimilitate maximă pentru θ , este acea valoare $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ cu proprietatea că

$$L(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta).$$

Întrucât funcțiile L și $\ln L$ au aceleași puncte de maxim rezultă că, dacă $\theta = (\theta_1, \dots, \theta_k)$, atunci

$$\hat{\theta}(x_1, \dots, x_n) = (\hat{\theta}_1(x_1, \dots, x_n), \dots, \hat{\theta}_k(x_1, \dots, x_n))$$

trebuie să verifice sistemul de ecuații

$$\frac{\partial \ln L(x_1, \dots, x_n; \theta_1, \dots, \theta_k)}{\partial \theta_j} = 0, \quad j = 1, 2, \dots, k.$$

Se demonstrează că estimatorul de verosimilitate maximă este consistent și asimptotic eficient, când n este suficient de mare.

Exemplul 1. Se consideră v.a. ξ repartizată $N(m, \sigma^2)$. Fie x_1, x_2, \dots, x_n valorile v.a. $\xi_1, \xi_2, \dots, \xi_n$ care formează un eșantion de volum n relativ la v.a. ξ . Funcția de verosimilitate corespunzătoare este

$$L(x_1, \dots, x_n; m, \sigma^2) = \frac{1}{\sigma^2(2\pi)^{\frac{n}{2}}} \prod_{i=1}^n \exp \left[-\frac{1}{2} \left(\frac{x_i - m}{\sigma} \right)^2 \right].$$

Estimatorii de verosimilitate maximă ai parametrilor m și σ^2 sunt soluții ale sistemului de ecuații

$$\frac{\partial L}{\partial m} = 0, \quad \frac{\partial L}{\partial \sigma^2} = 0$$

și sunt de forma

$$\hat{m} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{și} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Exemplul 2. Se consideră v.a. ξ repartizată Poisson cu parametrul $\lambda > 0$. Utilizând aceleși notații ca în exemplul precedent, se găsește funcția de verosimilitate

$$L(x_1, \dots, x_n; \lambda) = e^{-n\lambda} \frac{1}{\prod_{i=1}^n x_i!} \lambda^{\sum_{i=1}^n x_i}.$$

Estimatorul de verosimilitate maximă se obține rezolvând ecuația $\frac{\partial L}{\partial \lambda} = 0$ și se obține $\hat{\lambda} = \bar{x}$.

Exemplul 3. Raza unui cerc este măsurată cu o eroare de observație care este normal repartizată în jurul lui 0, cu varianța σ^2 necunoscută. Date fiind n măsurători independente ale razei, să se găsească o estimare absolut corectă pentru aria acestui cerc.

Dacă notăm cu R raza cercului și cu r rezultatele măsurătorilor, atunci r este repartizată $N(R, \sigma)$, unde $E(r) = R$, $E((r - R)^2) = \sigma^2$. Rezultă că $E(r^2) = \sigma^2 + R^2$.

Fie r_1, \dots, r_n cele n măsurători independente și $U(r_1, \dots, r_n)$ o estimare absolut corectă a ariei cercului. Avem

$$E(U(x_1, \dots, x_n)) = \pi R^2.$$

Luând

$$U(r_1, \dots, r_n) = r_1^2 + r_2^2 + \dots + r_n^2$$

rezultă

$$E(r_1^2 + r_2^2 + \dots + r_n^2) = nE(r^2) = n(\sigma^2 + R^2)$$

sau

$$\frac{\pi}{n} E(r_1^2 + \dots + r_n^2) - \pi\sigma^2 = \pi R^2.$$

Deci

$$\frac{\pi}{n}(r_1^2 + \dots + r_n^2) - \pi\sigma^2$$

este o estimare absolut corectă pentru aria cercului πR^2 .

Se știe că $\frac{n}{n-1}s^2$ este un estimator absolut corect pentru σ^2 , deoarece

$$E\left(\frac{n}{n-1}s^2\right) = \sigma^2.$$

Rezultă că dacă σ^2 este necunoscută, o estimare absolut corectă pentru aria cercului este

$$\frac{\pi}{n}(r_1^2 + \dots + r_n^2) - \pi \frac{n}{n-1}s^2.$$

Capitolul 13

Verificarea ipotezelor statistice

13.1 Ipoteze statistice

Prin ipoteză statistică¹ se înțelege o ipoteză asupra uneia sau mai multor legi care caracterizează anumite populații, adică asupra valorilor parametrilor acestor legi sau asupra tipului legilor.

Verificarea ipotezelor statistice este un ansamblu de metode ale statisticii matematice care permit, plecând de la date experimentale, validarea sau infirmarea unei ipoteze statistice.

În ceea ce privește ipotezele statistice deosebim următoarele tipuri:

1. *Ipoteza parametrică* care se referă la valorile parametrilor unei legi de repartiție specificate.
2. *Ipoteza neparametrică* care se referă la forma legii de repartiție.
3. *Ipoteza nulă* H_0 este ipoteza ce urmează a fi verificată și care se presupune apriori adevărată.
4. *Ipoteza alternativă* H_1 este orice ipoteză admisibilă cu care este confruntată ipoteza nulă H_0 .
5. *Ipoteza simplă* este o ipoteză parametrică referitoare la parametrii $\theta_1, \theta_2, \dots, \theta_k$, de forma $H_0 : \theta_1 = \theta_1^0, \dots, \theta_k^0 = \theta_k^0$.
6. *Ipoteza compusă* este o ipoteză parametrică de forma $H_0 : (\theta_1, \dots, \theta_k) \in \Theta$, unde $\Theta \subset \mathbb{R}^k$ este o submulțime (care nu se reduce la un punct) a mulțimii valorilor admisibile ale parametrilor.

¹Remarcăm că ipotezele statistice nu sunt aproape niciodată echivalente cu ipotezele științifice, care în mod obișnuit sunt ipoteze asupra fenomenelor.

13.2 Teste statistice

Testul statistic este un criteriu pentru verificarea ipotezei statistice, constând în calculul unei statistici și stabilirea unei reguli fixate în prealabil de acceptare sau respingere a ipotezei nule, cu o anumită probabilitate de a lua o decizie inexactă, când ipoteza nulă H_0 este confruntată cu ipoteza alternativă H_1 .

Testul pentru verificarea egalității unui parametru estimat cu o valoare dată se numește *test de semnificație*. Testul pentru verificarea concordanței dintre repartiția empirică și repartiția teoretică este numit *test de concordanță*.

Se consideră un eșantion (ξ_1, \dots, ξ_n) de volum n corespunzător v.a. ξ și valorile observate x_1, x_2, \dots, x_n . Fie H_0 și H_1 ipoteza nulă și respectiv ipoteza alternativă. Mecanismul general pentru construirea unui test este următorul:

1. Se alege un număr α , apropiat de zero, numit *prag de semnificație*.
2. Se construiește o statistică $T(x_1, \dots, x_n)$ și o mulțime $U \subset \mathbf{R}$ astfel încât $P(T(\xi_1, \dots, \xi_n) \in U) = \alpha$ dacă ipoteza H_0 este adevărată. Acest lucru se scrie sub forma $P(T(\xi_1, \dots, \xi_n) \in U | H_0) = \alpha$. Mulțimii U îi corespunde o mulțime $V \subset \mathbf{R}^n$ astfel încât $P((\xi_1, \dots, \xi_n) \in V | H_0) = \alpha$. Mulțimea V este numită *regiune critică* (sau *de respingere*), iar V^c este numită *regiune de acceptare*.
3. Dacă $(x_1, \dots, x_n) \in V$, atunci ipoteza H_0 este respinsă (deci H_1 este acceptată); iar dacă $(x_1, \dots, x_n) \in V^c$, atunci ipoteza H_0 este accepțată (deci H_1 este respinsă).

Regiunea critică nu este determinată în mod unic dacă se alege pragul de semnificație α .

În urma aplicării unui test se pot face două feluri de erori.

a. Respingerea eronată a ipotezei H_0 , când ea este adevărată, este numită *eroare de genul întâi*. Probabilitatea erorii de genul întâi este

$$P((\xi_1, \dots, \xi_n) \in V | H_0) = \alpha.$$

b. Acceptarea eronată a ipotezei H_0 , când ea este falsă, este numită *eroare de genul al doilea*. Probabilitatea erorii de genul al doilea, notată cu β , este

$$P((\xi_1, \dots, \xi_n) \in V^c | H_1) = \beta.$$

Cu cât probabilitățile α și β sunt mai mici, cu atât testul este mai puternic. Nu putem face ca ambele probabilități α și β să fie arbitrar de mici.

Dacă testul este parametric și se referă la parametrul θ , atunci probabilitatea respingerii ipotezei nule H_0 se numește *puterea testului* și se notează cu $\pi(V, \theta)$.

Evident, $\pi(V, \theta_0) = \alpha$ dacă $H_0 : \theta = \theta_0$ și $\pi(V, \theta_1) = 1 - \beta$ dacă $H_1 : \theta = \theta_1$. Graficul funcției $\pi(V, \theta)$ se numește *curba puterii testului*.

13.3 Testul χ^2

Fie ξ o v.a. care ia valorile distincte a_1, a_2, \dots, a_m cu probabilitățile p_1, \dots, p_m respectiv. Să notăm cu ν_1, \dots, ν_m frecvențele de apariție ale valorilor a_1, \dots, a_m într-un eșantion de volum n ($\nu_1 + \nu_2 + \dots + \nu_m = n$). Se poate demonstra că v.a.

$$\eta = \sum_{i=1}^m \frac{(\nu_i - np_i)^2}{np_i}$$

este, pentru $n \rightarrow \infty$, asymptotic repartizată χ^2 cu $m - 1$ grade de libertate și cu parametrul $\sigma = 1$ (vezi §3.14 și §3.21). Ne propunem să verificăm ipoteza $H_0 : p_i = p_i^0, i = 1, 2, \dots, m$. Dacă ipoteza H_0 este adevărată trebuie să avem

$$P\left(\sum_{i=1}^m \frac{(\nu_i - np_i^0)^2}{np_i^0} \leq x\right) \simeq \frac{1}{2^{\frac{m-1}{2}} \Gamma\left(\frac{m-1}{2}\right)} \int_0^x t^{\frac{m-1}{2}-1} e^{-\frac{t}{2}} dt.$$

Alegem $x = x_\alpha$ (vezi anexa 2) astfel încât

$$\frac{1}{2^{\frac{m-1}{2}} \Gamma\left(\frac{m-1}{2}\right)} \int_0^{x_\alpha} t^{\frac{m-1}{2}-1} e^{-\frac{t}{2}} dt = 1 - \alpha,$$

unde α este pragul de semnificație, apropiat de zero.

Regiunea critică va rezulta din condiția

$$\sum_{i=1}^m \frac{(\nu_i - np_i^0)^2}{np_i^0} > x_\alpha, \quad (13.1)$$

iar regiunea de acceptare din condiția

$$\sum_{i=1}^m \frac{(\nu_i - np_i^0)^2}{np_i^0} \leq x_\alpha. \quad (13.2)$$

Prin urmare, dacă în urma sondajului, valorile observate verifică (13.1) respingem ipoteza H_0 , iar dacă verifică (13.2) acceptăm ipoteza H_0 .

13.4 Testul F (Fisher-Snedecor)

Acest test este utilizat pentru verificarea egalităților varianțelor a două populații. Mai precis, considerăm două populații caracterizate de v.a. ξ și η repartizate $N(m_1, \sigma_1^2)$ și respectiv $N(m_2, \sigma_2^2)$. Fie $(\xi_1, \dots, \xi_{n_1})$ și $(\eta_1, \dots, \eta_{n_2})$ două eșantioane corespunzătoare celor două v.a., iar x_1, \dots, x_{n_1} și y_1, \dots, y_{n_2} valorile observate. Ne propunem să verificăm ipoteza compusă

$$H_0 : \sigma_1^2 = \sigma_2^2.$$

Se poate demonstra că dacă H_0 este adevărată, iar \bar{s}_1^2 și \bar{s}_2^2 sunt varianțele de sondaj corespunzătoare (vezi §11.3), atunci v.a. $\frac{\bar{s}_1^2}{\bar{s}_2^2}$ urmează o repartiție F (vezi §3.16) cu parametrii $n_1 - 1$ și $n_2 - 1$.

Din tabele (vezi anexa 3) alegem F astfel încât

$$P\left(\frac{\bar{s}_1^2}{\bar{s}_2^2} \leq F_\alpha\right) = 1 - \alpha.$$

Prin urmare, regiunea critică rezultă din condiția $\frac{\bar{s}_1^2}{\bar{s}_2^2} > F_\alpha$. Deci, acceptăm ipoteza H_0 , dacă obținem

$$\frac{n_2 - 1}{n_1 - 1} \frac{\sum_{i=1}^{n_1} (x_i - m_1)^2}{\sum_{i=1}^{n_2} (y_i - m_2)^2} \leq F_\alpha.$$

În caz contrar, respingem ipoteza H_0 .

13.5 Testul t (Student)

Acest test parametric verifică ipoteza referitoare la media unei populații normale a cărei varianță nu este cunoscută.

Se consideră o populație caracterizată de o v.a. ξ repartizată $N(m, \sigma)$ cu σ necunoscut. Ne propunem să verificăm ipoteza $H_0 : m = m_0$. Dacă (ξ_1, \dots, ξ_n) este un eșantion de volum n , atunci se demonstrează (vezi teorema 11.3 (5)) că v.a.

$$t = \frac{\bar{\xi} - m}{\frac{s}{\sqrt{n}}}$$

urmează o repartiție t cu $n - 1$ grade de libertate (vezi §3.15) ($\bar{\xi}$ și s^2 sunt media, respectiv varianța de sondaj, (vezi §11.3)).

Din tabele (vezi anexa 4) alegem t_α astfel încât

$$P\left(\left|\frac{\bar{\xi} - m_0}{\frac{s}{\sqrt{n}}}\right| \leq t_\alpha\right) = 1 - \alpha.$$

Prin urmare, regiunea critică rezultă din condiția $\left|\frac{\bar{\xi} - m_0}{\frac{s}{\sqrt{n}}}\right| > t_\alpha$. Deci, ac-

ceptăm ipoteza H_0 dacă valorile observate x_1, \dots, x_n verifică

$$\sqrt{n(n-1)} \frac{\bar{x} - m_0}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} \leq t_\alpha$$

și o respingem în caz contrar.

13.6 Testul Kolmogorov - Smirnov

Acest test este un test de concordanță pentru verificarea ipotezei H_0 conform căreia funcția de repartiție a v.a. este F_0 .

Presupunem că funcția de repartiție a v.a. este de tip continuu și fie F_n funcția empirică de repartiție corespunzătoare eșantionului (ξ_1, \dots, ξ_n) .

Conform teoremei 11.2 se poate scrie

$$\lim_{n \rightarrow \infty} P \left(\sup_{x \in \mathbf{R}} |F_n(x) - F(x)| \leq \frac{\lambda}{\sqrt{n}} \right) = \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2 \lambda^2} = K(\lambda).$$

Prin urmare, pentru n suficient de mare construim un test bazat pe regiunea critică

$$V = \left\{ (\xi_1, \dots, \xi_n) \left| \sup_{x \in \mathbf{R}} |F_n(x) - F_0(x)| > \frac{\lambda_\alpha}{\sqrt{n}} \right. \right\},$$

unde λ_α se află din condiția $K(\lambda_\alpha) = 1 - \alpha$ (vezi anexa 5).

Exemplul 1. Nouă bolnavi cărora le-a fost administrat un medicament oarecare semnalează următoarele variații ale presiunii săngelui lor: 7, 3, -1, 4, -3, 5, 6, -4, 1. Să se arate că aceste date nu indică că medicamentul este cauza acestor variații.

În ipoteza nulă, valorile de mai sus sunt privite ca un eșantion dintr-o populație de medie zero. Avem

$$\bar{\xi} = \frac{7 + 3 - 1 + 4 - 3 + 5 + 6 - 4 + 1}{9} = 2.$$

ξ_i	7	3	-1	4	-3	5	6	-4	1
$\xi_i - \bar{\xi}$	5	1	-3	2	-5	3	4	-6	-1
$(\xi_i - \bar{\xi})^2$	25	1	9	4	-25	9	16	36	1

de unde rezultă

$$\bar{s}^2 = \frac{\sum (\xi_i - \bar{\xi})^2}{n-1} = \frac{126}{8} = \frac{63}{4}$$

$$t = \frac{\bar{\xi}\sqrt{n}}{\bar{s}} = \frac{2 \cdot 3 \cdot 2}{\sqrt{63}} = 1,51$$

Această valoare a lui t nu este semnificativă; prin urmare, nu medicamentul este cauza acestor variații.

Exemplul 2. Pentru a studia superioritatea unei semănători s-a împărțit un teren în loturi care au fost alternativ lucrate cu noua semănătoare și cu cea veche. Pentru 10 perechi de loturi valorile excesului în greutate obținute pentru noua semănătoare față de aceleia obținute cu ajutorul semănătorii obișnuite sunt: 2,4; 1; 0,7; 0; 1,1; 1,6; 1,1; 0,4; 0,1 și 0,7. Să se testeze ipoteza superiorității noii semănători față de cea veche.

Din datele problemei rezultă

$$\bar{\xi} = \frac{\sum_{i=1}^{10} \xi_i}{10} = \frac{9,1}{10} = 0,91, \quad \sum_{i=1}^{10} (\xi_i - \bar{\xi})^2 = 4,609,$$

de unde

$$\bar{s}^2 = \frac{4,609}{9} = 0,512.$$

În ipoteza nulă, media populației este zero, iar

$$t = \frac{(\bar{\xi} - m)\sqrt{n}}{\bar{s}} = \frac{0,91 \cdot 3,1623}{0,715} = 4,027.$$

Pentru 9 grade de libertate și un prag de 1% găsim $t = 3,25$ (vezi anexa 4). Prin urmare, respingem ipoteza nulă; deci semănătoarea nouă este superioară celei vechi.

Capitolul 14

Regresia

14.1 Curge de regresie

Regresia este o metodă de cercetare a unei relații predeterminate exprimând legătura dintre o v.a. Y , numită variabilă dependentă și una sau mai multe v.a. X_1, X_2, \dots , numite variabile independente. Relația exactă sau ecuația de regresie a lui Y în funcție de X_1, X_2, \dots , pusă sub forma $y = f(x_1, x_2, \dots)$ definește o curbă sau o suprafață de regresie; scopul ei este de a permite pentru niște valori observate x_1, x_2, \dots ale v.a. X_1, X_2, \dots calculul unei estimații a lui Y .

În continuare, se va lua în considerație cazul unei singure variabile independente X (regresie simplă). În acest caz, ecuația de regresie este de forma $y = f(x)$; dacă f este o funcție liniară, regresia este numită liniară sau dreaptă de regresie. Dacă f nu este liniară, atunci regresia este numită curbilinie.

14.2 Dreapta de regresie

Ecuația de regresie este de forma $y = a + bx$. Această dependență liniară este un model determinist și nu reflectă exact legătura dintre X și Y . Valorile observate (x_i, y_i) nu se găsesc exact pe dreapta $y = a + bx$ și, de fapt, unei valori x_i îi pot corespunde mai multe valori y_i .

Dependența liniară dintre variabilele Y și X se interpretează probabilist prin relația (vezi §2.4) $E(Y|X=x) = a + bx$; prin urmare, variabila dependentă este egală în medie cu o funcție liniară de X , depinzând de parametrii necunoscuți a și b .

Abaterea unei valori observate y_i față de valoarea medie condiționată $E(Y|X=x_i)$

$$y_i - E(Y|X=x_i) = y_i - a - bx_i$$

reprezintă eroarea de observare.

Să considerăm un eșantion de volum n și fie X_1, X_2, \dots, X_n variabilele de sondaj corespunzătoare lui X , iar Y_1, Y_2, \dots, Y_n variabilele de sondaj corespunzătoare lui Y (vezi §11.2). V.a.

$$e_i = Y_i - a - bX_i, \quad i = 1, 2, \dots, n$$

sunt numite *erori aleatoare* sau *reziduuri aleatoare* și satisfac condițiile

$$E(e_i) = 0,$$

$$\text{Var}(e_i) = \sigma^2, \quad i = 1, 2, \dots, n,$$

$$\text{cov}(e_i, e_j) = 0, \quad i \neq j.$$

Estimarea parametrilor a și b se face prin *metoda celor mai mici pătrate*, adică în așa fel încât suma pătratelor abaterilor între punctele observate și punctele corespunzătoare ale dreptei să fie minimă. Mai precis, dacă (x_1, x_2, \dots, x_n) și (y_1, y_2, \dots, y_n) sunt valorile observate corespunzătoare vectorilor aleatori (X_1, X_2, \dots, X_n) și respectiv (Y_1, Y_2, \dots, Y_n) se consideră

$$S = \sum_{i=1}^n (y_i - a - bx_i)^2$$

și se determină valorile a și b pentru care suma S este minimă. Minimul poate fi determinat rezolvând sistemul

$$\frac{\partial S}{\partial a} = \frac{\partial S}{\partial b} = 0,$$

de unde se obțin *ecuațiile normale*

$$na + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i,$$

$$a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

și deci

$$b = \frac{n \sum_{i=1}^n x_i y_i - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2},$$

$$a = \frac{\sum_{i=1}^n y_i - b \sum_{i=1}^n x_i}{n}.$$

Fie $\bar{x}, \bar{y}, s_x^2, s_y^2$ respectiv media de sondaj a lui X , media de sondaj a lui Y , varianța de sondaj a lui X și varianța de sondaj a lui Y ; de asemenea,

$$\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \frac{1}{n^2} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)$$

reprezintă o statistică ce estimează $\text{cov}(X, Y)$ (vezi §11.3).

Se arată cu ușurință că dreapta de regresie trece prin punctul mediu (\bar{x}, \bar{y}) , iar ecuația de regresie poate fi scrisă sub forma

$$y = \frac{\text{cov}(x, y)}{s_x^2} (x - \bar{x}) + \bar{y} \quad \text{sau} \quad y = r(x, y) \left(\frac{s_y}{s_x} \right) (x - \bar{x}) + \bar{y},$$

unde

$$r(x, y) = \frac{\text{cov}(x, y)}{s_x s_y}.$$

Din reprezentarea grafică a dreptei de regresie (vezi fig. 14.1) se observă că $y = a$ când $x = 0$, iar panta dreptei este $\tan \theta = b$.

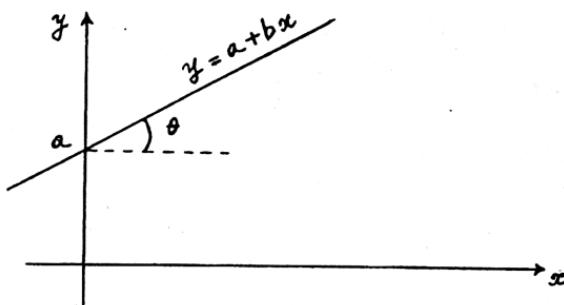


Fig.14.1

Prin urmare, variațiile celor două fenomene se produc în același sens sau în sens invers, după cum $\text{cov}(x, y) > 0$ (deci $b > 0$) sau $\text{cov}(x, y) < 0$ (deci $b < 0$).

Exemplul 1. De un resort se atârnă diverse greutăți (g) și apoi se măsoară lungimea resortului y (mm); datele sunt prezentate în tabelul 14.1. Ecuațiile normale sunt $7a + 2800b = 261$, 1 și $2800a + 140000b = 118450$. După rezolvare se obține $a = 17,29$ și $b = 0,05$; deci ecuația de regresie este $y = 17,29 + 0,05x$. Lungimea previzibilă a resortului corespunzătoare unei mase $x = 550$ va fi $y = 17,29 + 0,5 \cdot 550 = 44,79$.

x_i	y_i	$x_i y_i$	x_i^2
100	22,9	22290	10000
200	27,3	5640	40000
300	32,2	9660	90000
400	36,5	14600	160000
500	42,0	21000	250000
600	47,0	28200	360000
700	53,2	37240	490000
2800	261,1	118450	1400000

Tabelul 14.1

14.3 Regresie curbilinie

Cele mai întâlnite曲ine de regresie sunt următoarele

$$y = ax^p \text{ (funcția putere),}$$

$$y = ab^x \text{ (funcția exponențială),}$$

$$y = a + b \ln x \text{ (funcția logaritmică).}$$

Studiul pentru aceste cazuri se reduce la regresia liniară. Într-adevăr:

- în cazul funcției putere se vor considera v.a. $U = \ln X$ și $V = \ln Y$, relația dintre ele fiind dată de ecuația de regresie liniară $v = \ln a + pu$, pentru $a > 0$; cazul $a < 0$ se reduce cu ușurință la cel luat în considerație;

- în cazul funcției putere, $U = X$ și $V = \ln Y$, rezultă $v = \ln a + u \ln b$, $a > 0$;

- în cazul funcției logaritmice, $U = \ln X$ și $V = Y$, rezultă $v = a + bu$.

Dacă ecuația de regresie este de forma $y = a + bx + cx^2 + \dots$ atunci se obține *regresia polinomială*.

Coefficienții a, b, c, \dots se determină prin metoda celor mai mici pătrate. În cazul în care valorile variabilei independente X sunt echidistante, coeficienții regresiei polinomiale se pot determina prin *metoda polinoamelor ortogonale*, care constă în determinarea regresiei polinomiale sub forma $Y = b_0 P_0(x) + \dots + b_k P_k(x)$, unde $P_k(x)$ sunt polinoame de gradul k în x satisfăcând relația de ortogonalitate $\sum_{k=1}^n P_i(x_k)P_j(x_k) = 0$, $i \neq j$, pentru valorile observate x_1, x_2, \dots, x_n . Pentru diferite valori ale lui n , s-au întocmit tabele care dă direct valorile polinoamelor $P_k(x)$. Cu ajutorul acestor valori se calculează coeficienții regresiei polinomiale

$$b_k = \frac{\sum_{i=1}^n y_i P_k(x_i)}{\sum_{i=1}^n P_k^2(x_i)}.$$

NOTE ISTORICE

Istoria matematicii, referindu-se la creatorii teoriei probabilităților, consemnează următoarele fapte.

Matematicianul, filozoful și fizicianul Blaise Pascal (1623-1662) precum și matematicianul, literatul și judecătorul Pierre de Fermat (1601-1665) au cunoscut un om de lume, intelligent și fin, Antoine Gombaud Chevalier de Méré (1607-1685), versat în cunoașterea oamenilor, posedând cunoștințe foarte variate, cu idei originale, dar ignorant în matematică. Méré, pasionat jucător de cărți, și-a pus întrebarea dacă nu s-ar putea calcula şansele în joc. Astfel el a reușit să rezolve empiric câteva situații simple, dar nu a putut merge mai departe. Convins fiind că matematica nu poate fi de nici un ajutor, ca o provocare, a pus matematicienilor două probleme de calcul.

Prima problemă constă în determinarea numărului de aruncări cu zarurile pentru a obține un dublu șase. Pascal, Fermat și Roberval (1602-1675) au rezolvat foarte ușor problema.

A doua problemă, mai grea, se referă la un joc de noroc, în care doi parteneri angajează o partidă la un anumit număr de puncte; la un moment dat al jocului, ei au un număr inegal de puncte și intrerup partida înainte de a o termina. Întrebarea este cum trebuie împărțită, în mod echitabil, suma pusă în joc. Evident, fiecărui i se cuvine o parte proporțională cu șansa de a câștiga partida, șansă determinată de numărul de puncte de care mai are nevoie, ca să ajungă la numărul de puncte convenit prin regula jocului.

Pascal și Fermat au schimbat mai multe scrisori privitoare la această problemă pusă de Méré și au reușit, folosind fiecare în parte procedee oarecum deosebite, să o rezolve în același timp. Istoria matematicii atribuie conținutului acestor scrisori originea calculului probabilităților, noua ramură a matematicii, știința hazardului, *alea geometria*, cum îi spunea Pascal.

Totuși sunt de remarcat și alte aspecte privind nașterea teoriei probabilităților. Noțiunile de probabil, probabilitate, hazard sunt folosite de oameni din totdeauna.

La popoarele vechi, greci, fenicieni etc., care făceau transporturi de mărfuri cu vapoare pe diferite itinerare maritime, se practica asigurarea navelor sau a mărfurilor, fapt ce implica, prelucrarea datelor referitoare la aceste transporturi și măsurarea pe această bază a șanselor de reușită sau de eșec.

Chiar cu peste două milenii înaintea erei noastre, în China, cu ocazia unui recensământ general al populației, s-a constatat că raportul dintre numărul de băieți ce se nasc într-un an și numărul global al copiilor este aproximativ de 0,5.

În Roma antică se făceau cercetări statistice cu privire la consumul unor bunuri, pentru a se calcula rezervele necesare.

Probleme, de genul celor puse de Méré, apar în preocupările matematicienilor cu mult timp înainte. Astfel Luca Paccioli (1445-1514), în lucrarea sa *Summa* (1494), Gerolamo Cardano (1501-1576) și Nicola Fontana Tartaglia (1499-1557) s-au ocupat de problema privind repartizarea echitabilă a mizei într-un joc. De asemenea, Galileo Galilei (1564-1642) a scris *Considerazione sopra il Gioco dei Dadi*. Christian Huygens (1629-1695) în lucrarea sa *De Ratiociniis in Ludo Aleae* (Despre calculele la jocurile de noroc) (1657) rezolvă problema în forma cea mai generală. În anul 1669, într-o scrisoare, el sugerează folosirea probabilităților la întocmirea tabelelor de mortalitate.

Jakob Bernoulli (1654-1705), în opera sa *Ars Conjectandi* (Arta conjecturii) (1713), dezvoltă considerabil teoria probabilităților, arătându-i utilitatea în diverse activități omenești, printre care aplicarea ei la problema duratei vieții omului. Bernoulli introduce, în paralel, atât noțiunea de probabilitate apriori, cât și noțiunea de probabilitate aposteriori, legându-le prin vestita "lege a numerelor mari", pe care o demonstrează pentru prima dată, indicând totodată și importanța ei practică în variate domenii de activitate.

În timpul imediat următor, reflectând viața social-economică a epocii, direcțiile de folosire a teoriei probabilităților sunt extrem de variate, de exemplu: în tratarea jocurilor de noroc și a pariurilor, în problema determinării vinovăției inculpatului împotriva căruia existau câteva mărturii, în problema declarării ca decedați a indivizilor dispăruți fără urmă, la întocmirea tabelelor de mortalitate, în teoria rentelor viagere, în teoria tragerilor de artilerie etc.

Un prim rezultat al acestor preocupări este construirea statisticii demografice.

Un al doilea rezultat este folosirea calculului probabilităților în probleme de cercetare experimentală, concretizată prin întemeierea teoriei erorilor.

Abordările empirice s-au amplificat și le regăsim concretizate în secolul al XVII-lea sub forma primei societăți de asigurări în Anglia (1669). Cercetările statistice ale lui John Graunt (1620-1674), cu privire la structura populației, ale lui Willian Petty (1623-1687), cu privire la cuantificarea fenomenelor economice, ale lui Edmund Halley (1656-1742) care introduce ideea de durată probabilă de viață și lucrările lui Johann Peter Sussmilch (1707-1767), despre *aritmetică politică* (statistica), repurtează un succes decisiv.

Personalități ca Bayes (+1763), J. Bienaymé (1796-1878), Daniel Bernoulli (1700-1782), G. Boole (1815-1864), G.L.L. Buffon (1707-1788), P.L. Cebîșev (1821-1894), M.J.A. Condorcet (1743-1794), L. Euler (1707-1783), C.F. Gauss (1777-1855), P.S. Laplace (1749-1827), L. Lagrange (1736-1812), A. De Moivre (1667-1754), S.D. Poisson (1781-1840) au continuat, în secolele al XVIII-lea și al XIX-lea, să ducă cu succes mai departe dezvoltarea teoretică și direcțiile de aplicare a teoriei probabilităților.

De remarcat sunt lucrările lui Pierre Simon de Laplace *Théorie analytique des Probabilités* (1812) și *Essai philosophique sur les Probabilités* (1814). Laplace a avut chiar intenția, în lucrarea sa *Essai sur l'application de l'analyse à la probabilité des décisions rendus à la pluralité de voix* (1785), de a urmări realizarea binelui omenirii prin aplicarea teoriei probabilităților în viața social-politică, de exemplu, la alegeri, la votări și la stabilirea legilor.

Tot în această perioadă, se constată preocupări de aplicare a teoriei probabilităților în geometrie. Primul, care s-a ocupat cu astfel de probleme, a fost naturalistul, literatul și probabilistul George Louis Leclerc de Buffon. El a cercetat printre altele problema privind probabilitatea ca un disc circular aruncat peste o fașie dreptunghiulară, împărțită în pătrate, să cadă în întregime în interiorul unui pătrat. De asemenea, el a atacat probleme mai complicate de acest gen, în care discul circular este înlocuit cu o placă pătrată sau cu un ac.

Acest gen de probleme a dus la construirea metodei moderne de lucru a matematicii numită metoda numerelor întâmplătoare (cunoscută și sub denumirea de metoda Monte Carlo), folosită cu succes în probleme de pură cercetare matematică și de cercetare aplicativă.

De asemenea, reamintim lucrările lui Carl Friedrich Gauss, prin care se definește legea normală de repartiție, sau ale lui Siméon Denis Poisson care descoperă legea de repartiție a evenimentelor rare etc., la care se adaugă teorema limită centrală elaborată de Abraham de Moivre în anul 1738 și dezvoltată de Laplace în anul 1813.

Fundamentarea riguroso-științifică a teoriei probabilităților s-a făcut de abia în anul 1933 de către matematicianul rus A.N. Kolmogorov (1903-1987) care a dat o definiție axiomatică și a legat noțiunea de probabilitate de teoria mulțimilor și a măsurii, de matematica modernă.

În secolul al XX-lea, teoria probabilităților și statistica matematică sunt desăvârșite ca ramuri ale matematicii de o pleiadă de matematicieni și statisticieni dintre care amintim: E. Borel, F.P. Cantelli, H. Cramér, J.L. Doob, W. Doeblin, W. Feller, R.A. Fisher, M. Fréchet, B.V. Gnedenko, A.Ja. Hincin, A.M. Liapunov, M.G. Kendall, A.A. Markov, E.S. Pearson, H. Poincaré, Student, A. Wald și alții.

O fază superioară în îmbogățirea teoriei probabilităților o reprezintă modelarea stocastică. Conceptul de lanț Markov, introdus de matematicianul rus A.A. Markov (1856-1922) în anul 1906, este unul din cele mai fecunde concepte ale teoriei probabilităților. Modelele probabiliste Markov și semi-Markov reprezintă o clasă deosebit de importantă și fac obiectul a numeroase aplicații și cercetări făcute de B. Hostinsky, R.E. Baslow, S.N. Bernstein, K.L. Chung, D.A. Freedman, B.V. Gnedenko.

În această trecere în revistă se impune sublinierea deosebitei importanțe a școlii românești de teoria probabilităților. Academicenii Octav Onicescu

(1892-1983) și Gheorghe Mihoc (1906-1981), fondatori ai școlii românești de teoria probabilităților, au adus contribuții valoroase în dezvoltarea și aplicarea teoriei probabilităților și statisticii matematice. Ei au fost inițiatorii cercetării privind generalizarea conceptului de dependentă markoviană. În prezent, studiul cercetării românești este reprezentat la un nivel înalt de matematicienii Marius Iosifescu și Ioan Cuculescu prin importanțele lor contribuții recunoscute pe plan internațional.

Bibliografie

- [1] Ash, R.B. (1970) Basic Probability Theory. Wiley, New York.
- [2] Bachelier, L. (1912) Calcul des Probabilités. Gauthier-Villars, Paris.
- [3] Bailey, N.T. (1990) The Elements of Stochastic Processes with Applications to the Natural Sciences. Wiley, New York.
- [4] Barucha-Reid, A.T. (1960) Elements of the Theory of Markov Processes and Their Applications. McGraw-Hill, New York.
- [5] Bernoulli, J. (1713) Ars Conjectandi. Basileae impensis Thurnisiorum fratrum. Basilea, retipărită de Culture et Civilisation, Bruxelles, 1968.
- [6] Chung, K.L. (1967) Markov Chains with Stationary Transition Probabilities. Springer, New York.
- [7] Chung, K.L. (1974) Elementary Probability Theory with Stochastic Processes. Springer, New York.
- [8] Ciucu, G.; Tudor, C. (1978) Probabilități și procese stochastice, Vol. I, Ed. Academiei, București.
- [9] Cuculescu, I. (1993) Teoria probabilităților, Ed. All, București.
- [10] Doob, J.L. (1953) Stochastic Processes. Wiley, New York.
- [11] Feller, W. (1968) An Introduction to Probability Theory and Its Applications. Wiley, New York.
- [12] Gnedenko, B.V. (1968) The Theory of Probability. Mir Publisher, Moskow.
- [13] Iosifescu, M.; Mihoc, Gh., Theodorescu, R. (1966) Teoria probabilităților și statistică matematică. Ed. Tehnică, București.
- [14] Iosifescu, M.; Theodorescu, R. (1969) Random Processes and Learning. Springer, New York.

- [15] Iosifescu, M.; Tăutu, P. (1973) Stochastic Processes and Applications in Biology and Medicine. Ed. Academiei, Bucureşti.
- [16] Iosifescu, M. (1980) Finite Markov Processes and Their Applications, Wiley & Ed. Tehnică, Chichester & Bucureşti.
- [17] Iosifescu, M.; Grigorescu, Ş; Oprişan, Gh.; Popescu Gh. (1984) Elemente de modelare stochastică. Ed. Tehnică, Bucureşti.
- [18] Iosifescu, M.; Moineagu, C.; Trebici, V.; Ursianu, E. (1985) Mică enciclopedie de statistică. Ed. Științifică și Enciclopedică, Bucureşti.
- [19] Iosifescu, M.; Grigorescu, Ş. (1990) Dependence with Complete Connections and Its Applications. Cambridge Univ. Press, Cambridge.
- [20] Karlin, S.; Taylor, H.M. (1975) A First Course in Stochastic Processes. Academic Press, New York.
- [21] Kolmogorov, A.N. (1956) Foundations of the Theory of Probability. Chelsea, New York.
- [22] Laplace, P.S. (1812) Théorie Analytique des Probabilités. Courcier, Paris.
- [23] Mihoc, Gh. (1954) Elemente de calculul probabilităților. Ed. Tehnică, Bucureşti.
- [24] De Moivre, A. (1967) The Doctrine of Chances or a Method of Calculating the Probabilities of Events in Play. Chelsea, New York.
- [25] Neveu, J. (1970) Bases mathématiques du calcul des Probabilités. Masson, Paris.
- [26] Neveu, J. (1974) Cours de Probabilités. École Polytechnique, Paris.
- [27] Onicescu, O. (1977) Probabilități și procese aleatoare. Ed. Științifică și Enciclopedică, Bucureşti.
- [28] Onicescu, O.; Mihoc, Gh. (1958) Lecții de statistică matematică. Ed. Tehnică, Bucureşti.
- [29] Papoulis, A. (1965) Probability. Random Variables and Stochastic Processes. McGraw-Hill, New York.
- [30] Pearson, E.S.; Kendall, M.G. (1970) Studies in the History of Statistics and Probability. Griffin, London.
- [31] Renyi, A. (1973) Dialog despre calculul probabilităților. Ed. Enciclopedică, Bucureşti.

- [32] Todhunter, I. (1865) A History of the Mathematical Theory of Probability from the Time of Pascal to that of Laplace. Macmillan, Cambridge & London.
- [33] Ventsel, H. (1973) Théorie des probabilités. Ed. Mir, Moscou.

Anexa 1

Valori ale funcției $F(x) = \frac{2}{\sqrt{2\pi}} \int_0^x e^{-\frac{u^2}{2}} du = 2\Phi(x) - 1$.

x	$F(x)$	x	$F(x)$	x	$F(x)$	x	$F(x)$
0,00	0,0000	0,60	0,4515	1,20	0,7699	1,80	0,9281
0,05	0,0000	0,65	0,4843	1,25	0,7887	1,85	0,9357
0,10	0,0797	0,70	0,5161	1,30	0,8064	1,90	0,9426
0,15	0,1192	0,75	0,5467	1,35	0,8230	2,00	0,9545
0,20	0,1585	0,80	0,5763	1,40	0,8385	2,25	0,9576
0,25	0,1974	0,85	0,6047	1,45	0,8529	2,50	0,9876
0,30	0,2358	0,90	0,6319	1,50	0,8664	2,75	0,9940
0,35	0,2737	0,95	0,6579	1,55	0,8789	3,00	0,99730
0,40	0,3108	1,00	0,6827	1,60	0,8904	3,50	0,99953
0,45	0,3473	1,05	0,7063	1,65	0,9011	4,00	0,99994
0,50	0,3829	1,10	0,7287	1,70	0,9109	4,417	$1 \cdot 10^{-5}$
0,55	0,4177	1,15	0,7499	1,75	0,9199	4,892	$1 \cdot 10^{-6}$

Anexa 2

Repartiția χ^2 . Valorile lui x_α în funcție de probabilitățile $P(\chi^2 \leq x_\alpha^2) = 1 - \alpha$ și numărul gradelor de libertate.

n $-\alpha$	0,05	0,1	0,5	1,0	2,5	5,0	10,0	20,0	30,0	40,0
1	0,000000 393	0,000000 157	0,00000 393	0,0000 157	0,0000C 982	0,00 393	0,158	0,0642	0,148	0,275
0	1	2	3	4	5	6	7	8	9	10
2	0,00100	0,00200	0,0100	0,201	0,0506	0,103	0,211	0,416	0,713	1,02
3	0,0153	0,00243	0,0171	0,115	0,216	0,352	0,548	1,00	1,42	1,87
4	0,639	0,0908	0,207	0,297	0,484	0,711	1,06	1,65	2,19	2,75
5	0,158	0,210	0,412	0,554	0,831	1,15	1,61	2,34	3,00	3,66
6	0,299	0,381	0,676	0,827	2,24	1,64	2,20	3,07	3,83	4,57
7	0,485	0,598	0,989	1,24	1,69	2,17	2,83	3,82	4,67	5,49
8	0,710	0,857	1,34	1,65	2,18	2,73	2,49	4,59	5,53	6,42
9	0,972	1,15	1,73	2,09	2,70	3,33	4,17	5,38	6,39	7,36
10	1,26	1,48	2,16	2,56	3,25	3,94	4,87	6,18	7,27	8,30
11	1,59	1,83	2,60	3,05	3,82	4,57	5,58	6,99	8,15	9,24
12	1,93	2,21	3,07	3,57	4,40	5,23	6,30	7,81	9,03	10,2
13	2,31	2,62	3,57	4,11	5,01	5,89	7,04	8,63	9,93	11,1
14	2,70	3,04	4,07	4,66	5,63	6,57	7,79	9,47	10,8	12,1
15	3,11	3,48	4,60	5,23	6,26	7,26	8,55	10,3	11,7	13,0
16	3,54	3,94	4,15	5,81	6,91	7,96	9,31	11,2	12,6	14,0
17	3,98	4,42	5,70	6,41	7,56	8,67	10,1	12,0	13,5	14,9
18	4,4	4,90	6,26	7,01	8,23	9,39	10,9	12,9	14,4	15,9
19	4,91	5,41	6,48	7,63	8,91	10,1	11,7	13,7	15,4	16,9
20	5,40	5,92	7,43	8,26	9,59	10,9	12,4	14,7	16,3	17,8
21	5,90	6,45	8,03	8,90	10,3	11,6	13,2	15,4	17,2	18,8
22	6,40	6,98	8,64	9,54	11,0	12,3	14,0	16,3	18,1	18,7
23	6,92	7,53	9,26	10,2	11,7	13,1	14,8	17,2	19,0	20,7
24	7,45	8,08	9,89	10,9	12,4	13,8	15,7	18,1	19,9	21,7
25	7,99	9,65	10,5	11,5	13,1	14,6	16,5	18,9	20,9	22,6
26	8,54	9,22	11,1	12,2	13,8	15,4	17,3	19,8	21,8	23,6
27	9,09	9,80	11,8	12,9	14,6	16,2	18,1	20,7	22,7	24,5
28	9,66	10,4	12,5	13,6	15,3	16,9	18,9	21,6	23,6	25,5
29	10,2	11,0	13,1	14,3	16,0	17,7	19,8	22,5	24,6	26,5
30	10,8	11,6	13,8	15,0	16,8	18,5	20,6	23,4	25,5	27,4
31	11,4	12,2	14,5	15,7	17,5	19,3	21,4	24,3	26,4	28,4
32	12,0	12,8	15,1	16,4	18,3	20,1	22,3	25,1	27,4	29,4
33	13,6	13,4	15,8	17,1	19,0	20,9	23,1	26,0	28,3	30,3
34	13,2	14,1	16,5	17,8	19,8	21,7	24,0	26,9	29,2	31,3
35	13,8	14,7	17,2	18,5	20,6	22,5	24,8	27,8	30,2	32,3
36	14,4	15,3	17,9	19,2	21,3	23,3	25,6	28,7	31,1	33,3
37	15,0	16,0	18,6	20,0	22,1	24,1	26,5	29,6	32,1	34,2
38	15,6	16,6	19,3	20,7	22,9	24,9	27,3	30,5	33,0	35,2
39	16,3	17,3	20,0	21,4	23,7	25,2	28,2	31,4	33,9	36,2
40	16,9	17,9	20,7	22,2	24,4	26,5	29,1	32,3	34,9	37,1
41	17,5	18,6	21,4	32,9	25,2	27,3	29,9	33,3	35,8	38,1
42	18,2	19,2	22,1	23,7	26,0	28,1	30,8	34,2	36,8	39,1
43	18,8	19,9	22,9	24,4	26,8	29,0	31,6	35,1	37,7	40,0
44	19,5	20,6	23,6	25,1	27,6	29,8	32,5	36,0	38,3	41,0
45	20,1	21,3	24,3	25,9	28,4	30,6	33,4	36,9	39,6	42,0
46	20,8	21,9	25,0	26,7	29,2	31,4	34,2	37,8	40,5	43,0
47	21,5	22,6	25,8	27,4	30,0	32,3	35,1	38,7	41,5	43,9
48	22,1	23,3	26,5	28,2	30,8	33,1	35,9	39,6	42,4	44,9
49	22,8	24,0	27,2	28,9	31,6	33,9	36,8	40,5	43,4	45,9
50	23,5	24,7	28,0	29,7	32,4	34,8	37,7	41,4	44,3	46,9

0	1	2	3	4	5	6	7	8	9	10
51	24,1	25,4	28,7	30,5	33,2	35,6	38,6	42,4	45,3	47,8
52	24,8	26,1	29,5	31,2	34,0	36,4	39,4	43,3	46,2	48,8
53	25,5	26,8	30,2	32,0	34,8	37,3	40,3	44,2	47,2	49,8
54	26,2	27,5	31,0	32,8	35,6	38,1	41,2	45,1	48,1	50,8
55	26,9	28,2	31,7	33,7	36,4	39,0	42,1	46,0	49,1	51,7
56	27,6	28,9	32,5	34,3	37,2	39,8	42,9	47,0	50,0	52,7
57	28,2	29,6	33,2	35,1	38,2	40,6	43,8	47,9	51,0	53,7
58	28,9	30,3	34,0	35,9	38,8	41,5	44,7	48,8	51,9	54,7
59	29,6	31,0	34,8	36,7	39,7	42,3	45,6	49,7	52,9	55,6
60	30,3	31,7	35,5	37,5	40,5	43,2	46,5	50,6	53,8	56,6
61	31,0	32,5	36,6	38,3	41,3	44,0	47,3	51,6	54,8	57,6
62	31,7	33,2	37,1	39,1	42,1	44,9	48,2	52,5	55,7	58,6
63	32,5	33,9	37,8	39,9	43,0	45,7	49,1	53,4	56,7	59,6
64	33,2	34,6	38,6	40,6	43,8	46,6	50,0	54,3	57,6	60,5
65	33,9	35,4	39,4	41,4	44,6	47,4	50,9	55,3	58,6	61,5
66	34,6	36,1	40,2	42,2	45,4	48,3	51,8	56,2	59,5	62,5
67	35,3	36,8	40,9	43,0	46,3	49,2	52,7	57,1	60,5	63,5
68	36,0	37,6	41,7	43,8	47,1	50,0	53,5	58,0	61,4	64,4
69	36,7	38,3	42,5	44,6	47,9	50,9	54,4	59,0	62,4	65,4
70	37,5	39,0	43,3	45,4	48,8	51,7	55,3	59,9	63,3	66,4
71	38,2	39,8	44,1	46,2	49,6	52,6	56,2	60,8	64,3	67,4
72	38,9	40,5	44,8	47,1	50,4	53,5	57,1	61,8	65,3	68,4
73	39,6	41,3	45,6	47,9	51,3	54,3	58,0	62,7	66,2	69,2
74	40,4	42,0	46,4	48,7	52,1	55,2	58,0	63,6	67,2	70,3
75	41,1	42,8	47,2	49,5	52,9	56,1	59,8	64,5	68,1	71,3
76	41,8	43,5	48,0	50,3	53,8	56,9	60,7	65,5	69,1	72,3
77	42,6	44,3	48,8	51,1	54,6	57,8	61,6	66,4	70,0	73,2
78	43,3	45,0	49,6	51,9	55,5	58,7	62,5	67,3	71,0	74,2
79	44,1	45,8	50,4	52,7	56,3	59,5	63,4	68,3	72,0	75,2
80	44,8	46,5	51,2	53,5	57,2	60,4	64,3	69,9	72,9	76,2
81	45,5	47,3	52,0	54,4	58,0	61,3	65,2	70,1	73,9	77,2
82	46,3	48,0	52,8	55,2	58,8	62,2	66,1	71,1	74,8	78,1
83	47,0	48,8	53,6	56,0	59,7	63,0	67,0	72,0	75,8	79,1
84	47,8	49,6	54,4	56,8	60,5	63,9	67,9	72,9	76,8	80,1
85	48,5	50,3	55,2	57,6	61,4	64,7	68,8	73,9	77,7	81,1
86	49,3	51,1	56,0	58,5	62,2	65,6	69,7	74,8	78,7	82,1
87	50,0	51,9	56,8	49,3	63,1	66,5	70,6	75,7	79,6	83,0
88	50,8	52,6	57,6	60,1	63,9	67,4	71,5	76,7	80,6	84,0
89	51,5	53,4	58,4	60,9	64,8	68,2	72,4	77,6	81,6	85,0
90	52,3	54,2	59,2	61,8	65,6	69,1	73,3	78,6	82,5	86,0
91	53,0	54,9	60,0	62,6	66,5	70,0	74,2	79,5	83,5	87,0
92	53,8	55,7	60,8	63,4	67,4	70,9	75,1	80,4	84,4	88,0
93	54,5	56,5	61,6	64,2	68,2	71,8	76,0	81,4	85,4	88,9
94	55,3	57,2	62,4	65,1	69,1	72,6	76,9	82,3	86,1	89,9
95	56,1	58,0	63,2	65,9	69,9	73,5	77,8	83,2	87,3	90,9
96	56,8	58,8	64,1	66,7	70,8	74,4	78,7	84,2	88,3	91,9
97	57,6	59,6	64,9	67,6	71,6	75,3	79,6	85,1	89,2	92,9
98	59,4	60,4	65,7	68,4	72,5	76,2	80,5	86,1	90,2	93,8
99	59,1	61,1	66,5	69,2	73,4	77,0	81,4	87,0	91,2	94,8
100	59,9	61,9	67,3	70,1	74,2	77,9	82,4	87,9	92,1	95,8

50,0	60,0	70,0	80,0	90,0	95,0	97,5	99,0	99,5	99,9	99,5	
0,455	0,708	1,07	1,64	2,71	3,84	5,02	6,63	7,88	01,8	12,1	1
0	1	2	3	4	5	6	7	8	9	10	11
1,39	1,83	2,41	3,22	4,61	5,99	7,38	9,21	10,6	13,8	15,2	2
2,37	2,95	3,67	4,64	6,25	7,81	9,35	11,3	12,8	16,3	17,7	3
3,36	4,04	4,88	5,99	7,78	9,49	11,1	13,3	14,9	18,5	20,2	4
4,35	5,13	6,06	7,29	9,24	11,1	12,8	15,1	16,7	20,5	22,1	5
5,35	6,21	7,23	8,56	10,6	12,6	14,4	16,8	18,5	22,5	24,1	6
6,35	7,28	8,38	9,80	12,0	14,1	16,0	18,5	20,3	24,3	26,0	7
7,34	8,35	9,52	11,0	13,4	15,5	17,5	20,1	22,0	26,1	27,9	8
8,34	9,41	10,7	12,2	14,7	16,9	19,0	21,7	23,6	27,9	29,7	9
9,34	10,5	11,8	13,4	16,0	18,3	20,5	23,2	25,2	29,6	31,4	10
10,3	11,5	12,9	14,6	17,3	19,7	21,9	24,7	26,8	31,3	33,3	11
11,3	12,6	14,0	15,8	18,5	21,0	23,3	26,2	28,3	32,9	34,0	12
12,3	13,6	15,1	17,0	19,8	22,4	24,7	27,7	29,8	34,5	36,5	13
13,3	14,7	16,2	18,2	21,1	23,7	26,1	29,1	31,3	36,1	38,1	14
14,3	15,7	17,3	19,3	22,3	25,0	27,5	30,6	32,8	37,7	39,7	15
15,3	16,8	18,4	30,5	23,5	26,3	28,8	32,0	34,3	39,3	41,3	16
16,3	17,8	19,5	21,6	24,8	27,6	30,2	33,4	35,7	40,8	42,9	17
17,3	18,9	20,6	22,8	26,0	38,9	31,5	34,8	37,8	42,4	44,4	18
18,3	19,9	21,7	23,9	27,2	30,4	32,9	36,2	38,6	43,8	46,0	19
19,3	21,0	22,8	25,0	28,4	31,4	34,2	37,6	40,0	45,3	47,5	20
20,3	22,0	23,9	26,2	29,6	32,7	35,5	38,9	41,4	46,8	49,0	21
21,3	23,0	24,9	27,3	30,8	33,9	36,9	40,3	42,8	48,3	50,5	22
22,3	24,1	26,0	28,4	32,0	35,0	38,1	41,6	44,2	49,7	52,0	23
23,3	25,1	27,1	29,6	33,2	36,4	39,4	43,0	45,6	51,2	53,5	24
24,3	26,1	28,2	30,7	34,4	37,7	40,6	44,3	46,9	52,6	54,9	25
25,3	27,2	29,2	31,8	35,6	38,9	41,9	45,6	48,3	54,4	56,4	26
26,3	28,2	30,3	32,9	36,7	40,1	43,2	47,0	49,6	55,5	57,9	27
27,3	29,2	31,4	34,0	37,9	41,3	44,5	48,3	51,0	56,9	59,3	28
28,3	30,3	32,5	35,1	39,1	42,6	45,7	49,6	52,3	58,3	60,7	29
29,3	31,3	33,5	36,3	40,3	43,8	47,0	50,9	53,7	59,7	62,2	30
30,3	32,3	34,6	37,4	41,4	45,0	48,2	52,2	55,0	61,1	63,6	31
31,3	33,4	35,7	38,5	42,6	46,2	49,5	53,5	56,3	62,5	65,0	32
32,3	34,4	36,7	39,6	43,7	47,4	50,7	54,8	57,6	63,9	66,4	33
33,3	35,4	37,8	40,7	44,9	48,6	52,0	56,1	59,0	65,2	67,8	34
34,6	36,5	38,9	41,8	46,1	49,8	53,2	57,3	60,3	66,6	69,2	35
35,3	37,5	39,9	42,9	47,2	51,0	54,4	58,6	61,6	68,0	70,6	36
36,3	38,5	41,0	44,0	48,4	52,2	55,7	59,9	62,9	69,3	72,0	37
37,3	39,6	42,0	45,1	49,5	53,4	56,9	61,2	64,2	70,7	73,4	38
38,3	40,6	43,1	46,2	50,7	54,6	58,1	62,4	65,5	72,1	74,7	39
39,3	41,6	44,2	47,3	51,8	55,8	59,3	63,7	66,8	73,4	76,1	40
40,3	42,7	45,7	48,4	52,9	56,9	60,6	65,0	68,1	74,7	77,5	41
41,3	43,7	46,3	49,5	54,1	58,1	61,8	66,2	69,3	76,1	78,8	42
42,3	44,7	47,3	50,5	55,2	59,3	63,0	67,5	70,6	77,4	80,2	43
43,3	45,7	48,4	51,6	56,4	60,5	64,2	68,7	71,9	78,7	81,5	44
44,3	46,8	49,5	52,7	57,5	61,7	65,4	70,0	73,2	80,1	82,9	45
45,3	47,8	50,5	53,8	58,6	62,8	66,6	71,2	74,7	81,4	84,2	46
46,3	48,8	51,6	54,9	59,8	64,0	67,8	72,4	75,7	82,7	85,6	47
47,3	49,8	52,6	56,0	60,9	65,2	69,0	73,7	77,0	84,0	86,9	58
48,3	50,9	53,7	57,1	62,0	66,3	70,2	74,9	78,2	85,4	88,2	49
49,3	51,9	54,7	58,2	63,2	67,5	71,4	76,2	79,5	86,7	89,6	50
50,3	52,9	55,8	59,2	64,3	68,7	72,6	77,4	80,7	88,0	90,9	51
51,3	53,9	56,8	60,3	65,4	69,8	73,8	78,6	82,0	89,3	92,2	52
52,3	55,0	57,9	61,4	66,5	71,0	75,0	79,8	83,3	90,6	93,5	53
53,3	56,0	58,9	62,5	67,7	72,2	76,2	81,1	84,5	91,9	94,8	54
54,3	57,0	60,0	63,6	68,8	73,3	77,4	82,3	85,7	93,2	96,2	55
55,3	58,0	61,0	64,7	69,9	74,5	78,6	73,5	87,0	94,5	97,5	56
56,3	59,1	62,1	65,7	71,0	75,3	79,8	84,7	88,2	95,8	98,8	57
57,3	60,1	63,1	66,8	72,2	76,8	80,9	86,0	89,5	97,0	101,1	58
58,3	61,1	64,2	67,9	73,3	77,9	82,1	87,2	90,7	98,3	101,4	59

50,0	60,0	70,0	80,0	90,0	95,0	97,5	99,0	99,5	99,9	99,5	
0,455	0,708	1,07	1,64	2,71	3,84	5,02	6,63	7,88	01,8	12,1	1
0	1	2	3	4	5	6	7	8	9	10	11
59,3	62,1	65,2	69,0	74,4	79,1	83,3	88,4	92,0	99,6	102,7	60
60,3	63,2	66,3	70,0	75,5	80,2	84,5	89,6	93,2	100,9	104,0	61
61,3	64,2	67,3	71,1	76,6	81,4	85,7	90,8	94,4	102,2	105,3	62
62,3	65,2	68,4	72,2	77,7	82,5	86,8	92,0	95,6	103,4	106,6	63
63,3	66,2	69,4	73,3	78,9	83,7	88,0	93,2	96,9	104,7	107,9	64
64,3	67,2	70,5	74,4	80,0	84,8	89,2	94,4	98,1	106,0	109,2	65
65,3	68,3	71,5	75,4	81,1	86,0	90,3	95,6	99,3	107,3	110,5	66
66,3	69,3	72,6	76,5	82,2	87,1	91,5	96,8	100,6	108,5	111,7	67
67,3	70,3	73,6	77,6	83,3	88,3	92,7	98,0	101,8	109,8	113,0	68
68,3	71,3	74,6	78,6	84,4	89,4	93,9	99,2	103,0	111,1	114,3	69
69,3	72,4	75,7	79,7	85,5	90,5	95,0	100,4	104,2	112,3	115,6	70
70,3	73,4	76,7	80,8	96,6	91,7	96,2	101,6	105,4	113,6	116,9	71
71,3	74,4	77,8	81,9	87,7	92,8	97,4	102,8	106,6	114,8	118,4	72
72,3	75,4	78,8	82,9	88,8	93,9	98,5	104,0	107,9	116,1	119,4	73
73,3	76,4	79,9	84,0	90,5	95,1	99,7	105,2	109,1	117,3	120,7	74
74,3	77,5	80,9	85,1	91,1	96,2	100,8	106,4	110,3	118,6	121,9	75
75,3	78,5	82,0	86,1	92,2	97,4	102,0	107,6	111,5	119,9	123,2	76
76,3	79,5	83,0	87,2	93,3	98,5	103,2	108,8	112,7	121,1	124,5	77
77,3	80,5	84,0	88,3	94,4	99,6	104,3	110,0	113,9	122,3	125,7	78
78,3	81,5	85,1	89,3	95,5	100,7	105,5	111,1	115,1	123,6	127,0	79
79,3	82,6	86,1	90,4	96,6	101,9	106,6	112,3	116,3	124,8	128,3	80
80,3	83,6	87,2	91,5	97,7	103,0	107,8	113,5	117,5	126,1	129,5	81
81,3	84,6	88,2	92,5	98,8	104,1	108,9	114,7	118,7	127,3	130,8	82
82,3	85,6	89,2	93,6	99,9	105,3	110,1	115,9	119,9	128,6	132,0	83
83,0	86,6	90,3	94,7	101,0	106,4	111,2	117,1	121,1	129,6	133,3	84
84,3	87,7	91,3	95,7	102,1	107,5	112,4	118,2	122,3	131,5	134,5	85
85,3	88,7	92,4	96,8	103,2	108,6	113,5	119,4	123,5	132,3	135,8	86
86,3	89,7	93,4	97,9	104,3	109,8	114,7	120,6	124,7	133,5	137,0	87
87,3	90,7	94,4	98,9	105,4	110,9	115,8	121,8	125,9	134,7	138,3	88
88,3	91,7	95,5	100,0	106,5	112,0	117,0	122,0	127,1	136,0	139,5	89
89,3	92,8	96,5	101,1	107,6	113,1	118,1	124,0	128,3	137,2	140,8	90
90,3	93,8	97,6	102,1	108,7	114,3	119,3	125,3	129,5	138,4	142,0	91
91,3	94,8	98,6	103,2	109,8	115,4	120,4	126,3	130,7	139,7	143,3	92
92,3	95,8	99,6	104,2	110,9	116,5	121,6	127,6	131,9	140,9	144,5	93
93,3	96,8	100,7	105,3	111,9	117,6	122,7	128,8	133,1	142,1	145,8	94
94,3	97,9	101,7	106,4	113,0	118,8	123,9	130,0	134,2	143,3	147,0	95
95,3	98,9	102,8	107,4	114,1	119,8	125,0	131,1	135,4	144,6	148,2	96
96,3	99,9	103,8	108,5	115,2	121,0	126,1	132,3	136,6	145,8	149,5	97
97,3	100,9	104,8	109,5	116,3	122,1	127,3	133,5	137,8	147,0	150,7	98
98,3	101,9	105,9	110,6	117,4	123,2	128,4	134,6	139,0	148,2	151,9	99
99,3	102,9	106,9	111,7	118,5	124,3	129,4	135,8	140,2	149,4	153,2	100

Anexa 3

Repartiția Snedecor. Valorile lui F_α în funcție de probabilitatea $P(F \leq F_\alpha) =$

0,995 și de numărul gradelor de libertate n_1 și n_2 .

$n_2 \backslash n_1$	1	2	3	4	5	6	7	8	9	10	11	12
1	162	200	216	225	231	234	237	239	241	242	243	244
2	198	199	199	199	199	199	199	199	199	199	199	199
3	55,6	49,8	47,5	46,2	45,4	44,8	44,4	44,1	43,9	43,7	43,5	43,4
4	31,3	36,2	24,3	23,2	22,5	22,0	21,6	21,4	21,1	21,0	20,8	20,7
5	22,8	18,3	16,5	15,6	14,9	14,5	14,2	14,0	13,8	13,6	13,5	13,4
6	18,6	14,5	12,9	12,0	11,5	11,1	10,8	10,6	10,4	10,2	10,1	10,0
7	16,2	12,4	10,9	10,0	9,52	9,16	8,89	8,68	8,51	8,38	8,28	8,18
8	14,7	11,0	10,60	8,81	8,30	7,95	7,69	7,50	7,34	7,21	7,10	7,01
9	13,6	10,1	8,72	7,96	7,47	7,13	6,88	6,69	6,54	6,42	6,31	6,23
10	12,8	9,43	8,80	7,34	6,87	6,54	6,30	6,12	5,97	5,85	5,75	5,66
11	12,2	8,91	7,60	6,88	6,42	6,10	5,86	5,68	5,54	5,40	5,32	5,24
12	11,8	8,51	7,23	5,52	6,07	5,76	5,52	5,35	5,20	5,09	4,99	4,91
13	11,4	8,19	6,93	6,23	5,79	5,48	5,25	5,08	4,94	4,82	4,72	4,64
14	11,1	7,92	6,68	6,00	5,56	5,26	5,03	4,86	4,72	4,60	4,51	4,43
15	10,8	7,70	6,48	5,80	5,37	5,07	4,85	4,67	4,54	4,42	4,33	4,50
16	10,6	7,50	6,03	5,64	5,21	4,91	4,69	4,52	4,38	4,27	4,18	4,12
17	10,4	7,35	6,16	5,50	5,07	4,78	4,56	4,39	4,25	4,14	4,05	3,97
18	10,2	7,21	6,03	5,37	4,96	4,66	4,44	4,28	4,14	4,03	3,94	3,86
19	10,1	7,09	5,92	5,27	4,85	4,56	4,34	4,18	4,04	3,93	3,84	3,76
20	9,94	6,99	5,82	5,17	4,76	4,47	4,26	4,09	3,96	3,85	3,76	3,68
21	9,83	6,89	5,73	5,09	4,68	4,39	4,18	4,01	3,88	3,67	3,68	3,60
22	9,73	6,81	5,65	5,02	4,61	4,32	4,11	3,94	3,81	3,70	3,61	3,54
23	9,63	6,73	5,58	4,95	4,54	4,26	4,05	3,88	3,75	3,64	3,55	3,47
24	9,55	6,66	5,52	4,89	4,49	4,20	3,99	3,83	3,69	3,59	3,50	3,42
25	9,48	6,60	5,46	4,84	4,43	4,15	3,84	3,78	3,64	3,51	3,45	3,37
26	9,41	6,54	5,41	4,79	4,38	4,10	3,89	3,73	3,60	3,49	3,40	3,23
27	9,34	6,49	5,36	4,74	4,34	4,06	3,85	3,69	3,56	3,45	3,36	3,28
28	9,28	6,44	5,32	4,70	4,30	4,02	3,81	3,65	3,52	3,41	3,32	3,25
29	9,23	6,40	5,28	4,66	4,26	3,98	3,77	3,61	3,48	3,38	3,29	3,21
30	9,18	6,35	5,24	4,62	4,23	3,95	3,74	3,58	3,45	3,34	3,25	3,18
32	9,09	6,28	5,17	4,56	4,17	3,89	3,68	3,52	3,39	3,29	3,20	3,12
34	9,01	6,22	5,11	4,50	4,11	3,84	3,63	3,47	3,34	3,24	3,15	3,07
36	8,94	6,16	5,06	4,46	4,06	3,79	3,58	3,42	3,30	3,19	3,10	3,03
38	8,88	6,11	5,02	4,41	4,02	3,75	3,54	3,39	3,25	3,15	3,06	2,99
40	8,83	6,07	4,98	4,37	3,99	3,71	3,51	3,35	3,22	3,12	3,03	2,95
42	8,78	6,03	4,94	4,34	3,95	3,68	3,48	3,32	3,19	3,09	3,00	2,92
44	8,74	5,99	4,91	4,31	3,92	3,65	3,45	3,29	3,16	3,06	2,97	2,89
46	8,70	5,96	4,88	4,28	3,90	3,62	3,42	3,26	3,14	3,03	2,94	2,87
48	8,66	5,93	4,85	4,25	3,87	3,60	3,40	3,24	3,11	3,01	2,92	2,85
50	8,63	5,90	4,83	4,23	3,85	3,58	3,38	3,22	3,09	2,99	2,90	2,82
55	8,55	5,84	4,77	4,18	3,88	3,53	3,33	3,17	3,05	2,94	2,85	2,78
60	8,49	5,80	4,73	4,14	3,76	3,49	3,29	3,13	3,01	2,90	2,82	2,74
65	8,44	5,75	4,68	4,11	3,73	3,46	3,26	3,10	2,98	2,87	2,79	2,71
70	8,40	5,72	4,65	4,08	3,70	3,43	3,23	3,08	2,95	2,85	2,76	2,68
80	8,33	5,67	4,61	4,03	3,65	3,39	3,19	3,03	2,91	2,80	2,72	2,64
90	8,28	5,62	4,57	3,99	3,62	3,35	3,15	3,00	2,87	2,77	2,68	2,61
100	8,24	5,59	4,54	3,96	3,59	3,33	3,13	2,97	2,85	2,74	2,66	2,58
125	8,17	5,53	4,49	3,91	3,54	3,28	3,08	2,93	2,80	2,70	2,61	2,54
150	8,12	5,49	4,45	3,88	3,51	3,25	3,05	2,89	2,77	2,67	2,58	2,51
200	8,06	5,44	4,41	3,84	3,47	3,21	3,01	2,85	2,73	2,63	2,54	2,47
300	8,00	5,39	4,37	3,80	3,43	3,17	2,97	2,81	2,69	2,59	2,51	2,43
500	7,95	5,26	4,33	3,76	3,40	3,14	2,92	2,97	2,66	2,56	2,48	2,40
1000	7,92	5,33	4,31	3,74	3,337	3,11	2,92	2,77	2,64	2,54	2,45	2,38
∞	7,88	5,30	4,28	3,72	3,35	3,09	2,90	2,74	2,62	2,52	2,43	2,36

$n_1 \backslash n_2$	13	14	15	16	17	18	19	20	22	24	26	28
1	245	246	246	247	247	248	248	248	249	249	250	250
2	199	199	199	199	199	199	199	199	199	199	199	199
3	43,3	43,2	43,1	43,02	42,9	42,9	42,8	42,80	42,7	42,6	42,6	42,5
4	20,6	20,5	20,4	20,4	20,3	20,3	20,2	20,2	20,1	20,0	20,0	19,9
5	13,3	13,2	13,1	13,1	13,0	13,0	12,9	12,9	12,8	12,8	12,7	12,7
6	9,95	9,88	9,81	9,76	9,71	9,66	9,62	9,59	9,53	9,47	9,43	9,37
7	8,10	8,03	5,97	7,93	7,87	7,83	7,79	7,75	7,69	7,64	7,60	7,59
8	6,94	6,87	6,81	6,76	6,72	6,68	6,64	6,61	6,55	6,50	4,46	6,43
9	6,15	6,09	6,03	5,98	5,94	5,90	5,86	5,83	5,78	5,73	5,69	5,65
10	5,59	5,53	5,47	5,42	5,38	5,34	5,30	5,27	5,22	5,17	5,13	5,10
11	5,16	5,10	5,05	5,00	4,96	4,92	4,89	4,86	4,80	4,76	4,72	4,68
12	4,84	4,77	4,72	4,67	4,63	4,59	4,56	5,53	4,48	4,43	4,39	4,36
13	4,57	4,51	4,46	4,41	4,37	4,33	4,30	4,27	4,22	4,17	4,13	4,10
14	4,36	4,30	4,25	4,20	4,16	4,12	4,09	4,06	4,01	3,96	3,92	3,89
15	4,18	4,12	4,07	4,02	3,98	3,95	3,91	3,88	3,83	3,79	3,75	3,72
16	4,03	3,97	3,92	3,87	3,83	3,80	3,76	3,73	3,68	3,64	3,60	3,57
17	3,90	3,84	3,79	3,75	3,71	3,67	3,64	3,61	3,56	3,51	3,47	3,44
18	3,79	3,73	3,68	3,64	3,60	3,56	3,53	3,50	3,45	3,40	3,36	3,33
19	3,70	3,64	3,59	3,54	3,50	3,46	3,43	3,40	3,35	3,31	3,27	3,24
20	3,61	3,55	3,50	3,46	3,42	3,38	3,35	3,32	3,27	3,22	3,18	3,15
21	3,54	3,48	3,43	3,38	3,34	3,31	3,27	3,24	3,19	3,15	3,11	3,08
22	3,47	3,41	3,36	3,31	3,27	3,24	3,20	3,18	3,12	3,08	3,04	3,01
23	3,41	3,35	3,30	3,25	3,21	3,18	3,15	3,12	3,06	3,02	2,98	2,95
24	3,35	3,30	3,25	3,20	3,16	3,12	3,09	3,06	3,01	2,97	2,93	2,90
25	3,30	3,25	3,20	3,15	3,11	3,08	3,04	3,01	2,96	2,92	2,88	2,85
26	3,26	3,20	3,15	3,11	3,07	3,03	3,00	2,97	2,92	2,87	2,83	2,80
27	3,22	3,16	3,11	3,07	3,03	2,99	2,96	2,93	2,88	2,83	2,79	2,76
28	3,18	3,12	3,07	3,03	2,99	2,95	2,92	2,98	2,84	2,79	2,76	2,72
29	3,15	3,09	3,04	2,99	2,95	2,92	2,88	2,86	2,80	2,76	2,72	2,69
30	3,11	3,06	3,01	2,96	2,92	2,89	2,85	2,82	2,77	2,73	2,69	2,66
32	3,06	3,00	2,95	2,90	2,86	2,83	2,80	2,77	2,71	2,67	2,63	2,60
34	3,01	2,95	2,90	2,85	2,81	2,78	2,75	2,72	2,66	2,62	2,58	2,55
36	2,96	2,90	2,85	2,81	2,77	2,73	2,70	2,60	2,62	2,58	2,54	2,50
38	2,92	2,87	2,82	2,77	2,73	2,70	2,60	2,63	2,58	2,54	2,50	2,47
40	2,89	2,83	2,78	2,74	2,70	2,66	2,63	2,60	2,55	2,50	2,46	2,43
42	2,87	2,80	2,75	2,71	2,67	2,63	2,60	2,50	2,52	2,47	2,43	2,40
44	2,83	2,77	2,72	2,68	2,64	2,60	2,57	2,54	2,49	2,44	2,40	2,37
46	2,80	2,75	2,70	2,65	2,61	2,58	2,54	2,51	2,46	2,42	2,38	2,34
48	2,78	2,72	2,67	2,63	2,59	2,55	2,52	2,49	2,44	2,39	2,36	2,32
50	2,76	2,70	2,65	2,61	2,57	2,53	2,50	2,47	2,42	2,37	2,33	2,30
55	2,71	2,66	2,61	2,56	2,52	2,49	2,45	2,42	2,37	2,33	2,29	2,26
60	2,68	2,62	2,57	2	2,49	2,45	2,42	2,39	2,33	2,29	2,25	2,22
65	2,65	2,59	2,54	2,49	2,45	2,42	2,39	2,36	2,30	2,26	2,22	2,19
70	2,62	2,56	2,51	2,47	2,43	2,39	2,36	2,33	2,28	2,23	2,19	2,16
80	2,58	2,52	2,47	2,43	2,39	2,35	2,32	2,29	2,23	2,19	2,15	2,11
90	2,54	2,49	2,44	2,39	2,35	2,32	2,28	2,25	2,20	2,15	2,12	2,08
100	2,52	2,46	2,41	2,37	2,33	2,29	2,26	2,23	2,17	2,13	2,09	2,05
125	2,47	2,42	2,37	2,32	2,28	2,24	2,21	2,18	2,13	2,08	2,04	2,01
150	2,44	2,38	2,33	2,29	2,25	2,21	2,18	2,15	2,10	2,05	2,01	1,98
200	2,402	2,35	2,30	2,25	2,21	2,18	2,14	2,11	2,06	2,01	1,97	1,94
300	2,37	2,31	2,26	2,21	2,17	2,14	2,10	2,07	2,02	1,97	1,93	1,90
500	2,34	2,28	2,23	2,19	2,14	2,11	2,07	2,04	1,99	1,94	1,90	1,87
1000	2,32	2,26	2,21	2,16	2,12	2,09	2,05	2,02	1,97	1,92	1,88	1,84
∞	2,29	2,24	2,19	2,14	2,10	2,06	2,03	2,00	1,95	1,90	1,86	1,82

$n_1 \backslash n_2$	30	35	40	45	50	60	80	100	200	500	∞
1	250	251	251	252	252	253	253	253	254	254	255
2	199	199	199	199	199	199	199	199	200	200	200
3	42,5	42,4	42,3	42,3	42,2	42,1	42,1	42,0	41,9	41,9	41,8
4	19,9	19,8	19,8	19,7	19,7	19,6	19,15	19,5	19,4	19,4	19,3
5	12,7	12,6	12,5	12,5	12,5	12,5	12,3	12,3	21,2	12,2	12,1
6	9,36	9,29	9,24	9,20	9,17	9,12	9,06	9,03	8,95	8,91	1,88
7	7,53	7,47	7,42	7,38	7,35	9,31	7,25	7,22	7,15	7,10	7,08
8	6,40	6,33	6,29	6,25	6,22	6,18	6,12	6,09	6,02	5,98	5,95
9	5,62	5,56	5,52	5,48	5,45	5,41	5,36	5,32	5,26	5,21	5,19
10	5,07	5,01	4,97	4,93	4,90	4,86	4,80	4,77	4,71	4,67	4,64
11	4,65	4,60	4,55	4,52	4,49	4,44	4,39	4,36	4,29	4,25	4,23
12	4,33	4,27	4,23	4,19	4,17	4,12	4,07	4,04	3,97	3,93	3,90
13	4,07	4,01	3,97	3,94	3,91	3,87	3,81	3,78	3,71	3,67	3,65
14	3,86	3,80	3,76	3,73	3,70	3,66	3,60	3,57	3,50	3,46	3,44
15	3,69	3,63	3,58	3,55	3,52	3,48	3,43	3,39	3,33	3,29	3,26
16	3,54	3,48	3,44	3,40	3,373	3,33	3,28	3,25	3,18	3,14	3,11
17	3,41	3,35	3,31	3,28	,25	3,21	3,15	3,12	3,05	3,01	2,98
18	3,30	3,25	3,20	3,17	3,14	3,10	3,04	3,01	2,94	2,90	2,87
19	3,21	3,15	3,11	3,07	3,04	3,00	2,95	2,91	2,85	2,80	2,78
20	3,12	3,07	3,02	2,99	2,96	2,92	2,86	2,83	2,76	2,72	2,69
21	3,05	2,99	2,95	2,91	2,88	2,84	2,78	2,75	2,68	2,64	2,61
22	2,98	2,92	2,88	2,84	2,82	2,77	2,72	2,96	2,62	2,57	2,55
23	2,92	2,86	2,82	2,78	2,76	2,71	2,66	2,62	2,56	2,51	2,43
24	2,87	2,81	2,77	2,73	2,70	2,66	2,60	2,57	2,50	2,46	2,48
25	2,82	2,76	2,72	2,68	2,65	2,61	2,55	2,52	2,45	2,41	2,33
26	2,77	2,72	2,67	2,64	2,61	2,56	2,51	2,47	2,40	2,36	2,38
27	2,73	2,67	2,63	2,59	2,57	2,52	2,47	2,43	2,36	2,32	2,29
28	2,69	2,64	2,59	2,56	2,53	2,48	2,43	2,39	2,32	2,28	2,25
29	2,66	2,60	2,56	2,52	2,49	2,45	2,39	2,36	2,28	2,24	2,21
30	2,63	2,57	2,52	2,49	2,46	2,42	2,36	2,32	2,25	2,21	2,18
32	2,57	2,51	2,47	2,43	2,40	2,36	2,30	2,26	2,19	2,15	2,11
34	2,52	2,46	2,42	2,38	2,35	2,30	2,25	2,21	2,14	2,09	2,06
36	2,48	2,42	2,37	2,33	2,30	2,26	2,20	2,17	2,09	2,04	2,01
38	2,44	2,38	2,33	2,29	2,27	2,22	2,16	2,12	2,05	2,00	1,97
40	2,40	2,34	2,30	2,26	2,23	2,18	2,12	2,09	2,01	1,96	1,93
42	2,37	2,31	2,26	2,23	2,20	2,15	2,09	2,06	1,98	1,93	1,90
44	2,34	2,28	2,24	2,20	2,17	2,12	2,06	2,03	1,95	1,90	1,87
46	2,32	2,26	2,21	2,17	2,14	2,10	2,04	2,00	1,92	1,87	1,84
48	2,29	2,23	2,19	2,15	2,12	2,07	2,01	1,97	1,89	1,84	1,81
50	2,27	2,21	2,16	2,13	2,10	2,05	1,99	1,95	1,87	1,82	1,79
55	2,23	2,16	2,12	2,08	2,05	2,00	1,94	1,90	1,82	1,77	1,73
60	2,19	2,13	2,08	2,04	2,01	1,96	1,90	1,86	1,78	1,73	1,69
65	2,16	2,09	2,05	2,01	1,98	1,93	1,87	1,83	1,74	1,69	1,65
70	2,13	2,07	2,02	1,98	1,95	1,90	1,84	1,80	1,71	1,66	1,62
80	2,08	2,02	1,97	1,93	1,90	1,85	1,79	1,75	1,66	1,60	1,56
90	2,05	1,99	1,94	1,90	1,87	1,82	1,75	1,71	1,62	1,56	1,52
100	2,02	1,96	1,91	1,87	1,84	1,79	1,72	1,68	1,59	1,53	1,49
125	1,98	1,91	1,86	1,82	1,79	1,74	1,67	1,63	1,53	1,47	1,42
150	1,94	1,88	1,83	1,79	1,76	1,70	1,63	1,59	1,49	1,42	1,37
200	1,91	1,84	1,79	1,75	1,71	1,66	1,59	1,54	1,44	1,37	1,31
300	1,87	1,80	1,75	1,71	1,67	1,61	1,54	1,50	1,39	1,31	1,25
500	1,84	1,77	1,72	1,67	1,64	1,58	1,51	1,46	1,35	1,26	1,18
1000	1,81	1,75	1,69	1,65	1,61	1,56	1,48	1,43	1,31	1,22	1,13
∞	1,79	1,72	1,67	1,63	1,59	1,53	1,45	1,40	1,28	1,17	1,00

Anexa 4

Repartiția Student. Valorile lui t_α în funcție de probabilitatea $P(t \leq t_\alpha) = 1 - \alpha$ și numărul gradelor de libertate n .

$1-\alpha$	60	70	80	90	95	97,5	99	99,5	99,9	99,95
n										
1	0,325	0,727	1,376	3,078	6,314	12,71	31,82	63,66	381,3	636,6
2	0,289	0,617	1,061	1,886	2,920	4,303	6,965	9,925	22,23	31,60
3	0,277	0,584	0,978	1,638	2,353	3,182	4,541	5,841	10,22	12,91
4	0,271	0,569	0,941	1,533	2,132	2,776	3,747	4,604	7,173	8,610
5	0,267	0,559	0,920	1,476	2,015	2,571	3,365	4,032	5,893	6,859
6	0,265	0,553	0,906	1,440	1,943	2,447	3,143	3,707	5,208	5,959
7	0,263	0,549	0,896	1,415	1,895	2,365	2,998	3,499	4,785	5,405
8	0,262	0,546	0,889	1,397	1,860	2,306	2,896	3,355	4,501	5,041
9	0,261	0,543	0,883	1,383	1,833	2,262	2,821	3,250	4,297	4,781
10	0,260	0,542	0,879	1,372	1,812	2,228	2,764	3,169	4,144	4,587
11	0,260	0,540	0,876	1,363	1,796	2,201	2,718	3,106	4,025	4,437
12	0,259	0,539	0,873	1,356	1,782	2,179	2,681	3,055	3,930	4,318
13	0,259	0,538	0,870	1,350	1,771	2,160	2,650	3,012	3,853	4,221
14	0,258	0,537	0,868	1,345	1,761	2,145	2,624	2,977	3,787	4,140
15	0,258	0,536	0,866	1,341	1,753	2,131	2,602	2,947	3,733	4,073
16	0,258	0,535	0,865	1,337	1,746	2,120	2,583	2,921	3,686	4,015
17	0,257	0,534	0,863	1,333	1,740	2,110	2,567	2,898	3,646	3,965
18	0,257	0,534	0,862	1,330	1,734	2,101	2,552	2,878	3,611	3,922
19	0,257	0,535	0,861	1,328	1,729	2,093	2,539	2,861	3,579	3,833
20	0,257	0,533	0,860	1,325	1,725	2,089	2,528	2,845	3,552	3,850
21	0,257	0,532	0,859	1,323	1,721	2,080	2,518	2,831	3,527	3,819
22	0,256	0,532	0,858	1,321	1,717	2,074	2,508	2,819	3,505	3,792
23	0,256	0,532	0,858	1,319	1,714	2,069	2,500	2,807	3,485	3,767
24	0,256	0,531	0,857	1,318	1,711	2,064	2,492	2,797	3,467	3,745
25	0,256	0,531	0,856	1,316	1,708	2,060	2,485	2,787	3,450	3,725
26	0,256	0,531	0,856	1,315	1,706	2,056	2,479	2,779	3,435	3,707
27	0,256	0,531	0,855	1,314	1,703	2,052	2,473	2,71	3,421	3,690
28	0,256	0,530	0,855	1,313	1,701	2,048	2,467	2,763	3,408	3,674
29	0,256	0,530	0,854	1,311	1,699	2,045	2,462	2,756	3,396	3,659
30	0,256	0,530	0,854	1,310	1,697	2,042	2,457	2,750	3,385	3,646
40	0,255	0,529	0,851	1,303	1,684	2,021	2,423	2,704	3,307	3,551
50	0,255	0,528	0,849	1,298	1,676	2,009	2,403	2,678	3,362	3,495
60	0,254	0,527	0,848	1,296	1,671	2,000	2,390	2,660	3,232	3,460
80	0,254	0,527	0,846	1,292	1,664	1,990	2,374	2,639	3,195	3,415
100	0,254	0,526	0,845	1,290	1,660	1,984	2,365	2,626	3,0174	3,389
200	0,254	0,525	0,843	1,286	1,653	1,972	2,345	2,601	3,131	3,339
500	0,253	0,525	0,842	1,283	1,648	1,965	2,334	2,586	3,106	3,310
∞	0,253	0,524	0,842	1,282	1,645	1,960	2,326	2,576	3,090	3,291

Anexa 5

Testul Kolmogorov - Smirnov. Valorile lui $\frac{\lambda}{\sqrt{n}}$.

<i>n</i>	Prag de seminificație α				
	0,20	0,15	0,10	0,05	0,01
1	0,900	0,925	0,950	0,975	0,995
2	0,684	0,726	0,776	0,842	0,929
3	0,565	0,597	0,442	0,708	0,828
4	0,494	0,525	0,564	0,624	0,733
5	0,446	0,474	0,510	0,565	0,669
6	0,410	0,436	0,470	0,521	0,618
7	0,381	0,405	0,438	0,486	0,577
8	0,358	0,381	0,411	0,457	0,543
9	0,339	0,360	0,388	0,432	0,514
10	0,322	0,342	0,368	0,410	0,490
11	0,307	0,326	0,532	0,391	0,468
12	0,295	0,313	0,338	0,375	0,450
13	0,284	0,302	0,325	0,361	0,433
14	0,274	0,292	0,314	0,349	0,413
15	0,266	0,283	0,304	0,338	0,404
16	0,258	0,274	0,295	0,328	0,392
17	0,250	0,266	0,286	0,318	0,381
18	0,244	0,259	0,278	0,309	0,371
19	0,237	0,252	0,272	0,301	0,363
20	0,231	0,246	0,264	0,294	0,356
25	0,21	0,22	0,24	0,27	0,32
30	0,19	0,20	0,22	0,24	0,29
35	1,18	0,19	0,21	0,23	0,27
	1,07	1,14	1,22	1,36	1,63
> 35	<i>n</i>	<i>n</i>	<i>n</i>	<i>n</i>	<i>n</i>

Index

A

abatere medie pătratică 44

acul lui Buffon 35

aditivitate 7, 42

aditivitate tare 7

aproximare stocastică 166

axiomele lui Kolmogorov 7

C

caracteristică statistică 171

câmp de evenimente 3

câmp de evenimente finit generat 3

câmp de probabilitate 7

câturi partiiale 167

clasă (de stări) 132

clopotul lui Gauss 78

coeficient de corelație 45

continuitate monoton secvențială 8, 9, 43

convergență aproape sigură 95

convergență în medie 95

convergență în probabilitate 95

convergență în repartiție (slabă) 95

corelație (covarianță) 44

cuantilă 44

cumulanți (semi-invarianți) 64, 65

D

date de observație 172

densitate de probabilitate (de repartiție) 27

densitate spectrală 119

dependență cu legături complete

163

dependență markoviană 129

derivabilitate în medie de ordinul al doilea 117

derivată a două generalizată 118

diferența a două evenimente 2

diferența simetrică a două evenimente 2

dispersie (vezi varianță) 44

dispersie de sondaj 177

dreaptă de regresie 191

durata medie a primei treceri 133

E

ecuațiile lui Kolmogorov directe 145

ecuațiile lui Kolmogorov inverse 144

ecuația Markov de reinnoire 160

ecuații normale 192

ecuația de regresie 191

ecuația de reinnoire 124

eroare de genul întai 186

eroare de genul al doilea 186

eroare de observare 191

estimator absolut corect 182

estimator consistent 182

estimator eficient 182

estimator nedeplasat 182

eșantion statistic 172

eveniment 1

eveniment anterior unui moment nealeator 130

eveniment anterior unui timp de

- oprire 131
- eveniment complementar (opus) 2
- eveniment elementar 1
- eveniment elementar favorabil 2
- eveniment imposibil 2
- eveniment posterior unui moment nealeator 130
- eveniment posterior unui timp de oprire 131
- eveniment sigur 2
- evenimente dependente 17
- evenimente disjuncte 2
- evenimente disjuncte în ansamblul lor 3
- evenimente echivalente 2
- evenimente egal probabile 8
- evenimente incompatibile 2
- evenimente independente 17
- experiment aleator 1
- experiment Bernoulli 19
- experiment determinist, 1, 174
- F**
- fenomen de masă 171
- finit-aditivitate 8
- finit-subaditivitate 7
- flux poissonian 146
- formula lui Bayes 18
- formula lui Bernoulli 20
- formula Brodén-Borel-Levý 168
- formula de înmulțire a probabilităților 18
- formula lui Poincaré 7
- formula probabilității totale 18
- fracții continue 166
- frecvență absolută 172
- frecvență cumulată 172
- frecvență medie a primei trei ceri 133
- frecvență relativă 8, 172
- frontiere absorbante 134
- funcție aleatoare 115
- funcție aleatoare de ordinul al doilea 115
- funcție caracteristică 56
- funcție de corelație 116
- funcție empirică de repartiție 175
- funcție de estimare (estimator) 181
- funcție de frecvență 26
- funcție generatoare de momente 55
- funcție generatoare de probabilitate 54
- funcția lui Laplace 79
- funcție de masă 157
- funcție matricială de trecere 144
- funcție de reinnoire 123
- funcție de repartitie 26
- funcție de repartitie n -dimensională 28
- funcție de variabile aleatoare 36
- funcție de verosimilitate 182
- H**
- histograma frecvențelor relative 173
- I**
- indicatorul unui eveniment 4
- inegalitatea lui Cebîșev 44
- integrabilitate în medie de ordinul al doilea 118
- intersecție de evenimente 2
- intervale de grupare 172
- ipoteză alternativă 185
- ipoteză compusă 185
- ipoteză nulă 185
- ipoteză parametrică (neparametrică) 185
- ipoteză simplă 185
- ipoteză statistică 185
- L**
- lanț 115
- lanț Markov asociat 165

- lanț Markov finit 129
- lanț Markov omogen 130
- lanț Markov absorbant 134
- lanț Markov aperiodic 132
- lanț Markov ergodic 133
- lanț Markov ireductibil 132
- lanț Markov regulat 133
- lanț Markov recurrent 132
- legea logaritmului iterat 113
- legea slabă a numerelor mari 104
- legea tare a numerelor mari 104
- limita inferioară a unui sir de evenimente 4
- limita superioară a unui sir de evenimente 4
- lipsă de memorie 83
- M
 - matrice de corelație (covarianță) 45
 - matrice fundamentală 134
 - matricea intensităților de treccere 144
 - matricea probabilităților de treccere 130
 - matrice semi-Markov 157
 - matrice stocastică 130
 - medie (vezi valoare medie) 42
 - mediană 44
 - mers la întâmplare 134, 136
 - metoda verosimilității maxime 182
 - modelul Bernoulli 136
 - modelul Ehrenfest 137
 - modelul Greenwood 139
 - modul unei variabile aleatoare 44
 - moment 42
 - moment absolut 42
 - moment centrat 43
 - moment centrat absolut 43
 - moment centrat empiric (de sondaj) 177
- O
 - moment empiric (de sondaj) 176
 - multime boreliană 4
 - multimea parametrilor unui proces 115
- P
 - observare statistică 171
 - ogiva frecvențelor cumulate 174
- p
 - paradoxul lui Bertrand 15
 - pardonul lui Cardano 43
 - partiție 3
 - perioadă 132
 - poligonul frecvențelor relative 173
 - poligonul frecvențelor cumulate 174
 - populație statistică 171
 - prag de semnificație 186
 - probabilitate 7
 - probabilitate aposteriori 18
 - probabilitate a priori 18
 - probabilitate condiționată 17
 - probabilitate de trecere 164
 - probabilitate inițială 133
 - probabilități absolute 145
 - problema cutiei de chibrituri a lui Banach 70
 - problema întâlnirii 14
 - problema ruinei jucătorului 136
 - problema zilei de naștere 13
 - proces Feller-Arley 151
 - proces gaussian 121
 - proces $J - X$ 159
 - proces Markov omogen în timp 143
 - proces Markov de reînnoire 159
 - proces de moarte 148
 - proces de naștere 147
 - proces de naștere și de moarte 149
 - proces Poisson 145
 - proces de ramificare 140
 - proces semi-Markov 159

- proces stocastic 115
- proces stocastic cu parametru continuu 115
- proces stocastic cu parametru discret (vezi lanț) 115
- proces Yule-Furry 148
- propoziția Borel-Cantelli 19
- proprietate de clasă 132
- proprietate Markov 129, 143
- proprietate tare Markov 131
- puncte de concentrație 25
- puterea testului 186
- R
 - regiune de acceptare 186
 - regiune critică 186
 - regresie 181
 - regresie curbilinie 191, 194
 - regresie liniară 191
 - regresie polinomială 194
 - relația Chapman-Kolmogorov 130, 144
 - repartiție Beta 87
 - repartiție binomială 67
 - repartiția binomială generalizată a lui Poisson 67
 - repartiția binomial negativă 70
 - repartiție Cauchy 90
 - repartiție complet specificată 181
 - repartiție comună 42
 - repartiție condiționată 46
 - repartiție exponențială 83
 - repartiție Erlang 87
 - repartiție F (Snedecor-Fisher) 90
 - repartiție Gamma 86
 - repartiție geometrică 71
 - repartiție hipergeometrică 73
 - repartiție χ^2 (hi pătrat) 87
 - repartiție inițială 130, 145
 - repartiție lognormală 81
 - repartiție multimodală 44
 - repartiție multinomială 92
- S
 - selecție 172
 - σ -aditivitate 7
 - σ -algebră 3
 - σ -algebră Borel 4
 - σ -algebră generată 3
 - σ -câmp de evenimente 3
 - σ -subaditivitate 9
 - sistem aleator cu legături complete 164
 - sistem complet de evenimente 3
 - sondaj 172
 - spațiu de probabilitate 7
 - spațiu evenimentelor elementare (eșantioanelor, de selecție) 1
 - spațiu stărilor 115, 129
 - stare absorbantă 132
 - stare accesibilă 131
 - stare aperiodică 132
 - stare esențială 132

- stare neesențială 132
 - stare nerecurentă (tranzientă) 132
 - stare nereflexivă 131
 - stare nulă 133
 - stare periodică 132
 - stare pozitivă 133
 - stare recurentă 132
 - stare reflexivă 131
 - statistică 176
 - statistica Bose-Einstein 12
 - statistica Fermi-Dirac 12
 - statistica Maxwell-Boltzmann 12
 - staționaritate în sens larg 117, 119
 - staționaritate în sens restrâns 117
 - șir de reînnoire 123
 - șir slab stabil 104
 - șir tare stabil 104
- T**
- teorema lui Bernoulli 104
 - teorema lui Blackwell 124
 - teorema lui Borel 105
 - teorema lui Cebîșev 105, 111
 - teorema elementară a reînnoirii 125
 - teorema lui Glivenko 175
 - teorema Hardy-Littlewood 114
 - teorema lui Hausdorff 114
 - teorema lui Helly 97
 - teorema lui Hincin 104, 114
 - teorema integrală De Moivre-Laplace 103
 - teorema de inversiune 56
 - teorema lui Kolmogorov 107, 176
 - teorema lui Liapunov 111
 - teorema limită centrală 110
 - teorema limită locală De Moivre-Laplace 67
 - teorema Lindeberg-Feller 110
 - teorema lui Markov 106

- teorema Rao-Cramer-Fréchet 182
 - teoreme de continuitate 97
 - test de concordanță 186
 - testul F (Snedecor-Fisher) 187
 - testul χ^2 (hi pătrat) 187
 - testul Kolmogorov-Smirnov 189
 - test de semnificație 186
 - test statistic 186
 - testul *t* (Student) 188
 - timp mediu de recurență 133
 - timp de oprire 131
 - traекторia unui proces 115
- U**
- urna lui Bernoulli 20
 - urna lui Pólya 22
- V**
- valoare medie 41
 - valoare medie condiționată 45
 - valori tipice de sondaj (selecție) 176
 - variabilă aleatoare 25
 - variabilă aleatoare continuă 26
 - variabilă aleatoare discretă 25
 - variabilă aleatoare etajată (simplă) 26
 - variabilă aleatoare *P*-integrabilă 42
 - variabilă aleatoare *P*-sumabilă 42
 - variabile aleatoare bernoulliene 48
 - variabile aleatoare independente 29
 - variabile aleatoare necorelate 45
 - variabile de sondaj (selecție) 175
 - varianță 44
 - varianță de sondaj 177
 - vector aleator 25
 - volumul unei populații 171
- Z**
- zgomot alb 119

**LUCRĂRI RECOMANDATE DE
EDITURA TEHNICĂ**

CODUL LUCRĂRII	TITLUL LUCRĂRII	AUTORUL	PREȚUL
12101	Analiza numerică	T. Vladislav, I. Raşa	35 000
11487	Chimie anorganică	F. Shriver	160 000
11854	Genetica medicală. Progrese recente	D.Ştefănescu	36 000
12036	Sarcomul Kaposi	A. Mihail	46 500
12125	Birotică	D. Somnea	42 000
12008	Inițiere în Java Script și tehnologii Netscape	D. Somnea	60 000
12097	Proiectarea asistată de calculator a modulelor CADSTAR	P. Svasta	78 000
11871	Proiectarea interfețelor utilizator	A. Cooper	50 000
11969	Construcții civile	D. Mariusciac	56 000
12111	Rezistența materialelor și elemente de teoria elasticității	I. Mincă ș.a.	44 000
12054	ISO 9000 - pentru servicii	W. Brakhahn	36 000
11757	Manualul calității	B. Froman	25 000
11762	O nouă orientare în managementul calității	H. Mitonneau	25 000
12141	Succesul întreprinderilor mici și mijlocii	L. Rașcă	21 000
11610	Miturile vechilor civilizații mexicane	A. Morretta	56 000
11322	Mituri indiene	A. Morretta	50 000
11980	Identități europene (ediție. bilingvă)	S. Păun	150 000
11956	Istoria logicii, vol.4	A. Dumitriu	55 000
1903	Comunicații mobile terestre	N. Coțanis I. Marghescu	70 000

CODUL LUCRĂRII	TITLUL LUCRĂRII	AUTORUL	PREȚUL
12069	Dicționarul specialiștilor-Who's who în știință și tehnica		45 000
1959	Tehnologia materialelor	G. Amza	80 000
12020	Dicționar tehnic ilustrat francez-român	E. Ștefănuță	150 000
12061	Introducere în electrochimia organică	E. Ungureanu	40 000

Sediul Central:

R - 71341, Bucureşti, Piaţa Presei Libere nr.1

Tel: 224.36.66

222.66.30

222.83.48

222.18.84

Fax: 224.21.64

Depozit. Librărie. Anticariat

R - 70702, Bucureşti, str. Oteteleşanu nr.1

Tel: 313.98 43; Tel/Fax: 315.88.66; 310.39.53

Cont (în lei): 30361801 BCR Sect. I, Bucureşti, România

Lucrarea își propune să prezinte într-o manieră cât mai naturală și accesibilă, însă fără a renunța la rigoarea matematică, noțiuni și rezultate fundamentale din teoria probabilităților și statistica matematică, ramuri ale matematicii solicitate în cele mai variate domenii.

Teoria probabilităților se bazează pe un aparat matematic foarte dezvoltat, bogat în concepte și rezultate care permit descrierea și investigarea fenomenelor aleatoare.

Statistica matematică reprezintă mulțimea procedeelor prin care se studiază proprietăți, caracteristici ale populațiilor numeroase, folosind instrumentul matematic în analiză și interpretare.

Teoria probabilităților constituie aparatul matematic de bază al statisticii matematice, permîțând construirea logică a științei respective, și, în același timp, pune în evidență intervalul de aplicare a ei.

Universitaria