

BDaaS, indexarea si interogarea lor cu LLM

Conf.dr. Cristian KEVORCHIAN

Facultatea de Matematică și Informatică
Universitatea din Bucuresti

Azure SQL Database (PaaS)

Azure SQL Database (PaaS)

- Este o bază de date relațională complet gestionată, scalabilă, cu suport pentru T-SQL, AI integrat și securitate avansată.
- **Avantaje PaaS:**
 - Fără administrare de infrastructură
 - Scalare automată și backup-uri integrate
 - Integrare cu Azure AD, Key Vault, Defender for SQL

Interogarea sistemelor de date relationale cu LLM

1. Funcționalitățile unui LLM

- Modelele de limbaj mari (LLM) învață **relații semantice dintre tokeni**(fragmente de text), nu între structuri relaționale precum tabele.
- Ele operează pe baza unor **probabilități și context lingvistic**, nu pe constrângeri de integritate sau chei primare.

2. Funcționalitățile unei baze de date relaționale

- Învață (sau mai corect, **definește**) **relații între entități strict definite** prin schema SQL.
- Relațiile sunt **deterministe**, bazate pe reguli și tipuri de date, nu pe semantică.

3. Apropie unui Data Warehouse de un LLM

- Dacă adăugăm **embedding-uri ca dimensiuni semantice** peste datele relaționale (prin vector stores sau semantic layers), putem face interogări în limbaj natural.
- Practic, un Data Warehouse devine „interogabil ca un LLM”:
 - **Răspunde la întrebări în limbaj natural.**
 - **Folosește embeddings pentru context.**
 - **Generează SQL automat (Text-to-SQL)** pentru extragerea datelor.

	Bază de date relațională (RDBMS)	Data Warehouse (DW)	LLM (Large Language Model)
Obiectiv principal	Gestionarea tranzacțiilor și interogărilor structurate (OLTP)	Analiză istorică, agregare și raportare (OLAP)	Înțelegerea și generarea limbajului natural, extragerea cunoștințelor semantice
Tip de interogare	SQL explicit (SELECT, JOIN, WHERE etc.)	SQL + OLAP (CUBE, ROLLUP, agregări multidimensionale)	Limbaj natural, întrebări conversaționale (NLQ – Natural Language Query)
Model de date	Relațional (tabele, chei primare/străine)	Dimensional (stea, fulg de zăpadă)	Distribuțional și probabilistic (tokens, embeddings, vectori semantici)
Forma răspunsului	Set de date exact, structurat	Agregări și rapoarte sintetice	Text narativ, explicații, predicții sau inferențe
Precizie	Deterministă (rezultate exacte)	Deterministă și agregată	Probabilistică (rezultate estimate semantic)
Context temporal	Date curente, tranzacționale	Istoric și evolutiv (time-series, snapshots)	Context conversațional și contextualizare dinamică
Volum de date gestionat	De obicei limitat la operațiuni curente	Foarte mare (petabytes, date istorice)	Extrem de mare, dar prin inferență, nu stocare factuală
Mecanism de acces	Interfață SQL / API / aplicație	ETL + SQL / BI tools (Power BI, Tableau)	Prompt în limbaj natural / API conversațional
Nivel de abstractizare	Logic (coloane, tabele)	Semantic parțial (dimensiuni, ierarhii)	Semantic complet (relații latente între concepte)
Suport pentru ambiguitate	Niciunul – interogările trebuie să fie precise	Minim – structuri predefinite	Ridicat – poate interpreta întrebări incomplete sau vagi
Timp de răspuns	Milisecunde	Secunde până la minute (în funcție de volum)	Milisecunde până la secunde (în funcție de context și prompt)
Scop arhitectural	Procesare tranzacțională (OLTP)	Analiză și raportare strategică (OLAP)	Raționament, conversație și generare cognitivă
Tehnologii reprezentative	MySQL, PostgreSQL, SQL Server, Oracle	Snowflake, BigQuery, Azure Synapse, Databricks	GPT, Claude, Gemini, LLaMA, Mistral
Evoluție tipică	De la date operaționale → către DW prin ETL	De la consolidare → către inteligență augmentată	De la inferență conversațională → către integrare cu surse factual-verificabile
Interfață umană	Limbaj formal (SQL)	BI Dashboard / Query Designer	Limbaj natural, conversație
Tip de cunoaștere	Declarativă și structurală	Analitică și istorică	Semantică, contextuală și inferențială
Control și verificabilitate	Totală și auditabilă	Înaltă, prin metadata și lineage	Limitată, necesită verificare fact-based
Integrare cu alte sisteme	API, ODBC, JDBC	ETL, ELT, Data Lake	LangChain, RAG, Vector DB, Knowledge Graphs

RAG și Azure AI Search

- **RAG (Retrieval-Augmented Generation)** este o tehnică care combină căutarea tradițională cu inteligența artificială generativă. În loc ca modelul să se rezume doar la ce a fost antrenat, el caută informații relevante din surse externe (documente, **baze de date** etc.) și le folosește pentru a genera răspunsuri mai precise și mai documentate.
- Contextualizare **RAG** înseamnă:
 - Fragmentarea inteligentă a conținutului (nu doar pe baza dimensiunii, ci și a sensului)
 - Căutare semantică prin vectori (pentru relevanță mai profundă)
 - Filtrare și clasificare a rezultatelor pentru a reduce informațiile inutile

Motorul AI Search


- **Azure AI Search** este motorul care:
- Indexează documente din surse precum PDF-uri, site-uri web, baze de date
- Le fragmentează și le transformă în vectori semantici
- Permite căutări hibride (cuvinte cheie + vectori)
- Oferă rezultate relevante pe care le trimite către modelul AI pentru generare
- Răspunsurile generate sunt:
 - **Mai exacte**, fiind bazate pe datele conexe
 - **Mai eficiente**, folosind mai puțini tokeni (costuri mai mici)
 - **Mai sigure**, deoarece se bazează pe conținut validat

Baze de date vectoriale

- Bazele de date vectoriale (Pinecone, Weaviate, FAISS) sunt optimizate pentru:
- **Stocarea vectorilor:** reprezentări matematice ale textelor, imaginilor sau altor date nestructurate
- **Căutare prin similaritate:** găsirea celor mai apropiate vectori față de o interogare
- **Performanță ridicată:** pentru regăsire rapidă în seturi mari de date
- Sunt ideale pentru aplicații AI care folosesc încorporări (embeddings) și modele de limbaj mari (LLMs).


Baze de date vectoriale vs Azure AI Search

	Bază de date vectorială	Azure AI Search
Căutare vectorială	DA	DA
Căutare hibridă (vector + text)	NU	DA
Filtrare pe câmpuri și metadate	Limitat	DA
Indexare semantică integrată	Nu	DA
Vectorizare automată	Nu	DA
Integrare cu Azure OpenAI	NU	DA
Securitate și scalabilitate Azure	NU	DA



ite
pe

	Rol	Tehnologie recomandată
Stocare date	Baza de date relațională	Azure SQL Database
Indexare + Search	Recuperare semantică + vectori	Azure AI Search
Embedding	Transformare text în vectori	OpenAI ada-002/003
LLM	Generare Text-to-SQL + RAG	GPT-4 / GPT-4 Turbo
Execuție query	Interogare SQL	Azure SQL Database



■ RAG ■ Text-to-SQL

DEV4RAG

- **Semantic Kernel** este ideal pentru aplicații scalabile, cu logică complexă și integrare în ecosistemul Azure.
- **Foundry Local** este perfect pentru prototipuri, aplicații private sau medii fără conectivitate. Suportul multi-limbaj permite dezvoltatorilor să aleagă mediul potrivit: Python pentru AI, C# pentru enterprise, JS pentru web, REST pentru orice limbaj.

	Azure Semantic Kernel	Azure Foundry Local	LangChain	LlamaIndex
Tip Executie	Cloud și local	Exclusiv local	Cloud și local	Cloud și local
Funcții RAG	Pluginuri, căutare semantică, agentic RAG	Indexare locală, generare pe device	Chain-uri personalizabile, integrare cu vector search	Indexare, fragmentare, căutare și augmentare context
Control date	Mediu controlat, dar conectat la cloud	Complet local, fără expunere externă	Flexibil, control parțial în funcție de setup	Control complet asupra datelor și fluxului
Cazuri de utilizare	Aplicații enterprise, agenți autonomi	Chatboturi private, prototipuri offline	Aplicații AI scalabile, tool-uri personalizate	Aplicații RAG document-centric, QA pe date proprii
Limbaje suportate	Python, C#, Java, JS/TS, Go, REST	Python, C#, JS/TS, REST	Python, JS/TS	Python

DEMO

- **Azure SQL Database** – sursa de date
- **Azure AI Search** indexează datele și creează embedding-uri cu modelul:

OpenAI (text-embedding-ada-003)

- Embedding-urile sunt stocate în **Document Store / Vector DB** (Azure Cognitive Search + vector search).
- **RAG pipeline** recuperează contextul relevant și îl trimite către **GPT-4** pentru:
- **Text-to-SQL** (generare query SQL pe baza schemei).
- Răspunsuri augmentate bazate pe context.