

Azure AI Foundry

Conf.dr. Cristian KEVORCHIAN

Facultatea de Matematică și Informatica

Taxonomia Platformelor IA

1. Palantir AIP = AI Operating System

- **Categoria:** End-to-end AI Platform cu ontologie nativă
- **Destinație:** Human+AI operations, semantic reasoning, enterprise workflows
- **Poziționare:** "Operating System for AI in enterprises"

2. Azure AI Foundry = Unified AI Platform (PaaS)

- **Categoria:** AI Application Platform / AI PaaS
- **Destinație:** Developer experience, rapid deployment, agentic applications
- **Poziționare:** "Platform-as-a-Service for enterprise AI development"


3. AWS Bedrock = Foundation Model Service

- **Categoria:** Model-as-a-Service (MaaS) / LLM Marketplace
- **Destinație:** Model access, inference, fine-tuning
- **Poziționare:** "Easiest way to build and scale generative AI applications"

4. Google Vertex AI = MLOps + AI Platform

- **Categoria:** End-to-end ML Platform
- **Destinație:** ML lifecycle, model training/deployment, AutoML
- **Poziționare:** "Unified AI platform for building, deploying, and scaling ML models"

Clasificarea pe nivele de abstractizare



Azure AI Foundry – Definiție

Azure AI Foundry este platforma unificată(Microsoft) pentru **dezvoltarea, personalizarea, orchestrarea și guvernarea aplicațiilor AI și agenților inteligenți**. Este concepută pentru a accelera adoptarea AI la nivel enterprise, oferind un set complet de instrumente și servicii integrate în ecosistemul Azure.

- **Platformă end-to-end** pentru construcția și gestionarea soluțiilor AI.
- **Catalog extins de modele** (OpenAI, Microsoft Research, Hugging Face, Meta etc.).
- **Framework-uri pentru agenți**, instrumente de observabilitate, guvernare și integrare cu date enterprise.
- **Scalabilitate enterprise**: RBAC, politici, monitorizare, cost management, integrare cu Microsoft Defender și Entra ID.

Tabel comparative pentru scenario de utilizare

Platformă	Input	Platforma oferă	Use Case
AWS Bedrock	Specificații, orchestrare, data layer	• Modele (Claude, Llama, Titan, etc.) • Inference API • Fine-tuning basic	Doresc să accesez LLM-uri fără să construiesc infrastructură
Google Vertex AI	Business logic, date	• ML training & deployment • AutoML capabilities • Model registry • (+ Gemini models recent)	Doresc să dezvolt modele ML custom + să folosesc LLM-uri
Azure AI Foundry	Data sources, business requirements	• Agent framework • Model catalog (1800+) • Prompt Flow orchestration • Deployment & monitoring	Doresc să construiesc aplicații AI agentic rapid
Palantir AIP	Raw enterprise data, legacy systems	• Ontology Engine (semantic layer) • Data integration & lineage • AI agents aware of ontology • End-to-end governance	Doresc un OS complet pentru operațiuni AI enterprise cu semantic reasoning

	Microsoft Foundry	AWS Bedrock	Google Vertex AI
Scop principal	MF unificată pentru aplicații și agenți AI, cu fluxuri enterprise și guvernare	Serviciu gestionat pentru aplicații generative AI, cu flexibilitate multi-model	Platformă completă ML cu AutoML, antrenare personalizată și capabilități generative
Acces la modele	Peste 11.000 modele (fundamentale, raționale, multimodale, specifice industriei)	Modele de la Anthropic, Cohere, Meta, Stability AI, Mistral, Amazon Titan printr-un singur API	Modelele Google (Gemini , PaLM, Imagen) + AutoML + modele personalizate
LLM-uri (exemple)	GPT-4.1 (prin serviciile Azure OpenAI), Phi, onnx/olmo open-weights , modele partener & open (acces prin catalogul Foundry, cu rutare inteligentă de modele)	Anthropic Claude (Claude 3/Haiku/Opus), Cohere Command, Meta Llama, Mistral, Amazon Titan Text (diverse versiuni), plus embedding-uri dedicate	Gemini 1.5/2.5 (Pro, Flash), PaLM (modele anterioare), modele pentru cod/texte; embedding-uri Vertex
Personalizare	Fine-tuning, distilare, antrenare supravegheată, orchestrare multi-agent	Fine-tuning, RAG, caching/optimizare prompt, customization privată pe date proprii	AutoML, pipeline-uri personalizate, reantrenare completă, tuning avansat
Integrare	Azure (M365, GitHub, Power Platform, Fabric), IDE-uri și SDK-uri unificate	AWS (S3, Lambda, SageMaker, CloudWatch, IAM)	Google Cloud (BigQuery, Dataflow, GCS, Workbench)
Guvernare & Securitate	Conformitate enterprise, audit, monitorizare, izolare rețea	IAM, criptare, guardrails Bedrock, responsabilitate AI	Conformitate integrată, explainability, monitorizare
Model de tarificare	Bazat pe utilizare (compute, stocare, API); estimare via Azure Pricing Calculator	Pay-as-you-go per apel API; mod batch mai ieftin; opțiuni de throughput rezervat	Pay-as-you-go; tarife orare pentru training/inferință; token-based pentru GenAI
Nivel gratuit	Trial Azure + 200 USD credite	AWS free tier pentru Bedrock; fără angajamente inițiale	300 USD credite Google Cloud + free tier Vertex AI
Caz ideal de utilizare	Organizații din ecosistemul Microsoft ce necesită guvernare și agenți	Organizații orientate AWS ce caută multi-model și scalare serverless	Organizații axate pe analiză de date și AutoML
Puncte forte	Guvernare, interoperabilitate, integrare enterprise	Diversitate modele, simplitate serverless, ecosistem AWS	Ușurință AutoML, GenAI avansat, integrare analitică
Puncte slabe	Complexitate tarifară; dependent de serviciile Azure	Complexitate tarifară; utilitate maximă în ecosistem AWS	Cost ridicat pentru joburi lungi; curbă de învățare pentru pipeline-uri

Cloud vs Local

	Foundry Cloud (Azure)	Foundry Local (On-Premises)
Hosting	În cloud-ul Microsoft Azure	Pe infrastructura proprie sau cloud privat
Scalabilitate	Elastică, acces la GPU-uri H100/A100, autoscaling	Limitată la resursele hardware disponibile
Modele AI disponibile	GPT-4 Turbo, Phi-3, LLaMA, multimodale, acces la catalog extins	Modele open-source (LLaMA, Phi-3), fără acces la GPT-4 Turbo
Fine-Tuning & RAG	Suport complet pentru fine-tuning, LoRA, PEFT, RAG integrat cu Azure AI Search	Necesită configurare manuală pentru RAG și fine-tuning
Integrare cu ecosistem	Conectare nativă la Microsoft Fabric, Synapse, OneLake, Data Lake Gen2	Integrare limitată, necesită dezvoltare custom
Guvernare & Observabilitate	Politici RBAC, monitorizare, Responsible AI, Content Safety integrate	Responsabilitatea revine organizației
Securitate & Conformitate	Conformitate globală (ISO, GDPR, SOC), patch-uri automate	Control total asupra datelor, dar patch-uri manuale
Costuri	Pay-as-you-go sau rezervare de capacitate	Investiție inițială mare (hardware, GPU, storage)
Performanță	Optimizată pentru workload-uri mari, latență redusă	Depinde de infrastructura locală
Actualizări	Automate, acces la ultimele modele și funcționalități	Manuale, depind de echipa internă
Cazuri ideale	Enterprise global, proiecte AI avansate, integrare rapidă	Organizații cu cerințe stricte de data sovereignty, medii izolate

	Microsoft Foundry Resource	AI Hub Resources
Status	Recomandat (platforma actuală)	Moștenire (legacy)
Scop principal	Platformă unificată pentru aplicații AI enterprise (Generative AI, RAG, agenți, Prompt Flow)	Grupare proiecte AI bazate pe Azure ML
Integrare cu Azure OpenAI	Nativă, completă	Parțială
Prompt Flow	Suport complet, orchestration avansată	Suport limitat
Guvernanță și RBAC	Centralizat, enterprise-grade	Depinde de Azure ML Workspace
Networking securizat	Private Endpoints, Managed VNet	Configurabil prin AML
Resurse incluse	Compute, Storage, Key Vault, AI Search, OpenAI	Storage, Key Vault, AML compute
Suport modele open-source	Da (prin Foundry + extensii)	Da (nativ AML)
Scenarii recomandate	Aplicații Generative AI, RAG, agenți AI, enterprise deployment	Proiecte vechi, fluxuri AML, modele open-source
Viitor	Platforma standard Azure AI	Migrare către Foundry


Foundry Resource = viitorul platformei Azure AI, recomandat pentru toate proiectele noi.

AI Hub = util doar pentru moștenire sau cazuri speciale.


Microsoft Foundry Resources vs AI HUB Resources



MICROSOFT FOUNDRY RESOURCE



AI HUB RESOURCES



AGENȚI IA

Un **Agent IA** (Intelligent Agent) în contextul Azure Foundry este o entitate software autonomă sau semi-autonomă care utilizează modele de limbaj (LLM) și alte componente pentru a **percepe, raționa și acționa** în medii digitale, respectând obiectivele definite de utilizator.

Generalizând un Agent IA este un **orchestrator inteligent** care combină:

- **Capabilități cognitive** (înțelegerea limbajului natural, generarea de răspunsuri).
- **Capabilități operaționale** (executarea de acțiuni prin Tools).
- **Memorie** (pentru context și învățare incrementală).
- **Politici** (pentru controlul comportamentului și securitate).

Atribute ale Agentilor IA

1. Identitate

- Nume, rol, scop.
- Ex.: „Agent pentru suport clienți”, „Agent pentru analiză financiară”.

2. Skill-uri

- Task-uri pe care le poate rezolva (ex. sumarizare, căutare semantică, execuție cod).
- Implementate prin **Prompt Flow** sau modele LLM.

3. Tools

- API-uri REST, funcții custom, conectori Azure.
- Permite interacțiuni cu sisteme externe.

4. Memorie

- **Conversatională**: păstrează contextul dialogului.
- **Persistentă**: salvează informații relevante pentru sesiuni viitoare.

5. Politici și Guvernanță

- Controlul accesului la date.
- Respectarea regulilor de securitate și conformitate.

6. Autonomie

- Nivelul de decizie: complet autonom sau asistat de om.


7. Interfață

- Modalitatea de comunicare: chat, API, integrare în aplicații.

Project în Azure AI Foundry care conține doi agenți:

1. **Agent A** (GPT-4o) – primește inputul utilizatorului și decide dacă trebuie să consulte Agent B.
2. **Agent B** (GPT-4) – furnizează date suplimentare (ex. căutare, reasoning).

Fluxul este orchestrat în interiorul proiectului, iar fiecare agent poate fi conectat la un model diferit.



Azure AI Foundry

Tabel Comparativ

cu componentele principale ale unui agent în **Azure AI Foundry** și opțiunile disponibile

	Rol	Opțiuni disponibile în Azure AI Foundry
Modelul	Motorul LLM care generează răspunsuri	GPT-4o, GPT-4, GPT-3.5, modele fine-tuned, parametri ajustabili (temperature, max tokens, top_p)
Instrucțiuni	Prompt-ul de bază care definește rolul și comportamentul agentului	Text personalizat, reguli, ton (formal, prietenos, academic), context persistent
Tools	Funcții externe pe care agentul le poate invoca	API-uri REST, funcții custom, conectori Azure (ex. Cognitive Search, Dataverse), noduri în Prompt Flow
Knowledge	Surse de date pentru RAG (Retrieval-Augmented Generation)	Documente încărcate (PDF, TXT), colecții indexate în Azure AI Search, baze de date externe
Memorie	Capacitatea de a reține contextul conversației	Conversational Memory (implicit), Persistent Memory (opțional, via Cosmos DB sau Semantic Kernel)
GuardRails	Mecanisme de siguranță și conformitate	Content Filtering, Prompt Injection Defense, Policy Enforcement, Safety System integrat

Funcții externe pe care agentul le poate invoca

În contextul **Azure Foundry**, aceste funcții externe sunt instrumente pe care agentul IA le poate folosi pentru a interacționa cu sisteme și servicii din afara modelului LLM. Principalele categorii sunt:

1. API-uri REST

Exemple: Servicii interne (ERP, CRM). Servicii externe (traducere, analiză sentiment). Invocare: prin noduri REST în Prompt Flow sau direct din orchestratorul agentului.

2. Funcții Custom

Exemple: Calcul matematic avansat (regresii, optimizări). Transformări pe date (normalizare, agregare). Implementare: Python, C#, integrate ca tool.

3. Conectori Azure

Exemple: Azure Cognitive Search – căutare semantică în documente. Dataverse – acces la date din Power Platform. Azure Storage / Data Lake – manipulare fișiere mari.

4. Servicii Cognitive

Exemple: Computer Vision – analiză imagini. Speech Service – recunoaștere și sinteză vocală. Language Service – analiză text, entități, traducere.

5. Noduri Prompt Flow

Tipuri: **LLM Node** – apel model **GPT/ Python Node** – execuție cod custom/**REST Node** – apel API extern/**Data Node** – citire/scriere din SQL, Blob.

Model Context Protocol

- MCP (Model Context Protocol) este un protocol open-source creat de Anthropic care permite aplicațiilor AI să se conecteze în siguranță la diverse surse de date și instrumente.
- MCP stabilește o arhitectură client-server care permite modelelor lingvistice să acceseze resurse externe într-un mod standardizat. În loc ca fiecare aplicație să implementeze conexiuni personalizate pentru fiecare sursă de date, MCP oferă o interfață unificată.

Componentele principale sunt:

- **MCP Servers** - expun resurse specifice (baze de date, API-uri, sisteme de fișiere) printr-un protocol standardizat. De exemplu, un server MCP pentru Google Drive permite accesul la documentele tale.
- **MCP Clients** - aplicații AI (precum Claude) care se conectează la aceste servere pentru a accesa datele și instrumentele necesare.
- **Protocol standardizat** - definește cum clientul și serverul comunică, incluzând autentificarea, interogările și răspunsurile.

Surse de date pentru RAG

1. Documente încărcate (PDF, TXT)

- Se procesează prin **chunking** și **embedding** (ex. text-embedding-ada-002 sau Phi-3 embeddings).
- Vectorii rezultați se stochează în **Azure AI Search** sau în **Foundry IQ** pentru RAG.

2. Colecții indexate în Azure AI Search

- Indexurile existente pot fi extinse cu embeddings din documentele noi.
- Se aplică **hybrid search** (keyword + semantic search) pentru relevanță maximă.

3. Baze de date externe

- Conectare prin **MCP (Model Context Protocol)**, API-uri sau conectori nativi.
- Datele pot fi:
 - **Interogate direct** (live query).
 - **Încărcate parțial** și transformate în embeddings pentru integrare semantică.

4. Unificarea surselor

- Toate sursele sunt convertite în **spațiu vectorial comun**.
- Azure AI Foundry folosește **orchestrare multi-agent** → agenții pot accesa:
 - **Indecși din AI Search**.
 - **Embeddings din documente încărcate**.
 - **Rezultate din baze externe**.

Persistența Contextului Conversației

Foundry Agent Service oferă un memory store gestionat pentru continuitatea conversațiilor, Ignite 2025 a introdus integrarea simplificată prin portal și API-uri unificate, iar Playground folosește un Thread ID pentru menținerea contextului conversațional

a) Foundry Agent Service Memory

- Este un memory store gestionat (în preview) care păstrează preferințe, rezumate de chat și istoricul relevant.
- Asigură continuitate pe termen lung între sesiuni, dispozitive și fluxuri de lucru.
- Accesul la memorie este segmentat prin scope (de exemplu, per utilizator sau per agent), ceea ce permite izolarea și controlul.

b) Playground și Thread ID

- Playground-ul Foundry folosește un Thread ID unic pentru fiecare conversație sau sesiune de lucru.
- Acest identificator asigură continuitatea și izolarea contextului între interacțiuni.
- În implementările cu webhook, este obligatoriu să fie reutilizat același Thread ID, altfel istoricul conversației se pierde.

