

Model Context Protocol

unifică surse multiple de date și le disponibilizează agenților AI

Conf. Dr. Cristian KEVORCHIAN
Facultatea de Matematică și Informatică
Universitatea din București

Problema „ $N \times M$ ” în Integrarea AI

Problema provine din necesitatea de a conecta direct N sisteme (de exemplu, modele AI) la M sisteme (de exemplu, aplicații, baze de date, API-uri).

- Modelul Punct-la-Punct: Fără un strat de abstractizare sau un standard comun, fiecare conexiune trebuie construită și menținută individual.
- Formula Complexității: Numărul total de integrări (sau conectori specializați) necesare este dat de formula: $I = N \times M$

Implicații cheie

- **Complexitate Exponențială:** Pe măsură ce numărul de modele AI (**N**) și aplicații (**M**) crește, numărul de integrări crește **multiplicativ**, ducând rapid la o rețea de conexiuni greu de gestionat.
De exemplu, 5 modele AI și 5 aplicații necesită $5 \times 5 = 25$ de integrări.
- **Costuri Ridicate de Dezvoltare:** Fiecare conector este un efort unic de dezvoltare, testare și implementare.
- **Dificultăți de Mentenanță:** Modificările aduse unui singur sistem (e.g., actualizarea unui API) pot necesita modificarea multor conectori, deoarece aceștia sunt cuplați strâns (***tightly coupled***).
- **Timp îndelungat de Lansare (Time-to-Market):** Implementarea de noi modele sau aplicații devine lentă din cauza necesității de a construi noi conectori pentru fiecare integrare.
- **Vulnerabilități:** O rețea mare de integrări punct-la-punct crește suprafața de atac și face auditul de securitate mult mai complex

Soluții pentru Interoperabilitate

Soluția la problema „N x M” este introducerea unui standard sau a unui strat de abstractizare care să acționeze ca un intermediar comun sau o platformă centralizată.



În loc de N x M conexiuni, se urmărește:

1. N integrări de la modelele AI la stratul comun.
2. M integrări de la aplicații la stratul comun. Numărul total de integrări scade la $I = N + M$, simplificând drastic ecosistemul.

Standarde și Soluții

- **Platforme de Integrare (Middleware):** Utilizarea **Enterprise Service Bus (ESB)**, **Integration Platforms as a Service (iPaaS)** sau **API Gateways** pentru a gestiona traficul și transformările de date centralizat.
- **Standardizarea Datelor:** Adoptarea unui **format de date comun** (e.g., un format de date neutru/canonic) pentru toate mesajele schimbate în ecosistem.
- **API-uri Standardizate (e.g., REST, gRPC):** Implementarea de interfețe uniforme pentru a expune funcționalitatea AI și a aplicațiilor.
- **MLOps Platforms:** Utilizarea unor platforme dedicate care pot standardiza *deploy*-ul și *serving*-ul modelelor AI, expunându-le ca **microservicii** uniforme.

Model Context Protocol (MCP) Rezolvă Problema $N \times M$

1. Standardizarea Interfețelor (Abstractizare) MCP definește un set uniform de interfețe și comportamente pentru interacțiunea cu modelele AI.
 - a) Modelele AI (N) nu mai trebuie să dezvolte un conector dedicat pentru fiecare aplicație (M). Ele se conectează o singură dată la interfața standardizată MCP.
 - b) Aplicațiile (M) nu mai trebuie să cunoască API-ul specific sau cerințele de date ale fiecărui model AI (N). Ele comunică cu stratul MCP.
 - c) Reducerea Complexității: În loc de $N \times M$ integrări punct-la-punct, avem $N + M$ integrări (N integrări către MCP și M integrări dinspre MCP).

2. Format de Date Canonic (Context Comun)

MCP stabilește un format de date canonic (neutru, agnostic față de sursă/destinație) pentru transferul de date, denumit de obicei **Context**.

Transformarea Datelor: Datele de intrare de la aplicații sunt transformate în formatul **standard Context** înainte de a ajunge la model.

Uniformizarea leșirii: leșirea modelului (rezultatul predicției sau răspunsul) este, de asemenea, încapsulată în formatul standard Context înainte de a fi trimisă aplicației.

Decuplarea (Decoupling): Această standardizare a formatului de date decuplează modelele de aplicații. Modelele știu doar să prelucreze și să producă Context, iar aplicațiile știu doar să consume și să furnizeze Context, eliminând necesitatea de a scrie conectori de transformare unici pentru fiecare pereche.

3. Protocol de Mesagerie Definit

MCP oferă un protocol clar pentru modul în care Contextul este transferat, incluzând detalii despre:

Identificarea modelului: Specifică ce model ar trebui să prelucreze Contextul.

Tipul sarcinii (Task Type): Indică intenția solicitării (e.g., clasificare, sumarizare, generare).

Metadata: Informații suplimentare necesare pentru logging, audit, sau guvernanză.

Foundry IQ

Foundry IQ este un layer semantic și un sistem de cunoștințe cu management automatizat, dezvoltat de Microsoft ca parte a ecosistemului Azure AI.

Principalul său rol este de a simplifica și automatiza procesul de grounding al LLM-urilor, oferind context relevant din sistemul cognitiv al companiei.

Foundry IQ unifică și indexează date multimodale din surse disparate, acționând ca un integrator unic care furnizează agenților AI informații precise și aliniate guvernantei proprii, respectând permisiunile și politicile de securitate ale datelor.


Principale Beneficii

Crește acuratețea
răspunsurilor LLM

Reduce riscul de
halucinare

Asigură conformitate și
securitate

Foundry IQ: Unificarea și grounding-ul semantic al datelor pentru LLM-uri



Limitări și Considerente Cruciale

Foundry IQ
aduce
optimizări
semnificative
fluxului RAG
(Retrieval-
Augmented
Generation),
adoptarea sa
implică
următoarele
considerații:

Stadiul de Maturitate (Preview): Fiind un serviciu nou, funcționalitățile pot fi în stadiu de Previzualizare Publică sau Limitată. Acest lucru implică potențiale modificări ale API-urilor, lipsă de SLA (Service Level Agreement) garantat și, prin urmare, nu este recomandat pentru implementări de producție critice.

Dependența de Ecosistem: Nu este un produs Standalone. Utilizarea sa necesită o integrare strânsă cu infrastructura Microsoft Azure și serviciile de indexare subiacente, precum Azure AI Search sau servicii similare de vectorizare și căutare.

Pre-condiții de Infrastructură și Guvernanță: Implementarea presupune ca organizația să aibă o infrastructură Azure configurată și o planificare prealabilă a strategiei de Guvernanță a Datelor (Microsoft Purview / Entra ID) pentru a se asigura că Foundry IQ respectă politicile de acces la datele sursă.

Costurilor Suplimentare: Utilizarea unui serviciu complet gestionat implică costuri suplimentare pentru indexarea datelor, stocarea lor în formate vectorizate, costurile aferente interogărilor către LLM-uri (taxate pe token-uri) și taxele de serviciu

