


Sisteme și algoritmi distribuiți

Curs 5


Cuprins

- Consens – convergență (continuare curs 4)
- Defecte
- Algoritmi robuști la defect crash
- Algoritmi robuști la defect bizantin


Consens



Consensus




Consens




Consensus: definiție

Starea (valoarea) uniformă a nodurilor unui sistem distribuit.



Consens: definiție

Starea (valoarea) uniformă a nodurilor unui sistem distribuit.



Consens: definiție

Starea (valoarea) uniformă a nodurilor unui sistem distribuit.

Condiția de acord: $x_i = x_j, \forall i, j$ Nu există două procese care decid valori diferite.

Condiția de validitate: Dacă valoarea inițială a proceselor este v , atunci consensul se atinge cu valoarea uniformă v .

Condiția de terminare (algorithm): Într-un algoritm de consens, orice nod din sistem va decide eventual la un moment de timp. $d(x_i, x_j) < \epsilon$

Adesea se reduce la calcularea distribuită a valorii unei funcții de consens în starea inițială a sistemului.

$$x(0) \in \mathbb{R}^n \Rightarrow f(x(0)) \begin{cases} \text{media} \\ \text{median} \\ \text{majority} \end{cases}$$

Consensus *static*

Exemple:

- Majoritar $\underline{x_i^*} = \overset{\text{Maj}}{Maj}(x(0)) = \begin{cases} 1, \text{dacă } |\{i | x_i(0) = 1\}| \geq \frac{n}{2} + 1 \\ 0, \text{dacă } |\{i | x_i(0) = 1\}| < \frac{n}{2} + 1 \end{cases}$

- Medie (aritmetică) $x_i^* = \frac{1}{n} \sum_{i=1}^n x_i(0)$

- Mediană $x_i^* = x_{[\frac{n}{2}]}(0)$

- Max-consens $x_i^* = \max_{1 \leq i \leq n} \{ \underline{x_i(0)} \}$

- Min-consens $x_i^* = \min_{1 \leq i \leq n} \{ x_i(0) \}$

LE/LCR

}
Funcții independente de ordine și
multiplicitate

$$\begin{aligned} & \max \{1, 2, 1, 3\} \\ &= \max \{2, 1, 1, 1, 3\} = 3 \end{aligned}$$

Consens distribuit: aplicații

Calculul consensului este necesar în operații de nivel înalt:

- Elecția liderului (max-consens)
- Sincronizare ceasuri (medie dinamică, max-consens dinamic)
- Asigurare consistență baze de date (majoritar)
- COMMIT distribuit (majoritar)
- Localizare distribuită în rețele de senzori (medie)
- Formarea de grupuri în rețele de agenți (medie dinamică) *formation*

Algoritm FloodSet pentru consens

Păstrăm ipotezele anterioare:

- Topologie reprezentată printr-un graf directat tare conectat.
- Fiecare nod are un ID unic id_i .
- Dimensiune token $sizeof(v_i) = sizeof(ID) = B$ biți.

$$X = \mathbb{R}^m \mid \underbrace{f(x_1, \dots, x_m)}_{f: X \rightarrow \mathbb{R}, E}$$

Problemă: Calculați distribuit valoarea funcției f de consens în $x(0)$, astfel încât $\underline{x_i^*} = \underline{f(x(0))}$. $\leftarrow x_i(0) \mid \text{SPMID}$

- Considerăm $\underline{v_i} := \underline{x_i}$, i. e. $M = \{x_1, x_2, \dots, x_n\}$, $|M| = n$.
- Nodul i pornește din $\underline{x_i(0)} := \underline{v_i}$, $\forall i \in V$, converge către $\underline{x_i^*} = \underline{f(x(0))}$.
- Problema este o aplicație a soluției problemei de diseminare de jetoane.

Algoritm FloodSet pentru consens

Algoritm **FloodSet**($f()$):

M_i : - int id (id propriu)

- int v (token, inițial egal cu x_i)

- funcție obiectiv $f()$

- int t , integer, inițial 0

Funcție transformare nod i ():

1. Fie U mulțimea mesajelor $\langle v_j, id_j \rangle$ primite de la $\mathcal{N}_i^-$

2. $M(t+1) = M(t) \cup U$

3. Fie $V(t+1)$ mulțimea valorilor v_j din $M(t+1)$

4. Fie $I(t+1)$ mulțimea id-urilor id_j din $M(t+1)$

5. If $I(t+1) == I(t)$:

1. Return $f(M(t)) = f(v_1, \dots, v_n)$

6. Else: send($M(t+1)$, $\mathcal{N}_i^+$)

7. $t := t+1$

• Reducem operația de consens static la calculul unei funcții de consens $f(x(0))$.

• Dezavantaje:

1. FloodSet folosește mesaje $O(nB)$

2. FloodSet necesită memorie $O(nB)$

• În general urmărim ca dimensiunea mesajelor/memoriei să fie o funcție slab crescătoare de numărul de noduri (e.g. $\log(n)$, $n^{\frac{1}{p}}$)

• Consens majoritar: considerarea de stări reale ne conduce la algoritmi eficienți.

Reducția la dep. slab cresc. în n nu e posibilă pentru orice f .

Consens majoritar

Fie $v \in R^n$, atunci

$$\underline{Maj(v)} = \begin{cases} 1, & \text{dacă } |\{i | v_i = 1\}| \geq \frac{n}{2} + 1 \\ 0, & \text{dacă } |\{i | v_i = 1\}| < \frac{n}{2} + 1 \end{cases}$$

se rescrie notând $\bar{v} = \frac{1}{n} \sum_{i=1}^n v_i$

$$Maj(v) = \begin{cases} \underline{1}, & \text{dacă } \bar{v} \geq \frac{1}{2} \\ \underline{0}, & \text{dacă } \bar{v} < \frac{1}{2} \end{cases}$$

Consens majoritar

Păstrăm ipotezele anterioare:

- Topologie reprezentată printr-un graf directat **tare conectat**.
- Dimensiune token $\text{sizeof}(v_i) = \text{sizeof}(ID) = B$ biți.

- *Am nevoie UID*

Problemă: Calculați distribuit valoarea funcției $f() = \text{Maj}()$ de consens în $x(0)$, astfel încât $x_i^* = f(x(0))$.

- Considerăm $v_i := x_i$, i. e. $M = \{x_1, x_2, \dots, x_n\}$, $|M| = n$.
- Nodul i pornește din $x_i(0) := v_i$, $\forall i \in V$, converge către $x_i^* = f(x(0))$.
- Observație: $\text{Maj}(v) = \frac{1}{2} \left(1 + \text{sgn} \left(\text{Mean}(v) - \frac{1}{2} \right) \right)$

Algoritm Flooding cu ponderi uniforme

Algoritm **Flooding**(Maj, v):

Mem_i : - int $x_i(0)$ (token), inițial v_i
- int d (grad intrare), integer
- int t , integer, inițial 0

diagram

Funcție transformare nod i ():

$$m = \frac{1}{n} (x_1(0) + \dots + x_n(0))$$

1. Fie U mulțimea mesajelor $v_j = x_j(t)$ primite de la $\mathcal{N}_i^-$

2. $x_i(t+1) = \frac{1}{d+1} \left(x_i(t) + \sum_{j \in \mathcal{N}_i^-} x_j(t) \right) \Rightarrow x_i^* = m$

3. **If** (criteriu_oprire):

1. **Return** $\frac{1}{2} \left(1 + \text{sgn} \left(x(t) - \frac{1}{2} \right) \right)$

4. **Else**: send($x(t+1)$, $\mathcal{N}_i^+$)

5. $t := t + 1$

Algoritm Flooding pentru consens

- Inițial: $x_j(0) = v_j \in R$
- Iterație locală:

$$\underbrace{x_i(t+1)} = \underbrace{\frac{1}{d_i+1} \left(x_i(t) + \sum_{j \in \mathcal{N}_i^-} x_j(t) \right)}, \quad \forall i$$

Handwritten note: $\frac{1}{d_i+1} \begin{bmatrix} 0 & 0 & \dots & 1 & 0 & \dots \end{bmatrix} \cdot \begin{bmatrix} x_1(t) \\ \vdots \\ x_n(t) \end{bmatrix} = x(t)$

Mai pe larg: actualizarea lui $x_i(t+1)$ se face pe baza mediei aritmetice dintre starea $x_i(t)$ și stările vecinilor $x_j(t), j \in \mathcal{N}_i^-$; presupunem un transfer cu succes al stărilor $x_j(t)$ către P_i . Vectorial avem:

$$\underbrace{x(t+1)} \cdot \begin{bmatrix} x_1(t+1) \\ \vdots \\ x_n(t+1) \end{bmatrix} = \begin{bmatrix} \frac{1}{d_1+1} \left(x_1(t) + \sum_{j \in \mathcal{N}_1^-} x_j(t) \right) \\ \vdots \\ \frac{1}{d_n+1} \left(x_n(t) + \sum_{j \in \mathcal{N}_n^-} x_j(t) \right) \end{bmatrix} = \begin{bmatrix} \frac{1}{d_1+1} x_1(t) + \frac{1}{d_1+1} \sum_{j \in \mathcal{N}_1^-} x_j(t) \\ \vdots \\ \frac{1}{d_n+1} x_n(t) + \frac{1}{d_n+1} \sum_{j \in \mathcal{N}_n^-} x_j(t) \end{bmatrix}$$

Handwritten note: $\frac{1}{d_i+1} \begin{bmatrix} 1 & \dots & 1 \end{bmatrix} \cdot \begin{bmatrix} x_i(t) \\ \vdots \\ x_{j_s}(t) \end{bmatrix} = \frac{1}{|\mathcal{N}_i^-|} \sum_{j \in \mathcal{N}_i^-} x_j(t)$

Observăm pe fiecare componentă a vectorului din partea dreaptă un produs scalar între stările nodurilor $\{i \cup \mathcal{N}_i^-\}$ și vectorul unidimensional $\tilde{a}_i = \frac{1}{d_i+1} [1 \ 1 \ \dots \ 1]^T$. Sau, echivalent, între vectorul coloană definit de

$$[a_i]_k = \begin{cases} \frac{1}{d_i+1}, & k \in \{i \cup \mathcal{N}_i^-\} \\ 0, & k \notin \{i \cup \mathcal{N}_i^-\} \end{cases} \text{ și vectorul stărilor } x(t).$$

Algoritm Flooding pentru consens

Algoritm Flooding de medie prezentat anterior se exprimă recurent prin actualizarea liniară:

$$x_i(t+1) = \underbrace{a_{ii}}_{d_i+1} x_i(t) + \sum_{j \in \mathcal{N}_i^-} \underbrace{a_{ij}}_{d_i+1} x_j(t) \quad \forall i$$

Deci $x_i(t+1) = a_i^T x(t)$, iar dinamica stărilor sistemului este:

$$\boxed{x(t+1) = Ax(t)}, \quad \rightarrow \approx \text{adiacență}$$

unde

$$A = \begin{bmatrix} a_1^T \\ \dots \\ a_n^T \end{bmatrix} \in R^{n \times n}, x(t) = \begin{bmatrix} x_1(t) \\ \dots \\ x_n(t) \end{bmatrix} \in R^n.$$

Matricea A este în strânsă legătură cu matricea de adiacență a grafului care determină topologia.

Care este structura matricii A pentru ponderi uniforme?

Example

Pentru graful alăturat matricea asociată este:


$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 1/3 & 0 & 0 & 1/3 & 1/3 \\ 1/3 & 0 & 1/3 & 0 & 0 & 1/3 \end{bmatrix}$$

Definiție. Matricea A se numește stohastică pe linii dacă elementele $a_{ij} \geq 0$ și suma fiecărei linii este 1.

- Similar definim matricea stohastică pe coloane
- Matricile stohastice pe linii și coloane se numesc dublu stohastice.
- Exemplul de mai sus unde se încadrează?
- Alte exemple? Cum generăm matrici dublu stohastice?

$$x_1(t+1) = \frac{1}{2}x_1(t) + \frac{1}{2}x_2(t) = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 & 0 \end{bmatrix} \cdot x(t)$$

ponderi uniforme $\frac{1}{d_i+1}$



$$x(t+1) = A x(t)$$

$$\begin{bmatrix} \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}$$


Exemple

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$

$\neq A^T$

A stochastică /
 $A = A^T$
 $\Rightarrow$ dublu stochastică




Exemple

În general, pentru un inel de dimensiune n , matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & \cdots & 0 & 0 \\ 0 & 1/2 & 1/2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 1/2 & 0 & 0 & \cdots & 0 & 1/2 \end{bmatrix} \in R^{n \times n}$$

- Dublu stohastică
- Nesimetrică (graf directat)



Exemple


Pentru un graf de tip clică matricea asociată este:

$$A = \begin{bmatrix} 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{bmatrix}$$

- Dublu stohastică
- Simetrică

$x(t+1) = A \cdot x(t)$ converge într-o singură it.

$$x(1) = C \cdot \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix} \cdot x(0) = C \cdot \begin{bmatrix} \sum_i x_i(0) \\ \vdots \\ \sum_i x_i(0) \end{bmatrix}$$



Algoritm Flooding pentru consens

Din dinamică stărilor

se observă ușor:

$$\underline{x(t+1)} = Ax(t) = A^2 x(t-1) = A^3 x(t-2) = \dots = A^{t+1} x(0)$$

$$\underline{x(t)} = A^t x(0),$$

de aceea convergența depinde total de comportamentul matricii A^t (implicit, doar de structura grafului).

Teorema. Dacă matricea A este stohastică pe linii, atunci se atinge consensul asimptotic, i.e. $x(t) \rightarrow c\mathbf{1}$ când $t \rightarrow \infty$.

În plus, dacă matricea A este stohastică pe coloane (graful are grade de intrare uniforme), i.e. $\mathbf{1}^T A = A^T$, atunci


$$x_i(\infty) = c = \frac{1}{n} \sum_{i=1}^n x_i(0).$$

- Rezultat valabil nu doar pentru ponderi uniforme.
- Condiția necesară pentru consens este ca matricea ponderilor să fie stohastică pe linii (fiecare să realizeze la fiecare iterație o combinație convexă între starea proprie și stările vecinilor)
- Dacă matricea ponderilor este, în plus, stohastică pe coloane, atunci valoarea de consens este media aritmetică a stărilor inițiale.

Exemple

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix} \quad \underbrace{A^t}_{\text{red}}$$



A^2 :

0.2500	0.5000	0.2500	0	0	0
0	0.2500	0.5000	0.2500	0	0
0	0	0.2500	0.5000	0.2500	0
0	0	0	0.2500	0.5000	0.2500
0.2500	0	0	0	0.2500	0.5000
0.5000	0.2500	0	0	0	0.2500

$$= c \cdot \begin{bmatrix} 1 & \dots & \dots & 1 \\ \vdots & & & \vdots \\ 1 & \dots & \dots & 1 \end{bmatrix}$$


Example

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$

A^4 :


0.0625	0.2500	0.3750	0.2500	0.0625	0
0	0.0625	0.2500	0.3750	0.2500	0.0625
0.0625	0	0.0625	0.2500	0.3750	0.2500
0.2500	0.0625	0	0.0625	0.2500	0.3750
0.3750	0.2500	0.0625	0	0.0625	0.2500
0.2500	0.3750	0.2500	0.0625	0	0.0625



Example

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$




A^{10} :

0.206055	0.126953	0.087891	0.126953	0.206055	0.246094
0.246094	0.206055	0.126953	0.087891	0.126953	0.206055
0.206055	0.246094	0.206055	0.126953	0.087891	0.126953
0.126953	0.206055	0.246094	0.206055	0.126953	0.087891
0.087891	0.126953	0.206055	0.246094	0.206055	0.126953
0.126953	0.087891	0.126953	0.206055	0.246094	0.206055

Example

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$




A^{25} :

0.1746	0.1746	0.1667	0.1587	0.1587	0.1667
0.1667	0.1746	0.1746	0.1667	0.1587	0.1587
0.1587	0.1667	0.1746	0.1746	0.1667	0.1587
0.1587	0.1587	0.1667	0.1746	0.1746	0.1667
0.1667	0.1587	0.1587	0.1667	0.1746	0.1746
0.1746	0.1667	0.1587	0.1587	0.1667	0.1746

Exemple

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$



A^{70} :

0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667



$$= \frac{1}{6} \begin{bmatrix} 1 & - & - & - & - & 1 \\ - & 1 & - & - & - & 1 \\ - & - & 1 & - & - & 1 \\ - & - & - & 1 & - & 1 \\ 1 & - & - & - & 1 & - \\ - & 1 & - & - & - & 1 \end{bmatrix}$$

$$x(70) = A^{70} x(0) = \frac{1}{6} \sum_i x_i(0) \cdot \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

Example

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$



$$V(t) = \max(x(t)) - \min(x(t))$$

Plot: $V(t)$ vs. t


Exemple

Pentru un graf de tip clică matricea asociată este:

$$A = \begin{bmatrix} 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{bmatrix}$$

$$x(1) = x^*$$

- Convergență într-un singur pas




Exemple

Pentru graful alăturat matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 1/3 & 0 & 0 & 1/3 & 1/3 \\ 1/3 & 0 & 1/3 & 0 & 0 & 1/3 \end{bmatrix}$$

stochastică pe linii

$\neq A^T$



A³⁰:

0.060607	0.181818	0.242425	0.242424	0.181817	0.090909
0.060606	0.181818	0.242424	0.242425	0.181818	0.090909
0.060606	0.181818	0.242424	0.242424	0.181819	0.090909
0.060606	0.181818	0.242424	0.242424	0.181818	0.090909
0.060606	0.181818	0.242424	0.242424	0.181818	0.090909
0.060606	0.181818	0.242424	0.242424	0.181818	0.090909

$X(30) = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} w \cdot X(0) \cdot C \cdot \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$

asociată!

w v.p.st. al A



$\begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \cdot \begin{bmatrix} 0.06 & 0.18 & 0.24 & 0.24 & 0.18 & 0.09 \end{bmatrix}$

$\sum_i w_i = 1$

Example

Pentru graful alăturat matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 1/3 & 0 & 0 & 1/3 & 1/3 \\ 1/3 & 0 & 1/3 & 0 & 0 & 1/3 \end{bmatrix}$$



$$V(t) = \max(x(t)) - \min(x(t))$$

Plot: $V(t)$ vs. t

Valori și vectori proprii

Definiție. Valorile proprii (*eigenvalues*) ale matricii $A \in R^{n \times n}$ sunt date de n rădăcini ale polinomului caracteristic $p(z) = \det(zI_n - A)$. Mulțimea acestor valori se numește spectrul matricii A și este notat cu:

$$\lambda(A) = \{z : \det(zI_n - A) = 0\}.$$

Definiție. Pentru $\lambda \in \lambda(A)$ numim vectorii nenuli $x \in C^n$ care satisfac $Ax = \lambda x$ vectori proprii (*eigenvectors*). Mai exact x este vector propriu *la dreapta* dacă satisface:

$$Ax = \lambda x \quad \leftarrow x \leftarrow \frac{x}{\|x\|} \rightarrow \|x\| = 1$$

și vector propriu *la stânga* dacă satisface:

$$x^H A = x^H \lambda. \quad \left| \quad x^T A = x^T \lambda \right.$$

Un vector propriu definește un subspațiu 1-dimensional care este invariant la premultiplicarea cu A .

Reamintim: pentru $x \in C^n$, x^H reprezintă vectorul x transpus și conjugat.

Valori și vectori proprii - exemple

În cazul matricilor diagonale (triunghiulare), valorile proprii sunt elementele diagonalei, e.g.

$$\lambda(\underline{I_n}) = \{\underline{1}, \dots, \underline{1}\}.$$

Dacă $A = A^T$, atunci subspațiul v. p. la dreapta = subspațiul v. p. la stânga.

Când calculăm vectorul propriu asociat unei valori proprii fixate, în general ne interesează doar vectorul de pe sfera unitate.

Exemplu: Calculați vectorul propriu (la stânga și dreapta) asociat valorii proprii 1

ai matricii $A = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{bmatrix}$.

Valori și vectori proprii - exemple

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 1 \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \Leftrightarrow \begin{cases} x_1 + x_2 + x_3 = x_1 \Leftrightarrow x_1 = x_2 \\ 2x_2 + 2x_3 = x_2 \Leftrightarrow x_2 = 0 \\ 3x_3 = x_3 \Leftrightarrow x_3 = 0 \end{cases} \Rightarrow V_1 = \left\{ x \mid x = \begin{bmatrix} \alpha \\ 0 \\ 0 \end{bmatrix} \right\}$$

$$x^* = \begin{bmatrix} \alpha \\ 0 \\ 0 \end{bmatrix} \cdot \frac{1}{\left\| \begin{bmatrix} \alpha \\ 0 \\ 0 \end{bmatrix} \right\|} = \frac{1}{|\alpha|} \begin{bmatrix} \alpha \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

$$[w_1, w_2, w_3] \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{bmatrix} = [w_1, w_2, w_3]$$

$$\begin{cases} w_1 = w_1 \\ w_1 + 2w_2 = w_2 \\ w_1 + 2w_2 + 3w_3 = w_3 \end{cases} \begin{cases} w_1 = -w_2 \\ w_2 + 2w_3 = 0 \\ w_3 = -\frac{1}{2}w_2 \end{cases} \Rightarrow w = \begin{bmatrix} \alpha \\ -\alpha \\ \alpha/2 \end{bmatrix} = \alpha \begin{bmatrix} 1 \\ -1 \\ 1/2 \end{bmatrix}$$

$$w^* = \begin{bmatrix} 1 \\ -1 \\ 1/2 \end{bmatrix} \cdot \frac{1}{\left\| \begin{bmatrix} 1 & -1 & 1/2 \end{bmatrix} \right\|} = \begin{bmatrix} 2/3 \\ -2/3 \\ 1/3 \end{bmatrix}$$

$$\sqrt{1 + 1 + \frac{1}{4}}$$

Valori și vectori proprii (matrici stohastice)

Teorema Perron-Frobenius. Dacă matricea $A \in R^{n \times n}$ este stohastică (pe linii) și ireductibilă atunci: vectorul propriu la stânga $w \in R^n$ satisface $w \geq 0$ și

- 1) $\rho(A) = 1$ este simplă. (Valoarea Perron-Frobenius)
- 2) Vectorii proprii asociați lui $\rho(A)$ au componentele pozitive.
- 3) Fie w v. p. la stânga asociat lui $\rho(A)$ atunci $\lim_{t \rightarrow \infty} A^t = \underbrace{1w^T}_{\begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \cdot w}$. (Proiecția Perron)

Matrice ireductibilă. Matricea A este *ireductibilă* dacă nu este similară via permutări cu o matrice bloc superior triunghiulară.

Dacă matricea A este matricea de adiacență asociată unui graf (tare) conex, atunci A este ireductibilă.


Exemplu

Pentru un inel de dimensiune $n = 6$, matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 1/2 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$

A^{70} :

0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667
0.1667	0.1667	0.1667	0.1667	0.1667	0.1667




$$= \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \end{bmatrix}$$

Example

Pentru graful alăturat matricea asociată este:

$$A = \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 1/3 & 0 & 0 & 1/3 & 1/3 \\ 1/3 & 0 & 1/3 & 0 & 0 & 1/3 \end{bmatrix}$$



A³⁰:

0.060607	0.181818	0.242425	0.242424	0.181817	0.090909	= $\begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} [0.061 \quad 0.182 \quad 0.243 \quad 0.243 \quad 0.182 \quad 0.091]$
0.060606	0.181818	0.242424	0.242425	0.181818	0.090909	
0.060606	0.181818	0.242424	0.242424	0.181819	0.090909	
0.060606	0.181818	0.242424	0.242424	0.181818	0.090909	
0.060606	0.181818	0.242424	0.242424	0.181818	0.090909	
0.060606	0.181818	0.242424	0.242424	0.181818	0.090909	

Algoritm Flooding pentru consens

Teorema. Dacă matricea A este *stohastică pe linii*, i.e. $a_{ii} + \sum_{j \in \mathcal{N}_i^-} a_{ij} = 1, a_{ij} \geq 0 \ \forall j \in \mathcal{N}_i^- \cup \{i\}$, atunci se atinge consensul asimptotic:

$$x(t) \rightarrow c\mathbf{1} \text{ când } t \rightarrow \infty.$$

În plus, dacă matricea A este *stohastică pe coloane*, i.e. $\mathbf{1}^T A = A^T$, atunci valoarea de consens este

$$c = \frac{1}{n} \sum_{i=1}^n x_i(0).$$

Algoritm Flooding pentru consens

Fie v vectorul propriu la stânga al matricii A asociat valorii proprii 1, și iterația

$$x(t+1) = Ax(t),$$

atunci

$$v^T x(t) = v^T A^t x(0) = v^T x(0).$$

Observație: Unghiul tuturor iterațiilor $x(t)$ față de v este constant pentru orice t .

De aceea, în cazul convergenței, la limită: $x(\infty) = \lim_{t \rightarrow \infty} A^t x(0) = c \mathbf{1}$ avem relația (din th. P-F)

$$v^T x(\infty) = c = v^T x(0),$$

concluzionând că valoarea de consens este dată de $v^T x(0)$.

$$v^T A^t = \underbrace{(v^T A)}_{v^T} \cdot A^{t-1} = v^T \cdot A^{t-1} = \dots = v^T A = v^T$$

Pentru a răspunde la întrebarea:

Care este valoarea de consens a algoritmului de Flooding pe o topologie particulară?

este necesară calcularea vectorului propriu la stânga al matricii A asociat valorii proprii 1.

$$\left. \begin{array}{l} G \text{ medirectat} \Rightarrow A \text{ stohastică pe linii} \\ A = A^T \end{array} \right\} \Rightarrow A \text{ dublu stohastică}$$
$$c = \frac{1}{n} \sum_i x_i(0)$$

Algoritm Flooding cu ponderi uniforme

Algoritm **Flooding**(Maj, v):

Mem_i : - int x_i (token) , inițial v_i
- int d (grad intrare), integer
- int t , integer, inițial 0

Funcție transformare nod i ():

1. Fie U mulțimea mesajelor $v_j = x_j(t)$ primite de la $\mathcal{N}_i^-$
2. $x_i(t+1) = \frac{1}{d+1} \left(x_i(t) + \sum_{j \in \mathcal{N}_i^-} x_j(t) \right)$
3. **If** (criteriu_oprire):
 1. **Return** $\frac{1}{2} \left(1 + \text{sgn} \left(x(t) - \frac{1}{2} \right) \right)$
4. **Else**: send($x(t+1)$, $\mathcal{N}_i^+$)
5. $t := t+1$